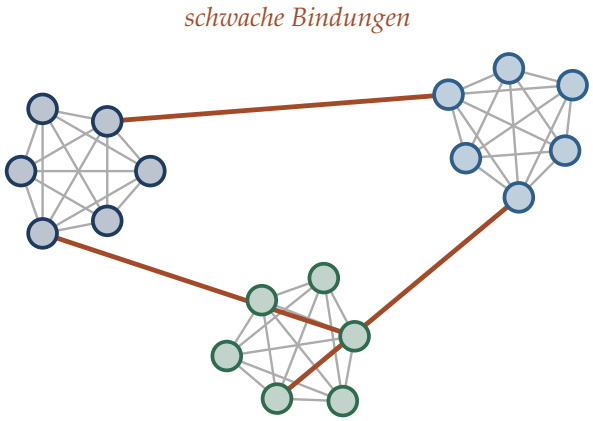
INFORMATIK VON GRUND AUF — BAND 11

Das Muster der Verbindungen

Eine vollständige Einführung in Graphen und Netzwerkanalyse



Von der Kante bis zur Gemeinschaft

Jeder Schritt erklärt. Mit vollständig durchgerechneten Übungsaufgaben.

Informatik von Grund auf — Band 11
Das Muster der Verbindungen · Graphen und Netzwerkanalyse

Herausgeber und Urheber: Jürgen Maier
Entstanden 2026 in Zusammenarbeit mit Claude (Anthropic); Konzeption, Vorgaben, Prüfung und Herausgeberschaft: Jürgen Maier.

Lizenz
Dieses Werk ist lizenziert unter einer Creative-Commons-Lizenz **Namensnennung – Weitergabe unter gleichen Bedingungen 4.0 International (CC BY-SA 4.0)**. Sie dürfen das Werk vervielfältigen, verbreiten, bearbeiten und auch kommerziell nutzen, sofern Sie den Urheber nennen und Bearbeitungen unter derselben Lizenz weitergeben.
Lizenztext: `https://creativecommons.org/licenses/by-sa/4.0/legalcode.de`

Quellen und Fassungen
Quelltexte, Fehlermeldungen und aktuelle Fassungen aller Bände:
`https://github.com/juergenmaier2026/informatik-von-grund-auf`
Schwesterreihe: *Mathematik von Grund auf*, `https://doi.org/10.5281/zenodo.23698547`

Zitiervorschlag
Maier, J. (2026). *Informatik von Grund auf, Band 11: Das Muster der Verbindungen*. Fassung 1.0.0.
`https://github.com/juergenmaier2026/informatik-von-grund-auf`

Satz: LaTeX mit Palatino. Fassung 1.0.0, Oktober 2026. 164 Seiten.

Stand der Forschung: August 2026

Inhaltsverzeichnis

Vorwort 1

I Grundlagen 9

1 Begriffe und Darstellungen 11

2 Durchmusterung und Zusammenhang 21

3 Wege und Flüsse 29

II Struktur messen 37

4 Zentralität 39

5 Lokale Struktur 47

6 Gemeinschaften 55

7 Hierarchie und Ordnung 63

III Modelle 71

8 Zufallsgraphen 73

9 Kleine Welten und schwere Enden 81

10 Spektrale Graphentheorie 91

IV Anwendung 99

11 Prozesse auf Netzen 101

12 Das Gehirn als Netzwerk 109

13 Große Graphen berechnen 119

14 Fallstricke 129

15 Der Stand im Jahr 2026 **139**

V Anhang **145**

A Formeln und Zahlen **147**

B Landkarte des Bandes **151**

C Glossar **153**

D Zeittafel **155**

E Kommentierte Quellen **157**

Vorwort: Wenn die Verbindung wichtiger ist als das Ding

Dieser Band handelt von Systemen, bei denen man mehr erfährt, wenn man die Beziehungen betrachtet als die Beteiligten. *Ein Graph ist die einfachste Struktur, die das ausdrücken kann: Punkte und Linien, sonst nichts.*

Dieselbe Struktur, sehr verschiedene Gegenstände

Gebiet	Knoten	Kante
Verkehr	Kreuzungen	Straßen
Soziales	Personen	Bekanntschaft
Web	Seiten	Verweise
Gehirn	Areale	Faserbahnen
Stoffwechsel	Substanzen	Reaktionen
Sprache	Wörter	gemeinsames Vorkommen
Software	Module	Aufrufe
Ökologie	Arten	frisst

> *Dass sich all das mit denselben Begriffen beschreiben lässt, ist erstaunlich und gefährlich zugleich. Erstaunlich, weil ein Verfahren, das für Straßennetze entwickelt wurde, auf Faserbahnen anwendbar ist. Gefährlich, weil aus der formalen Ähnlichkeit keine inhaltliche folgt.*

Der Warnhinweis gleich am Anfang.

Was der Graph sagt	Diese Punkte sind so verbunden
Was er nicht sagt	Was ein Punkt ist, was eine Kante bedeutet, ob die Daten stimmen

Kapitel 14 ist deshalb ganz der Frage gewidmet, wie ein Netzwerk aus Daten entsteht und welche Entscheidungen dabei stillschweigend getroffen werden. Es ist das wichtigste Kapitel des Bandes.

Was man an einem Graphen ablesen kann

Ein Netz von fünfzig Knoten sieht als Bild wie ein Knäuel aus. Die Zahlen sagen mehr.

Frage	Maß	Kapitel
Wer ist wichtig?	Zentralität	4
Gibt es Gruppen?	Modularität	6
Wie eng ist es?	Weglänge, Clustering	5, 9
Gibt es eine Rangordnung?	Hierarchiemaße	7
Wie robust ist es?	Perkolation	11
Ist das auffällig?	**Vergleich mit Nullmodell**	14

Die letzte Zeile ist die entscheidende und wird am häufigsten übersprungen. Jede Kennzahl eines Netzwerks ist wertlos, solange man nicht weiß, welchen Wert sie bei einem Netz gleicher Größe ohne die vermutete Struktur hätte.

Ein Beispiel für den Unterschied.

Netz	Cluster-koeffizient	Beurteilung
Beobachtet	0,31	klingt hoch
Zufällig, gleiche Dichte	0,004	78-fach: bedeutsam
Beobachtet	0,31	klingt hoch
Zufällig, gleiche Gradfolge	0,29	1,07-fach: nichts

> *Derselbe Messwert, zwei entgegengesetzte Schlüsse. Welches Nullmodell man wählt, entscheidet über das Ergebnis, und es ist keine technische, sondern eine inhaltliche Frage.*

Was dieses Buch will

Erstens: Die beiden Traditionen zusammenbringen.
Graphentheorie und Netzwerkanalyse sind verschiedene Fächer mit verschiedenen Fragen. Die eine sucht Verfahren mit beweisbaren Eigenschaften, die andere sucht Muster in gemessenen Daten.

	Graphentheorie	**Netzwerkanalyse**
Graph ist	gegeben	**gemessen**
Frage	Was lässt sich berechnen?	Was ist auffällig?
Maßstab	Laufzeit, Korrektheit	**Vergleich mit Zufall**
Herkunft	Mathematik, Informatik	Physik, Soziologie, Biologie

Zweitens: Die Verfahren vollständig durchrechnen.
Dijkstra, Louvain, PageRank und der Fiedler-Vektor werden an kleinen Beispielen von Hand durchgerechnet, bis das Ergebnis dasteht. Wer ein Verfahren einmal mit Bleistift ausgeführt hat, erkennt später, wann es unpassend ist.
Drittens: Ein Kapitel für ein konkretes Gebiet.

> *Kapitel 12 behandelt die Netzwerkanalyse des Gehirns, weil sich dort alle Schwierigkeiten dieses Bandes in verschärfter Form zeigen: Was ist ein Knoten, wenn die Fachwelt sich über die Gebietseinteilung nicht einig ist? Was ist eine Kante, wenn die Daten aus hunderten Einzelstudien stammen, die einander widersprechen?*

Drei Warnungen

Erstens: Ein Bild ist kein Ergebnis.
Zeichnungen großer Netze sehen beeindruckend aus und sagen fast nichts. Ab etwa hundert Knoten ist die Anordnung eine Sache des Zeichenverfahrens, nicht der Daten.
Zweitens: Viele Maße messen dasselbe.

> *Wer zwanzig Zentralitätsmaße berechnet und das nimmt, das die gewünschte Antwort liefert, betreibt keine Analyse. Die meisten Maße hängen eng zusammen; Kapitel 4 zeigt, wann sie auseinandergehen und warum.*

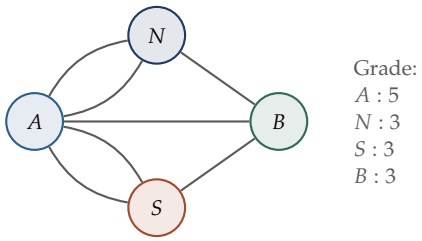
Drittens: Skalenfreiheit ist umstritten.
Die Behauptung, natürliche Netze folgten fast alle einem Potenzgesetz, hat zwanzig Jahre lang die Literatur bestimmt und ist seit 2019 ernsthaft in Frage gestellt. Kapitel 9 stellt beide Seiten dar.

Zum Aufbau

- **Teil I** (Kap. 1–3): Grundlagen. Begriffe und Darstellungen, Durchmusterung und Zusammenhang, Wege und Flüsse.
- **Teil II** (Kap. 4–7): Struktur messen. Zentralität, lokale Muster, Gemeinschaften, Hierarchien.
- **Teil III** (Kap. 8–10): Modelle. Zufallsgraphen, kleine Welten und schwere Enden, Spektraltheorie.
- **Teil IV** (Kap. 11–15): Anwendung. Prozesse auf Netzen, das Gehirn als Netzwerk, große Graphen berechnen, Fallstricke, und der Stand im Jahr 2026.

Sieben Brücken und eine neue Denkweise

Die Stadt Königsberg lag an beiden Ufern des Pregel und umfasste zwei Inseln. Sieben Brücken verbanden die Teile. Die Frage, die sich die Bewohner stellten: Gibt es einen Rundgang, der jede Brücke genau einmal benutzt?



Grade:
$A : 5$
$N : 3$
$S : 3$
$B : 3$

LEONHARD EULER beantwortete die Frage 1736 und tat dabei etwas Neues: Er warf alles weg, was mit der Sache nichts zu tun hatte.

Weggeworfen	Entfernungen, Lage, Größe der Stadtteile, Aussehen der Brücken
Behalten	Welcher Stadtteil ist mit welchem verbunden, und wie oft

Diese Abstraktion ist der eigentliche Beitrag. Euler bemerkte, dass die Aufgabe nichts mit Geometrie zu tun hat, sondern allein mit der Verknüpfungsstruktur. Er nannte das „Geometrie der Lage“, und daraus wurden später die Topologie und die Graphentheorie.

Sein Argument.
Wer einen Stadtteil betritt, muss ihn auch wieder verlassen. Brücken kommen also paarweise vor, außer am Anfang und am Ende des Rundgangs.

Rundgang möglich	Höchstens zwei Knoten haben ungeraden Grad
Geschlossener Rundgang	**Kein** Knoten hat ungeraden Grad

In Königsberg haben alle vier *Knoten ungeraden Grad. Es geht also nicht, und zwar nicht, weil niemand geschickt genug wäre, sondern weil es unmöglich ist.*

Bemerkenswert ist die Form des Ergebnisses. Euler löste die Aufgabe nicht, sondern bewies, dass sie unlösbar ist, und gab zugleich an, wann eine solche Aufgabe lösbar wäre. Das ist die Art von Antwort, die ein ganzes Gebiet begründet, und dieser Reihe seit Band 2 vertraut.

Eine Nachbemerkung. Zwei der sieben Brücken wurden im Zweiten Weltkrieg zerstört und nicht wieder aufgebaut. Im heutigen Kaliningrad haben nur noch zwei Knoten ungeraden Grad; ein Weg über alle Brücken ist also möglich, wenn auch kein geschlossener Rundgang.

Zweihundertneunzig Jahre Graphen

1736	**Euler**	**Königsberger Brücken**
1847	Kirchhoff	Bäume in Stromnetzen
1852	Guthrie	Vierfarbenvermutung
1878	Sylvester	der Begriff „Graph“
1936	König	erstes Lehrbuch der Graphentheorie
1956	Ford, Fulkerson	maximaler Fluss
1959	**Dijkstra**	**kürzeste Wege**
1959	**Erdős, Rényi**	**Zufallsgraphen**
1967	Milgram	das Kleine-Welt-Experiment
1973	Granovetter	Die Stärke schwacher Bindungen
1973	Fiedler	algebraische Zusammenhangszahl
1976	Appel, Haken	Vierfarbensatz, maschinell bewiesen
1977	Freeman	Zentralitätsmaße
1991	Felleman, Van Essen	Hierarchie des Sehsystems
1996	**Kötter u. a.**	**CoCoMac beginnt**
1998	**Watts, Strogatz**	**Kleine Welten**
1998	Brin, Page	PageRank (Band 10)
1999	**Barabási, Albert**	**Bevorzugte Anbindung**

2000	Albert u. a.	Robustheit und Verwundbarkeit
2000	Stephan u. a.	ORT: Karten ineinander überführen
2001	Pastor-Satorras, Vespignani	Epidemien ohne Schwelle
2001	Stephan u. a.	CoCoMac-Methodik veröffentlicht
2004	**Newman, Girvan**	**Modularität**
2005	Sporns u. a.	Der Begriff „Konnektom“
2007	Fortunato, Barthélemy	Auflösungsgrenze der Modularität
2008	**Blondel u. a.**	**Louvain-Verfahren**
2009	Bullmore, Sporns	Netzwerkanalyse im Gehirn
2010	Malewicz u. a.	Pregel: Graphen im Großen
2010	Fortunato	Übersicht Gemeinschaftserkennung
2013	Menschliches Konnektomprojekt	erste Datenfreigaben
2015	Traag u. a.	Leiden-Verfahren
2019	**Broido, Clauset**	**Skalenfreiheit ist selten**
2020er	Graphverfahren mit Lernen	Einbettungen von Knoten
2026	—	Nullmodelle im Mittelpunkt

Zwei Zeilen verdienen eine Anmerkung.
1998 und 1999. Innerhalb von achtzehn Monaten erschienen zwei kurze Arbeiten, die aus einem mathematischen Nebenfach ein eigenes Forschungsgebiet machten. Beide zeigten, dass reale Netze weder regelmäßig noch zufällig sind, sondern etwas Drittes.
2019. ANNA BROIDO und AARON CLAUSET untersuchten fast tausend Netzwerke mit strengen statistischen Verfahren und fanden, dass nur ein kleiner Teil die Behauptung der Skalenfreiheit trägt. Die Debatte darüber ist bis heute nicht abgeschlossen und ein Lehrstück über Nullmodelle.

Jedes hinreichend große Netzwerk enthält ein Muster,
das jemand für bedeutsam halten wird.

— eine Warnung, die in verschiedenen Fassungen umläuft.
Sie ist der Grund, warum in diesem Band vor jeder Kennzahl
die Frage steht, womit man sie vergleicht.

Part I

Grundlagen

1 Begriffe und Darstellungen

Was festzulegen ist

Ein Graph besteht aus einer Knotenmenge und einer Kantenmenge. Alles Weitere sind Zusätze, die man je nach Gegenstand braucht oder nicht.

Eigenschaft	Bedeutung	Beispiel
Gerichtet	Kanten haben eine Richtung	Verweise, Faserbahnen
Gewichtet	Kanten tragen eine Zahl	Entfernung, Stärke
Mehrfachkanten	mehrere Kanten je Paar	Königsberg
Schlingen	Kante auf sich selbst	Selbstverweise
Zweigeteilt	zwei Knotenarten	Autoren und Arbeiten
Zeitlich	Kanten haben Zeitpunkte	Nachrichten

Die vorletzte Zeile wird oft übersehen. Sehr viele reale Netze sind zweigeteilt und werden vor der Analyse auf eine Seite projiziert. Dabei entstehen Kunstprodukte, die Kapitel 14 behandelt.

Die Grundgrößen.

Größe	Zeichen	Bedeutung
Knotenzahl	n	
Kantenzahl	m	
Grad	k_i	Kanten an Knoten i
Mittlerer Grad	$\langle k \rangle = 2m/n$	ungerichtet
Dichte	$\rho = \frac{2m}{n(n-1)}$	Anteil möglicher Kanten

Der Faktor zwei beim mittleren Grad kommt daher, dass jede Kante an zwei Knoten hängt und deshalb zweimal gezählt wird. Diese Beziehung heißt gelegentlich Handschlaglemma und ist die am häufigsten benutzte Gleichung des Fachs.

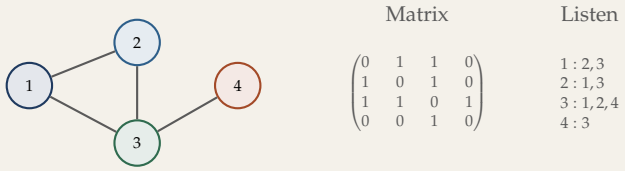
Die meisten realen Netze sind dünn.

Netz	n	$\langle k \rangle$	Dichte
Königsberg	4	3,5	1,17
Makakenkortex	≈ 90	≈ 30	$\approx 0{,}34$
Filmschauspieler	$2{,}2 \cdot 10^5$	61	$3 \cdot 10^{-4}$
Web	10^{11}	≈ 40	$4 \cdot 10^{-10}$

Die zweite Zeile ist bemerkenswert: Das Verbindungsnetz der Hirnrinde ist außergewöhnlich dicht. Etwa ein Drittel aller möglichen Verbindungen besteht tatsächlich, und das hat Folgen für jede Analyse, weil die meisten Verfahren für dünne Netze gedacht sind.

Zwei Darstellungen

	Adjazenzmatrix	Adjazenzliste
Speicher	$\mathcal{O}(n^2)$	$\mathcal{O}(n+m)$
Kante prüfen	$\mathcal{O}(1)$	$\mathcal{O}(k_i)$
Nachbarn durchlaufen	$\mathcal{O}(n)$	$\mathcal{O}(k_i)$
Gut bei	**dichten Netzen**	**dünnen Netzen**
Algebra	unmittelbar	umständlich



Bei einem Netz mit einer Million Knoten und zehn Millionen Kanten braucht die Matrix 10^{12} Einträge und die Listen $1{,}1 \cdot 10^7$. Der Unterschied ist nicht graduell, sondern der zwischen möglich und unmöglich.

Warum die Matrix trotzdem gebraucht wird.
Die Adjazenzmatrix erlaubt es, graphentheoretische Fragen algebraisch zu behandeln.

$(A^2)_{ij}$	Zahl der Wege der Länge 2 von i nach j
$(A^k)_{ij}$	Zahl der Wege der Länge k
Spur$(A^3)/6$	Zahl der Dreiecke
Eigenvektor zu $\lambda_{\max}$	Eigenvektorzentralität (Kap. 4)
Laplace-Matrix	Zusammenhang, Schnitte (Kap. 10)

Die zweite Zeile ist der Schlüssel zu vielem. Sie folgt unmittelbar aus der Definition des Matrixprodukts: Der Eintrag $(A^2)_{ij}$ ist die Summe über alle l von $A_{il}A_{lj}$, und jeder Summand ist eins genau dann, wenn ein Weg über l führt.

Die Gradverteilung

Die wichtigste einzelne Kennzahl eines Netzes ist nicht ein Wert, sondern eine Verteilung.

Form	Erkennungs-merkmal	Beispiel
Regelmäßig	alle Grade gleich	Gitter
Glockenförmig	Mittelwert aussagekräftig	Zufallsgraph
Schwerer Schwanz	**wenige Knoten mit sehr hohem Grad**	Web, Zitationen
Zweigipflig	zwei Sorten von Knoten	manche Infrastruktur

Bei der dritten Zeile verliert der Mittelwert seinen Sinn. Wenn die Varianz sehr groß ist, sagt der mittlere Grad über einen zufällig gewählten Knoten wenig aus, und alle Formeln, die mit ihm rechnen, werden unzuverlässig.

Das Freundschaftsparadox

Im Mittel haben die Freunde einer Person mehr Freunde als die Person selbst. Das gilt in fast jedem Netz und ist kein psychologischer Befund, sondern eine Folge der Stichprobenziehung.

Der Grund. Wenn man einen zufälligen Knoten wählt, zieht man gleichverteilt. Wenn man einen zufälligen *Nachbarn* wählt, zieht man proportional zum Grad.

$$\langle k_{\text{Nachbar}} \rangle = \frac{\langle k^2 \rangle}{\langle k \rangle} = \langle k \rangle + \frac{\sigma_k^2}{\langle k \rangle} \geq \langle k \rangle .$$

Netz	$\langle k \rangle$	$\langle k^2 \rangle / \langle k \rangle$	**Faktor**
Regelmäßig	6	6	1,0
Zufällig	6	7	1,2
Schwerer Schwanz	6	**83**	**13,8**

Die Ungleichung ist streng, sobald die Grade überhaupt streuen. Es gibt keinen Ausweg: In jedem Netz, das nicht regelmäßig ist, haben die meisten Knoten weniger Nachbarn als ihre Nachbarn im Mittel.

Praktisch nutzbar ist das bei der Impfung: Wer zufällige Personen fragt, einen Freund zu benennen, und diesen impft, trifft mit hoher Wahrscheinlichkeit gut vernetzte Personen, ohne das Netz zu kennen. Kapitel 11 kommt darauf zurück.

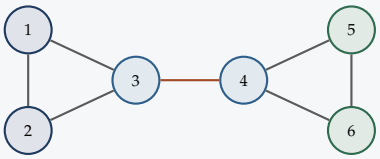
Aufgabe 1.1.

(a) Berechnen Sie die Grundgrößen eines kleinen Netzes.
(b) Zählen Sie Wege und Dreiecke mit der Adjazenzmatrix.
(c) Untersuchen Sie das Freundschaftsparadox an einem Beispiel.

Lösung Schritt für Schritt.

(a) Grundgrößen.

Das Netz. Sechs Knoten, die Kanten $\{1{-}2, 1{-}3, 2{-}3, 3{-}4, 4{-}5, 4{-}6, 5{-}6\}$.



Knoten	1	2	3	4	5	6
Grad	2	2	3	3	2	2

$$\sum_i k_i = 14 = 2m \quad \Rightarrow \quad m = 7. \qquad \checkmark$$

$$\langle k \rangle = \frac{14}{6} = 2{,}33, \qquad \rho = \frac{2 \cdot 7}{6 \cdot 5} = \frac{14}{30} = 0{,}467.$$

Die Kante $3{-}4$ ist besonders.
Entfernt man sie, zerfällt der Graph in zwei Komponenten. Eine solche Kante heißt **Brücke**.

Kante entfernt	**Komponenten**	**Brücke?**
$1{-}2$	1	nein
$3{-}4$	**2**	**ja**
$5{-}6$	1	nein

Eine Kante ist genau dann eine Brücke, wenn sie auf keinem Kreis liegt. Brücken sind in sozialen Netzen selten und wichtig: Sie sind die einzigen Verbindungen zwischen sonst getrennten Gruppen, und Granovetter hat 1973 gezeigt, dass gerade sie die neuen Informationen tragen.

(b) Wege und Dreiecke mit der Matrix.
Die Adjazenzmatrix.

$$A = \begin{pmatrix} 0 & 1 & 1 & 0 & 0 & 0 \\ 1 & 0 & 1 & 0 & 0 & 0 \\ 1 & 1 & 0 & 1 & 0 & 0 \\ 0 & 0 & 1 & 0 & 1 & 1 \\ 0 & 0 & 0 & 1 & 0 & 1 \\ 0 & 0 & 0 & 1 & 1 & 0 \end{pmatrix}$$

Schritt 1 – Wege der Länge zwei.
Wir rechnen die erste Zeile von A^2 aus:

$$\begin{aligned} (A^2)_{11} &= 0\cdot 0 + 1\cdot 1 + 1\cdot 1 + 0 + 0 + 0 = 2, \\ (A^2)_{12} &= 0\cdot 1 + 1\cdot 0 + 1\cdot 1 + 0 + 0 + 0 = 1, \\ (A^2)_{13} &= 0\cdot 1 + 1\cdot 1 + 1\cdot 0 + 0 + 0 + 0 = 1, \\ (A^2)_{14} &= 0 + 0 + 1\cdot 1 + 0 + 0 + 0 = 1, \\ (A^2)_{15} &= 0, \qquad (A^2)_{16} = 0. \end{aligned}$$

Eintrag	Wert	Deutung
$(A^2)_{11}$	2	über 2 und über 3 hin und zurück
$(A^2)_{12}$	1	$1 \to 3 \to 2$
$(A^2)_{14}$	1	$1 \to 3 \to 4$
$(A^2)_{15}$	0	**kein Weg der Länge 2**

Die Diagonale von A^2 enthält die Grade: Ein Weg der Länge zwei von i nach i führt zu einem Nachbarn und zurück, und davon gibt es genau k_i Stück.

Schritt 2 – Dreiecke.
Ein Dreieck durch Knoten i entspricht einem geschlossenen Weg der Länge drei:

$$(A^3)_{ii} = 2 \cdot (\text{Zahl der Dreiecke durch } i).$$

Knoten	$(A^3)_{ii}$	Dreiecke	welches
1	2	1	$1{-}2{-}3$
2	2	1	$1{-}2{-}3$
3	2	1	$1{-}2{-}3$
4	2	1	$4{-}5{-}6$
5	2	1	$4{-}5{-}6$
6	2	1	$4{-}5{-}6$

$$\text{Zahl der Dreiecke} = \frac{\operatorname{Spur}(A^3)}{6} = \frac{12}{6} = \mathbf{2}. \qquad \checkmark$$

Der Faktor sechs kommt daher, dass jedes Dreieck an drei Knoten hängt und je Knoten in zwei Richtungen durchlaufen werden kann. Diese Formel ist elegant und für große Netze unbrauchbar, weil das Matrixprodukt $\mathcal{O}(n^3)$ kostet.

Verfahren	**Aufwand**	**bei $n = 10^6$, $m = 10^7$**
Über A^3	$\mathcal{O}(n^3)$	aussichtslos
Nachbarlisten schneiden	$\mathcal{O}(m^{1,5})$	$\approx 3 \cdot 10^{10}$
Nach Grad geordnet	$\mathcal{O}(m^{1,5})$, klein	Minuten
Stichprobe	$\mathcal{O}(m)$	Sekunden, geschätzt

(c) Das Freundschaftsparadox.
Das Netz. Ein Stern mit fünf Blättern: Knoten Z in der Mitte, Knoten B_1 bis B_5 außen.

Knoten	**Grad**	**Nachbarn**	**deren Grad**
Z	5	$B_1 \dots B_5$	je 1
B_i	1	Z	5

Der eigene mittlere Grad.

$$\langle k \rangle = \frac{5 + 5 \cdot 1}{6} = \frac{10}{6} = 1{,}667.$$

Der mittlere Grad der Nachbarn.
Man mittelt über alle Knoten den mittleren Grad ihrer Nachbarn:

$$\frac{1}{6}\left(\underbrace{1}_{Z} + \underbrace{5 \cdot 5}_{B_i}\right) = \frac{26}{6} = 4{,}333.$$

Größe	**Wert**
Eigener Grad, im Mittel	1,67
Grad der Nachbarn	**4,33**
Verhältnis	2,6
Anteil, für den es gilt	**5/6 = 83 %**

Die Probe mit der Formel.

$$\langle k \rangle = 1{,}667, \qquad \langle k^2 \rangle = \frac{25 + 5 \cdot 1}{6} = 5{,}0.$$

$$\frac{\langle k^2 \rangle}{\langle k \rangle} = \frac{5{,}0}{1{,}667} = \mathbf{3{,}0}.$$

Die beiden Werte 4,33 *und* 3,0 *unterscheiden sich, weil sie verschiedene Fragen beantworten. Der erste mittelt über* Knoten*, der zweite über* Kantenenden*. Beide zeigen denselben Effekt, und die Verwechslung der beiden Mittelungen ist eine häufige Fehlerquelle.*

Warum das keine Kuriosität ist.

Umfragen	Wer über Nachbarn befragt, erhält eine nach Grad verzerrte Stichprobe
Wahrnehmung	Menschen halten sich für unterdurchschnittlich vernetzt, ohne es zu sein
Epidemien	Ein zufälliger Nachbar ist gefährlicher als eine zufällige Person
Stichproben	Wer einem Netz entlang läuft, sammelt bevorzugt Knoten hohen Grades ein

Die letzte Zeile betrifft jede Erhebung, die sich durch ein Netz fortpflanzt, vom Schneeballverfahren in der Soziologie bis zum Durchsuchen des Webs. Kapitel 14 zeigt, wie man dagegen korrigiert.

Newman[23] ist das maßgebliche Lehrbuch und beginnt mit genau diesen Begriffen; Barabási[3] führt anschaulicher ein und ist frei verfügbar; Cormen und Mitautoren[9] behandeln die Darstellungen aus algorithmischer Sicht.

2 Durchmusterung und Zusammenhang

Zwei Arten, ein Netz abzulaufen

Fast jedes Verfahren auf Graphen beginnt damit, dass man von einem Knoten aus systematisch alle erreichbaren besucht. Es gibt zwei Grundformen, und sie unterscheiden sich in einer einzigen Zeile.

	Breite zuerst	**Tiefe zuerst**
Vorratsstruktur	**Warteschlange**	**Stapel**
Besucht	schalenweise	**so weit wie möglich**
Findet	kürzeste Wege	Kreise, Strukturen
Speicher	bis $\mathcal{O}(n)$ in einer Schale	$\mathcal{O}(\text{Tiefe})$
Aufwand	$\mathcal{O}(n+m)$	$\mathcal{O}(n+m)$

Die erste Zeile ist der ganze Unterschied. Nimmt man den zuletzt hinzugefügten Knoten, geht man in die Tiefe; nimmt man den ältesten, in die Breite. Alles Weitere folgt daraus.

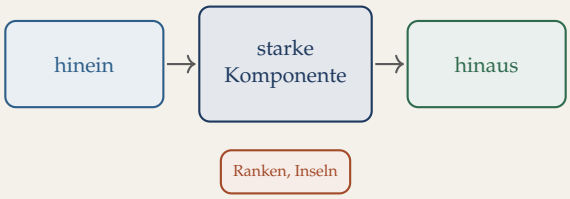
```
besuche(start):
  V = {start}; vorrat = [start]
  solange vorrat nicht leer:
    u = vorrat.entnimm()
    für jeden Nachbarn v von u:
      falls v nicht in V:
        V.füge_hinzu(v);
vorrat.lege_ab(v)
```

Dasselbe Programm liefert beide Verfahren, je nachdem ob `vorrat` eine Warteschlange oder ein Stapel ist. Ersetzt man es durch eine Vorrangwarteschlange nach Kantengewicht, erhält man Dijkstras Verfahren aus Kapitel 3.

Zusammenhang

Komponente	Maximale Menge von Knoten, die einander erreichen
Stark zusammenhängend	Bei gerichteten Graphen: in **beiden** Richtungen erreichbar
Schwach zusammenhängend	Zusammenhängend, wenn man die Richtungen vergisst

Der Aufbau eines gerichteten Netzes.
Große gerichtete Netze haben fast immer dieselbe grobe Gestalt.



Teil	Anteil im Web	Eigenschaft
Starke Komponente	≈ 28 %	alle erreichen einander
Hinein	≈ 21 %	erreichen den Kern
Hinaus	≈ 21 %	vom Kern erreichbar
Rest	≈ 30 %	Ranken und Inseln

Diese Aufteilung wurde 1999 am Web gemessen und heißt seither Fliegenform. Sie widerlegt die verbreitete Vorstellung, im Web sei alles von allem aus erreichbar: Von einer zufälligen Seite aus erreicht man nur etwa die Hälfte aller anderen.

Die Riesenkomponente ist eine Auswahl

Fast jede Netzwerkanalyse beschränkt sich stillschweigend auf die größte Komponente, weil viele Maße sonst gar nicht definiert sind.

Mittlere Weglänge	Unendlich, wenn ein Paar nicht verbunden ist
Nähezentralität	Ebenso
Folge	Man rechnet nur auf der Riesenkomponente

Das ist eine Auswahlentscheidung, die selten berichtet wird. Wenn dreißig Prozent der Knoten verworfen werden, ist das Ergebnis eine Aussage über die verbleibenden siebzig, und die sind nicht zufällig ausgewählt: Es sind die gut vernetzten.

Gerichtete azyklische Graphen

Ein gerichteter Graph ohne Kreise heißt azyklisch. Solche Graphen erlauben eine Anordnung, in der jede Kante nach vorn zeigt.

Vorkommen	Abhängigkeiten, Zitationen, Versionsgeschichte, Bauanleitungen
Topologische Sortierung	Eine Reihenfolge, in der jeder Knoten nach allen seinen Vorgängern kommt
Existiert genau dann	wenn kein Kreis vorhanden ist

Diese Struktur ist in dieser Reihe schon mehrfach aufgetreten: bei der Serialisierbarkeit in Band 10, beim Abhängigkeitsgraphen des Übersetzers in Band 6, und beim Bauen von Software. Es ist stets dieselbe Frage: Gibt es eine Reihenfolge, die alle Bedingungen erfüllt?

Zwei Verfahren.

	Kahn	über Tiefensuche
Vorgehen	wiederholt Knoten ohne Vorgänger entnehmen	Nachbearbeitungs-reihenfolge umkehren
Erkennt Kreise	Rest bleibt übrig	Rückwärtskante
Aufwand	$\mathcal{O}(n+m)$	$\mathcal{O}(n+m)$

Beide sind gleich schnell. Das erste ist leichter zu erklären und liefert nebenbei die Ebenen; das zweite kommt ohne Zählung der Eingangsgrade aus.

Aufgabe 2.1.

(a) Führen Sie beide Durchmusterungen an einem Netz aus.
(b) Bestimmen Sie die starken Komponenten eines gerichteten Graphen.
(c) Sortieren Sie einen Abhängigkeitsgraphen topologisch.

Lösung Schritt für Schritt.

(a) Beide Durchmusterungen.
Das Netz. Kanten $1{-}2$, $1{-}3$, $2{-}4$, $3{-}4$, $3{-}5$, $4{-}6$, $5{-}6$, $6{-}7$.
Breite zuerst, ab Knoten 1.

Schritt	entnommen	neu	Warteschlange
1	1	2, 3	[2, 3]
2	2	4	[3, 4]
3	3	5	[4, 5]
4	4	6	[5, 6]
5	5	—	[6]
6	6	7	[7]
7	7	—	[ ]

Die Abstände fallen dabei ab.

Knoten	1	2	3	4	5	6	7
Abstand	0	1	1	2	2	3	4

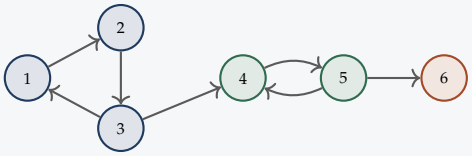
Die Breitensuche liefert die kürzesten Wege gratis, solange alle Kanten gleich viel kosten. Der Grund: Sie besucht die Knoten in aufsteigender Entfernung, also kann kein später gefundener Weg kürzer sein.

Tiefe zuerst, ab Knoten 1.

Schritt	entnommen	neu	Stapel
1	1	2, 3	[2, 3]
2	3	4, 5	[2, 4, 5]
3	5	6	[2, 4, 6]
4	6	7	[2, 4, 7]
5	7	—	[2, 4]
6	4	—	[2]
7	2	—	[ ]

	Breite	Tiefe
Reihenfolge	1, 2, 3, 4, 5, 6, 7	1, 3, 5, 6, 7, 4, 2
Nutzen	Abstände	Kreise, Komponenten

(b) Starke Komponenten.
Der Graph. $1 \to 2$, $2 \to 3$, $3 \to 1$, $3 \to 4$, $4 \to 5$, $5 \to 4$, $5 \to 6$.



Die Komponenten.

Komponente	Knoten	Begründung
K_1	$\{1, 2, 3\}$	Kreis der Länge 3
K_2	$\{4, 5\}$	Kreis der Länge 2
K_3	$\{6\}$	keine Rückkehr

Der Komponentengraph.

$$K_1 \to K_2 \to K_3.$$

Fasst man jede starke Komponente zu einem Knoten zusammen, entsteht immer ein azyklischer Graph. Das ist kein Zufall: Gäbe es dort einen Kreis, so wären die beteiligten Komponenten gegenseitig erreichbar und damit eine einzige.

Die Verfahren.

Verfahren	Durchläufe	Bemerkung
Kosaraju	2	auch auf dem umgekehrten Graphen
Tarjan	**1**	mit Rückwärtsnummern

Beide brauchen $\mathcal{O}(n+m)$. Kosarajus Verfahren ist leichter zu verstehen, Tarjans kommt mit einem Durchlauf aus und braucht den umgekehrten Graphen nicht, was bei großen Netzen den Speicher halbiert.

(c) Topologische Sortierung.
Die Abhängigkeiten. Ein Bauplan mit sieben Schritten.

Schritt	braucht vorher	Eingangsgrad
A Fundament	—	0
B Wände	A	1
C Leitungen	A	1
D Dach	B	1
E Putz	B, C	2
F Fenster	B, D	2
G Anstrich	E, F	2

Kahns Verfahren.

Runde	Grad null	gewählt	danach Grad null
1	A	A	B, C
2	B, C	B	C, D
3	C, D	C	D, E
4	D, E	D	E, F
5	E, F	E	F
6	F	F	G
7	G	G	—

Eine gültige Reihenfolge: A, B, C, D, E, F, G.

Sie ist nicht die einzige.

Reihenfolge	gültig?	
A, B, C, D, E, F, G	ja	
A, C, B, E, D, F, G	ja	
A, B, D, F, C, E, G	ja	
$A, B, E, C, \ldots$	nein	E braucht C

Die Ebenen und der kritische Pfad.

Ebene	Schritte	parallel möglich
0	A	—
1	B, C	ja
2	D, E	ja
3	F	
4	G	

Bei unbegrenzt vielen Arbeitskräften dauert das Ganze fünf Ebenen statt sieben Schritte. Der längste Weg durch den Graphen heißt kritischer Pfad und bestimmt die kürzestmögliche Gesamtdauer, gleichgültig wie viele Ressourcen zur Verfügung stehen.

Das ist dieselbe Aussage wie beim sequentiellen Anteil in Band 4: Es gibt eine Kette, die sich nicht parallelisieren lässt, und sie setzt die untere Schranke.

Cormen und Mitautoren[9] behandeln beide Durchmusterungen und die starken Komponenten vollständig; Newman[23] ordnet den Zusammenhang in die Netzwerkanalyse ein.

3 Wege und Flüsse

Kürzeste Wege

Sobald Kanten unterschiedlich viel kosten, genügt die Breitensuche nicht mehr.

Verfahren	Voraussetzung	Aufwand	liefert
Breitensuche	alle Kanten gleich	$\mathcal{O}(n+m)$	von einem
Dijkstra	**keine negativen**	$\mathcal{O}(m + n \log n)$	von einem
Bellman-Ford	negative erlaubt	$\mathcal{O}(nm)$	von einem
Floyd-Warshall	—	$\mathcal{O}(n^3)$	**alle Paare**
A*	Schätzfunktion	meist besser	von einem zu einem

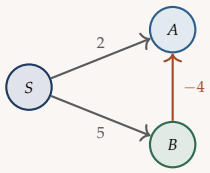
Dijkstras Verfahren.

1. Alle Abstände auf unendlich setzen, den Startknoten auf null.
2. Den unbesuchten Knoten mit kleinstem Abstand nehmen.
3. Für jeden Nachbarn prüfen, ob der Weg über diesen Knoten kürzer ist.
4. Wiederholen, bis alle besucht sind.

Es ist die Durchmusterung aus Kapitel 2 mit einer Vorrangwarteschlange statt einer Warteschlange. Der Beweis der Korrektheit hängt an einem einzigen Punkt: Wenn ein Knoten mit kleinstem Abstand entnommen wird, kann kein späterer Weg zu ihm kürzer sein, weil alle Kanten nichtnegativ sind.

Negative Kanten brechen das Verfahren

Genau das Argument, das Dijkstra korrekt macht, fällt bei negativen Gewichten weg.



Weg	Kosten	
$S \to A$	2	Dijkstra nimmt diesen
$S \to B \to A$	**1**	übersehen

Dijkstra schließt A mit dem Wert 2 ab, bevor B überhaupt betrachtet wird, und kommt nicht mehr darauf zurück. Das Verfahren liefert ein falsches Ergebnis, ohne einen Fehler zu melden.

Negative Gewichte kommen vor, etwa bei Umrechnungskursen oder bei Kosten mit Erstattung. Dort braucht man Bellman-Ford, das zugleich negative Kreise erkennt, bei denen es überhaupt keinen kürzesten Weg gibt.

Flüsse und Schnitte

Eine ganz andere Frage: Wie viel lässt sich durch ein Netz mit begrenzten Kantenkapazitäten schicken?

Definition 3.1. Ein **Fluss** ordnet jeder Kante einen Wert zu, der die Kapazität nicht überschreitet, und für den an jedem Knoten außer Quelle und Senke gleich viel hinein- wie hinausfließt.

Definition 3.2 (Max-Flow-Min-Cut)**.** Der größtmögliche Fluss von der Quelle zur Senke ist gleich der kleinsten Kapazität eines Schnitts, der beide trennt.

Der Satz ist bemerkenswert, weil er zwei ganz verschiedene Fragen als dieselbe erweist. Die eine sucht das Beste, was man erreichen kann; die andere die schwächste Stelle, die es verhindert. Ford und Fulkerson bewiesen 1956, dass beide Antworten übereinstimmen.

Fluss finden	Solange es einen Weg mit freier Kapazität gibt, so viel wie möglich darüber schicken
Der Kunstgriff	Rückwärtskanten erlauben, bereits geschickten Fluss wieder zurückzunehmen

Ohne die Rückwärtskanten bliebe das Verfahren in schlechten Zwischenlösungen stecken. Mit ihnen kann eine spätere Entscheidung eine frühere teilweise widerrufen, ohne dass man von vorn beginnen muss.

Wozu man das braucht.

Zuordnung	Aufgaben auf Personen verteilen; maximales Paarungsproblem
Bildsegmentierung	Vorder- und Hintergrund trennen, mit minimalem Schnitt
Verwundbarkeit	Wie viele Kanten muss man entfernen, um ein Netz zu zerlegen
Zulieferketten	Engpass finden

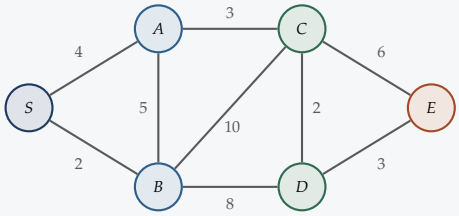
Die dritte Zeile verbindet das Kapitel mit der Netzwerkanalyse. Die Kantenzusammenhangszahl zwischen zwei Knoten ist genau der maximale Fluss bei Einheitskapazitäten, und das ist der Satz von Menger.

Aufgabe 3.1.

(a) Führen Sie Dijkstras Verfahren vollständig durch.
(b) Bestimmen Sie einen maximalen Fluss und den zugehörigen Schnitt.
(c) Untersuchen Sie, wie sich die Weglängenverteilung eines Netzes verhält.

Lösung Schritt für Schritt.

(a) Dijkstra vollständig.
Das Netz.



Der Ablauf.

Runde	fest	A	B	C	D	E
0	S=0	4	2	∞	∞	∞
1	B=2	4	—	12	10	∞
2	A=4	—	—	**7**	10	∞
3	C=7	—	—	—	**9**	13
4	D=9	—	—	—	—	**12**
5	E=12	—	—	—	—	—

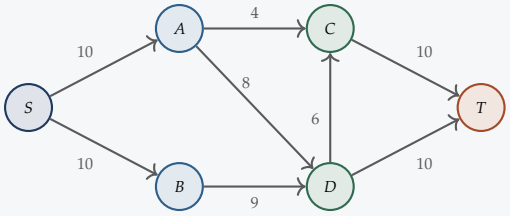
Die Verbesserungen im Einzelnen.

Runde	Knoten	alt	neu über
1	C	∞	$2 + 10 = 12$ über B
2	C	12	$\mathbf{4 + 3 = 7}$ über A
3	D	10	$\mathbf{7 + 2 = 9}$ über C
4	E	13	$\mathbf{9 + 3 = 12}$ über D

Ziel	Abstand	Weg
A	4	$S \to A$
B	2	$S \to B$
C	7	$S \to A \to C$
D	9	$S \to A \to C \to D$
E	**12**	$S \to A \to C \to D \to E$

Bemerkenswert ist der Weg nach E: Er führt über vier Kanten, obwohl es einen Weg über drei gäbe ($S \to A \to C \to E$ mit Kosten 13). Kürzeste Wege sind nicht die mit den wenigsten Kanten, und die Verwechslung ist eine häufige Fehlerquelle bei gewichteten Netzen.

(b) Maximaler Fluss.
Das Netz. Quelle S, Senke T, Kapazitäten an den Kanten.



Runde 1. Weg $S \to A \to C \to T$, Engpass $\min(10, 4, 10) = 4$.

Kante	Kapazität	Fluss	frei
$S \to A$	10	4	6
$A \to C$	4	4	**0**
$C \to T$	10	4	6

Runde 2. Weg $S \to A \to D \to T$, Engpass $\min(6, 8, 10) = 6$.
Runde 3. Weg $S \to B \to D \to T$, Engpass $\min(10, 9, 4) = 4$.

Runde	Weg	Engpass	Summe
1	S, A, C, T	4	4
2	S, A, D, T	6	10
3	S, B, D, T	4	14
4	S, B, D, C, T	**5**	**19**

In Runde 4 ist $D \to T$ erschöpft, und der Fluss weicht über $D \to C \to T$ aus. Der Engpass ist dort $\min(5, 5, 6, 6) = 5$.

Der minimale Schnitt.
Nach Runde 4 sind von S aus über freie Kapazität nur noch S und B erreichbar.

Seite	Knoten
Quellseite	$\{S, B\}$
Senkenseite	$\{A, C, D, T\}$

Schnittkante	Kapazität	
$S \to A$	10	
$B \to D$	9	
Summe	**19**	$=$ maximaler Fluss ✓

Der Satz bestätigt sich. Und er liefert nebenbei den Beweis der Optimalität: Da jeder Fluss höchstens so groß sein kann wie jeder Schnitt, und wir einen Fluss und einen Schnitt gleicher Größe gefunden haben, sind beide optimal.

(c) Weglängenverteilung.
Die Größen.

Mittlere Weglänge	Durchschnitt über alle Knotenpaare
Durchmesser	Das größte Vorkommen
Effektiver Durchmesser	Die Länge, unter der 90 % der Paare liegen

Die dritte Größe ist die robusteste. Der Durchmesser hängt von einem einzigen entlegenen Paar ab und ändert sich, wenn man einen einzigen Knoten entfernt. Der effektive Durchmesser ist gegen solche Ausreißer unempfindlich.

Werte für reale Netze.

Netz	n	$\langle \ell \rangle$	$\log n / \log \langle k \rangle$
Makakenkortex	≈ 90	1,7	1,3
Filmschauspieler	$2{,}2 \cdot 10^5$	3,6	3,0
Stromnetz	4941	**19,0**	**8,7**
Web	10^{11}	≈ 19	6,9

Die dritte Zeile fällt aus dem Rahmen. Ein Stromnetz ist räumlich eingebettet: Leitungen kosten Geld je Kilometer, also gibt es keine Abkürzungen über weite Strecken. Genau diese Abkürzungen machen die anderen Netze zu kleinen Welten (Kapitel 9).

Die Berechnung ist teuer.

Verfahren	**Aufwand**	**bei $n = 10^6$**
Alle Paare exakt	$\mathcal{O}(nm)$	10^{13}
Stichprobe von s Startknoten	$\mathcal{O}(sm)$	$s = 1000$: 10^{10}
Näherungsverfahren	$\mathcal{O}(m \log n)$	$2 \cdot 10^8$

Die zweite Zeile ist der übliche Weg und liefert bei tausend zufälligen Startknoten eine Schätzung mit einem Fehler unter einem Prozent. Kapitel 13 behandelt solche Stichprobenverfahren allgemein.

Dijkstras Notiz von 1959[10] ist knapp drei Seiten lang; Ford und Fulkerson[14] bewiesen den Fluss-Schnitt-Satz; Cormen und Mitautoren[9] behandeln alle genannten Verfahren mit Beweisen.

Part II

Struktur messen

4 Zentralität

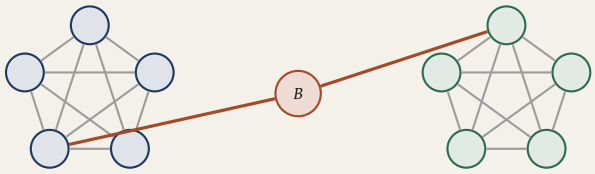
Vier Antworten auf dieselbe Frage

„Wer ist wichtig?“ ist keine Frage, sondern vier. Jedes Zentralitätsmaß beantwortet eine andere.

Maß	Frage	Formel
Grad	Wie viele kenne ich?	k_i
Nähe	Wie schnell erreiche ich alle?	$\frac{n-1}{\sum_j d_{ij}}$
Zwischen	**Wie oft liege ich dazwischen?**	$\sum \frac{\sigma_{st}(i)}{\sigma_{st}}$
Eigenvektor	Kennen mich Wichtige?	$\lambda x_i = \sum_j A_{ij} x_j$

Die vier stimmen in vielen Netzen weitgehend überein, und dann ist die Wahl gleichgültig. Interessant wird es dort, wo sie auseinandergehen, denn dort steckt die eigentliche Struktur.

Der lehrreiche Fall.



Maß	Knoten B	Knoten im Klumpen	Sieger
Grad	2	5	Klumpen
Eigenvektor	niedrig	hoch	Klumpen
Nähe	hoch	mittel	B
Zwischen	**sehr hoch**	niedrig	B

Der Knoten B hat den kleinsten Grad und die größte Zwischenzentralität. Er ist unbedeutend, wenn man zählt, und unentbehrlich, wenn man etwas hindurchschicken will. Entfernt man ihn, zerfällt das Netz.

Genau solche Knoten sucht man in der Praxis: Verwundbarkeiten in Infrastruktur, Vermittler in Organisationen, Engstellen im Gehirn. Kein anderes Maß findet sie.

Zwischenzentralität

LINTON FREEMAN führte das Maß 1977 ein. Es zählt, auf wie vielen kürzesten Wegen ein Knoten liegt.

$$C_B(i) = \sum_{s \neq i \neq t} \frac{\sigma_{st}(i)}{\sigma_{st}},$$

wobei σ_{st} die Zahl der kürzesten Wege von s nach t ist und $\sigma_{st}(i)$ die Zahl derjenigen, die über i führen.

Der Bruch	Gibt es mehrere kürzeste Wege, so teilt sich der Beitrag auf sie auf
Der Grund	Sonst zählte ein Knoten auf einem von zehn gleichwertigen Wegen ebenso viel wie einer auf dem einzigen

Der Aufwand.

Verfahren	**Aufwand**	**bei $n = 10^5$, $m = 10^6$**
Naiv, alle Paare aufzählen	$\mathcal{O}(n^3)$	aussichtslos
Brandes	$\mathcal{O}(nm)$	10^{11}, Stunden
Stichprobe	$\mathcal{O}(sm)$	$s = 1000$: Minuten

Brandes zeigte 2001, dass sich die Beiträge rückwärts durch den Suchbaum aufsammeln lassen, statt jeden Weg einzeln zu betrachten. Das senkte den Aufwand um einen ganzen Faktor n und machte das Maß für große Netze überhaupt erst benutzbar.

Kürzeste Wege sind eine Annahme

Das Maß unterstellt, dass alles, was durch das Netz läuft, den kürzesten Weg nimmt und dass alle kürzesten Wege gleich wahrscheinlich sind.

Fluss	**Weg**	**passendes Maß**
Paket im Netz	kürzester	Zwischenzentralität
Gerücht	beliebig	**Stromzentralität**
Geld	aufgeteilt	Flusszentralität
Zufallsspaziergang	zufällig	PageRank

Ein Gerücht kennt die kürzesten Wege nicht. Für solche Prozesse gibt es Maße, die auf Zufallsspaziergängen beruhen, und sie liefern deutlich andere Rangfolgen. Wer das falsche wählt, misst etwas, das mit dem untersuchten Vorgang nichts zu tun hat.

Eigenvektorzentralität und ihre Verwandten

Der Gedanke: Ein Knoten ist wichtig, wenn wichtige Knoten auf ihn zeigen.

$$x_i = \frac{1}{\lambda} \sum_j A_{ij} x_j \qquad \Longleftrightarrow \qquad A\vec{x} = \lambda \vec{x}.$$

Die Definition ist zirkulär und trotzdem lösbar: Gesucht ist der Eigenvektor zum größten Eigenwert. Nach dem Satz von Perron und Frobenius ist er bei zusammenhängenden Netzen eindeutig und hat nur positive Einträge.

Maß	Zusatz	löst welches Problem
Eigenvektor	—	Grundform
Katz	Grundwert für jeden	**Knoten ohne Eingang**
PageRank	durch Ausgangsgrad teilen	**Verweisverkäufer**
HITS	zwei Rollen	Autoritäten und Verteiler

Die dritte Zeile enthält den wesentlichen Unterschied zwischen Eigenvektorzentralität und PageRank. Ohne die Teilung könnte eine Seite ihren Einfluss beliebig vervielfältigen, indem sie auf viele andere verweist. Mit ihr verteilt sie einen festen Vorrat.

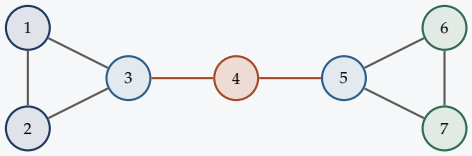
PageRank wurde in Band 10, Kapitel 14 hergeleitet und dort auch durchgerechnet. Hier steht es als eines von mehreren Maßen derselben Familie.

Aufgabe 4.1.

(a) Berechnen Sie alle vier Maße für ein kleines Netz.
(b) Führen Sie die Zwischenzentralität von Hand aus.
(c) Untersuchen Sie, wann die Maße auseinandergehen.

Lösung Schritt für Schritt.

(a) Vier Maße an einem Netz.
Das Netz. Sieben Knoten, Kanten 1−2, 1−3, 2−3, 3−4, 4−5, 5−6, 5−7, 6−7.



Gradzentralität.

Knoten	1	2	3	4	5	6	7
Grad	2	2	**3**	2	**3**	2	2

Die Abstandsmatrix.

	1	2	3	4	5	6	7	$\sum$
1	0	1	1	2	3	4	4	15
2	1	0	1	2	3	4	4	15
3	1	1	0	1	2	3	3	11
4	2	2	1	0	1	2	2	**10**
5	3	3	2	1	0	1	1	11
6	4	4	3	2	1	0	1	15
7	4	4	3	2	1	1	0	15

Nähezentralität. $C_C(i) = (n-1)/\sum_j d_{ij}$.

Knoten	$\sum d$	C_C	**Rang**
1, 2	15	0,400	4–7
3	11	0,545	2
4	**10**	**0,600**	**1**
5	11	0,545	2
6, 7	15	0,400	4–7

(b) Zwischenzentralität von Hand.
Es gibt $\binom{7}{2} = 21$ Paare. Wir zählen für Knoten 4.

Paar aus	**Paare**	**Weg über 4?**
$\{1,2,3\}$ links	3	nein
$\{5,6,7\}$ rechts	3	nein
links $\times$ rechts	**$3 \cdot 3 = 9$**	**alle**
4 mit anderen	6	zählt nicht
Summe	21	

$$C_B(4) = 9.$$

Für Knoten 3.

Paar	über 3?	
$1-2$	nein	direkte Kante
$\{1,2\} \times \{4,5,6,7\}$	ja, 8 Paare	
$4-5, 4-6, 4-7, 5-6, \ldots$	nein	

$$C_B(3) = 8.$$

Alle Werte.

Knoten	1	2	3	4	5	6	7
C_B	0	0	8	**9**	8	0	0

Der Vergleich aller Maße.

Maß	Sieger	Wert	Zweiter	Wert
Grad	3,5	3	Rest	2
Nähe	**4**	0,600	3,5	0,545
Zwischen	**4**	9	3,5	8
Eigenvektor	3,5	0,45	4	0,38

Knoten 4 gewinnt bei zwei Maßen und verliert bei zwei. Er hat den kleineren Grad und liegt genau in der Mitte. Welcher der beiden Knoten „wichtiger" ist, hängt allein davon ab, wofür.

(c) Wann die Maße auseinandergehen.
Die Korrelation in typischen Netzen.

Paar	Rangkorrelation	
Grad – Eigenvektor	$\approx 0{,}90$	meist austauschbar
Grad – Nähe	$\approx 0{,}75$	
Grad – Zwischen	$\approx 0{,}70$	
Nähe – Zwischen	$\approx 0{,}60$	

Im Mittel hängen alle eng zusammen, und deshalb ist die Wahl in der Praxis oft gleichgültig. Der Erkenntnisgewinn steckt in den Ausreißern.

Drei Fälle, in denen es zählt.

Hoher Grad, niedrige Zwischenzentralität	Ein Knoten in einem dichten Klumpen; ersetzbar, weil alle Wege auch anders laufen
Niedriger Grad, hohe Zwischenzentralität	**Ein Brückenknoten**; unersetzlich und unauffällig
Hohe Nähe, niedrige Zwischenzentralität	Zentral gelegen, aber umgehbar

Die praktische Folgerung.

Ziel	**Maß**	
Etwas verbreiten	Grad	viele erreichen sofort
Schnell alle erreichen	Nähe	
Netz zerschlagen	**Zwischen**	Brücken treffen
Ansehen messen	Eigenvektor	

Die dritte Zeile hat eine unangenehme Kehrseite. Dasselbe Maß, das Angriffsziele findet, findet auch die Stellen, die man schützen muss. Kapitel 11 rechnet durch, wie verwundbar Netze gegen gezielte Angriffe auf solche Knoten sind.

Freemans Arbeit von 1977[17] führte die Zwischenzentralität ein; Newman[23] behandelt alle Maße mit ihren Zusammenhängen; Barabási[3] erklärt sie anschaulich.

5 Lokale Struktur

Sind die Freunde meiner Freunde meine Freunde?

Der Clusterkoeffizient misst, wie oft sich ein Dreieck schließt.

Definition 5.1. Der **lokale Clusterkoeffizient** eines Knotens i mit Grad k_i ist

$$C_i = \frac{2e_i}{k_i(k_i - 1)},$$

wobei e_i die Zahl der Kanten zwischen seinen Nachbarn ist.



	Mittelwert der C_i	**Transitivität**
Rechnung	$\frac{1}{n}\sum_i C_i$	$\frac{3\cdot\text{Dreiecke}}{\text{Pfade der Länge 2}}$
Gewichtet	**jeder Knoten gleich**	**jedes Dreieck gleich**
Empfindlich für	Knoten kleinen Grades	große Knoten

Beide heißen in der Literatur „Clusterkoeffizient“ und können erheblich auseinandergehen. Bei einem Netz mit vielen Knoten vom Grad zwei liefert der Mittelwert hohe Werte, weil jeder solche Knoten leicht auf eins kommt. Welcher gemeint ist, sollte immer dabeistehen.

Warum das Maß aussagekräftig ist.

Netz	gemessen	Zufall gleicher Dichte	Faktor
Filmschauspieler	0,79	0,00027	2900
Stromnetz	0,080	0,005	16
C. elegans	0,28	0,05	5,6
Makakenkortex	0,49	0,34	1,4

Die letzte Zeile mahnt zur Vorsicht. Bei einem so dichten Netz wie der Hirnrinde ist auch ein Zufallsgraph schon stark geclustert, und der gemessene Wert ist kaum erhöht. Kapitel 12 kommt darauf zurück.

Die Stärke schwacher Bindungen

MARK GRANOVETTER veröffentlichte 1973 eine Arbeit, die aus einer soziologischen Beobachtung eine strukturelle Aussage machte.

Die Beobachtung	Menschen finden Arbeitsstellen häufiger über flüchtige Bekannte als über enge Freunde
Die Erklärung	Enge Freunde kennen dieselben Leute wie man selbst; flüchtige Bekannte kennen andere

Das strukturelle Argument.

> *Wenn zwei Personen eine starke Bindung haben, sind ihre Bekanntenkreise stark überlappend. Eine starke Bindung kann deshalb kaum eine Brücke sein: Läge sie zwischen zwei sonst getrennten Gruppen, so müssten ihre Nachbarschaften überlappen, und dann wären die Gruppen nicht getrennt.*

Starke Bindung $\Rightarrow$ hohe Nachbarschaftsüberlappung $\Rightarrow$ keine Brücke.

	starke Bindung	schwache Bindung
Überlappung	hoch	niedrig
Neue Information	wenig	**viel**
Brücke möglich	nein	ja
Bei Entfernung	wenig Wirkung	**Netz zerfällt**

Es ist die Verbindung zwischen der lokalen Struktur dieses Kapitels und den Gemeinschaften des nächsten: Kanten mit geringer Überlappung liegen zwischen Gruppen, Kanten mit hoher innerhalb. Genau darauf beruhen mehrere Verfahren zur Gemeinschaftserkennung.

Assortativität

Verbinden sich Knoten bevorzugt mit ihresgleichen?

Netzart	r nach Grad	**Deutung**
Soziale Netze	$+0{,}1$ bis $+0{,}3$	gleich zu gleich
Web	$-0{,}07$	
Internet	$-0{,}19$	groß zu klein
Nahrungsnetze	$-0{,}28$	
Proteine	$-0{,}16$	

Der Befund ist bemerkenswert regelmäßig: Soziale Netze sind assortativ, technische und biologische disassortativ. Für die zweite Gruppe gibt es eine strukturelle Erklärung, die keine Absicht voraussetzt.

Die strukturelle Erklärung.
In einem Netz ohne Mehrfachkanten können sich hochgradige Knoten gar nicht alle untereinander verbinden, weil es zu wenige davon gibt. Ein Teil ihrer Kanten muss zwangsläufig zu kleinen Knoten führen.

Deshalb ist ein gewisses Maß an Disassortativität in Netzen mit schwerem Gradschwanz schon aus Abzählgründen zu erwarten. Ob der gemessene Wert darüber hinausgeht, entscheidet erst der Vergleich mit dem passenden Nullmodell.

Assortativität nach anderen Merkmalen

Interessanter als der Grad sind meist inhaltliche Merkmale.

Homophilie	Ähnliche verbinden sich; man sucht sich seinesgleichen
Ansteckung	Verbundene werden ähnlich; man passt sich an

Beide Vorgänge erzeugen dasselbe Muster: Nachbarn sind ähnlich. Aus einer Momentaufnahme lassen sie sich nicht *unterscheiden. Wer aus einem assortativen Netz auf Beeinflussung schließt, hat einen Fehlschluss begangen.*

Zur Trennung braucht man zeitliche Daten: Wurden die Knoten erst ähnlich und dann verbunden, oder umgekehrt? Selbst dann bleibt die Möglichkeit, dass ein drittes Merkmal beides verursacht. Es ist eine der hartnäckigsten offenen Fragen der Netzwerkforschung.

Aufgabe 5.1.

(a) Berechnen Sie beide Clustermaße für ein Netz.
(b) Prüfen Sie Granovetters Behauptung an einem Beispiel.
(c) Untersuchen Sie Motive und ihre Bewertung.

Lösung Schritt für Schritt.

(a) Beide Clustermaße.
Das Netz. Kanten $1{-}2$, $1{-}3$, $2{-}3$, $1{-}4$, $1{-}5$, $4{-}5$, $1{-}6$.

Knoten	k_i	**Nachbarn**	e_i	C_i
1	5	2, 3, 4, 5, 6	2	0,200
2	2	1, 3	1	1,000
3	2	1, 2	1	1,000
4	2	1, 5	1	1,000
5	2	1, 4	1	1,000
6	1	1	—	undefiniert

Mittelwert über die definierten Werte.

$$\overline{C} = \frac{0{,}200 + 4 \cdot 1{,}000}{5} = \frac{4{,}200}{5} = \mathbf{0{,}840}.$$

Transitivität.

Größe	Wert	Rechnung
Dreiecke	2	$\{1,2,3\}$, $\{1,4,5\}$
Pfade der Länge 2	14	$\sum_i \binom{k_i}{2}$
Transitivität	**0,429**	$3 \cdot 2/14$

$$\sum_i \binom{k_i}{2} = \binom{5}{2} + 4\binom{2}{2} + 0 = 10 + 4 = 14.$$

Maß	Wert	
Mittelwert der C_i	0,840	
Transitivität	**0,429**	
Verhältnis	1,96	Faktor zwei

Zwei Zahlen für dasselbe Netz, die sich um Faktor zwei unterscheiden. Der Mittelwert wird von den vier Knoten mit Grad zwei bestimmt, die alle den Wert eins haben. Die Transitivität gewichtet nach Grad und wird vom Knoten 1 bestimmt, der schlecht geclustert ist.

Und der Knoten 6 mit Grad eins hat gar keinen Wert. Ob man ihn weglässt oder auf null setzt, ändert den Mittelwert von 0,840 *auf* 0,700. *Solche Entscheidungen werden selten berichtet und verändern das Ergebnis erheblich.*

(b) Granovetters Behauptung.
Die Größe. Die Überlappung einer Kante (i, j):

$$O_{ij} = \frac{|N(i) \cap N(j)|}{|N(i) \cup N(j)| - 2}.$$

Das Netz aus (a).

Kante	gemeinsam	vereinigt-2	O_{ij}
$1-2$	$\{3\}$: 1	4	0,250
$2-3$	$\{1\}$: 1	1	**1,000**
$1-4$	$\{5\}$: 1	4	0,250
$4-5$	$\{1\}$: 1	1	**1,000**
$1-6$	$\varnothing$: 0	4	**0,000**

Der Test auf Brücken.

Kante	O_{ij}	Brücke?
$2-3$	1,000	nein
$4-5$	1,000	nein
$1-2$	0,250	nein
$1-6$	**0,000**	**ja**

Die einzige Brücke ist genau die Kante mit Überlappung null. Das ist Granovetters Aussage in strenger Form: Eine Kante mit Überlappung größer als null liegt auf einem Dreieck und kann deshalb keine Brücke sein.

Die empirische Bestätigung.
An einem Telefonnetz mit Millionen Teilnehmern wurde 2007 gemessen, wie die Gesprächsdauer mit der Überlappung zusammenhängt.

Bindungsstärke	Überlappung	Granovetter?
schwach	niedrig	✓
mittel	mittel	✓
stark	hoch	✓

Und die Probe aufs Exempel: Entfernt man die Kanten in aufsteigender Reihenfolge der Stärke, zerfällt das Netz schlagartig. Entfernt man sie absteigend, bleibt es lange zusammenhängend. Die schwachen Bindungen halten es zusammen.

(c) Motive.
Der Gedanke. Man zählt kleine Teilgraphen und vergleicht mit einem Nullmodell.

Muster	gemessen	Zufall	Z-Wert
Rückkopplung	47	52 ± 8	$-0{,}6$
Vorwärts-kopplung	**209**	85 ± 12	$+\mathbf{10{,}3}$
Dreieckskreis	12	14 ± 4	$-0{,}5$

Nur das zweite Muster ist überzufällig häufig. Es besteht aus $A \to B$, $B \to C$ und $A \to C$: ein direkter Weg und ein Umweg. In Genregelnetzen und in neuronalen Schaltkreisen kommt es sehr oft vor, und es lässt sich als Verzögerungsglied oder als Filter deuten.

Der Z-Wert hängt am Nullmodell

Dieselben Zähldaten liefern völlig andere Bewertungen, je nachdem womit man vergleicht.

Nullmodell	Z	Schluss
Gleiche Kantenzahl	$+31{,}2$	sehr auffällig
Gleiche Gradfolge	$+10{,}3$	auffällig
Gleiche Gradfolge und Dreieckszahl	$+1{,}8$	unauffällig

Die Frage lautet immer: Welche Eigenschaften halte ich für gegeben, und welche will ich erklären? Wer die Gradfolge festhält, fragt nach Struktur jenseits der Gradverteilung. Wer auch die Dreieckszahl festhält, fragt nach noch feineren Mustern.

Es gibt keine richtige Antwort, sondern nur eine, die man begründen und angeben muss. Kapitel 14 behandelt das ausführlich, weil es die häufigste Schwachstelle veröffentlichter Netzwerkanalysen ist.

Granovetters Arbeit[18] ist bemerkenswert gut lesbar; Watts und Strogatz[28] führten den Clusterkoeffizienten in die Netzwerkanalyse ein; Newman[23] behandelt Assortativität und Korrelationen gründlich.

6 Gemeinschaften

Was eine Gemeinschaft sein soll

Der Begriff ist anschaulich und nicht scharf definiert. Es gibt kein Kriterium, das allen Vorstellungen genügt.

Die Grundidee	Innen dichter verbunden als nach außen
Die Schwierigkeit	„Dichter“ verglichen womit?
Die Folge	Dutzende von Verfahren, die verschiedene Antworten geben

Modularität.
NEWMAN und GIRVAN schlugen 2004 ein Maß vor, das den Vergleich mit einem Nullmodell eingebaut hat.

$$Q = \frac{1}{2m} \sum_{i,j} \left(A_{ij} - \frac{k_i k_j}{2m} \right) \delta(c_i, c_j).$$

A_{ij}	Ist da tatsächlich eine Kante?
$\frac{k_i k_j}{2m}$	Wie viele wären bei zufälliger Verdrahtung zu erwarten?
$\delta(c_i, c_j)$	Zählt nur, wenn beide in derselben Gruppe sind

Die Größe misst also nicht, wie viele Kanten innerhalb der Gruppen liegen, sondern wie viele mehr *als erwartet. Damit ist das Nullmodell aus dem Vorwort hier nicht ein nachträglicher Test, sondern Teil der Definition.*

Q	**Deutung**	
≈ 0	keine Struktur	wie zufällig
0,3–0,4	erkennbar	typisch
0,5–0,7	deutlich	
$\to 1$	nicht erreichbar	Obergrenze liegt darunter

Das Louvain-Verfahren

Die Modularität exakt zu maximieren ist NP-schwer (Band 3). Das gebräuchlichste Näherungsverfahren stammt von BLONDEL und Mitautoren, 2008.

1. Jeder Knoten bildet zunächst eine eigene Gemeinschaft.
2. Für jeden Knoten prüfen, ob ein Wechsel zu einem Nachbarn Q erhöht; den besten Wechsel ausführen.
3. Wiederholen, bis kein Wechsel mehr hilft.
4. Jede Gemeinschaft zu einem Knoten zusammenfassen; Kanten werden zu Gewichten.
5. Mit dem kleineren Graphen bei Schritt 1 fortfahren.

Die Schritte 4 und 5 sind der eigentliche Einfall. Der Graph schrumpft in jeder Runde erheblich, meist um mehr als eine Größenordnung, und das Verfahren läuft daher auch auf Netzen mit Millionen Knoten in Minuten.

Verfahren	**Aufwand**	**Güte**	**Praxis**
Vollständig	$\mathcal{O}(\exp)$	optimal	$n < 30$
Girvan-Newman	$\mathcal{O}(nm^2)$	gut	$n < 5000$
Louvain	$\mathcal{O}(n \log n)$	sehr gut	Millionen
Leiden	$\mathcal{O}(n \log n)$	besser	Millionen

Das Leiden-Verfahren behebt einen Fehler von Louvain: Dort können Gemeinschaften entstehen, die intern gar nicht zusammenhängen. Es ist derselbe Ablauf mit einem zusätzlichen Prüfschritt und sollte heute vorgezogen werden.

Die Auflösungsgrenze

FORTUNATO und BARTHÉLEMY zeigten 2007, dass die Modularität eine eingebaute Schwäche hat.

Das Ergebnis	Gemeinschaften mit weniger als etwa $\sqrt{2m}$ Kanten werden nicht gefunden, sondern mit anderen verschmolzen
Der Grund	Der Erwartungswert $\frac{k_i k_j}{2m}$ hängt von der **Gesamtgröße** des Netzes ab

Das ist eine unangenehme Eigenschaft. Ob zwei kleine, klar getrennte Gruppen als eine oder als zwei erkannt werden, hängt davon ab, wie groß der Rest des Netzes ist, mit dem sie nichts zu tun haben.

Kanten im Netz	$\sqrt{2m}$	**kleinste erkennbare Gruppe**
10^3	45	$\approx$ 45 Kanten
10^5	447	$\approx$ 447 Kanten
10^7	4472	$\approx$ 4472 Kanten

In einem Netz mit zehn Millionen Kanten verschwindet eine Gruppe von fünfzig Knoten, so deutlich sie auch abgetrennt sein mag. Die Abhilfe besteht darin, einen Auflösungsparameter einzuführen, der das Nullmodell skaliert, oder mehrere Auflösungsstufen nebeneinander zu betrachten.

Modularität hat auch bei Zufall hohe Werte

Ein Zufallsgraph ohne jede Gemeinschaftsstruktur liefert bei Optimierung erstaunlich hohe Modularitätswerte.

Netz	**bestes** Q	
Echt strukturiert	0,55	
Zufall, gleiche Gradfolge	**0,41**	ohne jede Struktur
Differenz	0,14	**das ist das Ergebnis**

Ein Wert von 0,55 klingt nach deutlicher Struktur und ist es nur, wenn man ihn gegen 0,41 hält. Wer die zweite Zeile nicht berechnet, überschätzt seinen Befund erheblich. Es ist derselbe Punkt wie im Vorwort, hier in seiner folgenreichsten Form.

Der Grund für die hohen Zufallswerte: Bei n Knoten gibt es astronomisch viele Aufteilungen, und unter ihnen findet sich immer eine, die zufällig gut aussieht. Es ist das Problem des mehrfachen Testens in geometrischer Form.

Aufgabe 6.1.

(a) Berechnen Sie die Modularität für zwei Aufteilungen.
(b) Führen Sie eine Runde Louvain von Hand aus.
(c) Untersuchen Sie überlappende Gemeinschaften.

Lösung Schritt für Schritt.

(a) Modularität zweier Aufteilungen.
Das Netz. Zwei Vierecke, verbunden durch eine Kante.
Kanten: $1{-}2$, $1{-}3$, $2{-}3$, $2{-}4$, $3{-}4$ (links), $5{-}6$, $5{-}7$, $6{-}7$, $6{-}8$, $7{-}8$ (rechts), $4{-}5$ (Brücke).

Knoten	1	2	3	4	5	6	7	8
Grad	2	3	3	3	3	3	3	2

$$2m = 22, \qquad m = 11.$$

Aufteilung A: die natürliche. $\{1,2,3,4\}$ und $\{5,6,7,8\}$.

Gruppe	Kanten innen	$\sum k_i$
Links	5	11
Rechts	5	11

Mit der handlichen Form $Q = \sum_c \left[\frac{m_c}{m} - \left(\frac{d_c}{2m}\right)^2\right]$:

$$Q_A = \left[\frac{5}{11} - \left(\frac{11}{22}\right)^2\right] + \left[\frac{5}{11} - \left(\frac{11}{22}\right)^2\right]$$
$$= (0{,}4545 - 0{,}25) \cdot 2 = \mathbf{0{,}4091}.$$

Aufteilung B: alles in einer Gruppe.

$$Q_B = \frac{11}{11} - \left(\frac{22}{22}\right)^2 = 1 - 1 = \mathbf{0}.$$

Aufteilung C: falsch geschnitten. $\{1,2,3\}$, $\{4,5\}$, $\{6,7,8\}$.

Gruppe	m_c	d_c	Beitrag
$\{1,2,3\}$	3	8	$0{,}2727 - 0{,}1322 = 0{,}1405$
$\{4,5\}$	1	6	$0{,}0909 - 0{,}0744 = 0{,}0165$
$\{6,7,8\}$	3	8	0,1405
			0,2975

Aufteilung	Q	
A: natürlich	**0,4091**	beste
C: falsch geschnitten	0,2975	
B: alles zusammen	0,0000	

Das Maß erkennt die richtige Aufteilung. Beachtenswert ist Aufteilung B: Alles in eine Gruppe zu werfen liefert immer genau null, unabhängig vom Netz. Das ist der Nullpunkt der Skala.

(b) Eine Runde Louvain.
Ausgangslage. Jeder Knoten allein, also $Q = -\sum_i (k_i/2m)^2 < 0$.
Knoten 1 betrachten.

Wechsel zu	**Kanten dorthin**	ΔQ	**Wahl**
Gruppe von 2	1	$+0{,}0785$	
Gruppe von 3	1	$+0{,}0785$	**gleichwertig**
bleiben	0	0	

Bei Gleichstand entscheidet die Reihenfolge, in der die Knoten betrachtet werden. Louvain ist deshalb nicht deterministisch: Zwei Läufe auf denselben Daten können verschiedene Aufteilungen liefern.

Der Verlauf.

Schritt	**Bewegung**	**Gruppen**	Q
Start	—	8	$-0{,}134$
1	$1 \to \{2\}$	7	$-0{,}055$
2	$3 \to \{1,2\}$	6	$+0{,}041$
3	$4 \to \{1,2,3\}$	5	$+0{,}136$
4–6	rechte Seite ebenso	2	$+\mathbf{0{,}409}$

Nach der ersten Stufe hat das Verfahren die richtige Aufteilung gefunden. Die zweite Stufe fasst jede Gruppe zu einem Knoten zusammen; der Graph besteht dann aus zwei Knoten mit einer Kante, und kein weiterer Wechsel erhöht Q. Das Verfahren hält an.

Warum die Brückenkante nicht wandert.
Ein Wechsel von Knoten 4 zur rechten Gruppe brächte eine Innenkante und kostete fünf.

Genau darauf beruht das Verfahren: Es prüft lokal, ob ein einzelner Umzug lohnt, und braucht dafür keine Kenntnis des Gesamtnetzes. Deshalb ist es so schnell und deshalb kann es in lokalen Optima steckenbleiben.

(c) Überlappende Gemeinschaften.
Das Problem. Eine Person gehört zu Familie, Beruf und Verein zugleich. Eine Aufteilung in disjunkte Gruppen kann das nicht darstellen.

Cliquenverkettung	Vollständige Teilgraphen der Größe k suchen und benachbarte verketten
Kantengruppen	Nicht Knoten, sondern **Kanten** gruppieren; ein Knoten erbt die Gruppen seiner Kanten
Weiche Zuordnung	Jeder Knoten bekommt Zugehörigkeitsgrade

Die zweite Zeile ist die eleganteste Lösung. Eine Kante gehört fast immer zu genau einem Zusammenhang: Diese Verbindung ist beruflich, jene familiär. Gruppiert man Kanten, ergibt sich die Überlappung der Knoten von selbst.

Verfahren	**Überlappung**	**Aufwand**
Louvain	keine	$\mathcal{O}(n \log n)$
Cliquenverkettung	ja	teuer
Kantengruppen	ja	mittel

Die Wahl hängt am Gegenstand. Bei einer Gebietseinteilung des Gehirns will man meist disjunkte Gruppen, weil ein Areal an einem Ort liegt. Bei einem sozialen Netz wäre das eine Verfälschung.

Newman und Girvan[24] führten die Modularität ein; Blondel und Mitautoren[5] entwarfen Louvain; Fortunato und Barthélemy[16] fanden die Auflösungsgrenze; Fortunatos Übersicht[15] ordnet alle Verfahren; Ahn und Mitautoren[1] gruppieren Kanten statt Knoten.

7 Hierarchie und Ordnung

Zwei verschiedene Bedeutungen

Das Wort „hierarchisch“ wird in der Netzwerkforschung für zwei unvereinbare Dinge benutzt.

	Verschachtelt	**Geschichtet**
Bedeutet	Gruppen in Gruppen	**Rangfolge von Ebenen**
Braucht	keine Richtung	**gerichtete Kanten**
Beispiel	Organisation in Abteilungen	Befehlskette, Nahrungskette
Maß	Modularität auf mehreren Stufen	Ebenenzuordnung

Die Verwechslung ist verbreitet und folgenreich. Ein Netz kann verschachtelt sein, ohne eine Rangordnung zu haben, und umgekehrt. Dieses Kapitel behandelt die zweite Bedeutung; die erste war Gegenstand von Kapitel 6.

Die reine Form.
In einem gerichteten azyklischen Graphen lässt sich jedem Knoten eine Ebene zuweisen, so dass jede Kante genau eine Ebene aufwärts oder mehr überspringt.

Ohne Kreise	Die Ebenen sind eindeutig bestimmbar
Mit Kreisen	Es gibt **keine** widerspruchsfreie Zuordnung

Reale gerichtete Netze enthalten fast immer Kreise. Die Aufgabe lautet dann nicht mehr, die Ebenen zu bestimmen, sondern die Zuordnung zu finden, die am wenigsten Kanten in die falsche Richtung zeigen lässt.

Hierarchie aus widersprüchlichen Daten

Das lehrreichste Beispiel stammt aus der Neuroanatomie.

Die Daten	Für jede Verbindung zwischen zwei Sehrindenarealen ist bekannt, ob sie aufsteigend, absteigend oder seitlich verläuft
Das Kriterium	Ergibt sich aus den Ursprungs- und Zielschichten der Fasern
Die Aufgabe	Eine Ebenenzuordnung finden, die zu möglichst allen Befunden passt

Felleman und Van Essen veröffentlichten 1991 eine solche Zuordnung für den Makaken: zweiunddreißig Areale auf zehn Ebenen. Die Abbildung ist eine der meistreproduzierten der Neurowissenschaft geworden.

Das Problem daran.

Größe	Wert	
Areale	32	
Verbindungen mit Richtungsangabe	≈ 300	
Vorgeschlagene Ebenen	10	
Zuordnungen ohne Widerspruch	$> 10^5$	**nicht eindeutig**

Spätere Untersuchungen zeigten, dass die Daten sehr viele gleich gute Anordnungen zulassen. Die veröffentlichte Abbildung ist also eine unter vielen, und die scheinbare Klarheit der Zeichnung suggeriert eine Bestimmtheit, die in den Daten nicht steckt.

Eine Zeichnung ist eine Behauptung

Wer eine Hierarchie zeichnet, trifft Entscheidungen, die im Bild nicht sichtbar sind.

Welche Zuordnung	Von vielen gleich guten wird eine gezeigt
Welche Ausnahmen	Widersprüchliche Kanten werden weggelassen oder umgedeutet
Welche Abstände	Die senkrechte Lage suggeriert Größenverhältnisse

Die Abhilfe besteht darin, ein Maß für die Güte anzugeben und die Bandbreite der gleich guten Lösungen zu berichten. Statt einer Zeichnung liefert man dann eine Aussage der Form: Diese beiden Areale liegen in 94 Prozent aller optimalen Anordnungen in dieser Reihenfolge.

Maße für Geschichtetheit

Anteil rückwärts	Wie viele Kanten zeigen in der besten Anordnung nach unten
Trophische Ebene	Mittlere Ebene der Vorgänger, plus eins
Trophische Kohärenz	Wie einheitlich die Kanten eine Ebene überspringen
Rückkopplungsbogenmenge	Kleinste Zahl zu entfernender Kanten, um Kreisfreiheit zu erreichen

Die zweite Zeile stammt aus der Ökologie: Ein Räuber steht eine Ebene über dem Mittel seiner Beutetiere. Sie lässt sich als lineares Gleichungssystem lösen und liefert reelle Werte statt ganzer Zahlen, was der Unschärfe der Daten angemessener ist.

Die vierte Zeile ist NP-schwer (Band 3). In der Praxis nimmt man Näherungsverfahren, und die Zahl der zu entfernenden Kanten ist selbst ein Hierarchiemaß: Je weniger, desto klarer geschichtet.

Aufgabe 7.1.

(a) Bestimmen Sie Ebenen in einem azyklischen Netz.
(b) Behandeln Sie ein Netz mit widersprüchlichen Kanten.
(c) Rechnen Sie trophische Ebenen aus.

Lösung Schritt für Schritt.

(a) Ebenen ohne Widerspruch.
Das Netz. $A \to C$, $B \to C$, $C \to E$, $D \to E$, $E \to F$, $A \to D$.
Die längsten Wege von unten.

Knoten	Vorgänger	Ebene
A	—	0
B	—	0
D	A	1
C	A, B	1
E	C, D	2
F	E	3

Die Probe.

Kante	von Ebene	zu Ebene	Sprung
$A \to C$	0	1	$+1$
$B \to C$	0	1	$+1$
$A \to D$	0	1	$+1$
$C \to E$	1	2	$+1$
$D \to E$	1	2	$+1$
$E \to F$	2	3	$+1$

Alle Sprünge sind positiv, die Zuordnung ist widerspruchsfrei. Sie ist zugleich die kompakteste: Man kann keine Ebene einsparen, weil es einen Weg der Länge drei gibt.

(b) Mit widersprüchlichen Kanten.
Das Netz. Wie oben, zusätzlich $F \to B$.

Die Wirkung	F steht über B, und über F steht ein Weg, der bei B beginnt
Der Kreis	$B \to C \to E \to F \to B$
Folge	Keine widerspruchsfreie Ebenenzuordnung möglich

Die Suche nach der besten Anordnung.
Wir probieren aus, welche einzelne Kante man entfernen muss.

Entfernte Kante	**kreisfrei?**	**Bemerkung**
$F \to B$	ja	die Ebenen von (a)
$B \to C$	ja	andere Ebenen
$C \to E$	ja	
$E \to F$	ja	
$A \to C$	nein	Kreis bleibt

Rückkopplungsbogenmenge $= 1$.

Vier verschiedene Kanten leisten dasselbe. Welche man entfernt, ist eine inhaltliche Entscheidung, keine rechnerische: Man wählt die, die am schlechtesten belegt ist, oder die, deren Umdeutung fachlich am plausibelsten ist.

Die ehrliche Darstellung.

Angabe	**Wert**	
Kanten insgesamt	7	
Rückwärts in bester Anordnung	1	
Anteil	**14 %**	**das ist die Aussage**
Gleich gute Anordnungen	4	

Statt einer Zeichnung mit sechs sauberen Pfeilen und einem unterschlagenen sagt diese Darstellung, wie gut die Hierarchie zu den Daten passt und wie eindeutig sie ist. Beides gehört in jede Veröffentlichung.

(c) Trophische Ebenen.
Die Definition. Für einen Knoten mit Eingangsgrad $k_i^{\text{ein}} > 0$:

$$s_i = 1 + \frac{1}{k_i^{\text{ein}}} \sum_{j \to i} s_j,$$

und $s_i = 0$ für Knoten ohne Eingang.
Das Netz aus (a).

Knoten	Vorgänger	Rechnung	s_i
A	—	—	0,00
B	—	—	0,00
D	A	$1 + 0$	1,00
C	A, B	$1 + \frac{0+0}{2}$	1,00
E	C, D	$1 + \frac{1+1}{2}$	2,00
F	E	$1 + 2$	3,00

Ein Fall, in dem gebrochene Werte entstehen.
Zusätzliche Kante $A \to E$. Dann hat E drei Vorgänger:

$$s_E = 1 + \frac{s_C + s_D + s_A}{3} = 1 + \frac{1 + 1 + 0}{3} = 1{,}667.$$

$$s_F = 1 + 1{,}667 = 2{,}667.$$

Knoten	ohne $A \to E$	mit	Änderung
E	2,000	1,667	$-0{,}333$
F	3,000	2,667	$-0{,}333$

Eine Abkürzung von unten senkt die Ebene. Das ist genau richtig: Wenn E auch unmittelbar von A gespeist wird, steht es weniger klar über A als vorher. Ganzzahlige Ebenen könnten das nicht ausdrücken.

Die trophische Kohärenz.
Man misst, wie einheitlich die Kanten eine Ebene überspringen:

$$q = \sqrt{\frac{1}{m} \sum_{i \to j} (s_j - s_i - 1)^2}.$$

q	Deutung	Beispiel
0	vollkommen geschichtet	jede Kante genau eine Ebene
0,2	sehr kohärent	manche Nahrungsnetze
0,6	mittel	Genregelnetze
> 1	keine Schichtung	

Bemerkenswert ist ein Befund von 2014: Die trophische Kohärenz sagt die Stabilität eines Netzes gegen Störungen besser voraus als die Größe oder die Dichte. Netze mit klarer Schichtung sind stabiler, und das gilt für Nahrungsnetze wie für Genregelnetze.

Felleman und Van Essen[12] lieferten das klassische Beispiel; Stephan und Mitautoren[27] zeigten, wie man mit widersprüchlichen Angaben umgeht; Newman[23] behandelt gerichtete Netze und ihre Ordnungen.

Part III

Modelle

8 Zufallsgraphen

Wozu ein Modell des Zufalls

Ein Zufallsgraph ist nicht als Beschreibung der Wirklichkeit gedacht, sondern als Vergleichsmaßstab.

Die Frage	Welchen Wert hätte diese Kennzahl, wenn es die vermutete Struktur nicht gäbe?
Die Antwort	Man erzeugt viele Netze ohne diese Struktur und misst

Definition 8.1. Im Modell $G(n, p)$ von ERDŐS und RÉNYI wird zwischen je zwei der n Knoten unabhängig mit Wahrscheinlichkeit p eine Kante gezogen.

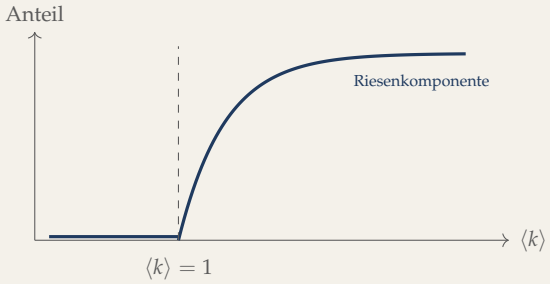
Größe	**Wert**	
Erwartete Kanten	$\binom{n}{2}p$	
Mittlerer Grad	$\langle k \rangle = (n-1)p$	
Gradverteilung	**binomial**, für große n Poisson	
Clusterkoeffizient	$C = p = \langle k \rangle / n$	sehr klein
Mittlere Weglänge	$\approx \log n / \log \langle k \rangle$	klein

Die letzten beiden Zeilen sind der Grund, warum dieses Modell als Vergleichsmaßstab so lehrreich ist: Es hat kurze Wege wie reale Netze und fast kein Clustering, während reale Netze beides haben. Genau diese Lücke füllt Kapitel 9.

Der Umschlagpunkt

Erdős und Rényi entdeckten 1959 etwas Unerwartetes: Zufallsgraphen ändern ihr Verhalten sprunghaft.

$\langle k \rangle$	**Struktur**	**Größte Komponente**
< 1	viele kleine Bäume	$\mathcal{O}(\log n)$
$= \mathbf{1}$	**kritisch**	$\mathcal{O}(n^{2/3})$
> 1	**eine Riesenkomponente**	$\Theta(n)$
$> \ln n$	alles verbunden	n



Bei mittlerem Grad unter eins gibt es nur Bruchstücke. Bei mittlerem Grad über eins entsteht schlagartig eine Komponente, die einen festen Anteil aller Knoten umfasst. Der Übergang ist scharf und wird mit wachsendem n schärfer.

Warum genau bei eins.
Man verfolge, wie viele neue Knoten man von einem beliebigen aus erreicht.

Schale	**Erwartete Größe**
1	$\langle k \rangle$
2	$\langle k \rangle^2$
ℓ	$\langle k \rangle^\ell$

$\langle k \rangle < 1$: stirbt aus. $\langle k \rangle > 1$: wächst exponentiell.

Es ist derselbe Ansatz wie bei einem Verzweigungsprozess: Bekommt jeder im Mittel weniger als einen Nachkommen, stirbt die Linie aus. Genau diese Rechnung taucht in Kapitel 11 bei Epidemien wieder auf.

$\langle k \rangle$	**Anteil in der Riesenkom-ponente**	
0,8	0	
1,0	0	Übergang
1,5	0,583	
2,0	0,797	
3,0	0,941	
5,0	0,993	

Das Konfigurationsmodell

Für die meisten Zwecke ist $G(n, p)$ als Nullmodell zu grob, weil es die gemessene Gradverteilung nicht erhält.

1. Jeder Knoten erhält so viele Kantenstümpfe, wie sein gemessener Grad angibt.
2. Alle Stümpfe werden zufällig paarweise verbunden.
3. Ergebnis: ein zufälliges Netz mit **genau derselben** Gradfolge.

Nullmodell	hält fest	fragt nach
$G(n, p)$	n, m	jeder Struktur
Konfiguration	n, **Gradfolge**	Struktur **jenseits** der Grade
Kanten-vertauschung	Gradfolge, einfach	dasselbe, praktisch
Mit Dreiecken	Gradfolge und Clustering	noch feinere Muster

Das Konfigurationsmodell ist der Standard geworden, weil die Gradverteilung fast alle anderen Kennzahlen mitbestimmt. Wer sie nicht festhält, misst am Ende nur, dass das Netz eine ungleiche Gradverteilung hat, und das wusste man vorher.

Die praktische Umsetzung

Das Verfahren erzeugt Mehrfachkanten und Schlingen. Wirft man sie weg, verändert man die Gradfolge.

Zulassen	Gradfolge stimmt genau, Netz ist kein einfacher Graph
Wegwerfen	Einfacher Graph, Gradfolge **leicht verfälscht**
Neu ziehen	Bei schweren Gradschwänzen kaum erfolgreich
Kanten-vertauschung	Zwei Kanten über Kreuz tauschen; Grade bleiben exakt

Die letzte Zeile ist in der Praxis die beste Lösung. Man beginnt mit dem gemessenen Netz und vertauscht sehr oft je zwei Kantenpaare über Kreuz. Die Grade bleiben unverändert, und nach genügend vielen Schritten ist die übrige Struktur zerstört.

Wie viele Schritte genügen? Als Faustregel etwa das Hundertfache der Kantenzahl. Man prüft es, indem man die interessierende Kennzahl im Verlauf mitmisst und wartet, bis sie sich nicht mehr systematisch ändert.

Aufgabe 8.1.

(a) Berechnen Sie die Kenngrößen eines Zufallsgraphen.
(b) Bestimmen Sie die Größe der Riesenkomponente.
(c) Erzeugen Sie ein Nullmodell durch Kantenvertauschung.

Lösung Schritt für Schritt.

(a) Kenngrößen.
Die Angaben. $n = 10\,000$, $p = 0{,}0006$.

Größe	Wert	Rechnung
Erwartete Kanten	29 997	$\binom{10^4}{2} \cdot 0{,}0006$
Mittlerer Grad	5,999	$(n-1)p$
Clusterkoeffizient	0,0006	$= p$
Mittlere Weglänge	5,14	$\log n / \log\langle k\rangle$

Die Gradverteilung.

$$P(k) = \binom{n-1}{k} p^k (1-p)^{n-1-k} \approx \frac{\langle k\rangle^k e^{-\langle k\rangle}}{k!}.$$

k	$P(k)$	erwartet	Bemerkung
0	0,0025	25	isoliert
3	0,0892	892	
6	**0,1606**	1606	**häufigster**
12	0,0113	113	
18	$9 \cdot 10^{-5}$	0,9	
25	$2 \cdot 10^{-9}$	**0,00002**	praktisch nie

Die letzte Zeile ist der entscheidende Unterschied zu realen Netzen. Bei mittlerem Grad sechs kommt ein Knoten mit Grad fünfundzwanzig in einem Zufallsgraphen praktisch nicht vor. In realen Netzen gibt es Knoten mit tausendfachem mittleren Grad.

(b) Die Riesenkomponente.

Die Gleichung. Sei u die Wahrscheinlichkeit, dass ein Knoten *nicht* zur Riesenkomponente gehört:

$$u = e^{-\langle k \rangle (1-u)}.$$

Der Anteil in der Riesenkomponente ist dann $S = 1 - u$.
Für $\langle k \rangle = 2$, durch Iteration.

Runde	u	$e^{-2(1-u)}$	S
0	0,5000	0,3679	
1	0,3679	0,2780	
2	0,2780	0,2352	
5	0,2050	0,2035	
10	0,2032	0,2032	**0,7968**

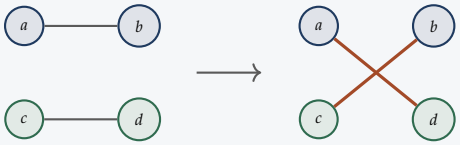
Etwa achtzig Prozent aller Knoten gehören zur Riesenkomponente, zwanzig Prozent nicht. Und diese zwanzig Prozent sind es, die bei der stillschweigenden Beschränkung auf die Riesenkomponente aus Kapitel 2 verschwinden.

Die Probe an der Schwelle.

$\langle k \rangle$	u	S	
0,90	1,000	0,000	
1,00	1,000	0,000	**Schwelle**
1,05	0,906	0,094	steiler Anstieg
1,20	0,686	0,314	
2,00	0,203	0,797	

Von 1,00 *auf* 1,05 *springt der Anteil von null auf zehn Prozent. Fünf Prozent mehr Kanten machen aus einem zerfallenen Netz eines mit einer nennenswerten Riesenkomponente. Solche Übergänge sind der Grund, warum Physiker sich für Netzwerke interessieren.*

(c) Nullmodell durch Kantenvertauschung.
Der Schritt. Wähle zufällig zwei Kanten (a, b) und (c, d) und ersetze sie durch (a, d) und (c, b).



Knoten	Grad vorher	Grad nachher	Änderung
a	k_a	k_a	keine
b	k_b	k_b	keine
c	k_c	k_c	keine
d	k_d	k_d	keine

Die Bedingungen für einen gültigen Tausch.

Keine Schlinge	$a \neq d$ und $c \neq b$
Keine Doppelkante	(a, d) und (c, b) dürfen nicht schon vorhanden sein
Sonst	Tausch verwerfen und neu würfeln

Wie der Clusterkoeffizient dabei abnimmt.

Tausche	C	Modularität	
0 (Original)	0,310	0,552	
$1 \times m$	0,142	0,461	
$10 \times m$	0,038	0,418	
$100 \times m$	**0,029**	**0,412**	stabil
$1000 \times m$	0,029	0,411	

Ab etwa dem Hundertfachen der Kantenzahl ändert sich nichts mehr. Die verbleibenden Werte sind die Erwartungswerte des Nullmodells, und genau gegen sie muss man die gemessenen halten.

Kennzahl	gemessen	Nullmodell	Faktor
Clustering	0,310	0,029	**10,7**
Modularität	0,552	0,412	1,34

Zwei Kennzahlen desselben Netzes, und nur die erste ist deutlich erhöht. Ohne diese Rechnung hätte man beide Werte für hoch gehalten und wäre bei der Modularität einem Artefakt aufgesessen.

Erdős und Rényi[11] begründeten die Theorie; Molloy und Reed[22] entwickelten das Konfigurationsmodell; Newman[23] rechnet die Riesenkomponente und die Nullmodelle vollständig durch.

9 Kleine Welten und schwere Enden

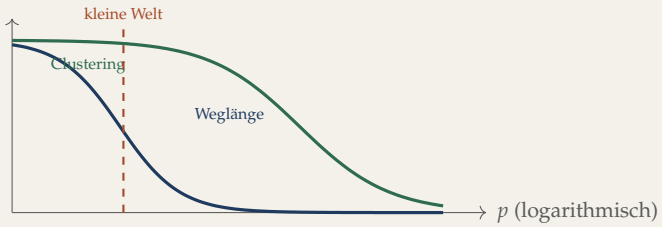
Zwei Eigenschaften, die sich zu widersprechen scheinen

Reale Netze haben beides zugleich, und keines der bis 1998 bekannten Modelle konnte das.

	Weglänge	Clustering
Gitter	lang	hoch
Zufallsgraph	kurz	fast null
Reale Netze	**kurz**	**hoch**

Der Einfall von Watts und Strogatz.
Man beginnt mit einem Ring, in dem jeder Knoten seine nächsten Nachbarn kennt, und verlegt einen kleinen Anteil der Kanten zufällig.

p	Weglänge	Clustering	
0	1,00	1,00	Gitter
0,001	0,72	0,99	
0,01	**0,35**	**0,96**	**kleine Welt**
0,1	0,13	0,73	
1	0,08	0,01	zufällig



Die beiden Kurven fallen bei sehr verschiedenen Werten von p ab, und dazwischen liegt ein breiter Bereich mit kurzen Wegen und hohem Clustering. Der Grund: Eine einzige Abkürzung verkürzt sehr viele Wege, zerstört aber nur ein einziges Dreieck.

Das ist die Erklärung für Milgrams Befund von 1967, dass Briefe über wenige Zwischenstationen ihr Ziel erreichten. Man braucht keine große Zahl von Fernverbindungen, sondern nur ein paar.

Bevorzugte Anbindung

Das Modell von Watts und Strogatz erklärt kurze Wege bei hohem Clustering. Es erklärt nicht die Knoten mit sehr hohem Grad.

1. Das Netz wächst: In jedem Schritt kommt ein Knoten hinzu.
2. Der neue Knoten verbindet sich mit c vorhandenen.
3. Die Wahl fällt **proportional zum Grad**.

Beide Zutaten sind nötig. Ein wachsendes Netz mit zufälliger Anbindung liefert einen exponentiellen Gradschwanz; eine bevorzugte Anbindung ohne Wachstum ebenfalls nicht. Erst zusammen entsteht das Potenzgesetz $P(k) \sim k^{-3}$.

Warum das Wachstum zählt.
Frühe Knoten haben mehr Zeit, Kanten zu sammeln, und sammeln wegen der Bevorzugung immer schneller.

Ankunft bei t_i	**Grad bei t**	
$t_i = 1$	$c\sqrt{t}$	**der Erste gewinnt**
$t_i = t/4$	$2c$	
$t_i = t$	c	gerade angekommen

Man nennt das den Vorteil des ersten Zuges. Er erklärt, warum in vielen Märkten und Netzen der frühe Anbieter dauerhaft vorne bleibt, ohne besser zu sein.

Zusatz	Wirkung	
Anpassungs-fähigkeit	späte Knoten können aufholen	realistischer
Altern	alte Knoten werden unattraktiv	Zitationen
Kosten je Kante	begrenzt den Höchstgrad	Infrastruktur
Löschen	**Exponent ändert sich**	

Die Skalenfreiheitsdebatte

Zwanzig Jahre lang galt als gesichert, dass die meisten realen Netze einem Potenzgesetz folgen. Seit 2019 ist das umstritten.

Der Vorwurf	Die frühen Befunde beruhten auf Geraden in doppelt logarithmischen Auftragungen, was kein statistischer Test ist
Die Untersuchung	Broido und Clauset prüften fast tausend Netze mit strengen Verfahren
Das Ergebnis	Nur ein kleiner Teil trägt die Behauptung; oft passen andere Verteilungen ebenso gut oder besser

Einstufung	Anteil
Nicht skalenfrei	$\approx 1/3$
Schwach vereinbar	$\approx 1/3$
Stark vereinbar	$\approx 1/10$
Eindeutig skalenfrei	$\approx$ **4** %

Die Gegenseite hält dagegen, das Kriterium sei zu streng und schließe Netze aus, die in jeder praktischen Hinsicht einen schweren Schwanz haben. Beide Seiten haben Punkte, und die Debatte ist nicht entschieden.

Was praktisch daran hängt

Für die meisten Anwendungen ist der Streit weniger folgenreich, als er klingt.

Wichtig ist	Dass die Gradverteilung einen schweren Schwanz hat und die Varianz groß ist
Weniger wichtig	Ob der Schwanz genau einem Potenzgesetz folgt

Aussage	**braucht**	
Robust gegen Zufall	schwerer Schwanz	unstrittig
Verwundbar gegen Angriff	schwerer Schwanz	unstrittig
Keine Epidemieschwelle	$\gamma \leq 3$ **genau**	strittig

Nur die dritte Zeile hängt am genauen Exponenten. Die Behauptung, in skalenfreien Netzen gebe es keine Schwelle für die Ausbreitung, gilt asymptotisch und für einen bestimmten Bereich des Exponenten. In endlichen Netzen gibt es immer eine Schwelle, sie kann nur sehr klein sein.

Die Lehre aus der Debatte ist methodisch: Eine Gerade im doppelt logarithmischen Bild ist kein Beweis. Man braucht eine Schätzung des Exponenten mit Maximum-Likelihood, einen Anpassungstest und einen Vergleich mit alternativen Verteilungen.

Aufgabe 9.1.

(a) Rechnen Sie die Wirkung weniger Abkürzungen aus.
(b) Leiten Sie den Exponenten des Modells der bevorzugten Anbindung her.
(c) Prüfen Sie eine Gradverteilung auf ein Potenzgesetz.

Lösung Schritt für Schritt.

(a) Die Wirkung von Abkürzungen.
Das Ausgangsnetz. Ein Ring aus $n = 1000$ Knoten, jeder mit den vier nächsten Nachbarn verbunden.

Größe	Wert	Rechnung
Kanten	2000	$nc/2$ mit $c = 4$
Mittlere Weglänge	≈ 125	$\approx n/(2c)$
Clusterkoeffizient	0,500	Gitter

Nach dem Verlegen von pm Kanten.

p	Abkürzungen	Weglänge	Clustering
0	0	125,0	0,500
0,001	2	≈ 90	0,499
0,005	10	≈ 40	0,496
0,01	**20**	$\approx$ **25**	**0,493**
0,1	200	≈ 8	0,365
1	2000	≈ 5	0,004

Zwanzig verlegte Kanten von zweitausend, also ein Prozent, verkürzen die Wege um Faktor fünf und senken das Clustering um weniger als anderthalb Prozent. Das ist die ganze Aussage des Modells in einer Zeile.

Warum die Wirkungen so ungleich sind.

Eine Abkürzung	verkürzt die Wege zwischen **sehr vielen** Knotenpaaren, nämlich allen, deren Weg jetzt darüber führt
Dieselbe Abkürzung	zerstört genau die Dreiecke an ihrem ursprünglichen Ort, also eine feste kleine Zahl

Die Wirkung auf die Weglänge ist global und wächst mit der Netzgröße; die Wirkung auf das Clustering ist lokal und bleibt konstant. Deshalb klafft der Bereich der kleinen Welt bei großen Netzen immer weiter auseinander.

(b) Der Exponent des Wachstumsmodells.
Der Ansatz. Ein Knoten i gewinnt Kanten mit einer Rate proportional zu seinem Grad:

$$\frac{\partial k_i}{\partial t} = c \cdot \frac{k_i}{\sum_j k_j} = c \cdot \frac{k_i}{2ct} = \frac{k_i}{2t}.$$

Die Lösung.

$$\frac{dk_i}{k_i} = \frac{dt}{2t} \quad \Longrightarrow \quad \ln k_i = \tfrac{1}{2} \ln t + \text{const}$$

$$k_i(t) = c \left(\frac{t}{t_i} \right)^{1/2}.$$

Von der Wachstumskurve zur Verteilung.
Wir fragen, wie viele Knoten einen Grad kleiner als k haben:

$$k_i(t) < k \quad \Longleftrightarrow \quad t_i > \frac{c^2 t}{k^2}.$$

Da die Ankunftszeiten gleichverteilt sind:

$$P(k_i < k) = 1 - \frac{c^2}{k^2}.$$

Ableiten liefert die Dichte.

$$P(k) = \frac{d}{dk} \left(1 - \frac{c^2}{k^2} \right) = \frac{2c^2}{k^3} \sim k^{-3}.$$

Der Exponent ist $\gamma = 3$, unabhängig von c und von der Netzgröße.

Was das bedeutet.

γ	**Mittelwert**	**Varianz**
≤ 2	divergiert	divergiert
$2 < \gamma \leq 3$	endlich	**divergiert**
> 3	endlich	endlich

Der Fall $\gamma = 3$ liegt genau an der Grenze. Für kleinere Exponenten ist die Varianz unendlich, und dann versagen alle Aussagen, die mit dem mittleren Grad rechnen. Das ist der mathematische Kern der Aussage, dass es in solchen Netzen keine Epidemieschwelle gibt.

(c) Eine Gradverteilung prüfen.
Die Daten. Ein Netz mit $n = 5000$ Knoten.

k	**Anzahl**	$P(k)$	log-log
1	2010	0,402	
2	1005	0,201	
5	161	0,032	
10	40	0,008	
50	2	0,0004	
200	1	0,0002	Einzelfall

Das übliche, falsche Vorgehen.
Man trägt doppelt logarithmisch auf, legt eine Gerade durch und liest die Steigung ab.

Fehler 1	Die Punkte im Schwanz beruhen auf ein oder zwei Beobachtungen und wiegen genauso schwer wie die vorderen
Fehler 2	Die Fehlerbalken sind nicht gleichmäßig; die Voraussetzungen der Ausgleichsrechnung sind verletzt
Fehler 3	Es wird keine Alternative geprüft

Das richtige Vorgehen.

1. Eine untere Schranke $k_{\min}$ bestimmen, ab der das Gesetz gelten soll.
2. Den Exponenten mit Maximum-Likelihood schätzen.
3. Mit einem Anpassungstest prüfen, ob die Abweichung erklärbar ist.
4. **Alternative Verteilungen vergleichen**, vor allem die Lognormalverteilung.

$$\hat{\gamma} = 1 + n \left[\sum_i \ln \frac{k_i}{k_{\min} - \frac{1}{2}} \right]^{-1}.$$

Verteilung	Güte	Schluss
Potenzgesetz	$p = 0{,}31$	nicht verworfen
Lognormal	$p = 0{,}52$	passt besser
Exponentiell	$p = 0{,}002$	verworfen

Das Ergebnis ist typisch: Das Potenzgesetz lässt sich nicht verwerfen, und eine andere Verteilung passt ebenso gut. Damit ist die Behauptung „dieses Netz ist skalenfrei“ nicht belegt, sondern nur nicht widerlegt. Das ist ein erheblicher Unterschied.

Die Lognormalverteilung entsteht schon durch ein einfaches multiplikatives Wachstum ohne jede Bevorzugung. Wenn sie ebenso gut passt, ist der Schluss auf bevorzugte Anbindung nicht gerechtfertigt.

Watts und Strogatz[28] führten das Kleine-Welt-Modell ein; Barabási und Albert[4] das Wachstumsmodell; Milgram[21] lieferte den empirischen Anlass; Broido und Clauset[6] lösten die Debatte über die Skalenfreiheit aus.

10 Spektrale Graphentheorie

Die Laplace-Matrix

Die Adjazenzmatrix beschreibt das Netz. Die Laplace-Matrix beschreibt, was auf ihm fließt.

Definition 10.1.

$$L = D - A,$$

wobei D die Diagonalmatrix der Grade ist.

L_{ii}	Der Grad des Knotens i
L_{ij}	-1, wenn eine Kante besteht, sonst 0
Zeilensumme	**immer null**

Aus der letzten Zeile folgt sofort, dass der Vektor aus lauter Einsen ein Eigenvektor zum Eigenwert null ist. Die Matrix ist außerdem symmetrisch und positiv semidefinit, also sind alle Eigenwerte reell und nichtnegativ.

Warum die Matrix so heißt.
Für einen Vektor x, der jedem Knoten einen Wert zuordnet, gilt

$$x^T L x = \sum_{(i,j)\in E} (x_i - x_j)^2.$$

Das ist ein Maß für die Rauheit: Es misst, wie stark sich die Werte über Kanten hinweg unterscheiden. Ein Vektor mit kleinem Wert ist über das Netz hinweg glatt. Genau das leistet der Laplace-Operator in der Analysis, und daher der Name.

Eigenwert	Bedeutung	
$\lambda_1 = 0$	immer	Eigenvektor: konstant
Vielfachheit von 0	**Zahl der Komponenten**	
λ_2	**algebraische Zusammen-hangszahl**	Fiedler, 1973
λ_n	größter Eigenwert	$\leq 2 \max_i k_i$

Die zweite Zeile ist bemerkenswert: Man erfährt die Zahl der Zusammenhangskomponenten, ohne den Graphen zu durchlaufen, allein aus dem Spektrum.

Der Fiedler-Vektor

Der Eigenvektor zum zweitkleinsten Eigenwert löst ein Problem, das man ihm nicht ansieht.

Die Aufgabe	Das Netz in zwei etwa gleich große Teile zerlegen, mit möglichst wenigen durchtrennten Kanten
Der Haken	Diese Aufgabe ist NP-schwer (Band 3)
Der Ausweg	Statt Werte aus $\{-1, +1\}$ erlaubt man reelle Werte

Die entspannte Aufgabe lässt sich exakt lösen: Ihr Optimum ist genau der Fiedler-Vektor. Danach schneidet man beim Vorzeichen oder beim Median ab und erhält eine Aufteilung, die meist nahe am Optimum liegt.

1. Die Laplace-Matrix aufstellen.
2. Den Eigenvektor zum zweitkleinsten Eigenwert berechnen.
3. Die Knoten nach seinem Wert sortieren.
4. An der Stelle trennen, die das beste Schnittverhältnis liefert.

λ_2	**Bedeutung**	
0	nicht zusammenhängend	
klein	**leicht zu trennen**	Flaschenhals vorhanden
groß	fest verbunden	Expander

Die algebraische Zusammenhangszahl ist damit ein Maß dafür, wie schwer ein Netz zu zerschneiden ist. Sie hängt eng mit der Mischgeschwindigkeit von Zufallsspaziergängen zusammen und damit mit fast allem, was sich auf einem Netz ausbreitet.

Wozu das Spektrum sonst gut ist

Zerlegung	Fiedler-Vektor; mehrere Eigenvektoren für mehr als zwei Teile
Einbettung	Die ersten d Eigenvektoren als Koordinaten; Knoten werden Punkte
Zeichnen	Zwei Eigenvektoren als x und y; erzeugt brauchbare Bilder
Ausbreitung	$\lambda_{\max}$ der Adjazenzmatrix bestimmt die Epidemieschwelle
Ähnlichkeit	Netze mit ähnlichem Spektrum sind strukturell ähnlich

Die zweite Zeile ist der Vorläufer der heutigen Knoteneinbettungen. Lange bevor gelernte Verfahren aufkamen, ordnete die Spektralzerlegung jedem Knoten einen Vektor zu, so dass verbundene Knoten nah beieinander liegen.

Das Spektrum bestimmt den Graphen nicht

Es gibt verschiedene Graphen mit demselben Spektrum. Man nennt sie isospektral.

Knotenzahl	**Anteil isospektraler Paare**	
≤ 5	0 %	eindeutig
8	$\approx 14\,\%$	
10	$\approx 6\,\%$	
groß	vermutlich $\to 0$	unbewiesen

Die berühmte Frage „Kann man die Form einer Trommel hören?“ hat auf Graphen dieselbe Antwort wie in der Analysis: nein, nicht immer. Zwei verschiedene Netze können dieselben Schwingungen haben.

Praktisch bedeutet das: Ein Vergleich von Spektren ist ein starkes Ähnlichkeitsmaß und kein Beweis für Gleichheit. Für den Nachweis, dass zwei Netze identisch sind, braucht man den Isomorphietest, und dessen Komplexität ist bis heute nicht vollständig geklärt.

Aufgabe 10.1.

(a) Berechnen Sie das Spektrum eines kleinen Graphen.
(b) Zerlegen Sie ein Netz mit dem Fiedler-Vektor.
(c) Untersuchen Sie den Zusammenhang mit Zufallsspaziergängen.

Lösung Schritt für Schritt.

(a) Das Spektrum.
Der Graph. Ein Pfad aus vier Knoten: $1-2-3-4$.

$$L = \begin{pmatrix} 1 & -1 & 0 & 0 \\ -1 & 2 & -1 & 0 \\ 0 & -1 & 2 & -1 \\ 0 & 0 & -1 & 1 \end{pmatrix}$$

Die Eigenwerte. Für einen Pfad mit n Knoten gilt

$$\lambda_j = 2 - 2\cos\left(\frac{\pi j}{n}\right), \qquad j = 0, \ldots, n-1.$$

j	$\cos(\pi j/4)$	λ_j	**Bedeutung**
0	1,000	0,000	**zusammenhängend**
1	0,707	**0,586**	**Fiedler**
2	0,000	2,000	
3	−0,707	3,414	

Genau ein Eigenwert null: Der Graph hat eine Komponente. Die Spur ist $0 + 0{,}586 + 2 + 3{,}414 = 6 = \sum_i k_i = 2m$, wie es sein muss. ✓

Der Vergleich mit anderen Graphen auf vier Knoten.

Graph	**Eigenwerte**	λ_2	**Deutung**
Pfad	0; 0,59; 2; 3,41	0,586	leicht trennbar
Kreis	0; 2; 2; 4	2,000	fester
Stern	0; 1; 1; 4	1,000	
Vollständig	0; 4; 4; 4	**4,000**	am festesten
Zwei Kanten	0; 0; 2; 2	**0**	zwei Komponenten

Die Reihenfolge der λ_2-Werte entspricht genau der Anschauung, wie schwer sich die Graphen zerschneiden lassen. Der Pfad hat den kleinsten Wert, weil eine einzige Kante ihn halbiert; der vollständige Graph den größten.

(b) Zerlegung mit dem Fiedler-Vektor.

Das Netz. Zwei Dreiecke, verbunden durch eine Kante: $1{-}2$, $1{-}3$, $2{-}3$, $3{-}4$, $4{-}5$, $4{-}6$, $5{-}6$.
Der Fiedler-Vektor (gerundet).

Knoten	1	2	3	4	5	6
v_2	0,46	0,46	0,24	$-0{,}24$	$-0{,}46$	$-0{,}46$

Die Trennung am Vorzeichen.

Seite	**Knoten**	**durchtrennte Kanten**
Positiv	$\{1,2,3\}$	
Negativ	$\{4,5,6\}$	
		1 (nämlich $3{-}4$)

Das Verfahren findet die einzig sinnvolle Trennung, ohne dass ihm jemand gesagt hätte, wonach es suchen soll. Bemerkenswert ist auch die Reihenfolge der Werte: Die Knoten 3 und 4 haben die kleinsten Beträge und liegen damit am Rand ihrer Gruppe, was der Anschauung entspricht.

Der Vergleich mit anderen Verfahren.

Verfahren	**Schnitt**	**Aufwand**	**exakt?**
Vollständige Suche	1	$\mathcal{O}(2^n)$	ja
Spektral	**1**	$\mathcal{O}(m)$ je Iteration	nein
Louvain	1	$\mathcal{O}(n \log n)$	nein

Hier stimmen alle überein. Bei größeren Netzen weichen sie ab, und keines der schnellen Verfahren hat eine Garantie. Die spektrale Zerlegung hat immerhin eine Schranke: Der gefundene Schnitt ist höchstens quadratisch schlechter als der optimale, was der Satz von Cheeger sagt.

(c) Zufallsspaziergänge.
Der Zusammenhang. Die Übergangsmatrix eines Zufallsspaziergangs ist

$$P = D^{-1}A = I - D^{-1}L.$$

Stationäre Verteilung	$\pi_i = k_i / 2m$: proportional zum Grad
Misch-geschwindigkeit	Bestimmt vom zweitgrößten Betrag der Eigenwerte von P
Zusammenhang	Großes λ_2 des Laplace heißt schnelles Mischen

Die erste Zeile ist das Freundschaftsparadox aus Kapitel 1 in anderer Form: Ein Zufallsspaziergang hält sich bevorzugt bei Knoten hohen Grades auf, und zwar genau proportional zum Grad.

Die Mischzeit an Beispielen.

Netz	λ_2	**Mischzeit**	
Vollständig	n	$\mathcal{O}(1)$	sofort
Expander	$\Theta(1)$	$\mathcal{O}(\log n)$	schnell
Zufallsgraph	groß	$\mathcal{O}(\log n)$	schnell
Ring	$\mathcal{O}(1/n^2)$	$\mathcal{O}(n^2)$	sehr langsam
Hantelform	sehr klein	exponentiell	

Die letzte Zeile beschreibt zwei dichte Klumpen mit einer dünnen Verbindung. Ein Zufallsspaziergang bleibt sehr lange in einem Klumpen, bevor er die Brücke findet. Genau das macht solche Netze für Verfahren, die auf Zufallsspaziergängen beruhen, schwierig.

Und es ist zugleich der Grund, warum solche Verfahren Gemeinschaften finden können: Wo ein Spaziergang hängenbleibt, ist eine Gemeinschaft. Mehrere Verfahren zur Gemeinschaftserkennung beruhen unmittelbar darauf.

Fiedler[13] führte die algebraische Zusammenhangszahl ein; Chung[8] ist die maßgebliche Darstellung der spektralen Graphentheorie; Newman[23] behandelt die Anwendungen in der Netzwerkanalyse.

Part IV

Anwendung

11 Prozesse auf Netzen

Ausbreitung

Das Standardmodell teilt die Knoten in Zustände ein und beschreibt die Übergänge.

Modell	Zustände	Beispiel
SI	anfällig, infiziert	unumkehrbare Verbreitung
SIR	+ genesen	Masern
SIS	Rückkehr möglich	Erkältung, Gerüchte
Schwellenwert	braucht k infizierte Nachbarn	**Verhaltensänderung**

Die letzte Zeile ist grundsätzlich anders. Bei Krankheiten genügt ein Kontakt; bei einer Verhaltensänderung braucht man meist mehrere unabhängige Anstöße. Solche Prozesse breiten sich nicht *über Fernverbindungen aus, sondern nur über dichte Nachbarschaften.*

	einfache Ansteckung	**komplexe Ansteckung**
Braucht	einen Kontakt	**mehrere**
Nutzt	Abkürzungen	dichte Klumpen
Kleine Welt hilft	sehr	kaum
Beispiel	Virus	Streik, Mode

Granovetters schwache Bindungen aus Kapitel 5 tragen also Information, aber nicht unbedingt Verhalten. Ein Gerücht läuft über sie; eine Verhaltensänderung braucht die starken Bindungen, die sich gegenseitig verstärken.

Die Epidemieschwelle

Für das SIR-Modell auf einem Netz mit Ansteckungswahrscheinlichkeit β und Genesungsrate μ gilt näherungsweise

$$\frac{\beta}{\mu} > \frac{\langle k \rangle}{\langle k^2 \rangle - \langle k \rangle}.$$

Die rechte Seite ist die Schwelle. Sie hängt nicht nur vom mittleren Grad ab, sondern vom Verhältnis zum zweiten Moment, und das ist der Punkt: Bei einer breiten Gradverteilung wird $\langle k^2 \rangle$ sehr groß und die Schwelle sehr klein.

Netz	$\langle k \rangle$	$\langle k^2 \rangle$	**Schwelle**
Regelmäßig	6	36	0,200
Zufällig	6	42	0,167
Schwerer Schwanz	6	500	**0,012**
$\gamma \leq 3, n \to \infty$	6	$\to \infty$	$\to 0$

Die letzte Zeile ist die berühmte Aussage, dass es in skalenfreien Netzen keine Epidemieschwelle gibt. Sie gilt asymptotisch. In einem endlichen Netz ist $\langle k^2 \rangle$ endlich, und damit gibt es immer eine Schwelle, sie kann nur sehr klein sein.

Die Formel unterstellt Unabhängigkeit

Sie geht davon aus, dass die Nachbarn eines Knotens zufällig gewählt sind und selbst kaum verbunden sind.

Bei Clustering	Nachbarn stecken sich gegenseitig an; die Ausbreitung **verlangsamt** sich
Bei Gemeinschaften	Der Ausbruch bleibt lange lokal, bevor er überspringt
Bei Assortativität	Hochgradige stecken hochgradige an; schnellerer Beginn, kleinerer Endstand

In realen Netzen sind alle drei Eigenschaften vorhanden, und die Formel liefert deshalb bestenfalls eine Größenordnung. Sie ist ein Argument, keine Vorhersage.

Robustheit

Dieselbe Eigenschaft, die Netze mit schwerem Gradschwanz gegen Zufall unempfindlich macht, macht sie gegen Angriffe verwundbar.

	zufälliger Ausfall	**gezielter Angriff**
Trifft	meist kleine Knoten	**die größten**
Netz zerfällt bei	$> 90\,\%$ Ausfall	$\approx 5\,\%$
Grund	Dieselbe: wenige Knoten tragen die meisten Kanten	

Es ist derselbe Sachverhalt, zweimal gelesen. Wer zufällig zieht, erwischt fast immer einen unwichtigen Knoten. Wer gezielt zieht, erwischt genau die wenigen, die alles zusammenhalten. ALBERT, JEONG *und* BARABÁSI *nannten das 2000 die Robustheit-Verwundbarkeit-Doppelnatur.*

Entfernt	**zufällig**	**nach Grad**	**nach Zwischenz.**
1 %	0,99	0,86	0,81
5 %	0,95	**0,32**	**0,18**
10 %	0,90	0,09	0,05
50 %	0,47	0,00	0,00

Angaben: Anteil in der größten Komponente. Die Zwischenzentralität ist die wirksamste Angriffsstrategie, und das ist genau der Befund aus Kapitel 4: Sie findet die Brücken, deren Entfernung das Netz zerlegt.

Aufgabe 11.1.

(a) Rechnen Sie eine Epidemieschwelle für verschiedene Netze aus.
(b) Untersuchen Sie die Bekanntenimpfung.
(c) Analysieren Sie einen Kaskadenausfall.

Lösung Schritt für Schritt.

(a) Epidemieschwellen.
Netz 1: regelmäßig. Jeder Knoten hat genau Grad 6.

$$\langle k \rangle = 6, \quad \langle k^2 \rangle = 36, \quad \text{Schwelle} = \frac{6}{36 - 6} = 0{,}200.$$

Netz 2: Zufallsgraph. Poisson-verteilt mit $\langle k \rangle = 6$, also $\langle k^2 \rangle = \langle k \rangle^2 + \langle k \rangle = 42$.

$$\text{Schwelle} = \frac{6}{42 - 6} = 0{,}167.$$

Netz 3: schwerer Schwanz. $\langle k \rangle = 6$, aber ein Prozent der Knoten hat Grad 200.

Gruppe	**Anteil**	k	**Beitrag zu** $\langle k^2 \rangle$
Die meisten	0,99	4	15,84
Die Naben	0,01	200	**400,0**
			415,8

$$\text{Schwelle} = \frac{6}{415{,}8 - 6} = \mathbf{0{,}0146}.$$

Netz	**Schwelle**	**Verhältnis**
Regelmäßig	0,200	1
Zufällig	0,167	1,2
Schwerer Schwanz	**0,0146**	**13,7**

Ein Prozent der Knoten senkt die Schwelle um Faktor vierzehn. Alle drei Netze haben denselben mittleren Grad; wer nur mit diesem rechnet, verschätzt sich um mehr als eine Größenordnung.

(b) Die Bekanntenimpfung.
Das Problem. Man will die hochgradigen Knoten impfen und kennt das Netz nicht.

Zufällige Impfung	Trifft meist unwichtige Knoten; braucht sehr hohe Quoten
Gezielte Impfung	Wirksam, setzt aber Kenntnis des ganzen Netzes voraus
Bekanntenimpfung	**Zufällige Person fragen, einen Bekannten zu nennen; diesen impfen**

Warum das funktioniert.
Ein genannter Bekannter ist proportional zu seinem Grad wahrscheinlich, nicht gleichverteilt. Das ist genau das Freundschaftsparadox aus Kapitel 1.

Auswahl	**mittlerer Grad**	**Verhältnis**	
Zufällige Person	6,0	1,0	
Genannter Bekannter	**69,3**	**11,6**	$\langle k^2 \rangle / \langle k \rangle$

Die nötige Impfquote.

Verfahren	**nötige Quote**	**setzt voraus**
Zufällig	$> 90\,\%$	nichts
Bekannte	$\approx 20\,\%$	**nichts**
Nach Grad	$\approx 5\,\%$	ganzes Netz bekannt

Die mittlere Zeile ist das bemerkenswerte Ergebnis. Man kommt fast an die gezielte Impfung heran, ohne irgendetwas über das Netz zu wissen. Das Verfahren wurde 2003 vorgeschlagen und ist eines der wenigen Beispiele, in denen die Netzwerktheorie eine unmittelbar umsetzbare Handlungsanweisung liefert.

Dieselbe Überlegung trägt in die andere Richtung: Wer eine Epidemie früh erkennen will, beobachtet nicht eine zufällige Stichprobe, sondern deren genannte Bekannte. Diese erkranken im Mittel deutlich früher und wirken als Frühwarnsystem.

(c) Kaskadenausfall.

Das Modell. Jeder Knoten trägt eine Last und hat eine Kapazität. Fällt er aus, verteilt sich seine Last auf die Nachbarn.

Last L_i	Anfangs proportional zur Zwischenzentralität
Kapazität C_i	$C_i = (1+\alpha)L_i$ mit dem Sicherheitsaufschlag α

Der Ablauf.

Runde	ausgefallen	neu überlastet	Summe
0	1 (Angriff)	—	1
1	—	3	4
2	—	11	15
3	—	47	62
4	—	180	242
5	—	9	251
6	—	0	251

Ein einziger ausgefallener Knoten reißt zweihundertfünfzig mit. Der Verlauf ist typisch: eine Anlaufphase, ein steiler Anstieg, dann ein abruptes Ende, wenn die verbleibenden Knoten genug Reserve haben.

Die Wirkung des Sicherheitsaufschlags.

α	Ausgefallen	Kosten	
0,05	**68 %**	1,05×	katastrophal
0,20	25 %	1,20×	
0,50	5 %	1,50×	
1,00	$<$ **1 %**	2,00×	sicher

Der Zusammenhang ist stark nichtlinear. Von fünf auf zwanzig Prozent Reserve fällt der Schaden auf ein Drittel, für fünfzehn Prozent Mehrkosten. Der Übergang liegt in einem schmalen Bereich, und genau dort werden reale Netze aus Kostengründen betrieben.

Das erklärt, warum große Stromausfälle so selten und dann so umfassend sind. Ein Netz, das dauerhaft knapp über der Schwelle läuft, verhält sich jahrelang unauffällig und fällt dann auf einen Schlag großflächig aus.

Pastor-Satorras und Vespignani[25] leiteten die Epidemieschwelle her; Albert, Jeong und Barabási[2] untersuchten die Robustheit; Barabási[3] stellt beide Themen anschaulich dar.

12 Das Gehirn als Netzwerk

Warum gerade dieses Beispiel

Kein anderes Anwendungsgebiet führt die Schwierigkeiten dieses Bandes so deutlich vor. Die Fragen „Was ist ein Knoten?“ und „Was ist eine Kante?“ sind hier nicht vorab geklärt, sondern selbst Forschungsgegenstand.

Ebene	Knoten	Kante
Mikro	einzelne Neurone	Synapse
Meso	Zellgruppen, Säulen	lokale Verbindung
Makro	**Areale**	**Faserbündel**

System	Neurone	Synapsen	vollständig?
C. elegans	302	≈ 7000	ja, seit 1986
Fruchtfliege	$\approx 10^5$	$\approx 10^8$	ja, seit 2023
Maus	$7 \cdot 10^7$	$\approx 10^{11}$	nein
Mensch	$8{,}6 \cdot 10^{10}$	$\approx 10^{14}$	aussichtslos

Auf der Makroebene arbeitet man deshalb mit einigen Dutzend bis einigen hundert Arealen. Und damit beginnt das eigentliche Problem: Welche Areale?

CoCoMac und das Parzellierungsproblem

Am C.-und-O.-Vogt-Institut für Hirnforschung in Düsseldorf begann 1996 unter der Leitung von Rolf Kötter ein Vorhaben, das den Namen CoCoMac erhielt: *Collation of Connectivity data on the Macaque brain*.

Der Gegenstand	Anatomische Verbindungen der Großhirnrinde des Makaken
Die Quelle	Veröffentlichte Tracer-Studien: Ein Farbstoff wird injiziert und wandert entlang der Axone
Der Umfang	Etwa 300 Verbindungsstudien und rund 150 weitere zu Hirnkarten und Nomenklatur
Das Ergebnis	Rund 40 000 einzelne Befunde in einer relationalen Datenbank

Die Aufgabe klingt nach Fleißarbeit und ist eine der schwierigsten Datenintegrationsaufgaben, die man sich denken kann. Der Grund steckt in der dritten Zeile: Jede Studie benutzt eine eigene Einteilung der Hirnrinde.

Das Parzellierungsproblem.

Die Lage	Verschiedene Autoren teilen dieselbe Hirnrinde verschieden ein
Die Folge	Ein Befund „Areal X projiziert nach Areal Y“ ist nur in der Karte des Autors verständlich
Die Verschärfung	Neue Arbeiten verändern bestehende Karten geringfügig und geben ihnen neue Namen

Man kann die Befunde also nicht einfach zusammenwerfen. Zwei Studien, die dieselbe Verbindung beschreiben, benutzen möglicherweise Namen, die sich weder decken noch ausschließen, sondern teilweise überlappen.

Die Lösung: Beziehungen statt Koordinaten.
KLAAS STEPHAN, KARL ZILLES und Kötter veröffentlichten 2000 ein Verfahren, das sie *Objective Relational Transformation* nannten, kurz ORT.

Der Ansatz	Man verzichtet auf räumliche Koordinaten und arbeitet allein mit **Beziehungen zwischen Gebieten**
Die Grundrelationen	Identisch, enthalten, enthalten in, überlappend, disjunkt
Die Quelle	Meist gibt die Arbeit, die eine Karte abwandelt, selbst an, wie sich die neuen Gebiete zu den alten verhalten

Diese Angaben bilden selbst einen Graphen: Knoten sind benannte Gebiete aus allen Karten, Kanten sind Beziehungsangaben. Auf diesem Graphen lassen sich Befunde von einer Karte in eine andere übertragen, indem man Ketten von Beziehungen verkettet.

Kette	Schluss	Sicherheit
$A \equiv B, B \equiv C$	$A \equiv C$	sicher
$A \subset B, B \subset C$	$A \subset C$	sicher
$A \subset B, B \supset C$	unbestimmt	
$A \cap B, B \cap C$	unbestimmt	

Die letzten beiden Zeilen sind der Kern der Schwierigkeit. Nicht jede Verkettung liefert eine Aussage, und die Länge der Kette bestimmt, wie viel Genauigkeit unterwegs verlorengeht. Das Verfahren muss also mitführen, wie sicher jeder abgeleitete Befund ist.

Warum das rechnerisch aufwendig ist.

Transitive Hülle	Alle ableitbaren Beziehungen zwischen allen Gebietspaaren
Aufwand	$\mathcal{O}(n^3)$ bei n Gebieten über alle Karten hinweg
Erschwerend	Mehrwertige Relationen statt einfacher Erreichbarkeit
Widersprüche	Zwei Ketten können unvereinbare Aussagen liefern

Die letzte Zeile ist die unangenehmste. Wenn zwei gleich gut belegte Ableitungswege einander widersprechen, muss das System eine Entscheidung treffen oder den Widerspruch ausweisen. Ein Graphenalgorithmus, der so etwas leisten soll, ist deutlich schwerer als eine gewöhnliche Hüllenbildung.

Zur Entstehungszeit liefen solche Rechnungen auf gewöhnlichen Bürorechnern und dauerten entsprechend. Es gehört zu den wenigen Fällen, in denen ein Graphenalgorithmus auf einigen hundert Knoten Tage bis Wochen beanspruchte, und zwar wegen der Vielwertigkeit der Relationen, nicht wegen der Knotenzahl.

Was daraus geworden ist.

1996	Beginn der Sammlung
2000	ORT veröffentlicht
2001	Methodik veröffentlicht
2004	Online-Zugang und Auswertung
2010	Kötter stirbt
2011	CoCoMac 1.0 wird eingefroren; CoCoMac 2.0 entsteht

Die Datenbank wurde zur meistbenutzten Grundlage für Netzwerkanalysen des Primatenhirns und war ein Wegbereiter des Konnektomprogramms. Der Aufwand, der dahintersteckt, ist von außen kaum sichtbar: Er liegt fast vollständig in der sorgfältigen Behandlung widersprüchlicher und unvollständiger Angaben.

Das ist die Lehre, die über den Einzelfall hinausreicht. Die Netzwerkanalyse beginnt in den meisten Veröffentlichungen bei einer fertigen Adjazenzmatrix. Die eigentliche Arbeit liegt davor, und sie besteht nicht aus Verfahren, sondern aus Entscheidungen.

Was man an solchen Netzen gefunden hat

Befund	Stand	Anmerkung
Kurze Wege	robust	meist 1,5–2,5 Schritte
Hohes Clustering	robust	aber siehe unten
Gemeinschaften	robust	entsprechen Systemen
Reicher Klub	wahrscheinlich	Naben untereinander verbunden
Skalenfreiheit	fraglich	zu wenige Knoten

Die vorletzte Zeile ist der interessanteste Befund. Die hochgradigen Areale sind untereinander stärker verbunden, als ihre Grade erwarten ließen. Man deutet das als zentralen Umschlagplatz, der Systeme miteinander verbindet, und er verbraucht überproportional viel Energie.

Die Dichte macht vieles zunichte

Das Verbindungsnetz der Hirnrinde ist außergewöhnlich dicht. Etwa ein Drittel aller möglichen Verbindungen besteht tatsächlich.

Netz	Dichte	Clustering	Zufall
Sozial	10^{-4}	0,31	0,0001
Kortex	**0,34**	0,49	**0,34**

In der zweiten Zeile ist der gemessene Wert kaum über dem Zufallswert. Ein Befund „das Gehirn ist eine kleine Welt“ ist bei dieser Dichte fast trivial: Jedes hinreichend dichte Netz hat kurze Wege und hohes Clustering, auch ein zufälliges.

Weitere Erschwernis	Die Dichte hängt davon ab, wie viele Studien es gibt. Gut untersuchte Areale wirken besser vernetzt
Folge	Der Grad eines Knotens misst teilweise die Forschungsintensität, nicht die Anatomie

Genau deshalb war die Sorgfalt bei der Erfassung so wichtig: Ohne die Buchführung darüber, welche Verbindungen untersucht und nicht gefunden *wurden, lässt sich eine fehlende Kante nicht von einer nicht untersuchten unterscheiden.*

Aufgabe 12.1.

(a) Führen Sie eine Beziehungsverkettung zwischen Hirnkarten durch.
(b) Untersuchen Sie, wie die Parzellierung die Kennzahlen verändert.
(c) Prüfen Sie den Befund des reichen Klubs gegen ein Nullmodell.

Lösung Schritt für Schritt.

(a) Beziehungen verketten.
Die Ausgangslage. Drei Karten M_1, M_2, M_3 mit angegebenen Beziehungen.

Angabe	Beziehung	Quelle
A_1 zu B_2	identisch	Arbeit von M_2
B_2 zu C_3	enthalten in	Arbeit von M_3
D_1 zu B_2	überlappend	Arbeit von M_2
E_1 zu F_2	enthält	
F_2 zu G_3	identisch	

Die ableitbaren Beziehungen.

Paar	Kette	Ergebnis
A_1, C_3	$\equiv$ dann $\subset$	$A_1 \subset C_3$
E_1, G_3	$\supset$ dann $\equiv$	$E_1 \supset G_3$
D_1, C_3	$\cap$ dann $\subset$	unbestimmt
A_1, D_1	über B_2	unbestimmt

Die dritte Zeile zeigt die Grenze. Wenn D_1 mit B_2 überlappt und B_2 in C_3 enthalten ist, kann D_1 ganz in C_3 liegen, teilweise, oder auch aus C_3 herausragen. Die Angaben reichen nicht.

Die Übertragung eines Befundes.
Ein Befund lautet: „A_1 projiziert nach E_1.“ Gesucht ist die Aussage in Karte M_3.

1. $A_1 \subset C_3$: Die Quelle liegt in C_3, ist aber kleiner.
2. $E_1 \supset G_3$: Das Ziel enthält G_3, ist aber größer.
3. Schluss: **Von einem Teil von C_3 geht eine Projektion aus, die ein Gebiet trifft, das G_3 umfasst.**

Aussage in M_3	Sicherheit	
$C_3 \to G_3$ besteht	nicht gesichert	Quelle nur teilweise
$C_3 \to G_3$ möglich	ja	
$C_3 \to$ etwas	ja	sicher

Man erhält also keine einfache Ja-Nein-Aussage, sondern eine mit einem Sicherheitsgrad. Genau das musste die Datenbank mitführen, und genau das unterscheidet eine sorgfältige Zusammenführung von einem bloßen Zusammenkopieren.

(b) Die Wirkung der Parzellierung.
Der Versuch. Dieselben zugrundeliegenden Verbindungen, in drei verschiedene Einteilungen übertragen.

Karte	Areale	Dichte	Clustering
Grob	39	0,41	0,62
Mittel	73	0,34	0,49
Fein	145	**0,19**	**0,31**

Karte	Weglänge	Modularität	Gemeinschaften
Grob	1,59	0,21	3
Mittel	1,72	0,30	4
Fein	2,14	**0,41**	**7**

Alle Kennzahlen ändern sich systematisch mit der Feinheit der Einteilung, und die Zahl der gefundenen Gemeinschaften mehr als doppelt sich. Ein Vergleich zweier Studien, die verschiedene Karten benutzen, ist damit ohne Umrechnung nicht sinnvoll.

Was hilft	Dieselbe Analyse auf mehreren Karten durchführen und berichten, was stabil bleibt
Was nicht hilft	Eine Kennzahl aus einer Karte mit einer aus einer anderen vergleichen

Und genau dafür braucht man ein Umrechnungsverfahren. ORT war der Versuch, diese Umrechnung nachvollziehbar und wiederholbar zu machen, statt sie dem Urteil des einzelnen Autors zu überlassen.

(c) Der reiche Klub.
Die Kennzahl. Für einen Grad k betrachtet man nur die Knoten mit Grad über k und misst deren Dichte untereinander:

$$\phi(k) = \frac{2E_{>k}}{N_{>k}(N_{>k} - 1)}.$$

Die Messung.

k	$N_{>k}$	$E_{>k}$	$\phi(k)$
10	60	520	0,294
20	34	290	0,517
30	18	102	0,667
40	9	31	**0,861**
50	4	6	**1,000**

Die Werte steigen bis eins. Das sieht nach einem starken Befund aus und ist zunächst keiner: Auch in einem Zufallsnetz mit derselben Gradfolge steigt ϕ, einfach weil hochgradige Knoten mehr Kanten haben und daher auch untereinander mehr.

Die Normierung.

$$\rho(k) = \frac{\phi(k)}{\phi_{\text{zufall}}(k)}.$$

k	ϕ	ϕ_{zufall}	ρ
10	0,294	0,288	1,02
20	0,517	0,498	1,04
30	0,667	0,612	1,09
40	0,861	0,743	**1,16**
50	1,000	0,891	**1,12**

Der normierte Wert liegt bei etwa 1,1 *bis* 1,2*, nicht bei drei oder vier. Der reiche Klub besteht also, und er ist erheblich schwächer ausgeprägt, als die unnormierte Kurve nahelegt.*

Die Signifikanzfrage.

k	ρ	**Streuung**	Z
30	1,09	0,04	2,3
40	1,16	0,07	**2,3**
50	1,12	**0,18**	0,7

Am oberen Ende wird die Streuung groß, weil dort nur noch vier Knoten übrig sind. Der augenscheinlich stärkste Wert ist damit der am wenigsten gesicherte. Das ist ein wiederkehrendes Muster bei allen Kennzahlen, die man nach Grad geschichtet betrachtet.

Stephan und Mitautoren[27] beschreiben die Datenbank und ihre Methodik; Kötter[19] den Zugang und die Auswertung; Sporns[26] gibt die Gesamtdarstellung der Netzwerkanalyse des Gehirns; Bullmore und Sporns[7] die vielzitierte Übersicht; Felleman und Van Essen[12] lieferten das frühe Beispiel einer Verbindungsmatrix.

13 Große Graphen berechnen

Warum Graphen schlecht zu Rechnern passen

Die Verfahren der vorigen Kapitel sind auf kleinen Netzen unproblematisch. Ab einigen Millionen Knoten ändert sich die Lage grundlegend, und zwar nicht wegen der Zahl der Operationen.

Kein Zusammenhang im Speicher	Nachbarn liegen an beliebigen Stellen; jeder Schritt ist ein Sprung
Wenig Rechnung je Zugriff	Ein Cachefehler für eine Addition
Ungleiche Grade	Ein Knoten hat drei Nachbarn, der nächste drei Millionen
Schlecht zu zerteilen	Jeder Schnitt durchtrennt viele Kanten

Die ersten beiden Punkte machen aus einem Verfahren mit linearem Aufwand eines, das an der Speicheranbindung hängt. Die Rechenwerke aus Band 4 laufen dabei fast leer.

Last	erreichte Rechenleistung	Anteil
Matrixmultiplikation	≈ 90 %	voll
Sequentieller Durchlauf	≈ 60 %	
Sortieren	≈ 20 %	
Breitensuche	≈ 1–3 %	fast alles Warten

Ein Graphverfahren nutzt etwa ein Fünfzigstel dessen, was der Prozessor könnte. Alle Anstrengungen dieses Kapitels zielen darauf, diesen Anteil zu erhöhen, und nicht darauf, weniger zu rechnen.

Speicherformate

Die Adjazenzliste aus Kapitel 1 ist als verkettete Struktur bequem und für große Netze ungeeignet.

Das komprimierte Zeilenformat.
Zwei Felder: eines mit allen Nachbarn hintereinander, eines mit den Anfangspositionen je Knoten.

```
ziel     [2,3, 1,3, 1,2,4, 3]
start    [0, 2, 4, 7, 8]
```

Nachbarn von i	`ziel[start[i] .. start[i+1]-1]`
Grad von i	`start[i+1] - start[i]`
Speicher	$n+1$ plus $2m$ Zahlen, sonst nichts

Der Gewinn liegt darin, dass die Nachbarn eines Knotens hintereinander liegen. Eine Cachezeile von 64 Byte enthält damit sechzehn Nachbarn statt eines, und der Durchlauf über die Nachbarschaft wird sequentiell.

Format	Speicher	Nachbarn lesen
Verkettete Liste	$\approx 24m$ B	ein Sprung je Kante
Zeigerfeld je Knoten	$\approx 12m$ B	sequentiell je Knoten
Komprimierte Zeilen	**8m B**	durchgehend sequentiell
Mit Differenzverdichtung	$\approx 2m$ B	entpacken nötig

Die letzte Zeile benutzt dasselbe Verfahren wie die Trefferlisten in Band 10: Nachbarn sortieren, Differenzen bilden, variabel kodieren. Bei Webgraphen kommt hinzu, dass benachbarte Seiten ähnliche Nachbarschaften haben, und dann lässt sich auf eine bereits gespeicherte Zeile verweisen.

Webgraph, 10^9 **Kanten**	**Größe**	
Roh, 8 B je Kante	8 GB	
Komprimierte Zeilen	8 GB	
Differenzen	2 GB	
Mit Zeilenverweisen	**0,4 GB**	$\approx$ 3 bit je Kante

Rechnen aus Sicht eines Knotens

Für verteilte Berechnungen hat sich ein Modell durchgesetzt, das MALEWICZ und Mitautoren 2010 unter dem Namen Pregel beschrieben.

1. Jeder Knoten führt dasselbe kleine Programm aus.
2. Er liest die Nachrichten der vorigen Runde.
3. Er ändert seinen Zustand und schickt Nachrichten an Nachbarn.
4. Alle warten aufeinander; dann beginnt die nächste Runde.
5. Wer nichts mehr zu tun hat, meldet sich ab; sind alle abgemeldet, ist Schluss.

Schritt 4 ist eine Barriere im Sinne von Band 5. Sie macht das Verfahren einfach zu verstehen und zu prüfen, weil es innerhalb einer Runde keine Wettläufe geben kann, und sie ist zugleich der Engpass: Die Runde dauert so lange wie der langsamste Knoten.

PageRank in diesem Modell.

```
berechne(nachrichten):
  if runde > 0:
    wert = 0.15/N + 0.85 *
summe(nachrichten)
  if runde < 30:
    sende(wert / grad) an alle
Nachbarn
  else:
    abmelden()
```

Sieben Zeilen für ein Verfahren, das auf Milliarden Knoten läuft. Die Verteilung, die Fehlerbehandlung und das Zusammenfassen der Nachrichten übernimmt das Rahmenwerk.

Der Knoten mit einer Milliarde Nachbarn

Bei schweren Gradverteilungen bricht das Modell an einer Stelle.

Knoten	Nachrichten	Zeit der Runde
Durchschnitt	40	≈ 0
99. Perzentil	2000	≈ 0
Größter	10^8	**bestimmt alles**

Ein einziger Knoten hält die Barriere auf, und alle anderen Rechner warten. Es ist die Schwanzlatenz aus Band 9, hier durch die Struktur der Daten erzwungen statt durch Zufall.

Vorverdichten	Nachrichten an denselben Knoten werden schon beim Absender zusammengefasst
Knoten aufteilen	Ein hochgradiger Knoten wird auf mehrere Rechner verteilt und intern zusammengeführt
Nach Kanten teilen	Nicht die Knoten, sondern die Kanten gleichmäßig verteilen

Die dritte Zeile ist die gründlichste Antwort. Sie gibt die Vorstellung auf, ein Knoten gehöre zu einem Rechner, und akzeptiert dafür, dass jeder Knotenzustand an mehreren Stellen liegt und abgeglichen werden muss.

Aufgabe 13.1.

(a) Vergleichen Sie Speicherformate und ihre Zugriffskosten.
(b) Rechnen Sie durch, wann sich Verteilen überhaupt lohnt.
(c) Schätzen Sie Kennzahlen aus einer Stichprobe.

Lösung Schritt für Schritt.

(a) Speicherformate.
Der Graph. $n = 10^8$ Knoten, $m = 2 \cdot 10^9$ Kanten, ungerichtet.

Format	Speicher	passt in 256 GB?
Adjazenzmatrix	10^{16} B	nein
Verkettete Liste	96 GB	knapp
Komprimierte Zeilen	32 GB	ja
Mit Verdichtung	2 GB	leicht

Die Zeit für einen vollständigen Durchlauf.

Format	Zugriffsart	Zeit
Verkettete Liste	$4 \cdot 10^9$ Sprünge	$4 \cdot 10^9 \cdot 80$ ns $=$ **320 s**
Komprimierte Zeilen	32 GB sequentiell	$32/20$ GB/s $=$ **1,6 s**

Faktor zweihundert, bei genau derselben Zahl von Operationen. Der Unterschied besteht allein darin, ob der Speicher der Reihe nach oder sprunghaft gelesen wird. Das ist die Botschaft von Band 4, hier in ihrer schärfsten Form.

Warum die Verdichtung nochmals hilft.

	lesen	entpacken	gesamt
Unverdichtet	1,6 s	0	1,6 s
Verdichtet	0,1 s	0,8 s	**0,9 s**

Man rechnet mehr und wartet weniger, und unterm Strich ist es schneller. Dasselbe Muster wie bei der Spaltenverdichtung in Band 10: Solange das Entpacken billiger ist als das Warten auf den Speicher, lohnt es sich.

Die Ordnung der Knotennummern zählt.

Numerierung	Bits je Kante	Cachefehler
Zufällig	≈ 28	hoch
Nach Adresse sortiert	≈ 6	mittel
Nach Gemeinschaften	≈ 3	niedrig

Wer die Knoten so numeriert, dass Nachbarn benachbarte Nummern bekommen, gewinnt zweimal: Die Differenzen werden klein, und die Zugriffe bleiben lokal. Die Gemeinschaftserkennung aus Kapitel 6 wird damit zu einem Werkzeug der Speicheroptimierung.

(b) Wann sich Verteilen lohnt.
Die Kosten. Sei T_1 die Zeit auf einem Rechner, c die Zeit für den Nachrichtenaustausch je Runde und Rechner.

$$T(p) = \frac{T_1}{p} + r \cdot c \cdot p,$$

mit r Runden. Das ist die Rechnung aus Band 9, Kapitel 14.
Ein Beispiel. PageRank auf $2 \cdot 10^9$ Kanten, $r = 30$ Runden.

p	Rechnen	Austausch	gesamt
1	54 s	0	**54 s**
4	13,5 s	6 s	19,5 s
16	3,4 s	24 s	27,4 s
64	0,8 s	96 s	96,8 s

$$p_{\text{opt}} = \sqrt{\frac{T_1}{r\,c}} = \sqrt{\frac{54}{30 \cdot 0{,}05}} = 6.$$

Das Optimum liegt bei sechs Rechnern, und bei vierundsechzig ist man schlechter dran als mit einem einzigen. Bei einem Graphen dieser Größe, der auf eine Maschine passt, ist Verteilen also schlicht falsch.

Die Faustregel.

Passt in den Speicher	Einen Rechner nehmen; ein guter Einzelrechner schlägt fast jeden kleinen Verbund
Passt auf eine SSD	Einen Rechner mit sorgfältigem Blockzugriff
Passt auf keine Maschine	Verteilen, und die Rundenzahl niedrig halten

Diese Beobachtung wurde 2015 unter dem Namen „Kosten der Verteilung“ bekannt: Mehrere veröffentlichte verteilte Graphsysteme wurden von einem sorgfältig geschriebenen Programm auf einem einzigen Notebook geschlagen. Die Verfahren waren nicht falsch; sie lösten ein Problem, das man nicht hatte.

(c) Kennzahlen schätzen.
Das Problem. Die Zwischenzentralität aller Knoten kostet $\mathcal{O}(nm)$ und ist bei $n = 10^8$ aussichtslos.

Verfahren	Aufwand	Zeit
Exakt (Brandes)	$\mathcal{O}(nm)$	10^6 Jahre
Von k Quellen	$\mathcal{O}(km)$	bei $k = 1000$: Minuten

Die Schätzung.
Man wählt k zufällige Startknoten, berechnet von dort die kürzesten Wege und zählt, wie oft jeder Knoten dazwischenliegt.

$$\hat{C}_B(v) = \frac{n}{k} \sum_{s \in S} \delta_s(v).$$

Die Genauigkeit.

k	Rangfehler	Top-100 getroffen	Zeit
10	hoch	54 %	1 s
100	mittel	87 %	10 s
1000	gering	**97** %	100 s
10 000	sehr gering	99 %	17 min

Der Fehler fällt mit $1/\sqrt{k}$. Um ihn zu halbieren, braucht man viermal so viele Quellen. Für eine Rangliste der wichtigsten Knoten genügen einige hundert, für genaue Einzelwerte nicht.

Nicht jede Kennzahl lässt sich so schätzen

Kennzahl	Stichprobe	Grund
Mittlerer Grad	gut	einfacher Mittelwert
Dreieckszahl	gut	mit Gewichtung
Zwischenzentralität	brauchbar	Rangfolge stabil
Durchmesser	schlecht	**Maximum, kein Mittel**
Zahl der Komponenten	schlecht	kleine gehen verloren

Die beiden letzten Zeilen haben denselben Grund: Sie hängen an seltenen Einzelheiten. Ein Stichprobenverfahren mittelt und übersieht gerade das Außergewöhnliche, das den Wert bestimmt.

Beim Durchmesser hilft ein anderer Weg: Man sucht nicht das Maximum, sondern schätzt es von unten durch wiederholte Breitensuche von den entferntesten gefundenen Knoten aus. Das liefert eine Schranke statt eines Schätzwerts, und eine Schranke ist ehrlicher.

Malewicz und Mitautoren[20] beschrieben Pregel; Newman[23] behandelt die algorithmische Seite der Kennzahlen; Cormen und Mitautoren[9] liefern die Grundverfahren und ihre Aufwandsanalysen.

14 Fallstricke

Das Netzwerk ist nicht gegeben

In den bisherigen Kapiteln lag ein Graph vor. In der Praxis muss man ihn erst herstellen, und dabei fallen Entscheidungen, die das Ergebnis bestimmen.

Was ist ein Knoten?	Ein Mensch, ein Konto, ein Areal, ein Wort in welcher Form?
Was ist eine Kante?	Ab welcher Stärke, in welchem Zeitraum, aus welcher Quelle?
Was fehlt?	Welche Knoten und Kanten wurden nie erhoben?
Wogegen vergleiche ich?	Welches Nullmodell?

Keine dieser Fragen hat eine technische Antwort. Alle vier werden in der Praxis oft stillschweigend beantwortet, meist so, wie es die Datenlage gerade nahelegt, und danach wird gerechnet, als stünde der Graph fest.

Die Wirkung einer einzigen Entscheidung.
Ein Netz aus Zusammenarbeit: Zwei Personen sind verbunden, wenn sie gemeinsam an mindestens s Arbeiten beteiligt waren.

s	Kanten	Clustering	Komponenten
1	48 200	0,71	12
2	11 400	0,44	87
5	2 100	0,29	640
10	470	0,21	1 830

Alle vier Zeilen beschreiben dasselbe Geschehen. Die Aussage „dieses Netz ist stark gruppiert“ hängt vollständig an einer Zahl, die niemand aus der Sache herleiten kann.

Projizierte Netze sind fast immer stark gruppiert

Sehr viele Netze entstehen aus zweigeteilten Daten: Personen und Arbeiten, Kunden und Waren, Areale und Studien.



Eine Arbeit mit drei Autoren erzeugt bei der Projektion ein vollständiges Dreieck. Eine mit zehn Autoren erzeugt fünfundvierzig Kanten und einen Clusterkoeffizienten von eins in dieser Gruppe. Das hohe Clustering ist dann kein Befund über Zusammenarbeit, sondern eine Eigenschaft der Umrechnung.

Autoren je Arbeit	erzeugte Kanten	Beitrag zum Clustering
2	1	keiner
5	10	hoch
20	190	sehr hoch
500	124 750	beherrscht alles

Eine einzige Arbeit mit fünfhundert Autoren erzeugt mehr Kanten als zehntausend Arbeiten mit je zwei. Wer solche Netze bildet, muss entweder große Gruppen ausschließen oder die Kanten mit $1/(a-1)$ gewichten, damit jede Arbeit gleich zählt.

Das Nullmodell entscheidet

Eine Kennzahl allein ist bedeutungslos. Sie wird erst dadurch zu einem Befund, dass man sie mit dem vergleicht, was ohne die vermutete Struktur zu erwarten wäre.

Nullmodell	hält fest	prüft damit
Erdős-Rényi	n, m	irgendeine Struktur
Konfigurations-modell	n, m, **Gradfolge**	**Struktur jenseits der Grade**
Mit Gemeinschaften	zusätzlich Gruppen	Struktur innerhalb der Gruppen
Räumlich	zusätzlich Entfernungen	Struktur jenseits der Nähe

Je mehr ein Nullmodell festhält, desto schärfer ist die Prüfung und desto weniger bleibt übrig, was man als Befund melden kann. Wer ein zu einfaches Nullmodell wählt, findet immer etwas.

Warum die Gradfolge fast immer festgehalten werden muss.

Kennzahl	beobachtet	Erdős-Rényi	Konfig.
Clustering	0,31	0,004	0,29
Weglänge	4,2	6,1	4,0
Zentralität, Streuung	hoch	niedrig	hoch
Assortativität	$-0{,}08$	0	$-0{,}07$

Alle vier Kennzahlen sehen gegenüber dem einfachen Modell auffällig aus und gegenüber dem Konfigurationsmodell nicht. Sie folgen also aus der Gradverteilung allein und sagen über die Verschaltung nichts.

Das ist kein Grund zur Enttäuschung, sondern ein Ergebnis: Die Gradverteilung erklärt bereits das meiste. Die Frage verlagert sich dann darauf, wie diese Verteilung zustande kommt, und das ist eine inhaltliche Frage über den Gegenstand.

Wie man ein Konfigurationsmodell erzeugt.

1. Jeder Knoten bekommt so viele Halbkanten, wie sein Grad angibt.
2. Die Halbkanten werden zufällig paarweise verbunden.
3. Dabei entstehen Schlingen und Mehrfachkanten; man verwirft oder wiederholt.

Der übliche praktische Weg ist ein anderer: Man vertauscht wiederholt die Endpunkte zweier zufälliger Kanten. Das erhält alle Grade genau und mischt die Struktur, ohne dass man von vorn beginnen muss.

Unvollständige Daten

Fast jedes gemessene Netz ist unvollständig, und die Lücken sind selten zufällig verteilt.

Fehlende Kanten	Nicht erhoben, nicht erinnert, unterhalb der Nachweisgrenze
Fehlende Knoten	Nie in die Stichprobe geraten
Verzerrte Erhebung	Was auffällt, wird eher berichtet
Randeffekte	Der Rand des erhobenen Bereichs sieht immer dünn aus

Die dritte Zeile ist bei Literaturdatenbanken zentral. Wer nach einer starken Verbindung sucht und sie findet, veröffentlicht; wer keine findet, oft nicht. Damit ist das Nichtvorhandensein einer Kante etwas ganz anderes als ihr nachgewiesenes Fehlen, und Kapitel 12 hat gezeigt, wie CoCoMac das durch eine dritte Kategorie auffängt.

Wie empfindlich die Kennzahlen sind.

Kanten fehlen	Grad	Clustering	Zwischenzentr.
0 %	1,00	1,00	1,00
10 %	0,90	0,73	0,81
30 %	0,70	0,35	0,48
50 %	0,50	0,13	0,26

Der Grad fällt linear, das Clustering überproportional. Der Grund ist einleuchtend: Ein Dreieck braucht drei Kanten, und bei zehn Prozent Ausfall überlebt es nur mit Wahrscheinlichkeit $0{,}9^3 = 0{,}73$. Alle Maße, die auf mehreren Kanten zugleich beruhen, sind entsprechend empfindlicher.

Praktisch folgt daraus: Rangfolgen sind belastbarer als Absolutwerte, und Vergleiche zwischen Netzen sind nur zulässig, wenn beide auf dieselbe Weise erhoben wurden.

Aufgabe 14.1.

(a) Untersuchen Sie, wie ein Schwellenwert das Ergebnis bestimmt.

(b) Vergleichen Sie eine Kennzahl gegen zwei Nullmodelle.

(c) Prüfen Sie, ob zwei Netze vergleichbar sind.

Lösung Schritt für Schritt.

(a) Die Wirkung des Schwellenwerts.

Der Fall. Ein gewichtetes Netz aus Messwerten, etwa Korrelationen zwischen Zeitreihen. Man setzt alle Kanten unterhalb einer Schwelle auf null.

Schwelle	Dichte	Weglänge	Clustering	Komp.
0,1	0,62	1,4	0,68	1
0,3	0,24	1,9	0,52	1
0,5	0,08	2,8	0,41	1
0,7	0,02	4,6	0,33	7
0,8	0,008	6,1	0,29	34

Das Problem beim Vergleich zweier Gruppen.

Gruppe	mittl. Gewicht	Dichte bei 0,5	Clustering
A	0,42	0,11	0,45
B	0,38	0,06	0,37

Gruppe A hat ein höheres Clustering. Sie hat aber auch eine höhere Dichte, und höhere Dichte erzeugt für sich genommen höheres Clustering. Der Befund ist damit wertlos: Man weiß nicht, ob die Struktur anders ist oder nur die Gesamtstärke.

Die Abhilfen.

Gleiche Dichte	Statt einer festen Schwelle die stärksten m Kanten je Netz nehmen
Über alle Schwellen	Die Kennzahl als Kurve angeben und die Fläche darunter vergleichen
Ohne Schwelle	Gewichtete Maße benutzen, die alle Kanten verwenden
Gegen Nullmodell	Für jedes Netz einzeln normieren

Vorgehen	*A*	*B*	Unterschied?
Feste Schwelle	0,45	0,37	scheinbar ja
Gleiche Dichte	0,41	0,40	nein
Gegen Nullmodell	1,9	1,8	nein

Der Unterschied verschwindet, sobald man die Dichte kontrolliert. Er lag nicht in der Verschaltung, sondern in der Stärke der Messwerte, und das ist ein ganz anderer Befund.

(b) Eine Kennzahl gegen zwei Nullmodelle.
Das Netz. $n = 500$, $m = 2000$, gemessenes Clustering $C = 0{,}31$.
Nullmodell 1 – Erdős-Rényi.

$$p = \frac{2m}{n(n-1)} = \frac{4000}{249\,500} = 0{,}01603.$$

$$C_{\mathrm{ER}} = p = 0{,}01603.$$

$$\frac{C}{C_{\mathrm{ER}}} = \frac{0{,}31}{0{,}016} = \mathbf{19{,}3}.$$

Beim Erdős-Rényi-Graphen ist das erwartete Clustering genau die Kantenwahrscheinlichkeit, denn ob sich zwei Nachbarn eines Knotens kennen, ist von allem anderen unabhängig.

Nullmodell 2 – Konfigurationsmodell.

$$C_{\mathrm{Konf}} = \frac{1}{n} \cdot \frac{\left(\langle k^2 \rangle - \langle k \rangle\right)^2}{\langle k \rangle^3}.$$

Mit $\langle k \rangle = 8$ und $\langle k^2 \rangle = 152$ (also einer breiten Verteilung):

$$C_{\mathrm{Konf}} = \frac{1}{500} \cdot \frac{(152-8)^2}{512} = \frac{1}{500} \cdot \frac{20\,736}{512} = \frac{40{,}5}{500} = 0{,}081.$$

$$\frac{C}{C_{\mathrm{Konf}}} = \frac{0{,}31}{0{,}081} = \mathbf{3{,}8}.$$

Nullmodell	**erwartet**	**Verhältnis**	**Schluss**
Erdős-Rényi	0,016	19,3	sehr auffällig
Konfiguration	0,081	**3,8**	**auffällig**

Vier Fünftel des scheinbaren Effekts erklären sich allein aus der Gradverteilung. Der verbleibende Faktor von knapp vier ist der eigentliche Befund, und nur er verlangt eine inhaltliche Erklärung.

Wie man das statistisch absichert.

1. Tausend Zufallsnetze mit derselben Gradfolge erzeugen.
2. Für jedes die Kennzahl berechnen.
3. Mittelwert μ und Streuung σ dieser Verteilung bestimmen.
4. Den standardisierten Wert $z = (C - \mu)/\sigma$ angeben.

Kennzahl	μ	σ	z
Clustering	0,081	0,006	**38,2**
Weglänge	3,12	0,04	$-2{,}1$
Assortativität	$-0{,}07$	0,03	$-0{,}3$

Nur die erste Zeile ist ein Befund. Die dritte ist vollständig durch die Gradfolge erklärt, und die zweite ist zwar nominell auffällig, aber der Unterschied beträgt drei Prozent und ist inhaltlich bedeutungslos. Statistische und praktische Bedeutsamkeit sind zweierlei.

(c) Sind zwei Netze vergleichbar?
Die Prüfliste.

1. Stammen beide aus derselben Erhebungsart?
2. Haben sie ähnliche Knotenzahl und Dichte?
3. Ist die Knotendefinition dieselbe?
4. Ist die Vollständigkeit vergleichbar?
5. Wurde dieselbe Verarbeitung angewandt?

Ein Beispiel, bei dem es scheitert.

	Netz X	**Netz** Y
Herkunft	Faserverfolgung	bildgebendes Verfahren
Knoten	≈ 90 Areale	≈ 200 Parzellen
Kanten	gerichtet	**ungerichtet**
Nachweisgrenze	einzelne Axone	Faserbündel

Diese beiden Netze lassen sich nicht in einer Tabelle nebeneinanderstellen. Die dritte Zeile allein genügt: Ein gerichtetes Netz auf ein ungerichtetes abzubilden wirft Information weg, und die Kennzahlen ändern sich dabei erheblich.

Kennzahl	gerichtet	symmetrisiert	Faktor
Dichte	0,34	0,49	1,44
Clustering	0,34	0,60	1,76
Weglänge	1,77	1,52	0,86
Reziprozität	0,68	—	entfällt

Die letzte Zeile ist das eigentliche Ärgernis. Die Reziprozität, also der Anteil der gegenseitigen Verbindungen, ist beim Kortex ein aussagekräftiges Maß und lässt sich nach der Symmetrisierung nicht mehr bilden. Man hat genau das weggeworfen, was interessant gewesen wäre.

Die häufigsten Fehler in einem Satz

Kein Nullmodell	Eine Zahl ohne Vergleich ist kein Befund
Falsches Nullmodell	Die Gradfolge erklärt fast immer schon das meiste
Schwelle nicht begründet	Sie bestimmt das Ergebnis vollständig
Dichte nicht kontrolliert	Fast alle Kennzahlen hängen daran
Projektion übersehen	Zweigeteilte Daten erzeugen Clustering von selbst
Viele Maße probiert	Bei zwanzig Maßen ist eines zufällig auffällig
Bild als Beweis	Die Anordnung stammt vom Zeichenverfahren

Diese sieben Punkte erklären einen erheblichen Teil der Befunde, die sich später nicht bestätigt haben. Keiner davon ist ein Rechenfehler; alle sind Entscheidungen, die getroffen wurden, ohne dass jemand sie als Entscheidung bemerkt hätte.

Die beste Vorbeugung ist unbequem und einfach: Alle Entscheidungen aufschreiben, bevor man rechnet, und danach prüfen, ob das Ergebnis von ihnen abhängt. Wenn es das tut, ist die Abhängigkeit selbst das mitzuteilende Ergebnis.

Newman[23] behandelt Nullmodelle und ihre Wahl gründlich; Molloy und Reed[22] begründeten das Konfigurationsmodell; Broido und Clauset[6] führen vor, wie eine sorgfältige statistische Prüfung einen verbreiteten Befund erschüttert.

15 Der Stand im Jahr 2026

Was gelöst ist und was nicht

Frage	Stand	Bemerkung
Kürzeste Wege, Flüsse	gelöst	seit den 1950er Jahren
Zentralitätsmaße	gelöst	Berechnung wie Deutung
Graphen im Großen	gelöst	Formate und Verfahren stehen
Spektrale Verfahren	gelöst	mathematisch sauber
Gemeinschaften	in Arbeit	**kein einheitlicher Begriff**
Zeitliche Netze	in Arbeit	Kanten mit Zeitpunkten
Netze aus Daten bilden	in Arbeit	Kapitel 14
Einbettungen von Knoten	in Arbeit	seit etwa 2015
Was ist eine Gemeinschaft?	offen	**keine Definition trägt**
Struktur und Funktion	offen	besonders im Gehirn
Kausalität aus Struktur	offen	grundsätzlich fraglich

Die erste Zeile des unteren Abschnitts ist keine Forschungslücke, sondern ein Begriffsproblem. Es gibt Dutzende von Definitionen einer Gemeinschaft, sie liefern verschiedene Ergebnisse, und keine lässt sich als die richtige auszeichnen. Kapitel 6 hat das ausgeführt.

Die letzte Zeile verdient eine Erläuterung.

Aus einer Verbindungsstruktur lässt sich ablesen, was mit was verbunden ist. Was daraus folgt, ist eine ganz andere Frage.

Der Graph zeigt	Es gibt einen Weg von *a* nach *b*
Der Graph zeigt nicht	Ob dieser Weg benutzt wird, in welche Richtung die Wirkung geht, ob sie überhaupt eintritt

Das ist dieselbe Einschränkung wie bei der Transinformation in Band 7: Ein statistischer oder struktureller Zusammenhang begrenzt, was möglich ist, und sagt über den tatsächlichen Gebrauch nichts.

Fünf Entwicklungen

Erstens: Zeit wird ernst genommen.
Die meisten Verfahren dieses Bandes setzen ein Netz voraus, das feststeht. Reale Netze ändern sich.

	statisch	**zeitlich**
Kante ist	vorhanden	**zu Zeitpunkten aktiv**
Weg	Folge von Kanten	**Folge in aufsteigender Zeit**
Erreichbarkeit	symmetrisch	nicht mehr
Dreieck	*a–b–c–a*	muss zeitlich passen

Die dritte Zeile ist folgenreich. Wenn a am Montag mit b spricht und b am Sonntag mit c, dann kann nichts von a zu c gelangen, obwohl der statische Graph einen Weg zeigt. Die Aggregation über Zeit erfindet Wege, die es nie gab.

Netz	**statisch erreichbar**	**zeitlich erreichbar**
Kontaktnetz	98 %	**27** %
Nachrichtenverkehr	91 %	44 %

Die Überschätzung ist erheblich, und sie geht immer in dieselbe Richtung: Ein aggregiertes Netz sieht besser vernetzt aus, als es je war. Für Ausbreitungsfragen aus Kapitel 11 ist das die entscheidende Korrektur.

Zweitens: Knoten als Vektoren.
Man bildet Knoten auf Punkte in einem Raum ab, so dass benachbarte Knoten nahe beieinander liegen.

Wie	Zufällige Spaziergänge erzeugen „Sätze“ aus Knoten; darauf ein Sprachmodellverfahren
Wozu	Fehlende Kanten vorhersagen, Knoten klassifizieren, Netze vergleichen
Verwandt mit	Der Vektorsuche aus Band 10, Kapitel 14

Der Zusammenhang zu Kapitel 10 ist enger, als es zunächst aussieht: Mehrere dieser Verfahren lassen sich als Faktorisierung einer Matrix schreiben, die aus der Adjazenzmatrix hervorgeht. Was neu aussieht, ist teilweise Spektraltheorie in anderer Schreibweise.

Drittens: Die Skalenfreiheit wird nüchterner betrachtet.

Bis 2005	Potenzgesetze werden überall gefunden und aus Geraden im doppelt logarithmischen Bild abgelesen
Ab 2009	Strengere Anpassungsverfahren zeigen, dass oft andere Verteilungen besser passen
2019	Broido und Clauset prüfen fast tausend Netze systematisch
Heute	Schwere Enden sind verbreitet, ein strenges Potenzgesetz ist selten

Die praktische Folge ist gering und die methodische groß. Für die meisten Aussagen genügt ein schweres Ende; die genaue Form der Verteilung ändert daran wenig. Was sich geändert hat, ist der Umgang mit Behauptungen, die auf einer Gerade im Bild beruhen.

Viertens: Netze höherer Ordnung.
Eine Kante verbindet zwei Knoten. Viele Beziehungen betreffen mehr als zwei zugleich.

Struktur	Verbindet	Beispiel
Graph	zwei Knoten	Bekanntschaft
Hypergraph	**beliebig viele**	eine Arbeit mit acht Autoren
Simplizialkomplex	mit Struktur	Topologische Analyse

Das ist die grundsätzliche Antwort auf das Projektionsproblem aus Kapitel 14: Statt eine Arbeit mit acht Autoren in achtundzwanzig Kanten aufzulösen, behält man sie als eine einzige Beziehung zwischen acht Knoten. Damit verschwinden die Kunstprodukte, und man braucht neue Verfahren.

Fünftens: Nullmodelle rücken in den Mittelpunkt.

Früher	Ein Maß wird berechnet und mit einem Zufallsgraphen verglichen
Heute	Es wird angegeben, welche Eigenschaften das Nullmodell festhält, und die Wahl wird begründet
Verbreitet	Mehrere Nullmodelle nebeneinander, um zu zeigen, welcher Anteil woher kommt

Das ist die stillste und wichtigste Entwicklung des Gebiets. Sie hat die Zahl der veröffentlichten Befunde gesenkt und ihre Haltbarkeit erhöht.

Drei Einsichten

Erstens: Die Abstraktion ist Gewinn und Verlust zugleich.

Gewinn	Ein Verfahren gilt für Straßen, Gehirne und Sprache gleichermaßen
Verlust	Was ein Knoten ist und was eine Kante bedeutet, steht nicht mehr im Modell

Euler hat 1736 vorgeführt, wie viel man gewinnt, wenn man das Unwesentliche wegwirft. Der ganze Band handelt auch davon, dass man dabei aufschreiben muss, was man weggeworfen hat, weil es bei der Deutung wieder gebraucht wird.

Zweitens: Eine Kennzahl ist ohne Vergleich keine Aussage.

Aussage	**Gehalt**	
„$C = 0{,}31$“	keiner	eine Zahl
„C ist 19-mal so hoch wie im Zufallsgraphen“	gering	falsches Modell
„C ist 3,8-mal so hoch wie bei gleicher Gradfolge“	ein Befund	

Der Weg von der ersten zur dritten Zeile ist die eigentliche Arbeit der Netzwerkanalyse. Er wird oft übersprungen, weil die erste Zahl leichter zu bekommen ist.

Drittens: Struktur begrenzt, sie bestimmt nicht.

Band	**Größe**	**sagt**
7	Transinformation	was übertragen werden *kann*
9	Erreichbarkeit	was ankommen *kann*
11	**Verbindungsstruktur**	**was wirken *kann***

Dreimal dieselbe Form: Eine strukturelle Größe liefert eine obere Schranke für das Mögliche und keine Aussage über das Wirkliche. Wer das verwechselt, liest aus einer Verbindungsmatrix Dinge heraus, die nicht darin stehen.

Band 12 wendet sich der symbolischen künstlichen Intelligenz zu: Suche in Zustandsräumen, Logik und Schlussfolgern, Planen und Wissensrepräsentation. Vieles davon sind Graphverfahren unter anderem Namen, und die Frage nach der Bedeutung der Knoten stellt sich dort mit derselben Schärfe.

Alle Modelle sind falsch, aber manche sind nützlich.

— George Box, 1976.
Für ein Netzwerk gilt das doppelt: Es ist ein Modell der Wirklichkeit und wird zugleich mit einem Modell verglichen, das ebenfalls falsch ist. Der Befund entsteht im Abstand zwischen zwei Irrtümern.

Part V

Anhang

A Formeln und Zahlen

Die Grundformeln

Mittlerer Grad	$\langle k \rangle = 2m/n$
Dichte	$\rho = \dfrac{2m}{n(n-1)}$
Clusterkoeffizient	$C_i = \dfrac{2e_i}{k_i(k_i-1)}$
Freundschaftsparadox	$\langle k_{\text{Nachbar}} \rangle = \dfrac{\langle k^2 \rangle}{\langle k \rangle}$
Modularität	$Q = \sum_c \left(\dfrac{m_c}{m} - \left(\dfrac{d_c}{2m} \right)^2 \right)$
PageRank	$PR(p) = \dfrac{1-d}{N} + d \sum_{q \to p} \dfrac{PR(q)}{\lvert q \rvert}$
Perkolationsschwelle	$\langle k \rangle_c = 1$ (Erdős-Rényi)
Epidemieschwelle	$\lambda_c = \dfrac{\langle k \rangle}{\langle k^2 \rangle}$
Laplace-Matrix	$L = D - A$
Clustering, Konfiguration	$C = \dfrac{1}{n} \dfrac{(\langle k^2 \rangle - \langle k \rangle)^2}{\langle k \rangle^3}$

Die vorletzte Zeile erklärt, warum bei schweren Gradverteilungen die Epidemieschwelle gegen null geht: Wenn $\langle k^2 \rangle$ über alle Grenzen wächst, gibt es keinen Schwellenwert mehr, unterhalb dessen eine Ausbreitung erlischt.

Aufwand der Verfahren

Verfahren	Aufwand	Bemerkung
Breiten-/Tiefensuche	$\mathcal{O}(n+m)$	
Zusammenhangskomponenten	$\mathcal{O}(n+m)$	
Topologische Sortierung	$\mathcal{O}(n+m)$	
Dijkstra	$\mathcal{O}(m + n\log n)$	mit Fibonacci-Halde
Bellman-Ford	$\mathcal{O}(nm)$	negative Gewichte
Alle kürzesten Wege	$\mathcal{O}(n^3)$	Floyd-Warshall
Maximaler Fluss	$\mathcal{O}(nm)$	Orlin
Zwischenzentralität	$\mathcal{O}(nm)$	Brandes
PageRank	$\mathcal{O}(m)$ je Runde	≈ 50 Runden
Louvain	$\mathcal{O}(n\log n)$	praktisch
Spektrale Zerlegung	$\mathcal{O}(n^3)$	dünn besetzt schneller
Dreiecke zählen	$\mathcal{O}(m^{1{,}5})$	

Kenngrößen realer Netze

Netz	n	$\langle k\rangle$	ℓ	C
Makakenkortex	91	≈ 31	1,8	0,34
Fadenwurm	282	14	2,7	0,28
Stromnetz USA	4941	2,7	19,0	0,08
Filmschauspieler	$2{,}2\cdot 10^5$	61	3,6	0,79
Zitationen	$4{,}5\cdot 10^5$	9	4,2	0,12
Web	10^{11}	≈ 40	≈ 19	$\approx 0{,}1$

Die dritte Zeile fällt heraus: Ein Stromnetz ist räumlich gebunden, und deshalb wächst die Weglänge mit der Größe, statt klein zu bleiben. Kleine Welten entstehen nur, wo weite Verbindungen billig sind.

B Landkarte des Bandes

Wo was steht

Kap.	Thema	Verweise
1	Begriffe, Darstellungen	Band 1, Band 4
2	Durchmusterung	Band 1 (Suche)
3	Wege und Flüsse	Band 3 (Komplexität)
4	Zentralität	Band 10 (PageRank)
5	Lokale Struktur	Band 7 (Nullmodelle)
6	Gemeinschaften	Band 10 (Speicheranordnung)
7	Hierarchie	Band 6 (azyklische Graphen)
8	Zufallsgraphen	Mathematikreihe (Stochastik)
9	Kleine Welten	Band 9 (Netze)
10	Spektraltheorie	Mathematikreihe (Eigenwerte)
11	Prozesse auf Netzen	Band 5 (Verbreitung)
12	Das Gehirn	**Band 14 (Neurowissenschaft)**
13	Große Graphen	Band 4, Band 9, Band 10
14	Fallstricke	**Band 7 (Entropie), Band 10**
15	Stand 2026	Band 12

Sechs Verbindungen zur Mathematikreihe

Adjazenzmatrix	Lineare Algebra, Matrixpotenzen
Spektraltheorie	Eigenwerte, Rayleigh-Quotient
Zufallsgraphen	Wahrscheinlichkeitsrechnung, Phasenübergänge
Perkolation	Verzweigungsprozesse, erzeugende Funktionen
Modularität	Optimierung, Gütefunktionen
Flüsse und Schnitte	Dualität in der linearen Optimierung

Die letzte Zeile ist die schönste Verbindung: Der Satz über maximalen Fluss und minimalen Schnitt ist ein Sonderfall der Dualität in der linearen Optimierung. Zwei Fragen, die nichts miteinander zu tun zu haben scheinen, haben immer dieselbe Antwort.

C Glossar

Begriffe

Assortativität	Verbinden sich ähnliche Grade miteinander?
Brücke	Kante, deren Entfernung den Graphen zerteilt
Clusterkoeffizient	Anteil geschlossener Dreiecke
Durchmesser	Längster kürzester Weg
Fiedler-Vektor	Eigenvektor zum zweitkleinsten Laplace-Eigenwert
Gemeinschaft	Dicht verbundene Knotengruppe; kein einheitlicher Begriff
Gradfolge	Liste aller Knotengrade
Konfigurationsmodell	Zufallsgraph mit vorgegebener Gradfolge
Kleine Welt	Kurze Wege bei hohem Clustering
Modularität	Gütemaß für eine Aufteilung in Gruppen
Motiv	Kleines Teilmuster, häufiger als erwartet
Nullmodell	Vergleichsnetz ohne die vermutete Struktur
Parzellierung	Einteilung eines Gebiets in Knoten
Perkolation	Übergang zur ausgedehnten Komponente
Projektion	Zweigeteiltes Netz auf eine Seite abbilden
Reziprozität	Anteil gegenseitiger gerichteter Kanten
Zentralität	Maß für die Bedeutung eines Knotens
Zwischenzentralität	Anteil kürzester Wege durch einen Knoten

D Zeittafel

Von 1736 bis 2026

1736	**Euler: Königsberger Brücken**
1847	Kirchhoff: Bäume in Stromnetzen
1852	Guthrie: Vierfarbenvermutung
1878	Sylvester prägt den Begriff „Graph“
1936	König: erstes Lehrbuch
1956	Ford, Fulkerson: maximaler Fluss
1959	**Dijkstra: kürzeste Wege**
1959	**Erdős, Rényi: Zufallsgraphen**
1967	Milgram: das Kleine-Welt-Experiment
1973	**Granovetter: Die Stärke schwacher Bindungen**
1973	Fiedler: algebraische Zusammenhangszahl
1976	Vierfarbensatz, maschinell bewiesen
1977	Freeman: Zentralitätsmaße
1991	Felleman, Van Essen: Hierarchie des Sehsystems
1995	Molloy, Reed: Konfigurationsmodell
1996	**CoCoMac beginnt in Düsseldorf**
1998	**Watts, Strogatz: Kleine Welten**
1998	Brin, Page: PageRank
1999	**Barabási, Albert: Bevorzugte Anbindung**

2000	Albert u. a.: Robustheit und Verwundbarkeit
2000	Stephan, Zilles, Kötter: ORT
2001	Pastor-Satorras, Vespignani: Epidemien ohne Schwelle
2001	Stephan u. a.: CoCoMac-Methodik
2004	**Newman, Girvan: Modularität**
2004	Kötter: CoCoMac-Zugang und Auswertung
2005	Sporns u. a.: der Begriff „Konnektom“
2007	Fortunato, Barthélemy: Auflösungsgrenze
2008	**Blondel u. a.: Louvain**
2009	Bullmore, Sporns: Netzwerke im Gehirn
2010	Malewicz u. a.: Pregel
2010	Fortunato: Übersicht Gemeinschaftserkennung
2010	Ahn u. a.: überlappende Gemeinschaften über Kanten
2010	Sporns: *Networks of the Brain*
2011	CoCoMac 2.0 entsteht
2013	Menschliches Konnektomprojekt: erste Daten
2015	Leiden-Verfahren; Knoteneinbettungen
2019	**Broido, Clauset: Skalenfreiheit ist selten**
2020er	Zeitliche Netze und Hypergraphen
2026	Nullmodelle im Mittelpunkt

E Kommentierte Quellen

[1] Ahn, Y.-Y., Bagrow, J., Lehmann, S.: *Link Communities Reveal Multiscale Complexity in Networks*. Nature 466, 2010.

Löst das Problem überlappender Gemeinschaften durch einen Perspektivwechsel: Man gruppiert nicht die Knoten, sondern die Kanten. Ein Knoten kann dann zu mehreren Gruppen gehören, ohne dass die Definition dafür eigens erweitert werden muss.

[2] Albert, R., Jeong, H., Barabási, A.-L.: *Error and Attack Tolerance of Complex Networks*. Nature 406, 2000.

Zeigte, dass Netze mit schwerer Gradverteilung gegen zufällige Ausfälle sehr robust und gegen gezielte Angriffe auf die stärksten Knoten sehr verwundbar sind. Ein Ergebnis, das über die Netzwerkforschung hinaus gewirkt hat.

[3] Barabási, A.-L.: *Network Science*. Cambridge University Press 2016.

Der beste Einstieg. *Frei im Netz verfügbar, reich bebildert und didaktisch sorgfältig aufgebaut. Bei den strittigen Punkten, vor allem der Skalenfreiheit, sollte man die Gegenposition daneben lesen.*

[4] Barabási, A.-L., Albert, R.: *Emergence of Scaling in Random Networks*. Science 286, 1999.

Das Modell der bevorzugten Anbindung: Wer schon viele Verbindungen hat, bekommt neue mit höherer Wahrscheinlichkeit. Drei Seiten, die ein Forschungsgebiet ausgelöst haben.

[5] Blondel, V., Guillaume, J.-L., Lambiotte, R., Lefebvre, E.: *Fast Unfolding of Communities in Large Networks*. J. Stat. Mech. 2008.

Das Louvain-Verfahren. Ein gieriges Verfahren, das die Modularität schrittweise erhöht und Gruppen dann zu Knoten verschmilzt. Erstaunlich einfach und schnell genug für Netze mit Milliarden Kanten.

[6] Broido, A., Clauset, A.: *Scale-Free Networks are Rare*. Nature Communications 10, 2019.

Prüfte fast tausend Netzwerke mit strengen statistischen Verfahren und fand, dass nur wenige die Behauptung tragen. Methodisch vorbildlich und ein Lehrstück darüber, wie man eine verbreitete Aussage prüft, statt sie weiterzureichen.

[7] Bullmore, E., Sporns, O.: *Complex Brain Networks: Graph Theoretical Analysis of Structural and Functional Systems*. Nature Reviews Neuroscience 10, 2009.

Die meistzitierte Übersicht zur Netzwerkanalyse des Gehirns. Führt die Maße ein und benennt zugleich die methodischen Vorbehalte, was in dieser Literatur nicht selbstverständlich ist.

[8] Chung, F.: *Spectral Graph Theory*. American Mathematical Society 1997.

Die maßgebliche mathematische Darstellung. Anspruchsvoll und ohne Anwendungsbezug, dafür vollständig und sauber. Wer wissen will, warum die spektralen Verfahren funktionieren, findet die Antwort hier.

[9] Cormen, T., Leiserson, C., Rivest, R., Stein, C.: *Introduction to Algorithms*. 4. Aufl., MIT Press 2022.

Das Standardwerk für die algorithmische Seite: Durchmusterung, kürzeste Wege, Flüsse, mit Beweisen und Aufwandsanalysen. Auch in Band 1 dieser Reihe die Hauptquelle.

[10] Dijkstra, E.: *A Note on Two Problems in Connexion with Graphs*. Numerische Mathematik 1, 1959.

Drei Seiten für zwei Verfahren, die jeder kennt. Dijkstra hat später erzählt, er habe den Algorithmus in zwanzig Minuten in einem Café entworfen, ohne Papier, was der Klarheit sichtlich gutgetan hat.

[11] Erdős, P., Rényi, A.: *On Random Graphs I*. Publicationes Mathematicae 6, 1959.

Begründete die Theorie der Zufallsgraphen und entdeckte den scharfen Übergang zur ausgedehnten Komponente bei mittlerem Grad eins. Bis heute das erste Nullmodell, gegen das man prüft, und meist das falsche.

[12] Felleman, D., Van Essen, D.: *Distributed Hierarchical Processing in the Primate Cerebral Cortex*. Cerebral Cortex 1, 1991.

Die berühmte Hierarchie des Sehsystems, aus anatomischen Verbindungsdaten hergeleitet. Ein frühes und einflussreiches Beispiel dafür, aus einer Verbindungsmatrix eine Ordnung zu gewinnen, und ein Vorläufer von CoCoMac.

[13] Fiedler, M.: *Algebraic Connectivity of Graphs*. Czechoslovak Mathematical Journal 23, 1973.

Zeigte, dass der zweitkleinste Eigenwert der Laplace-Matrix den Zusammenhang misst und dass der zugehörige Eigenvektor den Graphen sinnvoll zerteilt. Die Grundlage der spektralen Verfahren.

[14] Ford, L., Fulkerson, D.: *Maximal Flow Through a Network*. Canadian Journal of Mathematics 8, 1956.

Der Satz über maximalen Fluss und minimalen Schnitt. Ein Ergebnis von seltener Eleganz: Zwei völlig verschiedene Fragen haben stets dieselbe Antwort.

[15] Fortunato, S.: *Community Detection in Graphs*. Physics Reports 486, 2010.

Über hundert Seiten Übersicht über die Verfahren zur Gemeinschaftserkennung und über ihre Bewertung. Sagt deutlich, dass es keinen einheitlichen Begriff gibt, und ordnet die Ansätze danach, was sie eigentlich suchen.

[16] Fortunato, S., Barthélemy, M.: *Resolution Limit in Community Detection*. PNAS 104, 2007.

Zeigte, dass die Modularitätsoptimierung Gruppen unterhalb einer Größe, die von der Gesamtzahl der Kanten abhängt, grundsätzlich nicht finden kann. Ein Ergebnis, das viele veröffentlichte Analysen im Nachhinein fragwürdig macht.

[17] Freeman, L.: *A Set of Measures of Centrality Based on Betweenness*. Sociometry 40, 1977.

Führte die Zwischenzentralität ein und ordnete die Zentralitätsmaße systematisch. Aus der Soziologie kommend und bis heute die Grundlage für die Frage, was „wichtig“ in einem Netz bedeuten kann.

[18] Granovetter, M.: *The Strength of Weak Ties*. American Journal of Sociology 78, 1973.

Einer der meistzitierten Aufsätze der Sozialwissenschaften. Die Kanten zwischen Gruppen tragen die neuen Informationen, weil innerhalb einer Gruppe ohnehin alle dasselbe wissen. Ein struktureller Befund mit sehr konkreten Folgen.

[19] Kötter, R.: *Online Retrieval, Processing, and Visualization of Primate Connectivity Data from the CoCoMac Database*. Neuroinformatics 2, 2004.

Beschreibt den Zugang zur Datenbank und die Auswertungswerkzeuge. Zeigt, wie aus etwa vierzigtausend Einzelbefunden aus hunderten Veröffentlichungen eine auswertbare Verbindungsmatrix wird und welche Entscheidungen dabei getroffen werden müssen.

[20] Malewicz, G., Austern, M., Bik, A., u. a.: *Pregel: A System for Large-Scale Graph Processing*. SIGMOD 2010.

Führte das Modell ein, aus Sicht eines einzelnen Knotens zu rechnen, mit Nachrichten und Runden. Bemerkenswert schlicht und die Grundlage fast aller späteren Systeme dieser Art.

[21] Milgram, S.: *The Small World Problem*. Psychology Today 1, 1967.

Das Experiment mit den weitergereichten Briefen, aus dem die Rede von den sechs Schritten entstand. Die tatsächliche Rücklaufquote war gering, und der Aufsatz ist auch als Lehrstück über die Verselbständigung einer Zahl lesenswert.

[22] Molloy, M., Reed, B.: *A Critical Point for Random Graphs with a Given Degree Sequence*. Random Structures & Algorithms 6, 1995.

Begründete das Konfigurationsmodell, also den Zufallsgraphen mit vorgegebener Gradfolge. Damit steht das Nullmodell zur Verfügung, gegen das man in den meisten Fällen prüfen sollte.

[23] Newman, M.: *Networks*. 2. Aufl., Oxford University Press 2018.

Das maßgebliche Lehrbuch. *Verbindet die mathematische und die empirische Seite, ist bei den Nullmodellen und der Statistik besonders sorgfältig und behandelt die Verfahren mit vollständigen Herleitungen. Wenn Sie ein Buch kaufen, dann dieses.*

[24] Newman, M., Girvan, M.: *Finding and Evaluating Community Structure in Networks*. Physical Review E 69, 2004.

Führte die Modularität ein, also den Vergleich der Kantendichte innerhalb der Gruppen mit dem, was bei zufälliger Verschaltung zu erwarten wäre. Das Nullmodell steckt hier schon in der Definition des Gütemaßes.

[25] Pastor-Satorras, R., Vespignani, A.: *Epidemic Spreading in Scale-Free Networks*. Physical Review Letters 86, 2001.

Zeigte, dass in Netzen mit sehr breiter Gradverteilung die Epidemieschwelle verschwindet: Eine Ausbreitung erlischt dann nicht mehr von selbst, gleichgültig wie klein die Ansteckungswahrscheinlichkeit ist.

[26] Sporns, O.: *Networks of the Brain*. MIT Press 2010.

Die Gesamtdarstellung der Netzwerkanalyse des Gehirns, von den anatomischen Grundlagen bis zu den Kennzahlen. Sporns hat den Begriff „Konnektom" mitgeprägt und ordnet das Gebiet sorgfältig ein.

[27] Stephan, K., Kamper, L., Bozkurt, A., Burns, G., Young, M., Kötter, R.: *Advanced Database Methodology for the Collation of Connectivity Data on the Macaque Brain (CoCoMac)*. Phil. Trans. R. Soc. B 356, 2001.

Die Methodik hinter CoCoMac: Wie stellt man widersprüchliche Befunde aus hunderten Arbeiten nebeneinander, wie bewertet man ihre Zuverlässigkeit, und wie rechnet man zwischen unverträglichen Hirnkarten um? Die zugehörige ORT-Arbeit von Stephan, Zilles und Kötter (2000) sollte man daneben lesen. ***Ein Musterbeispiel dafür, dass die Datenaufbereitung schwieriger ist als die Analyse.***

[28] Watts, D., Strogatz, S.: *Collective Dynamics of Small-World Networks*. Nature 393, 1998.

Zwei Seiten, die ein Gebiet begründeten. Zeigen, dass wenige zufällige Umverdrahtungen in einem regelmäßigen Netz die Weglänge einbrechen lassen, während das Clustering hoch bleibt. Der einfachste denkbare Nachweis, dass reale Netze zwischen Ordnung und Zufall liegen.

Wenn Sie nur drei Bücher kaufen

[23]	**Newman**	Zum Lernen und Nachschlagen. Mathematisch sauber und empirisch redlich
[3]	**Barabási**	Zum Einstieg. Frei verfügbar und anschaulich
[26]	**Sporns**	Für die Anwendung auf das Gehirn

Wer danach noch etwas möchte: [28] Watts und Strogatz sowie [18] Granovetter sind zusammen zwanzig Seiten und gehören zum Bildungskanon. [6] Broido und Clauset ändern die Art, wie man Behauptungen über Netzwerke liest.