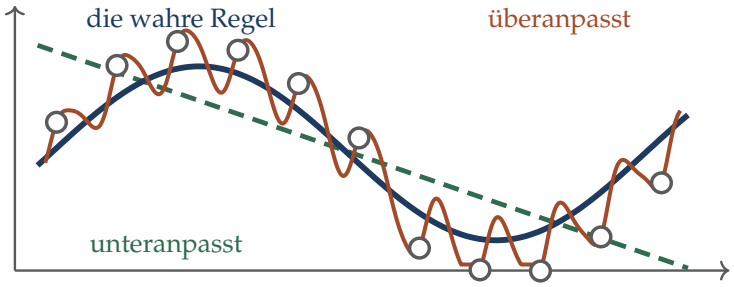
Informatik von Grund auf — Band 13

Der Schluss aus dem Beispiel

Eine vollständige Einführung in das maschinelle Lernen



Von der Anpassung bis zur Verallgemeinerung

Jeder Schritt erklärt. Mit vollständig durchgerechneten Übungsaufgaben.

Informatik von Grund auf — Band 13
Der Schluss aus dem Beispiel · Maschinelles Lernen

Herausgeber und Urheber: Jürgen Maier
Entstanden 2026 in Zusammenarbeit mit Claude (Anthropic); Konzeption, Vorgaben, Prüfung und Herausgeberschaft: Jürgen Maier.

Lizenz
Dieses Werk ist lizenziert unter einer Creative-Commons-Lizenz **Namensnennung – Weitergabe unter gleichen Bedingungen 4.0 International (CC BY-SA 4.0)**. Sie dürfen das Werk vervielfältigen, verbreiten, bearbeiten und auch kommerziell nutzen, sofern Sie den Urheber nennen und Bearbeitungen unter derselben Lizenz weitergeben.
Lizenztext: `https://creativecommons.org/licenses/by-sa/4.0/legalcode.de`

Quellen und Fassungen
Quelltexte, Fehlermeldungen und aktuelle Fassungen aller Bände:
`https://github.com/juergenmaier2026/informatik-von-grund-auf`
Dauerhaft archiviert bei Zenodo: `https://doi.org/10.5281/zenodo.23773283`
Schwesterreihe: *Mathematik von Grund auf*, `https://doi.org/10.5281/zenodo.23698547`

Zitiervorschlag
Maier, J. (2026). *Informatik von Grund auf, Band 13: Der Schluss aus dem Beispiel*. Fassung 1.0.1. `https://doi.org/10.5281/zenodo.23773283`

Satz: LaTeX mit Palatino. Fassung 1.0.1, Oktober 2026. 170 Seiten.

Stand der Forschung: August 2026

Inhaltsverzeichnis

Vorwort 1

I Grundlagen 9

1 Was Lernen heißt 11

2 Anpassen und Verallgemeinern 21

3 Lineare Modelle 29

4 Bäume und Ensembles 37

5 Abstände und Kerne 45

6 Wahrscheinlichkeitsbasierte Verfahren 55

7 Unüberwachtes Lernen 65

II Neuronale Netze 77

8 Netze und Rückpropagierung 79

9 Optimierung im Großen 87

10 Architekturen 95

11 Sprachmodelle 103

III Praxis und Grenzen 111

12 Bewertung 113

13 Fallstricke 123

14 Erklärbarkeit und Kausalität 133

15 Der Stand im Jahr 2026 143

IV Anhang **151**

A Formeln und Zahlen **153**

B Landkarte des Bandes **157**

C Glossar **159**

D Zeittafel **161**

E Kommentierte Quellen **163**

Vorwort: Vom Einzelfall zur Regel

Dieser Band handelt von Programmen, die aus Beispielen eine Regel gewinnen, statt sie vorgeschrieben zu bekommen. *Er behandelt damit ein Verfahren, das seit zweitausend Jahren als philosophisch fragwürdig gilt und trotzdem funktioniert.*

Das Problem der Induktion

Aus endlich vielen Beobachtungen folgt logisch keine allgemeine Regel.

	Deduktion	**Induktion**
Richtung	Regel → Fall	**Fälle → Regel**
Sicherheit	zwingend	nie zwingend
Neues Wissen	keines	ja
Band	12	**13**

> *Der Tausch ist unvermeidlich. Ein deduktiver Schluss ist sicher und sagt nichts Neues; ein induktiver sagt etwas Neues und ist nie sicher. Wer aus Daten lernen will, muss die Unsicherheit in Kauf nehmen.*

Warum trotzdem etwas herauskommt.

Die Bedingung	Man muss vorher festlegen, welche Regeln überhaupt in Frage kommen
Der Name dafür	Induktive Verzerrung: die Annahmen, die man mitbringt
Ohne sie	Zu jedem Datensatz passen unendlich viele Regeln gleich gut, und keine ist ausgezeichnet

> *Das Titelbild dieses Bandes zeigt es. Alle drei Kurven passen zu den Messpunkten; die dritte sogar exakt. Welche man wählt, entscheidet nicht die Datenlage, sondern die Annahme darüber, wie glatt die gesuchte Regel sein sollte.*

Damit ist die Kernfrage dieses Bandes gestellt. Sie lautet nicht „wie passe ich ein Modell an die Daten an“, sondern „wie verhindere ich, dass es sich zu gut anpasst“.

Die Umkehrung zu Band 12

Beide Bände behandeln dasselbe Ziel mit entgegengesetzten Mitteln und entgegengesetzten Schwächen.

	Band 12	Band 13
Wissen kommt	von Hand	**aus Daten**
Ergebnis	exakt, erklärbar	**ungefähr, undurchsichtig**
Versagt	am Rand des Gebiets	**bei verschobener Verteilung**
Fehlerart	fehlende Regel	**falsche Zuversicht**
Engpass	Wissenserwerb	**Datenqualität**
Garantien	logisch	statistisch, im Mittel

Die vierte Zeile ist die unangenehmste. Ein Regelsystem, das eine Regel nicht hat, findet nichts und schweigt. Ein lernendes System hat immer eine Antwort und gibt keinen Hinweis darauf, ob die Frage außerhalb seines Erfahrungsbereichs lag.

Was das Verfahren voraussetzt.

Gleiche Verteilung	Die künftigen Fälle stammen aus derselben Quelle wie die Beispiele
Genug Beispiele	Im Verhältnis zur Freiheit des Modells
Verwertbare Merkmale	Die Antwort muss aus dem Vorliegenden überhaupt erschließbar sein
Stabile Welt	Die Regel darf sich nicht ändern, während man sie lernt

Die erste Bedingung ist die wichtigste und die am häufigsten verletzte. Kapitel 12 und 13 zeigen, wie oft ein Modell in der Erprobung glänzt und im Einsatz versagt, weil sich die Verteilung verschoben hat.

Was dieses Buch will

Erstens: Die Verfahren durchrechnen.
Kleinste Quadrate, Gradientenabstieg, Entscheidungsbäume, Rückpropagierung und Aufmerksamkeit werden an kleinen Beispielen von Hand ausgeführt. Wer die Rückpropagierung einmal mit Bleistift durch drei Schichten geschoben hat, wird sie nie wieder für Magie halten.

Zweitens: Die Bewertung ernst nehmen.

> *Ein Modell zu bauen ist leicht. Herauszufinden, ob es taugt, ist schwer und wird routinemäßig falsch gemacht. Kapitel 12 behandelt Metriken, Datenlecks und Kalibrierung, und Kapitel 13 sammelt die Fälle, in denen ein gefeiertes Ergebnis sich später auflöste.*

Drittens: Die Verbindung zu den vorigen Bänden zeigen.

Band	Bezug	Kapitel
4	Matrizen, Rechenwerke	9
7	**Verdichten = Vorhersagen**	11
9	verteiltes Training	9
11	Einbettungen	7
12	Suche als Optimierung	9

Die zweite Zeile ist die tiefste Verbindung. Ein Sprachmodell ist ein Vorhersager, und Band 7 hat gezeigt, dass ein Vorhersager unmittelbar ein Verdichter ist. Wer gut verdichtet, hat etwas verstanden, und diese Gleichsetzung trägt weiter, als sie zunächst aussieht.

Drei Warnungen

Erstens: Ein gutes Ergebnis auf den Erprobungsdaten heißt nichts.
Wer die Erprobungsdaten mehrfach benutzt, um Modelle auszuwählen, hat sie zu Trainingsdaten gemacht. Die gemessene Güte ist dann zu hoch, und niemand merkt es.
Zweitens: Zahlen ohne Vergleich sind wertlos.

> *Eine Trefferquote von 94 Prozent klingt gut und ist bei einer Klasse, die in 94 Prozent der Fälle vorliegt, genau so viel wert wie Raten. Es ist dieselbe Forderung nach einem Nullmodell wie in Band 11.*

Drittens: Das Verfahren ist der kleinste Teil der Arbeit.
Der Aufwand liegt beim Beschaffen, Prüfen und Ordnen der Daten, beim Bewerten und beim Betrieb. Der Modellaufruf selbst sind wenige Zeilen.

Zum Aufbau

- **Teil I** (Kap. 1–3): Grundlagen. Was Lernen heißt, Anpassung und Verallgemeinerung, lineare Modelle.
- **Teil II** (Kap. 4–7): Klassische Verfahren. Bäume und Ensembles, Abstands- und Kernverfahren, wahrscheinlichkeitsbasierte Verfahren, unüberwachtes Lernen.
- **Teil III** (Kap. 8–11): Neuronale Netze. Rückpropagierung, Optimierung im Großen, Architekturen, Sprachmodelle.
- **Teil IV** (Kap. 12–15): Praxis und Grenzen. Bewertung, Fallstricke, Erklärbarkeit und Kausalität, und der Stand im Jahr 2026.

Ein Verfahren, das zweimal aufgegeben wurde

1958 stellte FRANK ROSENBLATT das Perzeptron vor: eine Maschine, die aus Beispielen lernte, Muster zu unterscheiden. Die *New York Times* berichtete, die Marine erwarte eine Maschine, die gehen, sprechen, sehen und sich ihrer selbst bewusst sein werde.

Jahr	Ereignis	Folge
1958	Perzeptron	große Erwartungen
1969	**Minsky, Papert**	**Kritik, Mittel versiegen**
1974	Werbos	Rückpropagierung, kaum beachtet
1986	**Rumelhart u. a.**	**Wiederentdeckung**
1995	Vapnik u. a.	Stützvektoren verdrängen Netze
2012	**AlexNet**	**zweite Wiederkehr**

MINSKY *und* PAPERT *zeigten 1969, dass ein einschichtiges Perzeptron das Exklusiv-Oder nicht lernen kann. Das war mathematisch richtig und wurde als Urteil über neuronale Netze überhaupt gelesen. Dass mehrschichtige Netze die Beschränkung nicht haben, war bekannt; es fehlte ein Verfahren, sie zu trainieren.*

Warum es dreimal erfunden werden musste.

Jahr	Wer	Warum folgenlos
1970	Linnainmaa	als numerisches Verfahren, ohne Bezug zur KI
1974	Werbos	Doktorarbeit, kaum verbreitet
1986	Rumelhart u. a.	diesmal mit Beispielen und Publikum

Die Rückpropagierung ist im Kern die Kettenregel der Differentialrechnung, systematisch angewandt. Dass sie mehrfach unabhängig gefunden wurde, überrascht deshalb nicht. Dass sie zweimal ohne Wirkung blieb, sagt mehr über die Aufnahmebereitschaft eines Faches als über die Idee.

Was 2012 anders war.

Zutat	1986	2012
Verfahren	vorhanden	unverändert
Daten	10^3 Bilder	$1{,}2 \cdot 10^6$
Rechenleistung	10^7 Op/s	10^{12} **Op/s**
Ergebnis	mäßig	**Durchbruch**

Das Verfahren war seit sechsundzwanzig Jahren dasselbe. Was fehlte, waren Daten und Rechenleistung, und beide kamen von außerhalb des Fachs: die Daten aus dem Netz, die Rechenleistung aus der Spieleindustrie. Die Grafikkarten aus Band 4 waren für Bildpunkte gebaut und rechneten zufällig genau die Matrixprodukte, die ein Netz braucht.

Es ist eine der lehrreichsten Episoden der Informatikgeschichte: Eine Idee war nicht falsch, sondern verfrüht, und niemand konnte das damals unterscheiden.

Siebzig Jahre lernende Systeme

1943	McCulloch, Pitts	formales Neuron
1949	Hebb	Lernregel
1958	**Rosenblatt**	**Perzeptron**
1959	Samuel	lernendes Dameprogramm
1967	Cover, Hart	Nächste-Nachbarn-Verfahren
1969	**Minsky, Papert**	**Grenzen des Perzeptrons**
1970	Linnainmaa	automatisches Differenzieren
1974	Werbos	Rückpropagierung
1977	Dempster u. a.	EM-Verfahren
1979	Fukushima	Neocognitron
1984	Breiman u. a.	Entscheidungsbäume
1986	**Rumelhart, Hinton, Williams**	**Rückpropagierung wirksam**
1989	Cybenko	Netze sind universelle Näherer
1994	Bengio u. a.	verschwindende Gradienten
1995	**Cortes, Vapnik**	**Stützvektormaschinen**
1996	Breiman	Bagging
1997	**Hochreiter, Schmidhuber**	**LSTM**
1998	LeCun u. a.	Faltungsnetze für Ziffern

2001	**Breiman**	**Random Forests; Die zwei Kulturen**
2001	Friedman	Gradientenverstärkung
2006	Hinton, Salakhutdinov	schichtweises Vortrainieren
2009	ImageNet	1,2 Millionen beschriftete Bilder
2012	**Krizhevsky u. a.**	**AlexNet**
2014	Goodfellow u. a.	erzeugende Gegenspieler
2015	Ioffe, Szegedy	Stapelnormalisierung
2015	He u. a.	Restverbindungen
2015	Kingma, Ba	Adam
2015	Sculley u. a.	versteckte technische Schulden
2017	**Vaswani u. a.**	**Aufmerksamkeit genügt**
2020	**Kaplan u. a.**	**Skalierungsgesetze**
2022	Anweisungs-abstimmung	Modelle werden benutzbar
2023–26	Größe und Effizienz	Modelle, Werkzeuge, Löser
2026	—	Bewertung als Engpass

Zwei Zeilen verdienen eine Anmerkung.
2001, Breiman. LEO BREIMAN veröffentlichte im selben Jahr die Random Forests und einen Aufsatz über die zwei Kulturen der Datenanalyse. Seine These: Die Statistik sucht Modelle, die die Wirklichkeit beschreiben; das maschinelle Lernen sucht Verfahren, die gut vorhersagen. Beide Ziele fallen nicht zusammen, und Kapitel 14 geht dem nach.
2020, Skalierungsgesetze. Der Befund, dass Verlust und Modellgröße über viele Größenordnungen einem Potenzgesetz folgen, hat die Forschungspraxis verändert: Man konnte vorhersagen, was ein größeres Modell leisten würde, ohne es zu bauen.

Alle Modelle sind falsch, manche sind nützlich.
Die Frage ist nie, ob ein Modell wahr ist,
sondern wie falsch es sein darf,
ohne unbrauchbar zu werden.

— nach GEORGE BOX, 1976.
Für dieses Gebiet gilt der Satz doppelt: Ein Modell,
das die Trainingsdaten exakt trifft, ist meist das nutzloseste.

Part I

Grundlagen

1 Was Lernen heißt

Eine brauchbare Definition

TOM MITCHELL gab 1997 eine Definition, die operationalisierbar ist und deshalb nützlicher als jede philosophische.

> *Ein Programm lernt aus Erfahrung E bezüglich einer Aufgabenklasse T und eines Gütemaßes P, wenn seine an P gemessene Leistung bei Aufgaben aus T mit wachsender Erfahrung E steigt.*

Anwendung	T	P	E
Schrift-erkennung	Ziffer bestimmen	Trefferquote	beschriftete Bilder
Diagnose	Befund bewerten	**was genau?**	Kranken-akten
Empfehlung	Vorschlag machen	Klicks? Zufrie-denheit?	Verlauf

Die dritte Spalte ist die schwierige. Sie zwingt dazu, das Ziel als Zahl auszudrücken, und diese Zahl bestimmt danach alles. Ein Empfehlungssystem, das auf Klicks optimiert wird, lernt, Aufmerksamkeit zu erregen, und nicht, nützlich zu sein. Das ist kein Fehler des Verfahrens, sondern eine genaue Erfüllung der Vorgabe.

Die drei Grundformen.

Form	**Gegeben**	**Gesucht**
Überwacht	Paare (x, y)	Abbildung $x \mapsto y$
Unüberwacht	nur x	**Struktur in den Daten**
Verstärkend	Belohnung nach Handlungen	Handlungsstrategie

Die zweite Zeile ist die unschärfste. „Struktur" ist kein wohldefinierter Begriff, und deshalb lässt sich unüberwachtes Lernen schwer bewerten. Kapitel 7 kommt darauf zurück.

Induktive Verzerrung

Ohne Annahmen ist Lernen unmöglich. Das lässt sich beweisen.
Der Kern des Arguments.

1.	Es gebe n mögliche Eingaben, davon m beobachtet.
2.	Für die $n - m$ unbeobachteten gibt es 2^{n-m} mögliche Zuordnungen.
3.	Alle sind mit den Beobachtungen verträglich.
4.	Ohne Zusatzannahme ist keine ausgezeichnet.

n	m	**verträgliche Regeln**	
16	8	256	
100	50	$1{,}1 \cdot 10^{15}$	
2^{20}	10^4	2^{10^6}	unvorstellbar

Die Daten schränken den Raum der Möglichkeiten ein und legen ihn nie fest. Was übrig bleibt, wählt die induktive Verzerrung aus, und ohne sie wählt man gar nichts.

Was verschiedene Verfahren annehmen.

Lineare Modelle	Der Zusammenhang ist linear
Nächste Nachbarn	Ähnliche Eingaben haben ähnliche Ausgaben
Entscheidungs-bäume	Wenige Merkmale genügen, achsenparallele Schnitte
Faltungsnetze	Örtliche Nähe zählt, Verschiebung ändert nichts
Regularisierung	Einfachere Regeln sind wahrscheinlicher richtig

Die vierte Zeile erklärt, warum Faltungsnetze bei Bildern so viel besser sind als allgemeine Netze: Sie bringen die richtige Annahme mit. Bei Daten ohne örtliche Struktur wäre dieselbe Annahme ein Nachteil.

Kein Verfahren ist allgemein das beste

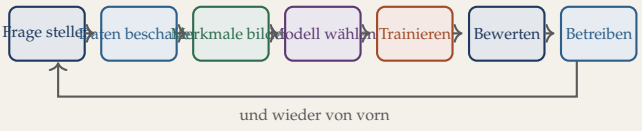
Über alle möglichen Zielfunktionen gemittelt sind alle Lernverfahren gleich gut. Es ist derselbe Satz wie in Band 12, Kapitel 5.

Falsche Lesart	Die Wahl des Verfahrens ist gleichgültig
Richtige Lesart	**Jedes Verfahren passt zu bestimmten Aufgaben**, und man muss wissen, zu welchen

Die Mittelung läuft über alle denkbaren Zusammenhänge, einschließlich reinen Rauschens. Reale Aufgaben sind kein Rauschen: Sie haben Glätte, Lokalität, Hierarchie. Ein Verfahren ist genau dann gut, wenn seine Verzerrung diese Eigenschaften trifft.

Praktisch folgt daraus eine Reihenfolge: Zuerst überlegt man, welche Struktur die Aufgabe hat, dann wählt man ein Verfahren. Wer umgekehrt vorgeht und alle Verfahren durchprobiert, bewertet am Ende Rauschen (Kapitel 12).

Der Ablauf einer Lernaufgabe



Schritt	Zeitanteil	Beachtung
Frage stellen	5 %	gering
Daten beschaffen und säubern	**50** %	sehr gering
Merkmale bilden	20 %	gering
Modell wählen und trainieren	10 %	fast alle
Bewerten	10 %	gering
Betreiben	5 %	sehr gering

Das Missverhältnis zwischen der zweiten und der vierten Spalte durchzieht das ganze Gebiet. Die Lehrbücher, die Vorträge und die Aufmerksamkeit gelten dem Schritt, der ein Zehntel der Arbeit ausmacht.

Der Rückpfeil ist nicht Zierde. Fast immer stellt sich beim Bewerten heraus, dass die Frage falsch gestellt oder die Daten unpassend waren, und man beginnt von vorn. Wer den ersten Durchlauf für den einzigen hält, plant falsch.

Aufgabe 1.1.

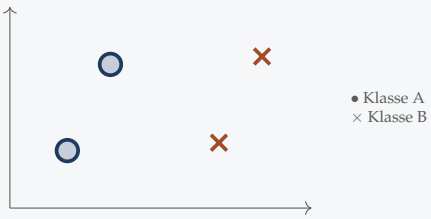
(a) Bestimmen Sie die induktive Verzerrung dreier Verfahren an denselben Daten.

(b) Rechnen Sie aus, wie viele Beispiele nötig sind.

(c) Untersuchen Sie, was ein schlecht gewähltes Gütemaß anrichtet.

Lösung Schritt für Schritt.

(a) Dieselben Daten, drei Verzerrungen.
Die Daten. Vier Punkte in der Ebene, zwei Klassen.



Verfahren	Trennfläche	Vorhersage bei (2,3; 3,0)
Lineares Modell	senkrechte Gerade	**A**
Nächster Nachbar	Zellgrenzen	**A**
Entscheidungs-baum	Achsenschnitt bei $x = 2{,}3$	**unbestimmt**

Alle drei erklären die vier Beispiele vollständig richtig und geben bei einem neuen Punkt am Rand verschiedene Antworten. Die Daten entscheiden nicht; die Annahme entscheidet.

Wo sie auseinandergehen.

Testpunkt	linear	Nachbar	Baum
(1,2; 1,5)	A	A	A
(3,4; 1,8)	B	B	B
(2,3; 0,2)	A	A	A
(2,3; 5,0)	**A**	A	A
(0,1; 1,0)	A	A	A
(6,0; 1,0)	B	B	B

Bei diesen sechs Punkten stimmen alle überein, weil sie weit von der Grenze liegen. Der Unterschied zeigt sich nur nahe der Trennfläche und weit außerhalb des Datenbereichs — genau dort, wo man die Vorhersage am wenigsten prüfen kann.

(b) Wie viele Beispiele nötig sind.
Der Ansatz. Für eine endliche Menge H möglicher Modelle gilt: Um mit Wahrscheinlichkeit $1 - \delta$ einen Fehler unter ε zu erreichen, genügen

$$m \geq \frac{1}{\varepsilon}\left(\ln |H| + \ln \frac{1}{\delta}\right).$$

Ein Beispiel. Konjunktionen über n binäre Merkmale. Jedes Merkmal kann vorkommen, negiert vorkommen oder fehlen:

$$|H| = 3^n.$$

n	$\lvert H\rvert$	$\ln \lvert H\rvert$	m bei $\varepsilon{=}0{,}05$
10	$5{,}9 \cdot 10^{4}$	11,0	280
30	$2{,}1 \cdot 10^{14}$	33,0	720
100	$5 \cdot 10^{47}$	109,9	2260
1000	10^{477}	1098,6	22 050

(jeweils $\delta = 0{,}05$)

> *Bemerkenswert ist, wie sanft die Zahl wächst. Die Zahl der Modelle steigt exponentiell mit n, ihr Logarithmus nur linear, und deshalb steigt der Bedarf an Beispielen ebenfalls nur linear. Das ist die entscheidende Eigenschaft: Man braucht Beispiele proportional zur* Beschreibungslänge *des Modells, nicht zur Zahl der Modelle.*

Der Zusammenhang zu Band 7 ist unmittelbar: $\ln \lvert H\rvert$ ist bis auf einen Faktor die Entropie einer Gleichverteilung über H, also die Zahl der bit, die man braucht, um ein Modell zu benennen. Wer ein Modell mit k bit beschreiben kann, braucht etwa k/ε Beispiele.

Bei unendlich vielen Modellen.

Modellklasse	**VC-Dimension**	**Bedarf $\approx$**
Gerade in der Ebene	3	≈ 100
Hyperebene in $\mathbb{R}^d$	$d+1$	$\approx 20(d{+}1)$
Intervall auf der Geraden	2	≈ 60
Neuronales Netz, p Gewichte	$\approx p \log p$	sehr groß

> *Die letzte Zeile ist der Punkt, an dem die klassische Theorie an ihre Grenze kommt. Heutige Netze haben mehr Parameter als Trainingsbeispiele und verallgemeinern trotzdem. Kapitel 2 behandelt diesen offenen Befund.*

(c) Ein schlecht gewähltes Gütemaß.

Der Fall. Ein System soll erkennen, welche Wartungsmeldungen dringend sind. Zwei Prozent sind es.

Gütemaß 1 – Trefferquote.

Modell	Trefferquote	Nutzen
„Nie dringend“	**98** %	null
Sorgfältiges Modell	96 %	hoch

Das nutzlose Modell gewinnt. Bei ungleich verteilten Klassen ist die Trefferquote irreführend, und zwar umso mehr, je seltener die interessante Klasse ist.

Gütemaß 2 – Kosten einbeziehen.

Fehlerart	Kosten	
Dringendes übersehen	50 000	Ausfall
Unnötig geprüft	200	Arbeitszeit
Verhältnis	**250 : 1**	

Modell	übersehen	unnötig	Kosten
„Nie dringend“	200	0	$\mathbf{10^7}$
Sorgfältig	20	380	$\mathbf{1{,}08 \cdot 10^6}$
Vorsichtig	4	1500	$\mathbf{5 \cdot 10^5}$

(bei 10 000 *Meldungen, davon* 200 *dringend)*

Die Reihenfolge dreht sich vollständig um. Das vorsichtige Modell prüft viermal so viel unnötig und ist trotzdem doppelt so gut, weil die eine Fehlerart zweihundertfünfzigmal teurer ist als die andere.

Die allgemeine Lehre.

Das Gütemaß	ist keine technische Größe, sondern eine Entscheidung darüber, was zählt
Wer es festlegt	sollte derjenige sein, der die Folgen trägt
Wann	**vor** dem Trainieren, nicht danach

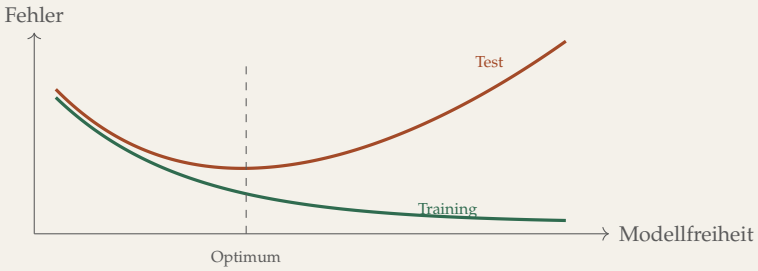
Die dritte Zeile ist eine methodische Forderung mit derselben Begründung wie die Vorabfestlegung in Band 11: Wer das Maß nachträglich wählt, wählt dasjenige, unter dem sein Modell am besten aussieht.

Mitchell[20] gab die operationale Definition; Domingos[7] fasst die praktischen Einsichten des Gebiets auf zehn Seiten zusammen; Shalev-Shwartz und Ben-David[26] behandeln die Lerntheorie streng.

2 Anpassen und Verallgemeinern

Zwei Fehler, die man auseinanderhalten muss

Trainingsfehler	Wie gut das Modell die gesehenen Beispiele trifft
Verallgemeinerungsfehler	Wie gut es künftige Fälle trifft
Die Lücke	Die Differenz; sie ist das eigentliche Problem



Der Trainingsfehler fällt monoton, der Testfehler nicht. Links vom Minimum ist das Modell zu starr und trifft nicht einmal die Trainingsdaten; rechts davon lernt es das Rauschen mit. Beide Fehlerarten sehen im Trainingsfehler gleich aus, und deshalb ist er als Maß wertlos.

Die Zerlegung des Fehlers.
Für den quadratischen Fehler lässt sich der erwartete Testfehler exakt zerlegen:

$$\mathbb{E}\left[(y-\hat{f}(x))^2\right] = \underbrace{\left(\mathbb{E}[\hat{f}(x)]-f(x)\right)^2}_{\text{Verzerrung}^2} + \underbrace{\operatorname{Var}[\hat{f}(x)]}_{\text{Streuung}} + \underbrace{\sigma^2}_{\text{Rauschen}} .$$

Anteil	Bedeutung	Abhilfe
Verzerrung	Das Modell kann die Regel nicht darstellen	**mehr Freiheit**
Streuung	Das Modell hängt zu stark an der Stichprobe	**weniger Freiheit, mehr Daten**
Rauschen	Nicht erklärbarer Anteil	keine

Die dritte Zeile ist die Untergrenze. Kein Modell kann besser sein als das Rauschen erlaubt, und wer sie unterschreitet, hat einen Fehler in der Bewertung gemacht — meist ein Datenleck (Kapitel 12).

Regularisierung

Man schränkt die Freiheit des Modells ein, ohne die Modellklasse zu wechseln.

Verfahren	Zusatzterm	Wirkung
Ridge (L_2)	$\lambda \sum w_j^2$	alle Gewichte klein
Lasso (L_1)	$\lambda \sum \lvert w_j \rvert$	**viele Gewichte genau null**
Elastisches Netz	beides	Kompromiss
Frühes Anhalten	—	wirkt wie L_2
Ausdünnen	zufällig Neuronen aus	bei Netzen

Die zweite Zeile ist die interessanteste. Der Betrag hat an der Null eine Ecke, und deshalb liegt das Optimum oft genau dort. Damit wählt das Verfahren nebenbei Merkmale aus, statt nur zu dämpfen.



Die Höhenlinien des Fehlers berühren die Beschränkungsmenge. Bei einer Raute geschieht das meist an einer Ecke, und eine Ecke liegt auf einer Achse: Ein Gewicht ist dann exakt null.

Die klassische Kurve gilt nicht mehr überall

Heutige Netze haben mehr Parameter als Trainingsbeispiele und verallgemeinern trotzdem gut.

Parameter je Beispiel	klassisch erwartet	beobachtet
0,1	gut	gut
1,0	sehr schlecht	schlecht
10	katastrophal	**wieder gut**
1000	katastrophal	**sehr gut**

Der Testfehler steigt bis zum Punkt, an dem das Modell die Daten gerade exakt trifft, und fällt danach wieder. Dieser doppelte Abstieg ist seit 2019 gut belegt und theoretisch nicht abschließend erklärt.

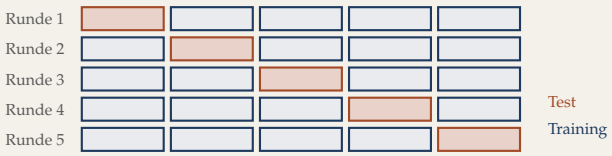
Die verbreitetste Deutung: Bei sehr vielen Parametern gibt es viele exakte Anpassungen, und das Optimierungsverfahren wählt unter ihnen bevorzugt eine glatte. Die Regularisierung steckt dann nicht im Zusatzterm, sondern im Verfahren selbst.

Wie man ehrlich bewertet

Teilmenge	wofür	wie oft benutzt
Training	Parameter anpassen	beliebig
Validierung	Modellwahl, Hyperparameter	oft
Test	**Endgültige Schätzung**	**genau einmal**

Die dritte Zeile wird routinemäßig verletzt. Wer den Testfehler ansieht, ein Modell ändert und wieder ansieht, hat den Test zur Validierung gemacht. Die endgültige Zahl ist dann zu optimistisch, und niemand weiß um wie viel.

Kreuzvalidierung.



Verfahren	Läufe	Datennutzung	Streuung
Einfache Teilung	1	70 %	hoch
5-fach	5	80 %	mittel
10-fach	10	90 %	gering
Auslassen eines	n	$\approx 100\,\%$	hoch, teuer

Die letzte Zeile überrascht: Wer jeweils nur ein Beispiel auslässt, nutzt fast alle Daten und bekommt trotzdem eine hohe Streuung, weil die Trainingsmengen einander fast gleichen und die Schätzungen deshalb stark zusammenhängen.

Aufgabe 2.1.

(a) Zerlegen Sie den Fehler an einem Zahlenbeispiel.
(b) Bestimmen Sie den Regularisierungsparameter durch Kreuzvalidierung.
(c) Untersuchen Sie, wie oft ein Testsatz sich abnutzt.

Lösung Schritt für Schritt.

(a) Fehlerzerlegung.
Die Lage. Die wahre Funktion sei $f(x) = x^2$, das Rauschen habe $\sigma^2 = 0{,}25$. Wir vergleichen drei Modellklassen an der Stelle $x_0 = 2$, also $f(x_0) = 4$.

Modell	$\mathbb{E}[\hat{f}(2)]$	$\mathrm{Var}[\hat{f}(2)]$
Konstante	2,3	0,04
Gerade	3,6	0,18
Parabel	4,0	0,52
Grad 8	4,0	3,80

Die Zerlegung.

Modell	**Verz.^{2}**	**Streu.**	**Rauschen**	**Summe**
Konstante	2,89	0,04	0,25	3,18
Gerade	0,16	0,18	0,25	0,59
Parabel	**0,00**	0,52	0,25	**0,77**
Grad 8	0,00	3,80	0,25	4,05

Bemerkenswert ist die dritte Zeile: Die Parabel ist die richtige *Modellklasse, hat Verzerrung null, und ist trotzdem schlechter als die Gerade. Bei wenigen Daten lohnt es sich, eine falsche, aber stabile Annahme zu treffen.*

Was mehr Daten ändern.

n	**Gerade**	**Parabel**	**Sieger**
10	0,59	0,77	Gerade
30	0,47	0,42	**Parabel**
100	0,43	0,30	Parabel
1000	0,41	0,26	Parabel

Die Streuung fällt mit $1/n$, die Verzerrung nicht. Ab etwa dreißig Beispielen kippt es. Das ist der Grund, warum die Frage nach dem besten Modell ohne Angabe der Datenmenge sinnlos ist.

(b) Den Regularisierungsparameter wählen.
Die Aufgabe. Ridge-Regression, λ ist zu bestimmen. Fünffache Kreuzvalidierung.

λ	**R1**	**R2**	**R3**	**R4**	**R5**
0	1,42	2,10	1,88	1,55	2,31
0,01	1,20	1,74	1,51	1,33	1,86
0,1	0,94	1,18	1,05	1,02	1,21
1	0,88	0,96	0,91	0,93	0,97
10	1,05	1,09	1,07	1,11	1,08
100	1,61	1,63	1,60	1,64	1,62

λ	**Mittel**	**Streuung**	
0	1,852	0,347	
0,01	1,528	0,261	
0,1	1,080	0,104	
1	**0,930**	**0,036**	bestes
10	1,080	0,022	
100	1,620	0,015	

Zwei Beobachtungen. Erstens liegt das Optimum bei $\lambda = 1$. Zweitens fällt die Streuung über die Runden monoton mit λ: Ein stärker regularisiertes Modell hängt weniger von der Stichprobe ab. Genau das ist der Streuungsanteil aus Aufgabe (a), hier unmittelbar messbar.

Die Ein-Standardfehler-Regel.

$$\text{Standardfehler} = \frac{0{,}036}{\sqrt{5}} = 0{,}016. \qquad 0{,}930 + 0{,}016 = 0{,}946.$$

Man wählt das einfachste *Modell, dessen Fehler noch innerhalb eines Standardfehlers vom besten liegt. Hier bleibt es bei $\lambda = 1$, denn $\lambda = 10$ liegt mit* 1,080 *darüber. Bei flacheren Kurven führt die Regel oft zu deutlich stärkerer Regularisierung, und das ist beabsichtigt.*

(c) Wie ein Testsatz sich abnutzt.
Der Fall. Ein Testsatz mit $n = 1000$ Beispielen. Man probiert k Modelle und nimmt das beste.

Die Schwankung. Bei einer wahren Trefferquote von $p = 0{,}80$:

$$\sigma = \sqrt{\frac{p(1-p)}{n}} = \sqrt{\frac{0{,}16}{1000}} = 0{,}0126.$$

Das Maximum von k Schätzungen.

k	**erw. Maximum**	**gemessen**	**Verzerrung**
1	$+0{,}00\sigma$	80,0 %	0,0
10	$+1{,}54\sigma$	81,9 %	**+1,9**
100	$+2{,}51\sigma$	83,2 %	+3,2
1000	$+3{,}24\sigma$	84,1 %	+4,1

Alle k Modelle seien gleich gut, nämlich achtzig Prozent. Wer hundert davon durchprobiert und das beste meldet, meldet 83,2 Prozent. Der Zugewinn ist reines Rauschen, und er wächst mit der Zahl der Versuche.

Warum das schleichend geschieht.

Nicht als Suche empfunden	Man probiert Lernraten, Merkmale, Architekturen einzeln
Über Monate verteilt	Niemand zählt mit
Über Personen verteilt	Ein ganzes Fachgebiet arbeitet am selben Testsatz

Lage	**effektives k**	**Verzerrung**
Eine Person, ein Tag	≈ 20	+2 %
Ein Vorhaben, ein Jahr	$\approx 10^3$	+4 %
Ein Fachgebiet, zehn Jahre	$\approx 10^5$	+5–6 %

Die letzte Zeile erklärt einen wiederkehrenden Befund: Wenn zu einem viel benutzten Vergleichsdatensatz ein frischer Testsatz nach denselben Regeln erhoben wird, fallen die Ergebnisse aller Verfahren um einige Prozentpunkte — die Rangfolge bleibt meist, das Niveau nicht.

Die Abhilfe ist unbequem: einen Testsatz zurückhalten, den niemand sieht, und ihn genau einmal benutzen. Wer das nicht kann, sollte wenigstens die Zahl der Versuche mitteilen, damit sich die Verzerrung abschätzen lässt.

Hastie, Tibshirani und Friedman[11] behandeln die Fehlerzerlegung und die Kreuzvalidierung gründlich; Domingos[7] fasst die praktischen Folgen zusammen; Shalev-Shwartz und Ben-David[26] liefern die Theorie.

3 Lineare Modelle

Warum man hier anfängt

Lineare Modelle sind das einfachste, was über den Mittelwert hinausgeht, und sie sind der Baustein fast aller späteren Verfahren.

Geschlossene Lösung	Man muss nicht suchen, sondern kann rechnen
Deutbar	Jedes Gewicht sagt, wie stark ein Merkmal wirkt
Grundlage	Ein Neuron ist ein lineares Modell mit einer Verzerrung danach
Maßstab	Was ein lineares Modell nicht schlägt, taugt nichts

Die letzte Zeile ist eine methodische Forderung. Wer ein aufwendiges Verfahren einsetzt, ohne den Vergleich mit einer linearen Regression zu zeigen, hat nichts belegt. Erstaunlich oft schneidet das einfache Modell fast gleich gut ab.

Die Kleinste-Quadrate-Lösung.
Gesucht ist w, das $\|Xw - y\|^2$ minimiert. Ableiten und null setzen liefert die Normalgleichungen:

$$X^\top X\, w = X^\top y \quad \Longrightarrow \quad w = (X^\top X)^{-1} X^\top y.$$

Größe	**Aufwand**	**bei $n = 10^6$, $d = 100$**
$X^\top X$ bilden	$\mathcal{O}(nd^2)$	10^{10}
Invertieren	$\mathcal{O}(d^3)$	10^6
Gesamt	$\mathcal{O}(nd^2 + d^3)$	Sekunden

Bei d im Bereich von Tausenden wird der zweite Term unangenehm, und bei $d > n$ ist $X^\top X$ singulär. Beides sind Gründe, statt zu invertieren iterativ vorzugehen — und genau das führt zum Gradientenabstieg.

Die Normalgleichungen sind numerisch heikel

Die Konditionszahl von $X^\top X$ ist das *Quadrat* derjenigen von X.

$\kappa(X)$	$\kappa(X^\top X)$	**verlorene Stellen**	
10^2	10^4	4	unbedenklich
10^6	10^{12}	12	alles
10^8	10^{16}	16	sinnlos

Bei doppelter Genauigkeit hat man etwa sechzehn Stellen. Eine Konditionszahl von 10^8 in den Daten genügt, um das Ergebnis vollständig zu zerstören. Deshalb rechnet man in der Praxis über die QR-Zerlegung, die mit $\kappa(X)$ statt dessen Quadrat auskommt.

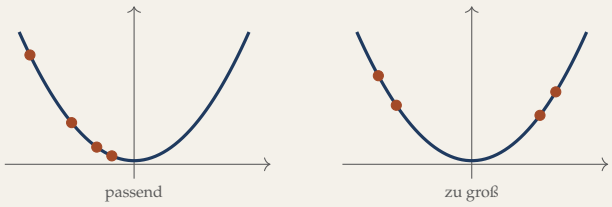
Hohe Konditionszahlen entstehen leicht: Zwei stark korrelierte Merkmale genügen. Die Ridge-Regularisierung aus Kapitel 2 hilft auch hier, denn sie addiert λI und macht die Matrix damit garantiert invertierbar.

Gradientenabstieg

Statt die Lösung zu berechnen, geht man ihr schrittweise entgegen.

$$w_{t+1} = w_t - \eta \, \nabla L(w_t).$$

η **zu klein**	langsam	viele Schritte
η **passend**	zügig	
η **zu groß**	schwingt	über das Ziel hinaus
η **viel zu groß**	divergiert	Werte laufen weg



Die Grenze für die Schrittweite.

Bei einer quadratischen Zielfunktion mit größtem Eigenwert $\lambda_{\max}$ der Hesse-Matrix konvergiert das Verfahren genau dann, wenn

$$\eta < \frac{2}{\lambda_{\max}}.$$

Die Konvergenzgeschwindigkeit hängt dagegen vom Verhältnis $\lambda_{\max}/\lambda_{\min}$ ab, also wieder von der Konditionszahl. Ein lang gestrecktes Tal zwingt zu kleinen Schritten in der steilen Richtung und macht den Fortschritt in der flachen quälend langsam.

κ	**Schritte für 10^{-3}**	
1	≈ 7	sofort
10	≈ 70	
100	≈ 700	
10^4	$\approx 70\,000$	unbrauchbar

Deshalb ist das Standardisieren der Merkmale keine Kosmetik, sondern der wirksamste einzelne Eingriff. Wer Merkmale mit Größenordnungen von 10^{-3} und 10^{6} mischt, erzeugt eine Konditionszahl von 10^{9} und wundert sich, dass nichts konvergiert.

Logistische Regression

Für eine Klassenzuordnung braucht man eine Ausgabe zwischen null und eins.

$$P(y = 1 \mid x) = \sigma(w^{\top} x), \qquad \sigma(z) = \frac{1}{1 + e^{-z}}.$$

	Quadratfehler	**Kreuzentropie**
Zielfunktion	nicht konvex	**konvex**
Gradient	fällt bei Sättigung	bleibt kräftig
Begründung	keine	**Maximum-Likelihood**

$$L = -\sum_{i} \left[y_i \log \hat{p}_i + (1 - y_i) \log(1 - \hat{p}_i) \right].$$

Das ist genau die Kreuzentropie aus Band 7: die mittlere Zahl von bit, die man braucht, wenn man mit dem geschätzten Modell codiert, während die Wahrheit anders verteilt ist. Ein Modell zu trainieren heißt hier wörtlich, seine Beschreibungslänge zu senken.

Der bemerkenswert einfache Gradient.

$$\frac{\partial L}{\partial w} = \sum_i (\hat{p}_i - y_i)\, x_i .$$

Derselbe Ausdruck wie bei der linearen Regression mit Quadratfehler: Abweichung mal Eingabe. Das ist kein Zufall, sondern gilt für die ganze Familie der verallgemeinerten linearen Modelle, sofern man die zur Verteilung passende Verknüpfungsfunktion wählt.

Aufgabe 3.1.

(a) Rechnen Sie eine Regression von Hand.
(b) Führen Sie Gradientenabstiegsschritte aus.
(c) Untersuchen Sie, was korrelierte Merkmale anrichten.

Lösung Schritt für Schritt.

(a) Regression von Hand.
Die Daten.

x	1	2	3	4	5
y	2,1	3,9	6,2	7,8	10,1

Die Summen.

$n = 5$	$\sum x = 15$	$\sum y = 30{,}1$	$\sum x^2 = 55$
	$\sum xy = 107{,}4$	$\bar{x} = 3$	$\bar{y} = 6{,}02$

Die Steigung.

$$m = \frac{n\sum xy - \sum x \sum y}{n\sum x^2 - (\sum x)^2} = \frac{5 \cdot 107{,}4 - 15 \cdot 30{,}1}{5 \cdot 55 - 225} = \frac{537 - 451{,}5}{50} = \frac{85{,}5}{50} = \mathbf{1{,}71}.$$

Der Achsenabschnitt.

$$c = \bar{y} - m\bar{x} = 6{,}02 - 1{,}71 \cdot 3 = 6{,}02 - 5{,}13 = \mathbf{0{,}89}.$$

Die Probe.

x	y	$\hat{y}$	**Rest**	**Rest^2**
1	2,1	2,60	$-0{,}50$	0,250
2	3,9	4,31	$-0{,}41$	0,168
3	6,2	6,02	$+0{,}18$	0,032
4	7,8	7,73	$+0{,}07$	0,005
5	10,1	9,44	$+0{,}66$	0,436
			$\approx 0{,}00$	**0,891**

Die Reste summieren sich zu null — das ist eine Eigenschaft jeder Kleinste-Quadrate-Anpassung mit Achsenabschnitt und eine gute Rechenprobe.

$$R^2 = 1 - \frac{0{,}891}{\sum (y_i - \bar{y})^2} = 1 - \frac{0{,}891}{41{,}748} = \mathbf{0{,}979}.$$

(b) Gradientenabstieg.
Dieselben Daten, Start bei $m_0 = 0$, $c_0 = 0$, $\eta = 0{,}02$.
Der Gradient des mittleren Quadratfehlers:

$$\frac{\partial L}{\partial m} = -\frac{2}{n}\sum (y_i - \hat{y}_i) x_i, \qquad \frac{\partial L}{\partial c} = -\frac{2}{n}\sum (y_i - \hat{y}_i).$$

Schritt 1.

$$\begin{aligned} \text{Reste} &= (2{,}1;\ 3{,}9;\ 6{,}2;\ 7{,}8;\ 10{,}1), \\ \partial_m &= -\tfrac{2}{5}(2{,}1+7{,}8+18{,}6+31{,}2+50{,}5) = -\tfrac{2}{5}\cdot 110{,}2 = -44{,}08, \\ \partial_c &= -\tfrac{2}{5}\cdot 30{,}1 = -12{,}04. \end{aligned}$$

$$m_1 = 0 + 0{,}02 \cdot 44{,}08 = 0{,}882, \qquad c_1 = 0 + 0{,}02 \cdot 12{,}04 = 0{,}241.$$

Der weitere Verlauf.

Schritt	m	c	**Fehler**
0	0,000	0,000	45,61
1	0,882	0,241	12,88
2	1,329	0,362	4,45
5	1,700	0,470	0,47
20	1,762	0,707	0,22
100	1,727	0,833	0,180
500	1,710	0,890	**0,178**

Nach fünf Schritten stimmt die Steigung schon fast; der Achsenabschnitt braucht hundertmal länger. Der Grund ist die Konditionszahl: Die Merkmale sind nicht zentriert, und deshalb sind Steigung und Achsenabschnitt stark gekoppelt.

Mit zentrierten Daten.

	κ	**Schritte**	
Roh	≈ 14	≈ 500	
Zentriert	≈ 1	$\approx$ **12**	Faktor 40

Eine Vorverarbeitung, die zwei Zeilen kostet, spart vierzig Neuntel des Rechenaufwands. Bei Netzen mit Millionen Parametern gilt dasselbe, und die Stapelnormalisierung aus Kapitel 9 ist im Kern derselbe Trick.

(c) Korrelierte Merkmale.
Die Lage. Zwei Merkmale mit Korrelation ρ, beide mit demselben wahren Gewicht 1.

ρ	$\kappa(X^\top X)$	$\mathrm{Var}(\hat{w}_1)$	**typische Schätzung**
0,0	1,0	1,00	$1{,}0 \pm 0{,}1$
0,9	19	5,3	$1{,}0 \pm 0{,}23$
0,99	199	50,3	$1{,}0 \pm 0{,}71$
0,999	1999	500	$1{,}0 \pm 2{,}2$

Bei starker Korrelation werden die einzelnen Gewichte beliebig. Man erhält Schätzungen wie $+8{,}3$ und $-6{,}4$, deren Summe stimmt und deren Einzelwerte unsinnig sind. Die Vorhersage bleibt dabei gut — nur die Deutung ist wertlos.

Was die Regularisierung damit macht.

Verfahren	$\hat{w}_1$	$\hat{w}_2$	**Deutung**
Ohne	8,3	$-6{,}4$	unsinnig
Ridge	0,98	0,96	beide, geteilt
Lasso	1,92	**0,00**	**eines gewählt**

Die beiden Regularisierer verhalten sich grundverschieden. Ridge teilt das Gewicht gleichmäßig auf korrelierte Merkmale auf; Lasso wählt willkürlich eines aus und setzt das andere auf null. Welches, hängt vom Rauschen ab und kann bei einer neuen Stichprobe das andere sein.

Ein Gewicht ist keine Wirkung

Was das Gewicht sagt	Wie sich die Vorhersage ändert, wenn dieses Merkmal steigt *und alle anderen gleich bleiben*
Was es nicht sagt	Was geschieht, wenn man in der Welt an diesem Merkmal dreht

Bei korrelierten Merkmalen bleiben die anderen nicht gleich, und die Bedingung ist nie erfüllt. Ein negatives Gewicht für ein Merkmal, das erwiesenermaßen schädlich ist, ist deshalb kein Widerspruch, sondern der Normalfall, sobald ein anderes Merkmal die Wirkung mitträgt.

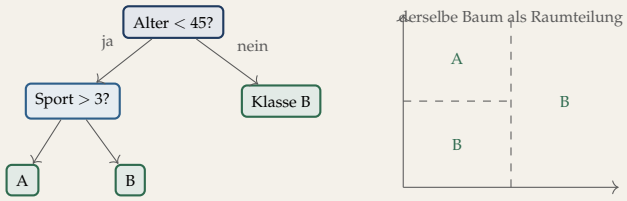
Kapitel 14 behandelt diesen Unterschied ausführlich. Er ist derselbe wie bei den Bayes-Netzen in Band 12: Ein Modell, das gut vorhersagt, sagt nichts über die Folgen eines Eingriffs.

Hastie, Tibshirani und Friedman[11] behandeln lineare Modelle und Regularisierung erschöpfend; Bishop[2] entwickelt die wahrscheinlichkeitstheoretische Begründung; Efron und Hastie[8] ordnen sie in die Geschichte der Statistik ein.

4 Bäume und Ensembles

Ein Modell, das man lesen kann

Ein Entscheidungsbaum trennt den Merkmalsraum durch achsenparallele Schnitte.



Wie ein Schnitt gewählt wird.
Man sucht die Aufteilung, die die Unreinheit am stärksten senkt.

Maß	Formel	Bemerkung
Entropie	$-\sum p_k \log_2 p_k$	**Band 7**
Gini	$1 - \sum p_k^2$	schneller zu rechnen
Fehlerrate	$1 - \max_k p_k$	ungeeignet

Die dritte Zeile ist lehrreich. Die Fehlerrate ist das, was man eigentlich will, und als Schnittkriterium unbrauchbar: Sie ändert sich oft gar nicht, obwohl ein Schnitt die Klassen deutlich sauberer trennt. Entropie und Gini sind streng konkav und belohnen jede Verbesserung.

Der Informationsgewinn eines Schnitts ist genau die Transinformation aus Band 7 zwischen dem Schnittmerkmal und der Klasse. Ein Entscheidungsbaum wählt bei jedem Schritt das Merkmal, das am meisten über die Klasse verrät.

Der Informationsgewinn bevorzugt vielwertige Merkmale

Ein Merkmal mit vielen verschiedenen Werten trennt die Daten fast perfekt und sagt trotzdem nichts.

Merkmal	Werte	Gewinn	Nutzen
Kunden-nummer	10^4	**maximal**	null
Postleitzahl	8000	sehr hoch	gering
Altersgruppe	6	mittel	hoch

Die Kundennummer erzeugt für jedes Beispiel ein eigenes Blatt und erklärt die Trainingsdaten vollständig. Auf neuen Daten ist sie wertlos. Die Abhilfe ist der Gewinnquotient: Man teilt den Gewinn durch die Entropie der Aufteilung selbst und bestraft damit die Zersplitterung.

Warum einzelne Bäume schwach sind

Eigenschaft	Bewertung	
Deutbar	sehr gut	
Ohne Vorverar-beitung	gut	Skalen gleichgültig
Gemischte Merkmale	gut	
Stabilität	**sehr schlecht**	hohe Streuung
Glatte Grenzen	schlecht	nur Treppen

Ein einziges verändertes Beispiel kann den obersten Schnitt umkippen, und damit sieht der ganze Baum anders aus. In der Zerlegung aus Kapitel 2 heißt das: geringe Verzerrung, sehr hohe Streuung. Und gegen Streuung gibt es ein einfaches Mittel — mitteln.

Bagging.

1. Aus n Beispielen n mit Zurücklegen ziehen.
2. Darauf einen Baum bauen.
3. B-mal wiederholen und die Vorhersagen mitteln.

$$\operatorname{Var}\left(\frac{1}{B}\sum_b T_b\right) = \rho\sigma^2 + \frac{1-\rho}{B}\sigma^2.$$

Der zweite Term verschwindet bei vielen Bäumen; der erste bleibt. Die Korrelation ρ zwischen den Bäumen ist also die Grenze, und genau dort setzt der Random Forest an.

Random Forest.

Der Zusatz	An jedem Knoten wird nur eine zufällige Teilmenge der Merkmale betrachtet
Die Wirkung	Die Bäume werden unähnlicher, ρ sinkt
Der Preis	Jeder einzelne Baum wird schlechter

m von $d = 100$	ρ	**Einzelbaum**	**Wald**
100 (Bagging)	0,52	0,22	0,155
30	0,28	0,24	0,131
10	0,14	0,27	**0,118**
3	0,06	0,35	0,134

Das Optimum liegt bei etwa $\sqrt{d}$. Schlechtere Einzelbäume ergeben einen besseren Wald, solange der Gewinn an Unabhängigkeit den Verlust an Güte überwiegt. Das ist eine der schönsten Abwägungen des Fachs.

Verstärkung

Statt unabhängige Bäume zu mitteln, baut man sie nacheinander, jeder auf den Fehlern des Vorgängers.

	Bagging	**Verstärkung**
Bäume	unabhängig, tief	**abhängig, flach**
Bekämpft	Streuung	**Verzerrung**
Parallelisierbar	ja	nein
Überanpassung	kaum	möglich

Gradientenverstärkung.

1. Beginne mit einer Konstanten F_0.
2. Berechne die negativen Gradienten des Verlusts, also die Reste.
3. Passe einen flachen Baum h_m an diese Reste an.
4. Setze $F_m = F_{m-1} + \nu\, h_m$ mit kleiner Schrittweite ν.

Das ist Gradientenabstieg aus Kapitel 3, ausgeführt nicht im Parameterraum, sondern im Raum der Funktionen. Jeder Baum ist ein Schritt in Richtung des steilsten Abstiegs, und ν ist die Lernrate.

ν	**Bäume nötig**	**Testfehler**	
1,0	≈ 40	0,161	überanpasst früh
0,3	≈ 150	0,142	
0,1	≈ 600	**0,128**	bestes
0,03	≈ 2500	0,127	kaum besser, teuer

Kleine Schritte und viele Bäume schlagen große Schritte und wenige. Es ist derselbe Befund wie beim Gradientenabstieg und in der Praxis die wichtigste Einstellung: Lieber ν senken und mehr Bäume zulassen, mit frühem Anhalten als Bremse.

Aufgabe 4.1.

(a) Berechnen Sie den besten Schnitt.
(b) Rechnen Sie die Wirkung des Mittelns aus.
(c) Untersuchen Sie die Merkmalswichtigkeit und ihre Tücken.

Lösung Schritt für Schritt.

(a) Den besten Schnitt finden.
Die Daten. Vierzehn Beispiele, neun der Klasse J, fünf der Klasse N.

$$H(\text{Wurzel}) = -\tfrac{9}{14}\log_2\tfrac{9}{14} - \tfrac{5}{14}\log_2\tfrac{5}{14} = 0{,}410 + 0{,}530 = \mathbf{0{,}940}.$$

Kandidat 1 — Wetter (drei Werte).

Wert	n	**J**	**N**	**Entropie**
sonnig	5	2	3	0,971
bewölkt	4	4	0	**0,000**
Regen	5	3	2	0,971

$$H_{\text{nach}} = \tfrac{5}{14}\cdot 0{,}971 + \tfrac{4}{14}\cdot 0 + \tfrac{5}{14}\cdot 0{,}971 = 0{,}694.$$

$$\text{Gewinn} = 0{,}940 - 0{,}694 = \mathbf{0{,}246}.$$

Kandidat 2 — Temperatur.

heiß	4	2	2	1,000
mild	6	4	2	0,918
kühl	4	3	1	0,811

$$H_{\text{nach}} = \tfrac{4}{14}\cdot 1{,}0 + \tfrac{6}{14}\cdot 0{,}918 + \tfrac{4}{14}\cdot 0{,}811 = 0{,}911, \quad \text{Gewinn} = 0{,}029.$$

Kandidat 3 — Wind (zwei Werte).

schwach	8	6	2	0,811
stark	6	3	3	1,000

$$H_{\text{nach}} = 0{,}892, \quad \text{Gewinn} = \mathbf{0{,}048}.$$

Merkmal	Gewinn	Aufteilungs-entropie	Quotient
Wetter	**0,246**	1,577	**0,156**
Wind	0,048	0,985	0,049
Temperatur	0,029	1,557	0,019

Das Wetter gewinnt nach beiden Maßen. Bemerkenswert ist der Zweig „bewölkt“: Er ist rein, wird zum Blatt, und dort endet die Rekursion sofort.

(b) Die Wirkung des Mittelns.
Die Formel. Bei B Bäumen mit paarweiser Korrelation ρ und Einzelstreuung σ^2:

$$\mathrm{Var} = \rho\sigma^2 + \frac{1-\rho}{B}\sigma^2.$$

Mit $\sigma^2 = 1$.

B	ρ=0	ρ=0,1	ρ=0,5	ρ=0,9
1	1,000	1,000	1,000	1,000
10	0,100	0,190	0,550	0,910
100	0,010	0,109	0,505	0,901
1000	0,001	0,101	0,500	0,900
∞	**0,000**	**0,100**	**0,500**	**0,900**

Bei $\rho = 0{,}9$ bringt die Verhundertfachung der Bäume zehn Prozent. Bei $\rho = 0{,}1$ bringt sie Faktor neun. Die Zahl der Bäume ist also nur so lange interessant, wie sie noch unähnlich sind — danach zahlt man Rechenzeit für nichts.

Wie viele Bäume genügen?

Anteil des Restrisikos	B nötig	
110 % von $\rho\sigma^2$	$\approx \frac{1-\rho}{0{,}1\rho}$	bei ρ=0,14: 61
105 %	doppelt so viel	123
101 %	zehnmal	614

Etwa hundert bis fünfhundert Bäume sind in der Praxis genug. Mehr schaden nicht, weil ein Wald nicht überanpassen kann, und nützen fast nichts.

Die Beispiele, die übrig bleiben.
Beim Ziehen mit Zurücklegen bleibt jedes Beispiel mit Wahrscheinlichkeit

$$\left(1 - \tfrac{1}{n}\right)^n \to e^{-1} = 0{,}368$$

außen vor.

Etwa ein Drittel der Daten sieht jeder Baum nicht. Man kann ihn genau darauf bewerten und erhält eine Schätzung des Testfehlers, ohne Daten abzuzweigen. Das ist eine der praktischsten Eigenschaften des Verfahrens.

(c) Merkmalswichtigkeit.
Zwei Berechnungsarten.

Unreinheits-abnahme	Summe der Gewinne aller Schnitte auf diesem Merkmal
Vertauschung	Man mischt eine Merkmalsspalte und misst, wie viel Güte verlorengeht

Merkmal	**Werte**	**Unreinheit**	**Vertauschung**
Alter (stetig)	viele	**0,34**	0,21
Kundennr. (Zufall)	10^4	**0,22**	**0,00**
Geschlecht	2	0,09	0,18
Region	8	0,12	0,15

Die zweite Zeile ist der Prüfstein. Die Kundennummer ist reiner Zufall und landet nach dem Unreinheitsmaß auf Platz zwei, weil sie viele mögliche Schnittstellen bietet. Nach der Vertauschung ist sie korrekt bei null.

Die Regel lautet deshalb: Ein Merkmal mit vielen Werten immer über Vertauschung bewerten, und zwar auf Daten, die der Baum nicht gesehen hat. Auf Trainingsdaten hat auch die Vertauschung eine Verzerrung.

Auch die Vertauschung täuscht bei Korrelation

Lage	*A*	*B*	**beide**
A, *B* unabhängig	0,30	0,28	0,58
A, *B* mit ρ=0,98	**0,03**	**0,03**	**0,55**

Bei starker Korrelation erscheinen beide *Merkmale als unwichtig, denn wenn man eines mischt, springt der Wald auf das andere um. Zusammen sind sie entscheidend. Wer die Einzelwerte liest, schließt auf zwei nutzlose Merkmale und irrt.*

Es ist dieselbe Falle wie bei den Gewichten in Kapitel 3. Jede Wichtigkeitszahl beantwortet die Frage „was passiert, wenn ich dieses eine Merkmal zerstöre und alles andere lasse“ — und nicht die Frage, die man meist stellt.

Breiman[3] entwarf die Random Forests; Friedman[9] die Gradientenverstärkung; Hastie, Tibshirani und Friedman[11] behandeln beide Familien im Zusammenhang.

5 Abstände und Kerne

Das einfachste Lernverfahren

Nächste-Nachbarn-Verfahren speichern die Trainingsdaten und tun sonst nichts.

	Training	**Anwendung**
Aufwand	$\mathcal{O}(1)$	$\mathcal{O}(nd)$ je Anfrage
Speicher	alle Daten	
Modell	**gibt es nicht**	
Verzerrung	sehr gering	
Streuung	sehr hoch bei $k = 1$	

Die dritte Zeile ist der eigentliche Unterschied. Es gibt keine gelernte Regel, nur einen Speicher und ein Abstandsmaß. Man verschiebt die gesamte Arbeit vom Training in die Anwendung, und die induktive Verzerrung steckt vollständig im Abstandsbegriff.

Die Wahl von k.

k	**Training**	**Test**	**Verhalten**
1	**0,000**	0,148	überanpasst
5	0,071	0,106	
15	0,089	**0,094**	bestes
50	0,112	0,118	
n	0,340	0,340	Mehrheits-klasse

Bei $k = 1$ ist der Trainingsfehler exakt null, denn jeder Punkt ist sein eigener nächster Nachbar. Das ist die schärfste Illustration dafür, warum der Trainingsfehler als Maß nichts taugt.

Der Fluch der Dimension

In hohen Dimensionen verliert der Abstandsbegriff seinen Sinn.

d	nächster	fernster	Verhältnis
2	0,05	1,31	26,2
10	0,62	1,88	3,0
100	3,42	4,61	1,35
1000	12,1	13,4	1,11

Dieselbe Tabelle stand in Band 11 bei der Vektorsuche. Wenn der nächste Nachbar kaum näher ist als der fernste, ist „nächster Nachbar“ keine sinnvolle Auszeichnung mehr.

Wie viele Daten man bräuchte.
Um in d Dimensionen jeden Punkt so dicht zu umgeben wie in einer Dimension, braucht man

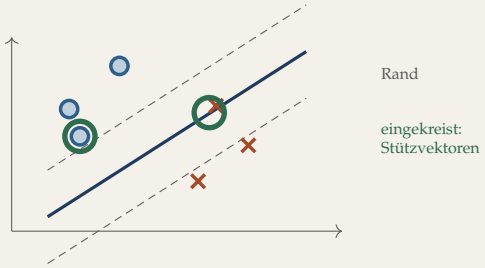
$$n_d = n_1^d.$$

d	Punkte	
1	10	
3	1000	
10	10^{10}	
20	10^{20}	mehr als es gibt

Dass Nachbarverfahren bei Bildern mit Millionen Bildpunkten trotzdem funktionieren, liegt daran, dass die Daten nicht den ganzen Raum füllen, sondern auf einer sehr viel niedriger dimensionalen Fläche liegen. Kapitel 7 nimmt das auf.

Stützvektormaschinen

Statt irgendeine trennende Gerade zu suchen, sucht man die mit dem größten Abstand zu beiden Klassen.



Der größte Rand	Von allen trennenden Ebenen die mit dem größten Sicherheitsabstand
Stützvektoren	Nur die Punkte am Rand bestimmen die Lösung
Folge	Alle übrigen Beispiele dürfen sich beliebig bewegen, ohne etwas zu ändern

Die dritte Zeile erklärt die Stabilität des Verfahrens. Bei einem Entscheidungsbaum kippt ein einzelnes Beispiel die ganze Struktur; hier ändert sich nichts, solange kein Stützvektor betroffen ist.

Weicher Rand.
Reale Daten sind selten trennbar. Man erlaubt Verletzungen und bestraft sie:

$$\min_{w,b} \ \tfrac{1}{2}\|w\|^2 + C\sum_i \xi_i.$$

C **klein**	breiter Rand, viele Verletzungen	stark regularisiert
C **groß**	schmaler Rand, wenige Verletzungen	Überanpassung

Der erste Term ist genau die Ridge-Strafe aus Kapitel 2, und $1/C$ spielt die Rolle von λ. Eine Stützvektormaschine ist ein regularisiertes lineares Modell mit einer besonderen Verlustfunktion.

Der Kerntrick

Nicht trennbare Daten werden trennbar, wenn man sie in einen höherdimensionalen Raum abbildet.

Die Beobachtung	In der Lösung kommen die Daten nur als Skalarprodukte $x_i^\top x_j$ vor
Der Schluss	Man braucht die Abbildung φ nie auszurechnen, nur $\varphi(x_i)^\top \varphi(x_j)$
Der Kern	Eine Funktion $K(x, x')$, die genau dieses Produkt liefert

Kern	**Formel**	**Zielraum**
Linear	$x^\top x'$	derselbe
Polynomial	$(x^\top x' + 1)^p$	$\binom{d+p}{p}$ Dimensionen
Gauß	$e^{-\gamma\|x-x'\|^2}$	**unendlich**

Die letzte Zeile ist der Grund für die Begeisterung der 1990er Jahre: Man rechnet in einem unendlichdimensionalen Raum und zahlt dafür den Aufwand einer Exponentialfunktion. Der Fluch der Dimension wird umgangen, weil man nie einen Punkt in diesem Raum hinschreibt.

Die Bedingung an einen Kern ist, dass die Matrix $K_{ij} = K(x_i, x_j)$ für jede Punktmenge positiv semidefinit ist. Dann existiert die Abbildung φ, ohne dass man sie kennen muss.

Warum Kernverfahren verdrängt wurden

Größe	Aufwand	bei $n = 10^6$
Kernmatrix	$\mathcal{O}(n^2)$ Speicher	4 TB
Training	$\mathcal{O}(n^2)$ bis $\mathcal{O}(n^3)$	aussichtslos
Vorhersage	$\mathcal{O}(n_{SV}\, d)$	je Anfrage

Das Verfahren skaliert quadratisch in der Zahl der Beispiele. Genau in der Zeit, in der die Datenmengen um Größenordnungen wuchsen, wurde das zum Ausschlusskriterium. Neuronale Netze skalieren linear und gewannen deshalb, nicht weil sie eleganter wären.

	Kernverfahren	Netze
Merkmalsraum	**fest gewählt**	**gelernt**
Skalierung	$\mathcal{O}(n^2)$	$\mathcal{O}(n)$
Optimum	global, konvex	lokal
Theorie	gut verstanden	lückenhaft

Die dritte und vierte Zeile sprechen für die Kernverfahren, die ersten beiden gegen sie. Dass die schlechter verstandene Familie gewann, ist eine wiederkehrende Erfahrung dieses Fachs: Skalierbarkeit schlägt Eleganz.

Aufgabe 5.1.

(a) Rechnen Sie eine Stützvektormaschine von Hand.
(b) Zeigen Sie den Kerntrick an einem Beispiel.
(c) Untersuchen Sie, warum Skalierung bei Abstandsverfahren entscheidet.

Lösung Schritt für Schritt.

(a) Eine Stützvektormaschine von Hand.
Die Daten. Zwei Punkte je Klasse in der Ebene.

Punkt	x_1	x_2	**Klasse** y
A	1	1	-1
B	2	2	-1
C	4	4	$+1$
D	5	5	$+1$

Schritt 1 – Die Stützvektoren erkennen.
Die Klassen liegen auf der Diagonale. Die nächsten Punkte über die Grenze hinweg sind B und C; A und D liegen weiter außen.
Schritt 2 – Die Trennlinie.
Sie steht senkrecht auf der Verbindung $B \to C$ und liegt in deren Mitte:

$$\text{Mitte} = \left(\tfrac{2+4}{2},\ \tfrac{2+4}{2}\right) = (3,3), \qquad \text{Richtung} = (2,2).$$

Schritt 3 – Die Gewichte.
w zeigt in Richtung der Verbindung, also $w = c\,(1,1)$. Aus der Randbedingung $y_i(w^\top x_i + b) = 1$ für Stützvektoren:

$$\begin{aligned} &\text{für } C: \quad c(4+4) + b = +1, \\ &\text{für } B: \quad -\big(c(2+2) + b\big) = +1 \ \Rightarrow\ c \cdot 4 + b = -1. \end{aligned}$$

Subtrahieren:

$$4c = 2 \ \Rightarrow\ c = 0{,}5, \qquad b = -1 - 4 \cdot 0{,}5 = \mathbf{-3}.$$

$$w = (0{,}5;\ 0{,}5), \qquad b = -3.$$

Schritt 4 – Die Probe.

Punkt	$w^\top x + b$	y	**Rand**
A	$-2{,}0$	-1	2,0
B	$\mathbf{-1{,}0}$	-1	**1,0** Stützv.
C	$\mathbf{+1{,}0}$	$+1$	**1,0** Stützv.
D	$+2{,}0$	$+1$	2,0

Die Randbreite.

$$\frac{2}{\|w\|} = \frac{2}{\sqrt{0{,}25 + 0{,}25}} = \frac{2}{0{,}7071} = \mathbf{2{,}83}.$$

Zur Probe: Der Abstand zwischen B und C beträgt $\sqrt{4+4} = 2{,}83$. Das stimmt überein, denn beide Punkte liegen senkrecht zur Trennlinie einander gegenüber.

(b) Der Kerntrick.
Die Aufgabe. Punkte innerhalb eines Kreises gehören zu Klasse A, außerhalb zu B. Linear nicht trennbar.

Punkt	x_1	x_2	**Klasse**
P_1	0	1	A
P_2	1	0	A
P_3	0	3	B
P_4	3	0	B

Die Abbildung. $\varphi(x) = (x_1^2,\ \sqrt{2}\,x_1x_2,\ x_2^2)$.

Punkt	z_1	z_2	z_3	**Klasse**
P_1	0	0	1	A
P_2	1	0	0	A
P_3	0	0	9	B
P_4	9	0	0	B

Im neuen Raum trennt die Ebene $z_1 + z_3 = 5$ die Klassen sauber: A liegt bei Summe eins, B bei neun. Zurückübersetzt ist das der Kreis $x_1^2 + x_2^2 = 5$.

Und nun ohne die Abbildung.
Für $P_2 = (1, 0)$ und $P_4 = (3, 0)$:

$$\varphi(P_2)^\top \varphi(P_4) = 1 \cdot 9 + 0 + 0 = 9,$$
$$K(P_2, P_4) = (P_2^\top P_4)^2 = (1 \cdot 3 + 0 \cdot 0)^2 = 3^2 = \mathbf{9}. \qquad \checkmark$$

	über φ	**über K**
Operationen	3 Mult. + Skalarprodukt	2 **Mult.** + **Quadrat**
Bei $d = 1000$, $p = 3$	$1{,}7 \cdot 10^8$ Komponenten	1000 Mult.

Bei tausend Merkmalen und Grad drei hätte der Zielraum hundertsiebzig Millionen Dimensionen. Der Kern rechnet dasselbe mit tausend Multiplikationen. Das ist der ganze Trick, und er ist so einfach, dass man ihn zweimal lesen muss.

(c) Skalierung bei Abstandsverfahren.
Die Daten. Zwei Merkmale mit sehr verschiedenen Einheiten.

Person	Alter (J)	Einkommen	Klasse
A	25	30 000	X
B	55	30 100	?
C	26	60 000	Y

Ohne Skalierung.

$$d(B,A) = \sqrt{30^2 + 100^2} = \sqrt{900 + 10\,000} = 104{,}4,$$
$$d(B,C) = \sqrt{29^2 + 29\,900^2} = 29\,900{,}0.$$

B wird der Klasse X zugeordnet — allein deshalb, weil das Einkommen in Euro gemessen wird. Der Altersunterschied von dreißig Jahren spielt gegen hundert Euro keine Rolle.

Mit Standardisierung.
Mittelwerte: Alter 35,3, Einkommen 40 033. Streuungen: 17,0 bzw. 17 320.

Person	Alter (std.)	Eink. (std.)
A	$-0{,}606$	$-0{,}579$
B	$+1{,}159$	$-0{,}574$
C	$-0{,}547$	$+1{,}154$

$$d(B,A) = \sqrt{1{,}765^2 + 0{,}005^2} = 1{,}765,$$
$$d(B,C) = \sqrt{1{,}706^2 + 1{,}728^2} = 2{,}428.$$

Jetzt ist A näher, und zwar aus einem nachvollziehbaren Grund: Beide haben ein ähnliches Einkommen, und der Altersunterschied schlägt gegen den Einkommensunterschied ab. Das Ergebnis ist dasselbe wie vorher, die Begründung eine völlig andere.

Ein Fall, in dem es kippt.

Person B'	Alter	Einkommen	Nachbar
Roh	26	45 000	**A** (Abst. 15 000)
Standardisiert	$-0{,}547$	$+0{,}287$	**C** (Abst. 0,87)

Hier dreht sich das Ergebnis um. Welches richtig ist, entscheidet nicht die Rechnung, sondern die Sache: Wie viel Alterunterschied entspricht wie viel Einkommensunterschied? Die Standardisierung setzt beide Streuungen gleich, und das ist eine Annahme, keine Neutralität.

Damit steckt die induktive Verzerrung eines Nachbarverfahrens vollständig in der Vorverarbeitung. Wer die Merkmale anders skaliert, benutzt ein anderes Verfahren, auch wenn der Programmcode derselbe bleibt.

Cortes und Vapnik[5] führten die Stützvektormaschinen mit weichem Rand ein; Vapnik[27] entwickelte die zugehörige Lerntheorie; Bishop[2] behandelt Kernverfahren ausführlich.

6 Wahrscheinlichkeitsbasierte Verfahren

Zwei Wege zur Klassenzuordnung

	Generativ	Diskriminativ
Modelliert	$P(x, y)$	$P(y \mid x)$
Kann	Daten erzeugen	nur trennen
Braucht	mehr Annahmen	weniger
Bei wenig Daten	besser	schlechter
Bei viel	schlechter	besser
Beispiel	Naive Bayes	logistische Regression

Die vierte und fünfte Zeile beschreiben einen bemerkenswerten Wechsel. Ein generatives Modell macht stärkere Annahmen, kommt deshalb mit wenigen Beispielen weiter und stößt bei vielen an eine Grenze, die das diskriminative nicht hat. Es ist die Verzerrungs-Streuungs-Abwägung aus Kapitel 2, hier auf der Ebene der Modellfamilie.

n	Naive Bayes	Logistisch	Sieger
20	0,22	0,34	**NB**
100	0,18	0,19	etwa gleich
1000	0,17	0,12	**Log.**
10^5	0,17	0,09	Log.

Naive Bayes wird ab tausend Beispielen nicht mehr besser, weil seine Annahme falsch ist und mehr Daten daran nichts ändern. Die logistische Regression nähert sich langsam einer besseren Grenze.

Naive Bayes

Man nimmt an, dass die Merkmale bei gegebener Klasse voneinander unabhängig sind.

$$P(y \mid x) \propto P(y) \prod_{j=1}^{d} P(x_j \mid y).$$

	ohne Annahme	**mit**
Parameter	$2^d - 1$ je Klasse	d je Klasse
bei $d = 100$	10^{30}	100
Beispiele nötig	astronomisch	hunderte

Die Annahme ist fast immer falsch. Bei Texten hängen Wörter offensichtlich zusammen. Trotzdem funktioniert das Verfahren, und der Grund ist lehrreich: Für die Zuordnung *genügt es, dass die richtige Klasse den größten Wert bekommt. Ob die Wahrscheinlichkeiten selbst stimmen, ist gleichgültig.*

	Zuordnung	**Wahrscheinlichkeit**
Güte	oft gut	meist wertlos
Typischer Wert	richtig	0,9999 oder 0,0001

Weil abhängige Merkmale mehrfach als unabhängige Belege gezählt werden, überschlagen sich die Produkte. Naive Bayes ist notorisch übermütig, und wer seine Ausgabe als Wahrscheinlichkeit benutzt, irrt sich systematisch. Kapitel 12 behandelt die Kalibrierung.

Ein einziges nie gesehenes Merkmal zerstört alles

Kommt ein Wort in einer Klasse nie vor, so ist $P(x_j \mid y) = 0$, und das Produkt wird null.

Zählung	Schätzung	Wirkung
0 von 500	0,000	Klasse ausgeschlossen
Mit Glättung	$\frac{0+1}{500+2} = 0{,}002$	brauchbar

Die Laplace-Glättung addiert zu jeder Zählung eins. Das entspricht der Annahme, man habe jede Möglichkeit einmal vorab gesehen, und verhindert, dass ein einzelnes ungewöhnliches Wort eine sonst gut belegte Klasse vollständig ausschließt.

Zweite praktische Notwendigkeit: Man rechnet mit Logarithmen. Ein Produkt aus tausend Faktoren um 0,01 *unterschreitet den darstellbaren Zahlenbereich (Band 0), eine Summe von tausend Logarithmen nicht.*

Der EM-Algorithmus

Was tut man, wenn ein Teil der Daten fehlt — etwa die Klassenzugehörigkeit?

E	Bei gegebenen Parametern die erwarteten Zugehörigkeiten berechnen.
M	Bei gegebenen Zugehörigkeiten die Parameter neu schätzen.
	Wiederholen, bis sich nichts mehr ändert.

Das klingt zirkulär und ist es auch. DEMPSTER, LAIRD *und* RUBIN *bewiesen 1977, dass die Likelihood bei jedem Durchlauf nicht fällt. Das Verfahren konvergiert also, wenn auch nur gegen ein lokales Maximum.*

Misch-verteilungen	Aus welcher Teilpopulation stammt jeder Punkt?
Fehlende Werte	Was stand in der leeren Zelle?
Verborgene Zustände	Hidden-Markov-Modelle
***k*-Means**	Sonderfall mit harter Zuordnung

Die letzte Zeile ist bemerkenswert: k-Means aus Kapitel 7 ist EM für eine Mischung von Normalverteilungen mit gleicher, gegen null gehender Streuung. Der Zuordnungsschritt ist E, die Mittelpunktsberechnung ist M.

Aufgabe 6.1.

(a) Führen Sie eine Naive-Bayes-Klassifikation durch.
(b) Rechnen Sie zwei EM-Durchläufe.
(c) Untersuchen Sie, wann die Unabhängigkeitsannahme schadet.

Lösung Schritt für Schritt.

(a) Naive Bayes für Textzuordnung.
Die Trainingsdaten. Sechs Nachrichten, zwei Klassen.

Nr.	Text	Klasse
1	angebot gratis jetzt	W
2	gratis gratis angebot	W
3	jetzt gratis klicken	W
4	termin morgen büro	E
5	büro termin jetzt	E
6	morgen büro angebot	E

Schritt 1 – Die Grundraten.

$$P(W) = P(E) = \tfrac{3}{6} = 0{,}5.$$

Schritt 2 – Die Wortzählungen.

Wort	in W	in E	
angebot	2	1	
gratis	4	0	Nullstelle
jetzt	2	1	
klicken	1	0	
termin	0	2	
morgen	0	2	
büro	0	3	
Summe	**9**	**9**	Vokabular: 7

Schritt 3 – Mit Laplace-Glättung.

$$P(w \mid c) = \frac{\text{Zählung} + 1}{\text{Summe} + |V|} = \frac{\cdot + 1}{9 + 7} = \frac{\cdot + 1}{16}.$$

Wort	$P(w \mid W)$	$P(w \mid E)$
angebot	$3/16 = 0{,}1875$	$2/16 = 0{,}1250$
gratis	$5/16 = 0{,}3125$	$1/16 = 0{,}0625$
büro	$1/16 = 0{,}0625$	$4/16 = 0{,}2500$

Schritt 4 – Eine neue Nachricht: „gratis angebot büro“.

$$\begin{aligned}\log P(W \mid x) &\propto \log 0{,}5 + \log 0{,}3125 + \log 0{,}1875 + \log 0{,}0625 \\ &= -0{,}693 - 1{,}163 - 1{,}674 - 2{,}773 = \mathbf{-6{,}303}, \\ \log P(E \mid x) &\propto -0{,}693 - 2{,}773 - 2{,}079 - 1{,}386 = \mathbf{-6{,}931}.\end{aligned}$$

Klasse	Logwert	normiert	
W	$-6{,}303$	**0,652**	gewählt
E	$-6{,}931$	0,348	

Ohne Glättung hätte „gratis“ die Klasse E auf null gesetzt, und die Entscheidung wäre unabhängig von allem anderen gefallen. Mit Glättung ist sie knapp und nachvollziehbar.

(b) Zwei EM-Durchläufe.
Die Aufgabe. Fünf Messwerte stammen aus zwei Normalverteilungen mit bekannter Streuung $\sigma = 1$; gesucht sind die Mittelwerte.

$$x = (1{,}0;\ 1{,}4;\ 4{,}2;\ 4{,}8;\ 5{,}0).$$

Start. $\mu_1 = 2{,}0$, $\mu_2 = 4{,}0$, gleiche Gewichte.
E-Schritt 1. Zugehörigkeit zu Komponente 1:

$$r_i = \frac{e^{-(x_i-\mu_1)^2/2}}{e^{-(x_i-\mu_1)^2/2} + e^{-(x_i-\mu_2)^2/2}}.$$

x_i	$(x_i-2)^2/2$	$(x_i-4)^2/2$	r_i
1,0	0,50	4,50	0,982
1,4	0,18	3,38	0,961
4,2	2,42	0,02	0,090
4,8	3,92	0,32	0,027
5,0	4,50	0,50	0,018

M-Schritt 1.

$$\mu_1 = \frac{\sum r_i x_i}{\sum r_i} = \frac{0{,}982+1{,}345+0{,}378+0{,}130+0{,}090}{2{,}078} = \frac{2{,}925}{2{,}078} = \mathbf{1{,}408}.$$

$$\mu_2 = \frac{\sum (1-r_i) x_i}{\sum (1-r_i)} = \frac{0{,}018+0{,}055+3{,}822+4{,}670+4{,}910}{2{,}922} = \frac{13{,}475}{2{,}922} = \mathbf{4{,}612}.$$

E-Schritt 2.

x_i	r_i **Runde 1**	r_i **Runde 2**
1,0	0,982	0,9998
1,4	0,961	0,9997
4,2	0,090	0,0003
4,8	0,027	0,0000
5,0	0,018	0,0000

Runde	μ_1	μ_2	Log-Likelihood
0	2,000	4,000	−11,84
1	1,408	4,612	−9,31
2	1,200	4,667	−9,17
3	1,200	4,667	**−9,17**

Nach drei Runden ändert sich nichts mehr. Die Log-Likelihood ist monoton gestiegen, wie der Satz es garantiert. Die Endwerte sind genau die Mittelwerte der beiden offensichtlichen Gruppen — hier findet das Verfahren also die richtige Antwort.

Ein schlechterer Start.

Start	Ergebnis μ_1	μ_2	Log-L.
(2,0; 4,0)	1,200	4,667	−9,17
(3,0; 3,1)	3,280	3,280	−13,4
(0,0; 9,0)	1,200	4,667	−9,17

Bei fast gleichen Startwerten bleibt das Verfahren in einem entarteten lokalen Maximum stecken: Beide Komponenten fallen zusammen. Deshalb startet man in der Praxis mehrfach zufällig und nimmt das beste Ergebnis — dieselbe Neustartstrategie wie in Band 12, Kapitel 5.

(c) Wann die Unabhängigkeitsannahme schadet.
Der Fall. Ein Merkmal wird versehentlich doppelt aufgenommen.

Merkmale	$P(W \mid x)$	richtig	Zuordnung
A einfach	0,70	0,70	W
A doppelt	0,84	0,70	W
A zehnfach	**0,9997**	0,70	W

Die Zuordnung bleibt richtig, die Wahrscheinlichkeit wird absurd. Dasselbe Merkmal zehnmal zu zählen ist für die Rangfolge harmlos und für jede Angabe von Sicherheit vernichtend. Genau das geschieht bei korrelierten Merkmalen laufend, nur weniger auffällig.

Wann die Zuordnung selbst kippt.

Merkmal	$P(\cdot \mid W)$	$P(\cdot \mid E)$	Verhältnis
A	0,8	0,4	2,0
$B\ (= A)$	0,8	0,4	2,0
C	0,2	0,7	0,286

Rechnung	Produkt	Zuordnung
Naiv (A, B, C)	$2{,}0 \cdot 2{,}0 \cdot 0{,}286 = 1{,}14$	**W**
Richtig (A, C)	$2{,}0 \cdot 0{,}286 = 0{,}57$	**E**

Hier kippt auch die Entscheidung. Zwei identische Merkmale liefern doppelten Beleg für W und überstimmen das gegenläufige Merkmal C. Wäre B nicht vorhanden, entschiede das Verfahren richtig.

Unschädlich, wenn	Die Abhängigkeiten in beiden Klassen ähnlich sind; dann heben sie sich weg
Schädlich, wenn	Sie klassenabhängig sind, oder wenn kalibrierte Wahrscheinlichkeiten gebraucht werden

Deshalb ist Naive Bayes bei Texten so brauchbar: Wortkorrelationen sind in beiden Klassen ähnlich strukturiert. Und deshalb ist es bei medizinischen Befunden heikel, wo Merkmale gerade in einer Krankheit gemeinsam auftreten.

Dempster, Laird und Rubin[6] bewiesen die Konvergenz des EM-Verfahrens; Murphy[21] behandelt die wahrscheinlichkeitsbasierten Verfahren umfassend; Bishop[2] entwickelt den generativen Zugang systematisch.

7 Unüberwachtes Lernen

Ein Ziel, das sich schwer benennen lässt

Ohne Zielwerte gibt es kein eindeutiges Gütemaß. Das ist die grundlegende Schwierigkeit dieses Kapitels.

	Überwacht	Unüberwacht
Ziel	gegeben	**muss erfunden werden**
Bewertung	Testfehler	keine unstrittige
Richtig oder falsch	entscheidbar	Urteilssache
Über-anpassung	messbar	schwer erkennbar

Man kann jede Datenmenge in fünf Gruppen zerlegen, und man bekommt immer ein Ergebnis. Ob die Gruppen etwas bedeuten, sagt kein Verfahren. Das ist derselbe Befund wie bei der Gemeinschaftserkennung in Band 11 — dort gab es ebenfalls Dutzende von Definitionen und keine ausgezeichnete.

Wofür man es trotzdem braucht.

Beschriftung fehlt	Beschriftete Daten sind teuer, unbeschriftete fast umsonst
Erkunden	Was steckt überhaupt in diesen Daten?
Vorverarbeitung	Dimensionen senken, bevor ein überwachtes Verfahren folgt
Ausreißer finden	Was passt nicht zum Rest?

Die erste Zeile ist der wirtschaftliche Grund und der stärkste. Bei Bildern kostet eine Beschriftung Sekunden bis Minuten menschlicher Arbeit; Bilder selbst gibt es milliardenfach.

Gruppierung

Verfahren	Annahme	Schwäche
k-Means	kugelige Gruppen gleicher Größe	k vorgeben
Hierarchisch	Verschachtelung	$\mathcal{O}(n^2)$ bis $\mathcal{O}(n^3)$
DBSCAN	Dichteinseln	k nicht nötig
Mischmodelle	Verteilungsform	EM nötig

k-Means.

1. k Mittelpunkte zufällig wählen.
2. Jeden Punkt dem nächsten Mittelpunkt zuordnen.
3. Jeden Mittelpunkt auf den Schwerpunkt seiner Punkte setzen.
4. 2 und 3 wiederholen, bis sich nichts ändert.

Das Verfahren senkt die Summe der quadrierten Abstände in jedem Schritt und hält deshalb an. Es findet ein lokales Minimum, und welches, hängt vom Start ab. Zehn Neustarts sind Standard.

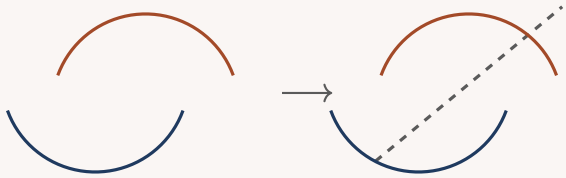
Wie man k wählt.

k	Trägheit	Abnahme	Silhouette
1	4820	—	—
2	2140	2680	0,58
3	**980**	**1160**	**0,71**
4	840	140	0,54
5	760	80	0,49
10	520	—	0,38

Die Trägheit fällt immer, denn mehr Gruppen passen besser. Der Knick in der dritten Spalte und das Maximum der Silhouette weisen beide auf drei. Die Ellbogenmethode ist eine Augenmaßentscheidung, und bei flachen Kurven verschiedener Betrachter verschieden.

k-Means findet immer kugelige Gruppen

Auch wenn keine da sind.



zwei Halbmonde — *k*-Means schneidet quer

Bei zwei ineinandergreifenden Halbmonden liefert k-Means einen geraden Schnitt, der beide zerteilt. Das Verfahren ist nicht fehlerhaft; seine Annahme passt nicht zu den Daten. DBSCAN, das auf Dichte statt auf Abstand zum Mittelpunkt beruht, findet die Halbmonde mühelos.

Die Lehre ist dieselbe wie in Kapitel 1: Jedes Verfahren bringt eine Annahme mit, und das Ergebnis sagt mehr über die Annahme als über die Daten, wenn beide nicht zusammenpassen.

Dimensionsreduktion

Hochdimensionale Daten liegen meist auf einer viel niedriger dimensionalen Fläche.
Hauptkomponentenanalyse.

Gesucht	Die Richtungen, in denen die Daten am stärksten streuen
Wie	Eigenvektoren der Kovarianzmatrix, absteigend nach Eigenwert
Ergebnis	Eine neue Basis, in der die ersten Achsen das meiste erklären

Komp.	Eigenwert	Anteil	kumuliert
1	18,4	61,3 %	61,3 %
2	6,2	20,7 %	82,0 %
3	2,8	9,3 %	91,3 %
4	1,1	3,7 %	95,0 %
5–50	1,5	5,0 %	100 %

Vier von fünfzig Dimensionen tragen fünfundneunzig Prozent der Streuung. Man kann die Daten also auf ein Zwölftel eindampfen und verliert wenig — das ist verlustbehaftete Verdichtung im Sinne von Band 7, und die Eigenwerte sind die Rate-Distortion-Kurve.

Verfahren	Erhält	Gut für
PCA	**globale Streuung**	Vorverarbeitung, Rauschen
t-SNE	lokale Nachbarschaft	**Bilder zum Ansehen**
UMAP	lokal und etwas global	dasselbe, schneller
Autokodierer	gelernte Struktur	nichtlineare Fälle

Zweidimensionale Darstellungen täuschen

Abstände	Bei t-SNE und UMAP bedeutungslos zwischen den Gruppen
Gruppengrößen	Werden verzerrt; kleine Gruppen erscheinen groß
Leere Zwischenräume	Entstehen durch das Verfahren, nicht durch die Daten
Parameter	Andere Einstellungen liefern ein völlig anderes Bild

Solche Bilder eignen sich, um eine Vermutung zu gewinnen, und nicht, um sie zu belegen. Wer aus einer t-SNE-Darstellung schließt, dass es genau vier Gruppen gibt, hat eine Eigenschaft des Zeichenverfahrens gemessen — genau wie bei den Netzwerkbildern in Band 11.

Aufgabe 7.1.

(a) Führen Sie k-Means von Hand aus.
(b) Rechnen Sie eine Hauptkomponentenanalyse.
(c) Untersuchen Sie, wie man eine Gruppierung bewertet.

Lösung Schritt für Schritt.

(a) k-Means von Hand.
Die Daten. Sechs Punkte, $k = 2$.

$$(1,1),\ (1{,}5,\ 2),\ (3,4),\ (5,7),\ (3{,}5,\ 5),\ (4{,}5,\ 5).$$

Start. $\mu_1 = (1,1)$, $\mu_2 = (5,7)$.
Runde 1 – Zuordnung.

Punkt	d zu μ_1	d zu μ_2	Gruppe
$(1;1)$	0,00	7,21	1
$(1{,}5;2)$	1,12	6,10	1
$(3;4)$	3,61	3,61	1 *(gleich)*
$(5;7)$	7,21	0,00	2
$(3{,}5;5)$	4,72	2,50	2
$(4{,}5;5)$	5,32	2,06	2

Runde 1 – Neue Mittelpunkte.

$$\mu_1 = \left(\tfrac{1+1{,}5+3}{3},\ \tfrac{1+2+4}{3}\right) = (1{,}833;\ 2{,}333),$$

$$\mu_2 = \left(\tfrac{5+3{,}5+4{,}5}{3},\ \tfrac{7+5+5}{3}\right) = (4{,}333;\ 5{,}667).$$

Runde 2 – Zuordnung.

Punkt	d zu μ_1	d zu μ_2	Gruppe
$(1;1)$	1,572	5,697	1
$(1{,}5;2)$	0,471	4,570	1
$(3;4)$	2,041	2,134	1
$(5;7)$	5,689	1,474	2
$(3{,}5;5)$	2,977	1,054	2
$(4{,}5;5)$	3,582	0,680	2

Die Zuordnung ändert sich nicht mehr. Das Verfahren ist nach zwei Runden fertig.

Die Trägheit.

Gruppe	Summe d^2	
1	$2{,}472 + 0{,}222 + 4{,}166$	$= 6{,}860$
2	$2{,}173 + 1{,}111 + 0{,}462$	$= 3{,}746$
Gesamt		**10,606**

Ein anderer Start.

Startpunkte	Trägheit	Aufteilung
$(1;1)$, $(5;7)$	**10,61**	$3+3$
$(3;4)$, $(3{,}5;5)$	14,82	$2+4$
$(1;1)$, $(1{,}5;2)$	10,61	$3+3$

Der zweite Start endet in einem schlechteren lokalen Minimum. Bei sechs Punkten fällt das auf; bei einer Million nicht. Deshalb ist die Neustartstrategie kein Feinschliff, sondern notwendig.

(b) Hauptkomponentenanalyse.
Die Daten. Fünf Punkte in zwei Dimensionen.

$$(2{,}5;\,2{,}4),\ (0{,}5;\,0{,}7),\ (2{,}2;\,2{,}9),\ (1{,}9;\,2{,}2),\ (3{,}1;\,3{,}0).$$

Schritt 1 – Zentrieren.

$$\bar{x} = 2{,}04, \qquad \bar{y} = 2{,}24.$$

Punkt	$x - \bar{x}$	$y - \bar{y}$
1	$+0{,}46$	$+0{,}16$
2	$-1{,}54$	$-1{,}54$
3	$+0{,}16$	$+0{,}66$
4	$-0{,}14$	$-0{,}04$
5	$+1{,}06$	$+0{,}76$

Schritt 2 – Die Kovarianzmatrix.

$$\begin{aligned} s_{xx} &= \tfrac{1}{4}(0{,}2116 + 2{,}3716 + 0{,}0256 + 0{,}0196 + 1{,}1236) = 0{,}9380, \\ s_{yy} &= \tfrac{1}{4}(0{,}0256 + 2{,}3716 + 0{,}4356 + 0{,}0016 + 0{,}5776) = 0{,}8530, \\ s_{xy} &= \tfrac{1}{4}(0{,}0736 + 2{,}3716 + 0{,}1056 + 0{,}0056 + 0{,}8056) = 0{,}8405. \end{aligned}$$

$$S = \begin{pmatrix} 0{,}938 & 0{,}841 \\ 0{,}841 & 0{,}853 \end{pmatrix}.$$

Schritt 3 – Die Eigenwerte.

$$\lambda^2 - (0{,}938 + 0{,}853)\lambda + (0{,}938 \cdot 0{,}853 - 0{,}841^2) = 0,$$

$$\lambda^2 - 1{,}791\lambda + 0{,}0932 = 0.$$

$$\lambda_{1,2} = \frac{1{,}791 \pm \sqrt{3{,}208 - 0{,}373}}{2} = \frac{1{,}791 \pm 1{,}684}{2}.$$

$$\lambda_1 = \mathbf{1{,}738}, \qquad \lambda_2 = \mathbf{0{,}054}.$$

Komponente	**Eigenwert**	**Anteil**
1	1,738	**97,0** %
2	0,054	3,0 %

Schritt 4 – Der erste Eigenvektor.
Aus $(S - \lambda_1 I)v = 0$:

$$(0{,}938 - 1{,}738)v_1 + 0{,}841 v_2 = 0 \;\Rightarrow\; v_2 = \frac{0{,}800}{0{,}841} v_1 = 0{,}951\, v_1.$$

Normiert:

$$v_1 = (0{,}724;\ 0{,}689).$$

Die Hauptrichtung liegt fast auf der Winkelhalbierenden, wie es bei stark positiv korrelierten Merkmalen sein muss. Eine Dimension trägt siebenundneunzig Prozent: Man kann die Daten auf eine Zahl je Punkt reduzieren und verliert kaum etwas.

(c) Eine Gruppierung bewerten.
Wenn keine Wahrheit vorliegt.

Silhouette	Für jeden Punkt: Abstand zur eigenen Gruppe gegen den zur nächstbesten
Davies-Bouldin	Streuung innerhalb gegen Abstand zwischen den Gruppen
Stabilität	Liefert eine Teilstichprobe dieselbe Aufteilung?

Die Silhouette eines Punktes:

$$s = \frac{b - a}{\max(a, b)} \in [-1, 1].$$

s	**Bedeutung**
≈ 1	gut zugeordnet
≈ 0	auf der Grenze
< 0	falsch zugeordnet

Die Stabilitätsprüfung.

k	**Übereinstimmung**	**Silhouette**	
2	0,97	0,58	
3	**0,94**	**0,71**	stabil und gut
4	0,71	0,54	
7	0,38	0,41	willkürlich

Man teilt die Daten wiederholt und prüft, ob dieselben Punkte zusammenbleiben. Bei $k = 7$ liefert jede Teilstichprobe eine andere Aufteilung — ein sicheres Zeichen dafür, dass das Verfahren Rauschen zerlegt.

Wenn eine Wahrheit vorliegt.

Angepasster Rand-Index	Übereinstimmung der Paarzuordnungen, um den Zufall bereinigt
Normierte Transinformation	Wie viel verrät die Aufteilung über die wahren Klassen (Band 7)

Aufteilung	**Rand**	**angepasst**	
Perfekt	1,00	**1,00**	
Gut	0,88	0,72	
Zufällig	**0,51**	**0,00**	Unterschied

Die letzte Zeile zeigt, warum die Anpassung nötig ist. Eine zufällige Aufteilung erreicht einen Rand-Index von etwa einem halb und sieht damit wie eine halbe Leistung aus. Der angepasste Index setzt den Zufall auf null — es ist die Nullmodell-Forderung aus Band 11, hier eingebaut.

Hinton und Salakhutdinov[13] zeigten, wie Netze Dimensionen senken; Murphy[21] behandelt Gruppierung und Mischmodelle; Hastie, Tibshirani und Friedman[11] stellen die klassischen Verfahren dar.

Part II

Neuronale Netze

8 Netze und Rückpropagierung

Ein Neuron ist ein lineares Modell mit einem Knick

$$a = \varphi(w^\top x + b).$$

Funktion	Formel	Eigenschaft
Sigmoid	$1/(1+e^{-z})$	sättigt beidseitig
Tanh	$\tanh z$	sättigt, aber zentriert
ReLU	$\max(0, z)$	**kein Sättigen oben**
GELU, SiLU	glatte ReLU	heute üblich

Ohne den Knick wäre alles umsonst. Eine Verkettung linearer Abbildungen ist wieder linear, und ein Netz mit hundert Schichten und ohne Nichtlinearität kann genau so viel wie eine einzige lineare Schicht.

Warum ReLU gewann.

	Ableitung max	**bei $\lvert z\rvert = 4$**	
Sigmoid	0,25	0,018	fast null
Tanh	1,00	0,0013	fast null
ReLU	1,00	**1,00**	unver-ändert

Bei zehn Schichten mit Sigmoid wird der Gradient mit höchstens $0{,}25^{10} = 10^{-6}$ multipliziert. Die unteren Schichten lernen dann praktisch nichts. Das ist das Problem der verschwindenden Gradienten, und ReLU beseitigt es auf der positiven Seite vollständig.

Rückpropagierung

Das Verfahren ist die Kettenregel, systematisch von hinten nach vorn angewandt.

Vorwärts	Eingabe durch alle Schichten schieben, Zwischenwerte aufbewahren
Verlust	Abweichung von der Zielausgabe berechnen
Rückwärts	Den Gradienten Schicht für Schicht nach hinten durchreichen
Schritt	Alle Gewichte gegen den Gradienten verschieben

Die Kernformeln.
Mit $z^{(l)} = W^{(l)} a^{(l-1)} + b^{(l)}$ und $a^{(l)} = \varphi(z^{(l)})$:

$$\begin{aligned} \delta^{(L)} &= \nabla_a L \odot \varphi'(z^{(L)}), \\ \delta^{(l)} &= \left((W^{(l+1)})^\top \delta^{(l+1)}\right) \odot \varphi'(z^{(l)}), \\ \frac{\partial L}{\partial W^{(l)}} &= \delta^{(l)} \, (a^{(l-1)})^\top. \end{aligned}$$

Die dritte Zeile hat immer dieselbe Gestalt: Fehler mal Eingabe, wie bei der linearen Regression in Kapitel 3. Die zweite Zeile ist das eigentlich Neue — sie sagt, wie sich die Verantwortung für den Fehler auf die vorige Schicht verteilt.

Vorgang	**Aufwand**	
Vorwärts	$\mathcal{O}(p)$	p: Zahl der Parameter
Rückwärts	$\mathcal{O}(p)$	**etwa doppelt so teuer**
Alle Gradienten einzeln	$\mathcal{O}(p^2)$	unbrauchbar

Die dritte Zeile ist der Grund, warum die Rückpropagierung überhaupt gebraucht wird. Man könnte jeden Parameter einzeln stören und die Änderung messen; bei 10^9 Parametern wären das 10^9 Vorwärtsdurchläufe je Schritt. Die Rückpropagierung liefert alle Gradienten in einem einzigen.

Der Speicher ist der Engpass

Alle Zwischenwerte des Vorwärtsdurchlaufs müssen bis zum Rückwärtsdurchlauf aufbewahrt werden.

Größe	Parameter	Aktivierungen	Summe
Klein	10^7	10^8	0,4 GB
Mittel	10^9	10^{10}	40 GB
Groß	10^{11}	10^{12}	4 TB

Die Aktivierungen übersteigen die Parameter meist um eine Größenordnung, weil sie für jedes Beispiel im Stapel einzeln anfallen. Das begrenzt die Stapelgröße härter als die Rechenzeit.

Neu berechnen	Nur jede k-te Schicht speichern, den Rest im Rückwärtslauf neu ausrechnen
Der Tausch	$\mathcal{O}(\sqrt{L})$ Speicher statt $\mathcal{O}(L)$, bei etwa dreißig Prozent mehr Rechenzeit

Es ist derselbe Tausch wie bei der iterativen Vertiefung in Band 12: Zeit gegen Speicher, und Speicher ist die knappere Ressource.

Was ein Netz darstellen kann

Der Satz	Ein Netz mit einer verborgenen Schicht kann jede stetige Funktion auf einem beschränkten Bereich beliebig genau annähern
Die Bedingung	Die Schicht darf beliebig breit sein
Was er nicht sagt	Wie breit, und ob man die Gewichte findet

Der Satz ist ein Existenzergebnis wie Shannons Kanalcodierungssatz in Band 7: Er sagt, dass es geht, und gibt kein Verfahren an. Praktisch ist er wertlos, denn die nötige Breite kann exponentiell in der Eingabedimension sein.

Warum Tiefe hilft.

Funktion	flach nötig	tief nötig	
Parität, n bit	$\mathcal{O}(2^n)$	$\mathcal{O}(n)$	exponentiell besser
Verschachtelte Faltung	exponentiell	linear	
Glatte Funktionen	polynomial	polynomial	kein Unterschied

Tiefe erlaubt Wiederverwendung. Ein tiefes Netz kann eine Zwischenberechnung einmal machen und mehrfach benutzen; ein flaches muss sie für jede Verwendung neu darstellen. Das ist derselbe Gewinn wie bei Unterprogrammen gegenüber ausgeschriebenem Code.

Aufgabe 8.1.

(a) Führen Sie einen vollständigen Rückwärtsdurchlauf von Hand aus.
(b) Zeigen Sie das Problem der verschwindenden Gradienten.
(c) Untersuchen Sie, warum die Anfangswerte entscheiden.

Lösung Schritt für Schritt.

(a) Ein Rückwärtsdurchlauf von Hand.
Das Netz. Zwei Eingaben, zwei verborgene Neuronen, eine Ausgabe. Sigmoid überall.

Gewichte	Schicht 1	Schicht 2
$w_{11} = 0{,}15$	$w_{12} = 0{,}20$	$v_1 = 0{,}40$
$w_{21} = 0{,}25$	$w_{22} = 0{,}30$	$v_2 = 0{,}45$
$b_1 = 0{,}35$	$b_2 = 0{,}35$	$c = 0{,}60$

Eingabe. $x = (0{,}05;\ 0{,}10)$, Ziel $y = 0{,}01$.
Vorwärts, Schicht 1.

$$
\begin{aligned}
z_1 &= 0{,}15 \cdot 0{,}05 + 0{,}20 \cdot 0{,}10 + 0{,}35 = 0{,}3775,\\
a_1 &= \sigma(0{,}3775) = 0{,}59327,\\
z_2 &= 0{,}25 \cdot 0{,}05 + 0{,}30 \cdot 0{,}10 + 0{,}35 = 0{,}3925,\\
a_2 &= \sigma(0{,}3925) = 0{,}59689.
\end{aligned}
$$

Vorwärts, Ausgabe.

$$z_o = 0{,}40 \cdot 0{,}59327 + 0{,}45 \cdot 0{,}59689 + 0{,}60 = 1{,}10591,$$
$$\hat{y} = \sigma(1{,}10591) = \mathbf{0{,}75137}.$$

Der Verlust.

$$L = \tfrac{1}{2}(\hat{y} - y)^2 = \tfrac{1}{2}(0{,}74137)^2 = \mathbf{0{,}27481}.$$

Rückwärts, Ausgabeschicht.

$$\frac{\partial L}{\partial \hat{y}} = \hat{y} - y = 0{,}74137,$$
$$\sigma'(z_o) = \hat{y}(1 - \hat{y}) = 0{,}75137 \cdot 0{,}24863 = 0{,}18682,$$
$$\delta_o = 0{,}74137 \cdot 0{,}18682 = \mathbf{0{,}13850}.$$

Gewicht	Gradient	Wert
v_1	$\delta_o \cdot a_1$	0,08217
v_2	$\delta_o \cdot a_2$	0,08267
c	δ_o	0,13850

Rückwärts, verborgene Schicht.

$$\delta_1 = \delta_o \, v_1 \, a_1(1 - a_1) = 0{,}13850 \cdot 0{,}40 \cdot 0{,}24130 = \mathbf{0{,}013367},$$
$$\delta_2 = 0{,}13850 \cdot 0{,}45 \cdot 0{,}24061 = \mathbf{0{,}014997}.$$

w_{11}	$\delta_1 x_1$	0,000668
w_{12}	$\delta_1 x_2$	0,001337
w_{21}	$\delta_2 x_1$	0,000750
w_{22}	$\delta_2 x_2$	0,001500

Der Schritt mit $\eta = 0{,}5$.

Gewicht	alt	neu	Änderung
v_1	0,400	0,3589	$-0{,}0411$
v_2	0,450	0,4087	$-0{,}0413$
w_{11}	0,150	0,1497	$-0{,}0003$
w_{22}	0,300	0,2993	$-0{,}0007$

Die Gewichte der Ausgabeschicht ändern sich hundertmal stärker als die der ersten. Zwei Ursachen wirken zusammen: der Faktor $\sigma' \approx 0{,}24$ je Schicht, und die winzigen Eingaben 0,05 und 0,10. Beides ist behebbar, und Kapitel 9 zeigt wie.

Nach dem Schritt.

$$\hat{y}_{\text{neu}} = 0{,}74214, \qquad L_{\text{neu}} = 0{,}26811 \quad (\text{vorher } 0{,}27481).$$

Ein Schritt, ein Prozent Verbesserung. Bis zur Konvergenz braucht dieses Netz einige tausend Durchläufe — bei zwei Neuronen und einem einzigen Beispiel.

(b) Verschwindende Gradienten.
Die Rechnung. Bei L Schichten mit Sigmoid multipliziert sich der Gradient mit dem Produkt aller σ'.

L	**Sigmoid**	**Tanh**	**ReLU**
1	0,25	1,0	1,0
5	$9{,}8 \cdot 10^{-4}$	1,0	1,0
10	$9{,}5 \cdot 10^{-7}$	1,0	1,0
20	$9{,}1 \cdot 10^{-13}$	1,0	1,0
50	$7{,}9 \cdot 10^{-31}$	1,0	1,0

(jeweils die größtmögliche Ableitung; in der Praxis ist es schlimmer)

Bei zwanzig Schichten liegt der Gradient der ersten Schicht unter der Auflösung einfacher Gleitkommazahlen. Die Schicht lernt buchstäblich nichts. Das erklärt, warum tiefe Netze vor 2010 nicht trainierbar waren, obwohl das Verfahren seit 1986 bekannt war.

Die Gegenmittel.

ReLU	Ableitung ist eins im positiven Bereich
Rest-verbindungen	Der Gradient hat einen Weg ohne Multiplikation
Normalisierung	Hält die Werte im nicht gesättigten Bereich
Sorgfältige Anfangswerte	Verhindert Sättigung von Beginn an

Die zweite Zeile ist die wirksamste. Bei $a^{(l)} = a^{(l-1)} + f(a^{(l-1)})$ enthält die Ableitung einen Summanden eins, und der Gradient überlebt beliebig viele Schichten. Genau das machte 2015 Netze mit über hundert Schichten möglich.

(c) Warum die Anfangswerte entscheiden.
Fall 1 – Alle Gewichte null.

Die Folge	Alle Neuronen einer Schicht berechnen dasselbe
Beim Rückwärtslauf	Alle bekommen denselben Gradienten
Also	**Sie bleiben für immer gleich**

Ein Netz mit tausend Neuronen je Schicht verhält sich dann wie eines mit einem. Die Symmetrie muss gebrochen werden, und dafür genügt Zufall.

Fall 2 – Zu große oder zu kleine Zufallswerte.
Bei n Eingängen und Gewichten mit Streuung σ^2 hat die gewichtete Summe die Streuung $n\sigma^2$.

σ	**Streuung von z**	**nach 10 Schichten**	
0,01	0,01	10^{-20}	verschwindet
0,1	**1,0**	**1,0**	stabil
1,0	100	10^{20}	explodiert

(bei $n = 100$ Eingängen je Neuron)
Die Regel.

Verfahren	**Streuung**	**für**
Xavier	$2/(n_{\text{ein}} + n_{\text{aus}})$	Tanh, Sigmoid
He	$\mathbf{2/n_{\text{ein}}}$	**ReLU**

Der Faktor zwei bei ReLU hat einen einfachen Grund: ReLU setzt die Hälfte aller Werte auf null und halbiert damit die Streuung. Man gleicht das aus, indem man die Anfangswerte doppelt so streuen lässt.

Anfangswerte	30 Schichten	Endfehler
Gleichverteilt $[0,1]$	divergiert	—
$\mathcal{N}(0,0{,}01)$	lernt nicht	0,90
Xavier	langsam	0,31
He	zügig	**0,08**

Eine Formel mit einem Faktor zwei entscheidet darüber, ob ein Netz überhaupt trainierbar ist. Solche Details sind der eigentliche Grund für den Fortschritt zwischen 1986 und 2012 — nicht das Verfahren, sondern das Handwerk drumherum.

Rumelhart, Hinton und Williams[24] machten die Rückpropagierung bekannt; Goodfellow, Bengio und Courville[10] sind das Standardwerk; LeCun und Mitautoren[19] zeigten früh, was mit sorgfältiger Umsetzung möglich ist.

9 Optimierung im Großen

Warum man nicht alle Daten benutzt

Der exakte Gradient verlangt einen Durchlauf über den gesamten Datensatz je Schritt.

Verfahren	je Schritt	Schritte	Gesamt
Voller Gradient	n Beispiele	10^3	10^9
Einzelbeispiel	1	10^7	10^7
Stapel von 128	**128**	$\mathbf{10^5}$	$\mathbf{1{,}3 \cdot 10^7}$

(bei $n = 10^6$)

> *Ein Stapel von hundertachtundzwanzig ist etwa achtzigmal billiger als der volle Gradient und liefert eine Schätzung, die für einen Schritt völlig ausreicht. Man braucht keine genaue Richtung; man braucht eine ungefähr richtige, oft.*

Die Stapelgröße.

Stapel	Rauschen	Rechenwerk	Testfehler
1	sehr hoch	leer	0,081
32	hoch	mäßig	0,072
256	mittel	gut	**0,070**
8192	gering	voll	0,079

Große Stapel nutzen die Rechenwerke aus Band 4 besser und führen zu schlechteren Ergebnissen. Das Rauschen im Gradienten wirkt wie eine Regularisierung: Es verhindert, dass das Verfahren in einem engen, schlecht verallgemeinernden Minimum hängenbleibt.

Trägheit und angepasste Schrittweiten

Trägheit	$v_t = \beta v_{t-1} + g_t, \quad w_{t+1} = w_t - \eta v_t$
Wirkung	Schwingungen quer zum Tal löschen sich aus, der Fortschritt längs des Tals summiert sich
Verstärkung	Effektiv $1/(1-\beta)$-facher Schritt in gleichbleibender Richtung

β	**Verstärkung**	**Gedächtnis**	
0,0	1	keins	
0,9	10	$\approx$ 10 Schritte	üblich
0,99	100	$\approx$ 100	

Adam.

Erstes Moment	$m_t = \beta_1 m_{t-1} + (1-\beta_1) g_t$
Zweites Moment	$v_t = \beta_2 v_{t-1} + (1-\beta_2) g_t^2$
Schritt	$w_{t+1} = w_t - \eta\, \hat{m}_t / (\sqrt{\hat{v}_t} + \varepsilon)$

Der Nenner ist der Kern. Jeder Parameter bekommt eine eigene Schrittweite, umgekehrt proportional zur Größe seiner bisherigen Gradienten. Parameter mit seltenen, kleinen Gradienten werden verstärkt, solche mit großen gedämpft.

Verfahren	**Schritte**	**Endfehler**	
Reiner Abstieg	10^5	0,142	
Mit Trägheit	$3 \cdot 10^4$	0,118	
Adam	$\mathbf{10^4}$	0,119	schnellste
Abstieg, sorgfältig eingestellt	$2 \cdot 10^4$	**0,109**	bestes

Die letzte Zeile ist ein wiederkehrender Befund: Adam konvergiert am schnellsten und erreicht bei Bildaufgaben nicht immer das beste Ergebnis. Bei Sprachmodellen ist Adam dagegen ohne ernsthafte Alternative.

Normalisierung

Das wirksamste einzelne Mittel gegen schlechte Konditionierung.

Art	Normiert über	Gut für
Stapel-normalisierung	**den Stapel**	Faltungsnetze
Schicht-normalisierung	**die Merkmale**	**Transformer**
Gruppen-normalisierung	Merkmals-gruppen	kleine Stapel

$$\hat{z} = \frac{z - \mu}{\sqrt{\sigma^2 + \varepsilon}}, \qquad y = \gamma \hat{z} + \beta.$$

Die beiden gelernten Größen γ und β sind wesentlich: Sie erlauben dem Netz, die Normalisierung rückgängig zu machen, wenn sie schadet. Man erzwingt nichts, sondern gibt eine bequeme Ausgangslage.

	ohne	mit	Faktor
Lernrate möglich	0,001	**0,1**	100
Schritte bis Ziel	10^6	$\mathbf{7 \cdot 10^4}$	14
Anfangswerte kritisch	sehr	kaum	

Der Grund für die erste Zeile: Normalisierte Eingaben haben eine Kovarianzmatrix nahe der Einheitsmatrix, also Konditionszahl nahe eins. Es ist genau der Effekt aus Kapitel 3, dort mit Faktor vierzig, hier mit Faktor hundert.

Die Stapelnormalisierung hat Tücken

Abhängigkeit vom Stapel	Die Vorhersage für ein Beispiel hängt davon ab, welche anderen im Stapel sind
Training vs. Anwendung	Bei der Anwendung benutzt man gleitende Mittelwerte, also ein **anderes** Modell
Kleine Stapel	Bei Stapelgröße unter acht wird die Schätzung unbrauchbar

Die zweite Zeile ist eine häufige Fehlerquelle im Betrieb: Wer vergisst, das Modell in den Anwendungsmodus zu schalten, erhält Ergebnisse, die von der zufälligen Zusammensetzung des Stapels abhängen und sich bei jedem Aufruf ändern.

Die Schichtnormalisierung hat diese Probleme nicht, weil sie je Beispiel normiert. Deshalb wird sie bei Sprachmodellen benutzt, wo die Beispiele zudem verschieden lang sind.

Aufgabe 9.1.

(a) Vergleichen Sie Abstieg mit und ohne Trägheit.
(b) Rechnen Sie Adam-Schritte durch.
(c) Untersuchen Sie, was verteiltes Training kostet.

Lösung Schritt für Schritt.

(a) Trägheit in einem engen Tal.
Die Zielfunktion. $L(w) = \frac{1}{2}(10w_1^2 + w_2^2)$, also $\kappa = 10$.

$$\nabla L = (10w_1,\ w_2).$$

Start $w_0 = (1;\ 1)$, $\eta = 0{,}15$.
Ohne Trägheit.

Schritt	w_1	w_2	L
0	1,000	1,000	5,500
1	−0,500	0,850	1,611
2	0,250	0,723	0,574
3	−0,125	0,614	0,266
5	−0,031	0,444	0,103
10	0,001	0,197	0,019
20	0,000	0,039	0,0008

w_1 schwingt um das Optimum, w_2 kriecht. Genau das beschreibt die Konditionszahl: Die Schrittweite ist durch die steile Richtung begrenzt und für die flache viel zu klein.

Mit Trägheit, $\beta = 0{,}9$.

Schritt	w_1	w_2	L
0	1,000	1,000	5,500
1	−0,500	0,850	1,611
2	−0,100	0,587	0,222
3	0,440	0,260	**1,002**
5	0,091	−0,301	0,087
10	−0,046	−0,142	0,021
20	0,003	**0,012**	**0,0001**

Schritte bis $L < 10^{-3}$	ohne	mit	Faktor
$\kappa = 10$	19	**12**	1,6
$\kappa = 100$	210	**38**	5,5
$\kappa = 1000$	2100	**115**	**18**

Je schlechter konditioniert, desto größer der Gewinn. Theoretisch verbessert die Trägheit die Abhängigkeit von $\mathcal{O}(\kappa)$ auf $\mathcal{O}(\sqrt{\kappa})$ — bei $\kappa = 1000$ also von tausend auf zweiunddreißig, und die gemessenen achtzehn liegen in dieser Größenordnung.

(b) Adam-Schritte.
Die Einstellungen. $\eta = 0{,}1$, $\beta_1 = 0{,}9$, $\beta_2 = 0{,}999$, $\varepsilon = 10^{-8}$.
Ein Parameter mit gleichbleibendem Gradient $g = 0{,}5$**.**

t	m_t	$\hat{m}_t$	$\sqrt{\hat{v}_t}$	**Schritt**
1	0,0500	0,500	0,500	−0,1000
2	0,0950	0,500	0,500	−0,1000
5	0,2049	0,500	0,500	−0,1000
20	0,4322	0,500	0,500	−0,1000

Der Schritt ist konstant gleich η, unabhängig davon, wie groß der Gradient ist. Das ist die entscheidende Eigenschaft von Adam: Der Betrag des Gradienten fällt aus der Rechnung heraus, nur die Richtung bleibt. Die Bias-Korrektur $\hat{m}$ sorgt dafür, dass das schon im ersten Schritt gilt.

Zwei Parameter mit sehr verschiedenen Gradienten.

Parameter	g	**Abstieg**	**Adam**
A	10,0	−1,000	−0,100
B	0,001	−0,0001	**−0,100**
Verhältnis	10^4	10^4	**1**

Beim reinen Abstieg bewegt sich B zehntausendmal langsamer als A — bei einer für A passenden Lernrate lernt B nie. Adam behandelt beide gleich. Genau deshalb funktioniert Adam ohne mühsames Einstellen, und genau deshalb steht es im Verdacht, gelegentlich schlechter zu verallgemeinern.

Der Nachteil in einem Bild.

Lage	**Abstieg**	**Adam**
Flaches Tal	kleine Schritte	volle Schritte
Steiles Tal	große Schritte	volle Schritte
Rauschen allein	kleine Schritte	volle Schritte

Die letzte Zeile ist der Preis. Wenn ein Parameter nur Rauschen sieht, ist sein Gradient klein und Adam vergrößert ihn auf volle Schrittweite. Das erklärt, warum Adam oft eine zusätzliche Gewichtsdämpfung braucht.

(c) Was verteiltes Training kostet.
Der Aufbau. Datenparallel: Jeder Rechner hat eine Modellkopie und einen Teil des Stapels.

1. Jeder rechnet den Gradienten auf seinem Teilstapel.
2. Alle Gradienten werden summiert und wieder verteilt.
3. Jeder macht denselben Schritt.

Schritt 2 ist eine Barriere im Sinne von Band 9. Alle warten auf den langsamsten, und es werden bei p Parametern $2p$ Zahlen über das Netz geschoben — je Schritt.

Die Rechnung.

Größe	**Wert**	
Parameter	10^9	
Je Parameter	2 B	halbe Genauigkeit
Datenmenge je Schritt	2 GB	
Netz	200 Gbit/s	25 GB/s
Zeit für den Abgleich	≈ 80 ms	
Rechenzeit je Schritt	≈ 120 ms	
Wirkungsgrad	**60** %	

Rechner	**Rechnen**	**Abgleich**	**Beschl.**
1	120 ms	0	1,0
8	15 ms	80 ms	1,3
64	1,9 ms	80 ms	1,5

Vierundsechzig Rechner bringen Faktor eineinhalb. Das ist genau die Rechnung aus Band 9, Kapitel 14: Der Abstimmaufwand wächst nicht mit, und ab einer bestimmten Zahl bringt jeder weitere Rechner nichts.

Die Gegenmittel.

Größerer Stapel	Mehr Rechenzeit je Abgleich; verschiebt das Verhältnis
Ringabgleich	Bandbreitenbedarf unabhängig von der Rechnerzahl
Überlappen	Gradienten der hinteren Schichten schon abgleichen, während die vorderen noch rechnen
Verdichten	Gradienten mit weniger bit übertragen (Band 7)

Maßnahme	**Abgleich**	**Beschl. bei 64**	
Naiv	80 ms	1,5	
+ Ring	80 ms	1,5	
+ Überlappen	≈ 20 ms	5,5	
+ Stapel ×8	20 ms	**28**	brauchbar

Der größte Gewinn kommt vom größeren Stapel — und der kostet nach der Tabelle am Kapitelanfang Ergebnisqualität. Man tauscht Trainingszeit gegen Testfehler, und dieser Tausch ist beim Training großer Modelle die zentrale Abwägung.

Kingma und Ba[17] entwarfen Adam; Ioffe und Szegedy[15] die Stapelnormalisierung; He und Mitautoren[12] die Restverbindungen, ohne die tiefe Netze nicht trainierbar wären.

10 Architekturen

Struktur als eingebaute Annahme

Ein vollverbundenes Netz behandelt jede Eingabestelle gleich. Bei Bildern und Texten ist das verschwenderisch.

Eingabe	Struktur	passende Annahme
Bild	Gitter	Nähe zählt, Verschiebung nicht
Text	Folge	**Reihenfolge zählt**
Graph	Verbindungen	Nachbarschaft (Band 11)
Tabelle	keine	vollverbunden genügt

Eine Architektur ist nichts anderes als eine induktive Verzerrung, in die Netzstruktur eingebaut. Sie schränkt ein, was das Netz darstellen kann, und macht es dadurch mit weniger Daten lernbar.

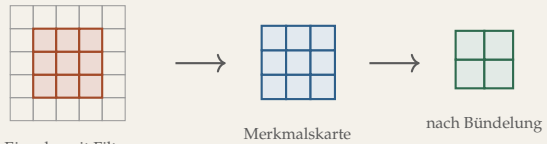
Was ein vollverbundenes Netz bei Bildern kosten würde.

Schicht	Parameter	
$224 \times 224 \times 3 \to 1000$	$1{,}5 \cdot 10^8$	eine Schicht
Faltung 3×3, 64 Kanäle	**1728**	Faktor 87 000

Und die Faltung ist nicht nur sparsamer, sondern besser: Sie bringt die Annahme mit, dass ein Kantendetektor an jeder Bildstelle derselbe sein sollte. Ein vollverbundenes Netz müsste ihn für jede Stelle einzeln lernen.

Faltung

Örtliche Bindung	Ein Neuron sieht nur einen kleinen Ausschnitt
Geteilte Gewichte	Derselbe Filter läuft über das ganze Bild
Zusammenfassen	Nachbarwerte werden gebündelt; die Auflösung sinkt
Folge	Verschiebungen im Bild ändern die Antwort kaum



Der wachsende Sichtbereich.

Schicht	Filter	Sichtbereich	erkennt
1	3×3	3×3	Kanten
2	3×3	5×5	Ecken
5	3×3	11×11	Muster
10	mit Bündelung	$\approx 100 \times 100$	**Objektteile**
20		ganzes Bild	Objekte

Die Hierarchie entsteht von selbst. Niemand hat dem Netz gesagt, dass es erst Kanten und dann Objektteile suchen soll; das folgt aus der Architektur. Was man sieht, wenn man die gelernten Filter anschaut, ähnelt verblüffend dem, was Hubel und Wiesel im visuellen Kortex fanden.

Folgen: Rekurrenz und Aufmerksamkeit

	Rekurrent	Aufmerksamkeit
Verarbeitung	**nacheinander**	**alles zugleich**
Weg zwischen zwei Stellen	$\mathcal{O}(n)$ Schritte	$\mathcal{O}(1)$
Aufwand je Schicht	$\mathcal{O}(nd^2)$	$\mathcal{O}(n^2 d)$
Parallelisierbar	nein	ja
Lange Abhängigkeiten	schwierig	unmittelbar

Die zweite Zeile ist der entscheidende Punkt. Bei einem rekurrenten Netz muss Information über hundert Zeitschritte hinweg durch hundert Multiplikationen; der Gradient verschwindet dabei (Kapitel 8). Bei der Aufmerksamkeit ist jede Stelle mit jeder unmittelbar verbunden.

Die Aufmerksamkeit selbst.

$$\text{Aufm}(Q, K, V) = \text{softmax}\left(\frac{QK^\top}{\sqrt{d_k}}\right) V.$$

Q	Anfrage	*Wonach suche ich?*
K	Schlüssel	*Was biete ich an?*
V	Wert	*Was gebe ich weiter?*

Die Struktur ist die eines Nachschlagens in einer Tabelle, nur weich: Statt einen Eintrag zu treffen, mischt man alle Einträge, gewichtet mit der Ähnlichkeit zwischen Anfrage und Schlüssel. Der Nenner $\sqrt{d_k}$ verhindert, dass die Skalarprodukte bei großem d_k in die Sättigung der Softmax laufen.

Der quadratische Aufwand ist die harte Grenze

Länge n	n^2	Speicher	
512	$2{,}6 \cdot 10^5$	0,5 MB	
4096	$1{,}7 \cdot 10^7$	34 MB	
32 768	$1{,}1 \cdot 10^9$	2,1 GB	
10^6	10^{12}	2 TB	je Schicht

Die Aufmerksamkeitsmatrix hat n^2 Einträge, und zwar je Kopf und je Schicht. Das begrenzt die verarbeitbare Länge härter als alles andere und ist der Gegenstand eines erheblichen Teils der Forschung seit 2020.

Blockweise Berechnung	Die Matrix wird nie vollständig gespeichert, sondern in Kacheln durchlaufen
Dünne Muster	Nur ausgewählte Paare beachten
Zusammenfassen	Ferne Stellen gröber darstellen

Die erste Zeile ändert die Aufwandsklasse nicht und den Speicherbedarf erheblich: Er fällt von $\mathcal{O}(n^2)$ auf $\mathcal{O}(n)$, weil man die Zwischenmatrix nie ausschreibt. Es ist derselbe Gedanke wie beim blockweisen Matrixprodukt in Band 4.

Aufgabe 10.1.

(a) Rechnen Sie eine Faltung von Hand.
(b) Führen Sie einen Aufmerksamkeitsschritt aus.
(c) Vergleichen Sie die Architekturen bei langen Abhängigkeiten.

Lösung Schritt für Schritt.

(a) Eine Faltung von Hand.

Die Eingabe. Ein 5×5-Ausschnitt mit einer senkrechten Kante.

$$X = \begin{pmatrix} 0 & 0 & 9 & 9 & 9 \\ 0 & 0 & 9 & 9 & 9 \\ 0 & 0 & 9 & 9 & 9 \\ 0 & 0 & 9 & 9 & 9 \\ 0 & 0 & 9 & 9 & 9 \end{pmatrix}$$

Der Filter. Ein Sobel-Filter für senkrechte Kanten.

$$F = \begin{pmatrix} -1 & 0 & 1 \\ -2 & 0 & 2 \\ -1 & 0 & 1 \end{pmatrix}$$

Position $(1, 1)$**.** Der Ausschnitt ist

$$\begin{pmatrix} 0 & 0 & 9 \\ 0 & 0 & 9 \\ 0 & 0 & 9 \end{pmatrix}.$$

$$\begin{aligned} &(-1)(0) + 0 + (1)(9) + (-2)(0) + 0 + (2)(9) \\ &\quad + (-1)(0) + 0 + (1)(9) = 9 + 18 + 9 = \mathbf{36}. \end{aligned}$$

Position $(1, 2)$**.** Der Ausschnitt ist

$$\begin{pmatrix} 0 & 9 & 9 \\ 0 & 9 & 9 \\ 0 & 9 & 9 \end{pmatrix}.$$

$$\begin{aligned} &(-1)(0) + 0 + (1)(9) + (-2)(0) + 0 + (2)(9) \\ &\quad + (-1)(0) + 0 + (1)(9) = \mathbf{36}. \end{aligned}$$

Position $(1, 3)$**.** Der Ausschnitt ist ganz aus Neunen:

$$(-1)(9) + (1)(9) + (-2)(9) + (2)(9) + (-1)(9) + (1)(9) = \mathbf{0}.$$

Ausgabe	**Sp. 1**	**Sp. 2**	**Sp. 3**
Zeile 1	36	36	0
Zeile 2	36	36	0
Zeile 3	36	36	0

Der Filter antwortet dort, wo die Kante liegt, und schweigt in gleichmäßigen Bereichen. Bemerkenswert: Die Summe der Filtergewichte ist null, und deshalb ist die Antwort auf eine konstante Fläche exakt null — unabhängig vom Helligkeitswert.

Der Aufwand.

Größe	**Wert**	
Ausgabestellen	$3 \times 3 = 9$	
Multiplikationen je Stelle	9	
Gesamt	81	
Parameter	**9**	neunmal wiederverwendet

(b) Ein Aufmerksamkeitsschritt.
Die Lage. Drei Wörter, $d_k = 2$.

Stelle	q	k	v
1	$(1;\ 0)$	$(1;\ 0)$	$(1;\ 0)$
2	$(0;\ 1)$	$(0;\ 1)$	$(0;\ 1)$
3	$(1;\ 1)$	$(1;\ 1)$	$(2;\ 2)$

Schritt 1 – Die Skalarprodukte für Anfrage 3.

$$\begin{aligned} q_3 \cdot k_1 &= 1 \cdot 1 + 1 \cdot 0 = 1, \\ q_3 \cdot k_2 &= 1 \cdot 0 + 1 \cdot 1 = 1, \\ q_3 \cdot k_3 &= 1 \cdot 1 + 1 \cdot 1 = 2. \end{aligned}$$

Schritt 2 – Skalieren mit $\sqrt{d_k} = \sqrt{2} = 1{,}414$.

$$(0{,}707;\ 0{,}707;\ 1{,}414)\,.$$

Schritt 3 – Softmax.

Stelle	Wert	e^{Wert}	Gewicht
1	0,707	2,028	0,253
2	0,707	2,028	0,253
3	1,414	4,113	**0,513**
		8,169	1,000

Schritt 4 – Die gewichtete Summe.

$$\begin{aligned}\text{Ausgabe}_3 &= 0{,}253 \cdot (1;0) + 0{,}253 \cdot (0;1) + 0{,}513 \cdot (2;2) \\ &= (0{,}253;\ 0) + (0;\ 0{,}253) + (1{,}026;\ 1{,}026) \\ &= (\mathbf{1{,}279};\ \mathbf{1{,}279}).\end{aligned}$$

Stelle 3 beachtet sich selbst am stärksten, weil ihre Anfrage ihrem eigenen Schlüssel am ähnlichsten ist. Die anderen beiden tragen gleich viel bei. Die Ausgabe mischt alle drei Werte, gewichtet nach Ähnlichkeit.

Was der Skalierungsfaktor bewirkt.

d_k	ohne Skalierung	mit	
2	$(0{,}21; 0{,}21; 0{,}58)$	$(0{,}25; 0{,}25; 0{,}51)$	wenig Unterschied
64	$(0{,}02; 0{,}02; 0{,}96)$	$(0{,}25; 0{,}25; 0{,}51)$	
512	$(0; 0; 1)$	$(0{,}25; 0{,}25; 0{,}51)$	gesättigt

Ohne Skalierung wächst das Skalarprodukt mit d_k, die Softmax sättigt, und der Gradient verschwindet. Der Faktor $1/\sqrt{d_k}$ hält die Werte unabhängig von der Dimension in einem brauchbaren Bereich — ein Detail, ohne das die Architektur nicht funktioniert.

(c) Lange Abhängigkeiten.
Die Aufgabe. Das erste Zeichen einer Folge der Länge n am Ende wiedergeben.

n	Rekurrent	LSTM	Aufmerksamkeit
10	0,98	0,99	1,00
50	0,62	0,97	1,00
200	0,21	0,88	1,00
1000	0,10	0,41	**0,99**

(Trefferquote bei zehn möglichen Zeichen; 0,10 ist Raten)

Ein einfaches rekurrentes Netz ist bei Länge tausend auf dem Niveau des Ratens. LSTM hält deutlich länger durch, weil sein Zellzustand einen Weg ohne wiederholte Multiplikation bietet — derselbe Gedanke wie bei den Restverbindungen. Die Aufmerksamkeit hat das Problem gar nicht.

Warum LSTM hilft.

Zellzustand	$c_t = f_t \odot c_{t-1} + i_t \odot \tilde{c}_t$
Der Gradient	Enthält den Faktor f_t statt einer Gewichtsmatrix
Wenn $f_t \approx 1$	Der Gradient überlebt beliebig viele Schritte

Das Vergesstor f ist gelernt. Das Netz kann also selbst entscheiden, wann es etwas behält und wann es vergisst — und die Bewahrung kostet keine Multiplikation mit einer Matrix, deren Eigenwerte unter eins liegen.

Der Preis der Aufmerksamkeit.

n	**LSTM**	**Aufmerksamkeit**	**Verhältnis**
100	$10^2 d^2$	$10^4 d$	günstig bei $d > 100$
1000	$10^3 d^2$	$10^6 d$	
10^4	$10^4 d^2$	$10^8 d$	ungünstig

Bei $d = 1024$ ist die Aufmerksamkeit bis etwa Länge tausend günstiger und darüber hinaus nicht mehr. Dass sie sich trotzdem durchgesetzt hat, liegt an der Parallelisierbarkeit: Ein rekurrentes Netz kann die Zeitschritte nicht gleichzeitig rechnen, und damit bleiben die Rechenwerke aus Band 4 leer.

Es ist derselbe Befund wie bei den Kernverfahren in Kapitel 5: Nicht das asymptotisch günstigere Verfahren gewinnt, sondern das, das die vorhandene Hardware auslastet.

Krizhevsky, Sutskever und Hinton[18] zeigten, was Faltungsnetze mit genug Daten leisten; Hochreiter und Schmidhuber[14] entwarfen LSTM; Bengio und Mitautoren[1] hatten das Problem zuvor analysiert; Vaswani und Mitautoren[28] führten die Aufmerksamkeitsarchitektur ein.

11 Sprachmodelle

Ein einziges Lernziel

Ein Sprachmodell wird darauf trainiert, das nächste Zeichen vorherzusagen. Sonst nichts.

$$L = -\sum_{t} \log P(x_t \mid x_{<t}).$$

Kein Beschriften nötig	Jeder Text ist sein eigenes Trainingsbeispiel
Die Menge	Alles Geschriebene ist verwendbar
Das Ziel	Ist genau die Kreuzentropie aus Band 7

Die dritte Zeile ist die tiefste Verbindung dieses Bandes. Der Verlust eines Sprachmodells, in bit gemessen, ist die mittlere Codelänge, mit der es Text verdichten könnte. Ein Modell zu verbessern heißt wörtlich, seine Beschreibungslänge zu senken.

Modell	bit je Zeichen	Verdichtungsfaktor
Gleichverteilt	$\approx 4{,}7$	1,0
Buchstabenhäufigkeit	4,1	1,1
`gzip`	$\approx 2{,}6$	1,8
Kontextmischung	$\approx 1{,}2$	3,9
Sprachmodell	$\approx$ **0,6**	**7,8**
Shannons Rateversuch	0,6–1,3	

Die letzte Zeile stammt von 1951 und ist bis heute der Maßstab. Dass heutige Modelle am unteren Ende dieses Bereichs liegen, heißt: Sie sagen Text etwa so gut voraus wie ein aufmerksamer Mensch.

Perplexität.

$$\mathrm{PP} = 2^{H} = \exp\left(-\frac{1}{n}\sum_{t}\log P(x_t \mid x_{<t})\right).$$

Die Perplexität ist die Zahl der Möglichkeiten, zwischen denen das Modell im Mittel schwankt. Eine Perplexität von zehn heißt: So unsicher wie bei einer gleichverteilten Wahl aus zehn Wörtern. Es ist die Exponentialfunktion der Entropie und sagt nichts Neues, nur anschaulicher.

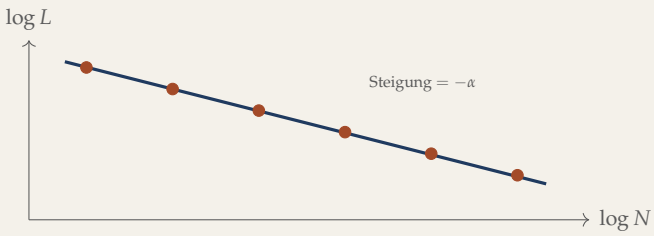
Skalierungsgesetze

KAPLAN und Mitautoren fanden 2020 einen bemerkenswert regelmäßigen Zusammenhang.

$$L(N) \approx \left(\frac{N_c}{N}\right)^{\alpha}, \qquad \alpha \approx 0{,}07\text{–}0{,}095.$$

Größe	Exponent	Deutung
Parameter N	$\approx 0{,}076$	
Daten D	$\approx 0{,}095$	
Rechenaufwand C	$\approx 0{,}050$	

Ein Potenzgesetz über mehrere Größenordnungen, ohne erkennbaren Knick. Das war der eigentliche Befund: Man konnte vorhersagen, was ein zehnmal größeres Modell leisten würde, ohne es zu bauen. Damit wurde aus einer Forschungsfrage eine Investitionsentscheidung.



Die richtige Aufteilung des Aufwands.

Rechen-aufwand	Parameter	Zeichen	Verhältnis
10^{21}	$4 \cdot 10^{8}$	$8 \cdot 10^{9}$	20
10^{23}	$4 \cdot 10^{9}$	$8 \cdot 10^{10}$	20
10^{25}	$4 \cdot 10^{10}$	$8 \cdot 10^{11}$	20

Etwa zwanzig Trainingszeichen je Parameter. Die frühen großen Modelle waren nach diesem Maßstab deutlich unterversorgt: Sie hatten zu viele Parameter und zu wenige Daten. Ein kleineres, länger trainiertes Modell schlug sie bei gleichem Aufwand.

Ein Potenzgesetz sagt nicht, dass es so weitergeht

Was belegt ist	Über den gemessenen Bereich ist die Gerade sehr gut angepasst
Was nicht belegt ist	Dass sie sich fortsetzt
Die Untergrenze	Die Entropie der Sprache selbst; darunter geht es nicht

Es ist derselbe Vorbehalt wie bei der Skalenfreiheit in Band 11: Eine Gerade im doppelt logarithmischen Bild ist eine Beobachtung über einen Bereich, keine Naturkonstante. Und der Verlust kann nicht unter die Entropie fallen — dort liegt eine harte Grenze aus Band 7.

Hinzu kommt: Der Verlust ist nicht das, was interessiert. Zwischen einer Verbesserung von 2,1 auf 2,0 bit und einer merklichen Verbesserung der Brauchbarkeit besteht kein einfacher Zusammenhang.

Vom Vorhersager zum brauchbaren System

Ein Modell, das nur das nächste Zeichen vorhersagt, setzt eine Frage fort, statt sie zu beantworten.

Stufe	Daten	Wirkung
Vortraining	sehr viel Text	Sprachkenntnis
Anweisungs-abstimmung	Anweisung-Antwort-Paare	**beantwortet statt fortsetzt**
Rückmeldungs-abstimmung	Vergleichs-urteile	Stil, Zurückhaltung

Stufe	Rechenanteil	Datenmenge
Vortraining	$\approx 99\,\%$	10^{12} Zeichen
Abstimmung	$\approx 1\,\%$	10^{4}–10^{6} Beispiele

Ein Prozent des Aufwands verändert das Verhalten grundlegend. Die verbreitete Deutung: Die Fähigkeiten entstehen im Vortraining, und die Abstimmung wählt aus, welche davon gezeigt werden. Das ist plausibel und nicht bewiesen.

Was beim Erzeugen geschieht.

Verfahren	Wählt	Ergebnis
Gierig	stets das wahrscheinlichste	eintönig, wiederholend
Ziehen	nach Verteilung	vielfältig, gelegentlich unsinnig
Temperatur	schärft oder glättet	steuert beides
Kernziehen	aus den obersten p	üblicher Kompromiss

Bemerkenswert ist, dass gierige Wahl schlecht funktioniert. Das wahrscheinlichste Zeichen an jeder Stelle ergibt nicht die wahrscheinlichste Folge — und die wahrscheinlichste Folge ist ohnehin oft eine sehr langweilige.

Aufgabe 11.1.

(a) Rechnen Sie Verlust und Perplexität aus.
(b) Wenden Sie die Skalierungsgesetze an.
(c) Untersuchen Sie, was die Temperatur bewirkt.

Lösung Schritt für Schritt.

(a) Verlust und Perplexität.
Die Lage. Ein Modell sagt für fünf aufeinanderfolgende Wörter voraus.

Wort	$P(\text{richtig})$	$-\log_2 P$	$-\ln P$
der	0,40	1,322	0,916
Hund	0,05	4,322	2,996
bellt	0,20	2,322	1,609
sehr	0,10	3,322	2,303
laut	0,50	1,000	0,693
Summe		**12,288**	8,517

Der mittlere Verlust.

$$H = \frac{12{,}288}{5} = \mathbf{2{,}458}\ \text{bit je Wort}, \qquad L = \frac{8{,}517}{5} = 1{,}703\ \text{nat}.$$

Die Perplexität.

$$\mathrm{PP} = 2^{2{,}458} = \mathbf{5{,}49}.$$

Das Modell ist im Mittel so unsicher, als müsste es zwischen fünfeinhalb gleichwahrscheinlichen Wörtern wählen. Bei einem Vokabular von fünfzigtausend ist das eine erhebliche Leistung: Die Perplexität ohne jedes Wissen läge bei fünfzigtausend.

Die Verdichtungsleistung.

Kodierung	**bit je Wort**	**für 10^6 Wörter**
Feste Länge (50 000)	15,6	1,95 MB
Nach Häufigkeit	≈ 11	1,38 MB
Mit diesem Modell	**2,46**	**0,31 MB**

Man könnte den Text mit diesem Modell und arithmetischer Codierung (Band 7) auf ein Sechstel verdichten. Der Preis ist, dass Sender und Empfänger dasselbe Modell brauchen — und das ist gigabytegroß.

(b) Die Skalierungsgesetze anwenden.
Die Frage. Ein Modell mit 10^9 Parametern erreicht Verlust 2,80. Was leistet eines mit 10^{11}?

$$\frac{L_2}{L_1} = \left(\frac{N_1}{N_2}\right)^{\alpha} = \left(\frac{10^9}{10^{11}}\right)^{0{,}076} = (10^{-2})^{0{,}076} = 10^{-0{,}152} = 0{,}705.$$

$$L_2 = 2{,}80 \cdot 0{,}705 = \mathbf{1{,}97}.$$

N	**Verlust**	**Perplexität**	**Faktor Aufwand**
10^8	3,33	10,1	0,1
10^9	2,80	6,0	1
10^{10}	2,35	3,8	10
10^{11}	1,97	2,6	100
10^{12}	1,66	1,9	1000

Hundertfacher Aufwand senkt den Verlust um dreißig Prozent. Das ist der Kern des Potenzgesetzes: Fortschritt ist verlässlich und teuer. Wer den Verlust halbieren will, braucht etwa den zehntausendfachen Aufwand.

Die nötigen Daten.

N	**Zeichen ($20N$)**	**entspricht**
10^9	$2 \cdot 10^{10}$	$\approx$ 30 Mio. Bücher
10^{11}	$2 \cdot 10^{12}$	$\approx$ alles Digitalisierte
10^{12}	$2 \cdot 10^{13}$	gibt es nicht

Die letzte Zeile ist die praktisch wirksame Grenze. Die Rechenleistung ließe sich beschaffen; der Text nicht. Deshalb hat sich die Forschung seit etwa 2023 auf Datenqualität, Mehrfachnutzung und erzeugte Trainingsdaten verlagert.

(c) Die Wirkung der Temperatur.
Die Formel.

$$P_T(i) = \frac{e^{z_i/T}}{\sum_j e^{z_j/T}}.$$

Die Ausgangswerte. $z = (3{,}0;\ 2{,}0;\ 1{,}0;\ 0{,}0)$.

T	P_1	P_2	P_3	P_4
0,1	**0,99995**	0,00005	0,000	0,000
0,5	0,8390	0,1135	0,0154	0,0021
1,0	0,6439	0,2369	0,0871	0,0321
2,0	0,4756	0,2884	0,1749	0,1061
5,0	0,3196	0,2617	0,2142	0,1754
∞	0,25	0,25	0,25	0,25

Bei $T \to 0$ wird die Verteilung zum sicheren Ereignis — das ist die gierige Wahl. Bei $T \to \infty$ wird sie gleichverteilt, also reines Raten. Dazwischen steuert T, wie stark das Modell seinen eigenen Vorlieben folgt.

Die Entropie der Ausgabeverteilung.

T	**Entropie**	**Perplexität**	**Verhalten**
0,1	0,001	1,00	wiederholt sich
0,7	1,04	2,06	brauchbar
1,0	1,34	2,53	brauchbar
2,0	1,82	3,53	wird wirr
5,0	1,97	3,92	fast Rauschen

Warum gierige Wahl in Schleifen läuft.

1.	Das Modell erzeugt eine Wortfolge A.
2.	Nach A ist die Fortsetzung mit A oft am wahrscheinlichsten, denn Wiederholung kommt in Texten vor.
3.	Die Wahrscheinlichkeit steigt mit jeder Wiederholung, weil der Kontext immer eindeutiger darauf hinweist.
4.	Eine sich selbst verstärkende Schleife.

Das Ziehen bricht die Schleife, weil es gelegentlich etwas anderes wählt. Eine zusätzliche Strafe für bereits benutzte Wörter hilft ebenfalls. Beides sind Eingriffe in das Erzeugen, nicht in das Modell — und sie zeigen, dass „das wahrscheinlichste Wort“ nicht dasselbe ist wie „das beste Wort“.

Kaplan und Mitautoren[16] fanden die Skalierungsgesetze; Vaswani und Mitautoren[28] lieferten die Architektur; Goodfellow, Bengio und Courville[10] behandeln die Grundlagen des Folgenlernens.

Part III

Praxis und Grenzen

12 Bewertung

Eine Zahl genügt nie

	vorhergesagt +	**vorhergesagt –**
tatsächlich +	RP	FN
tatsächlich –	FP	RN

Maß	**Formel**	**Frage**
Präzision	$\frac{RP}{RP+FP}$	Wie viele Treffer stimmen?
Sensitivität	$\frac{RP}{RP+FN}$	Wie viele Fälle finde ich?
Spezifität	$\frac{RN}{RN+FP}$	Wie viele Gesunde erkenne ich?
F_1	$\frac{2PS}{P+S}$	Kompromiss

Präzision und Sensitivität lassen sich gegeneinander tauschen, indem man die Entscheidungsschwelle verschiebt. Wer nur eine der beiden meldet, sagt nichts: Man kann jede von beiden auf eins bringen, indem man die andere zerstört.

Die Kurven.

	ROC	**Präzision-Sensitivität**
Achsen	FP-Rate gegen Sensitivität	Sensitivität gegen Präzision
Bei seltener Klasse	täuscht	ehrlich
Zufallslinie	Diagonale	waagerecht bei π

Die zweite Zeile ist wichtig. Die ROC-Kurve benutzt im Nenner die Zahl der Negativen, und wenn diese riesig ist, wirkt sich eine große absolute Zahl von Fehlalarmen kaum aus. Die Fläche unter der ROC-Kurve sieht dann hervorragend aus, während die Präzision bei zwei Prozent liegt.

Kalibrierung

Ein Modell, das 0,8 ausgibt, sollte in achtzig Prozent dieser Fälle recht haben.

Ausgabe	Fälle	tatsächlich +	Anteil
0,0–0,2	412	38	0,092
0,2–0,4	198	52	0,263
0,4–0,6	156	79	0,506
0,6–0,8	187	131	0,701
0,8–1,0	347	318	0,916

Dieses Modell ist gut kalibriert: Die Anteile liegen nahe der Mitte jedes Bereichs. Ein Modell kann hervorragend trennen und dabei völlig fehlkalibriert sein, und umgekehrt. Beides sind verschiedene Eigenschaften.

Verfahren	Kalibrierung	Grund
Logistische Regression	gut	maximiert die Likelihood
Naive Bayes	sehr schlecht	Unabhängigkeits-annahme
Stützvektoren	schlecht	kennt keine Wahrschein-lichkeiten
Random Forest	mittel	zu vorsichtig an den Rändern
Tiefe Netze	übermütig	**seit etwa 2015 schlechter**

Die letzte Zeile ist ein bemerkenswerter Befund: Moderne, größere und genauere Netze sind schlechter kalibriert als ältere, kleinere. Sie werden treffsicherer und zugleich übermütiger.

Datenlecks

Die häufigste Ursache für Ergebnisse, die im Betrieb nicht halten.

Zeitleck	Bei Zeitreihen zufällig aufgeteilt; das Modell sieht die Zukunft
Gruppenleck	Mehrere Aufnahmen desselben Patienten in Training **und** Test
Vorverarbeitungsleck	Standardisierung über alle Daten **vor** der Aufteilung
Zielleck	Ein Merkmal, das es zum Vorhersagezeitpunkt noch nicht gibt

Leck	gemessen	tatsächlich	Differenz
Zeit	0,94	0,61	−0,33
Gruppe	0,91	0,72	−0,19
Vorverarbeitung	0,88	0,86	−0,02
Ziel	**0,99**	**0,55**	**−0,44**

Die letzte Zeile ist die tückischste. Ein Merkmal wie „Zahl der Facharztüberweisungen“ sagt eine Diagnose hervorragend voraus — weil es erst nach der Diagnose entsteht. Das Modell hat nichts gelernt außer der Reihenfolge der Akteneinträge.

Die Prüffrage lautet stets: Stand dieses Merkmal zum Zeitpunkt der Vorhersage tatsächlich zur Verfügung? Ein auffällig gutes Ergebnis ist ein Anlass zum Misstrauen, nicht zur Freude.

Verteilungsverschiebung

Die Grundannahme aus dem Vorwort — künftige Fälle stammen aus derselben Quelle — hält selten lange.

Art	Was sich ändert	Beispiel
Eingabe-verschiebung	$P(x)$	anderes Gerät
Konzept-verschiebung	$P(y \mid x)$	Verhalten ändert sich
Zielverschiebung	$P(y)$	Krankheit wird seltener
Rückkopplung	**das Modell ändert die Welt**	am unangenehmsten

Die letzte Zeile ist die grundsätzlichste. Ein Modell, das aufgrund seiner Vorhersagen Entscheidungen auslöst, verändert die Verteilung, aus der die nächsten Trainingsdaten stammen. Wer Kredite nur an Vorhergesagte vergibt, erfährt nie, wie sich die Abgelehnten verhalten hätten.

Nach Einsatz	Monat 1	Monat 6	Monat 24
Güte	0,88	0,84	0,71
Eingabeabstand	0,02	0,11	0,34

Ein Modell altert. Die Überwachung der Eingabeverteilung ist deshalb kein Zusatz, sondern Teil des Betriebs — und sie schlägt an, bevor die Güte einbricht, weil man die Eingaben sofort sieht und die Zielwerte erst später.

Aufgabe 12.1.

(a) Rechnen Sie alle Maße aus einer Vierfeldertafel.
(b) Vergleichen Sie ROC und Präzisionskurve bei seltener Klasse.
(c) Untersuchen Sie ein Datenleck quantitativ.

Lösung Schritt für Schritt.

(a) Alle Maße aus einer Tafel.
Die Lage. Zehntausend Fälle, zweihundert davon positiv.

	Vorh. +	Vorh. –	Summe
Tats. +	160	40	200
Tats. –	**490**	9310	9800
Summe	650	9350	10 000

Maß	Rechnung	Wert
Trefferquote	$\frac{160+9310}{10\,000}$	**0,947**
Präzision	$\frac{160}{650}$	**0,246**
Sensitivität	$\frac{160}{200}$	**0,800**
Spezifität	$\frac{9310}{9800}$	0,950
F_1	$\frac{2 \cdot 0{,}246 \cdot 0{,}800}{1{,}046}$	**0,376**

Die Trefferquote von 94,7 Prozent klingt hervorragend. Ein Modell, das immer „negativ“ sagt, käme auf 98 Prozent. Die Präzision von 24,6 Prozent ist die ehrliche Zahl: Drei von vier Alarmen sind falsch.

Was die Schwelle bewirkt.

Schwelle	Präz.	Sens.	F_1	Alarme
0,10	0,09	0,97	0,165	2150
0,30	0,25	0,80	**0,376**	650
0,50	0,41	0,58	0,481	283
0,70	0,68	0,31	0,426	91
0,90	0,89	0,08	0,147	18

Dasselbe Modell, fünf sehr verschiedene Bewertungen. Welche Zeile die richtige ist, entscheidet nicht die Statistik, sondern das Kostenverhältnis aus Kapitel 1.

(b) ROC gegen Präzisionskurve.
Die Lage. Ein Prozent Positive, also 100 von 10 000.

Schw.	RP	FP	FP-Rate	Präz.
0,9	30	10	0,0010	**0,75**
0,7	60	100	0,0101	0,38
0,5	80	400	0,0404	0,17
0,3	90	1200	0,1212	**0,07**
0,1	98	4000	0,4040	0,02

Kennzahl	Wert	Eindruck
Fläche unter ROC	**0,93**	sehr gut
Fläche unter PS	**0,26**	mäßig
Zufallswert ROC	0,50	
Zufallswert PS	**0,01**	

Dasselbe Modell, zwei Urteile. Die ROC-Fläche von 0,93 wirkt hervorragend; die Präzisionsfläche von 0,26 zeigt, wie viele Fehlalarme man in Kauf nimmt. Beide sind richtig gerechnet und beantworten verschiedene Fragen.

Die letzte Zeile ist der Schlüssel. Der Zufallswert der Präzisionskurve ist der Anteil der Positiven, hier ein Prozent. Ein Wert von 0,26 ist also sechsundzwanzigmal besser als Raten — eine erhebliche Leistung, die die absolute Zahl verbirgt.

Warum die ROC-Kurve täuscht.

Anteil Positive	ROC-Fläche	PS-Fläche	
50 %	0,93	0,92	ähnlich
10 %	0,93	0,68	
1 %	0,93	0,26	
0,1 %	**0,93**	**0,05**	unver-ändert

Die ROC-Fläche ändert sich überhaupt nicht mit dem Klassenverhältnis. Das ist manchmal erwünscht — sie misst die reine Trennfähigkeit — und für die Frage „ist das im Betrieb brauchbar“ vollkommen ungeeignet.

(c) Ein Datenleck quantitativ.
Der Fall. Röntgenbilder, Vorhersage einer Erkrankung. 1000 Patienten, je fünf Aufnahmen, also 5000 Bilder.
Aufteilung 1 – nach Bildern.

Größe	Wert	
Trainingsbilder	4000	
Testbilder	1000	
Patienten in beiden	≈ **1000**	alle
Gemessene Güte	**0,91**	

Aufteilung 2 – nach Patienten.

Trainings-patienten	800	4000 Bilder
Testpatienten	200	1000 Bilder
Patienten in beiden	**0**	sauber
Gemessene Güte	**0,72**	

Neunzehn Prozentpunkte Unterschied, allein durch die Art der Aufteilung. Das Modell hat gelernt, Patienten wiederzuerkennen — an Körperbau, Implantaten, Aufnahmewinkel — und schließt von dort auf die Diagnose. Auf einem neuen Patienten nützt das nichts.

Wie viel davon reines Wiedererkennen ist.

Versuch	Güte	
Echte Beschriftungen	0,91	
Zufällige Beschriftungen, je Patient fest	**0,79**	sollte 0,50 sein
Zufällige Beschriftungen, je Bild	0,51	wie erwartet

Die mittlere Zeile ist der Beweis. Man würfelt für jeden Patienten eine Beschriftung und weist sie allen seinen Bildern zu. Ein Modell ohne Leck müsste bei fünfzig Prozent landen; es kommt auf neunundsiebzig. Der Unterschied ist reine Patientenerkennung.

Diese Prüfung mit zufälligen Beschriftungen ist das wirksamste einzelne Mittel gegen Datenlecks. Sie kostet einen zusätzlichen Trainingslauf und deckt auf, was keine noch so sorgfältige Durchsicht des Codes findet.

Weitere Prüfungen mit zufälligen Daten

Beschriftungen mischen	Die Güte muss auf Zufallsniveau fallen
Merkmal einzeln entfernen	Ein Absturz weist auf ein verdächtig starkes Merkmal hin
Zeitlich zurücksetzen	Auf älteren Daten trainieren, auf neueren prüfen
Ein neuer Erhebungsort	Der schärfste Test überhaupt

Die letzte Zeile trennt brauchbare von unbrauchbaren Modellen zuverlässiger als jede Kreuzvalidierung. Modelle, die an einer Klinik hervorragend arbeiten und an der nächsten auf Zufallsniveau fallen, sind ein wiederkehrender Befund, und die Ursache ist fast immer ein Merkmal des Erhebungsverfahrens statt des Patienten.

Domingos[7] warnt vor den typischen Bewertungsfehlern; Hastie, Tibshirani und Friedman[11] behandeln die Maße und Kurven; Murphy[21] die Kalibrierung.

13 Fallstricke

Scheinkorrelationen

Ein Modell lernt, was den Fehler senkt, und nicht, was gemeint war.

Hautläsionen	Aufnahmen mit Lineal daneben sind häufiger bösartig; das Modell erkennt das Lineal
Lungen-aufnahmen	Die Erkrankten kamen aus einer anderen Klinik; das Modell erkennt den Gerätetyp
Wölfe und Hunde	Wölfe wurden im Schnee fotografiert; das Modell erkennt Schnee
Panzer im Wald	Alle Aufnahmen des einen Typs entstanden bei Sonne

In allen vier Fällen ist das Modell korrekt: Es hat die Regelmäßigkeit gefunden, die in den Daten am stärksten ist. Der Fehler liegt in den Daten, nicht im Verfahren. Ein Verfahren, das „eigentlich Gemeintes“ von „zufällig Mitgemessenem“ unterscheiden könnte, gibt es nicht.

Prüfung	Güte	Deutung
Ursprünglicher Test	0,94	scheinbar gut
Lineale entfernt	**0,67**	Leck bestätigt
Andere Klinik	0,62	
Nur Bildrand sichtbar	**0,81**	Bild gar nicht nötig

Die letzte Zeile ist die aufschlussreichste Prüfung. Wenn ein Modell allein aus dem Bildrand achtzig Prozent erreicht, hat es nichts über den Befund gelernt. Solche gezielten Verstümmelungen der Eingabe decken mehr auf als jede Erklärungsmethode.

Verzerrung in den Daten

Wenn die Trainingsdaten eine Ungleichheit enthalten, gibt das Modell sie wieder — meist verstärkt.

Erhebungs-verzerrung	Bestimmte Gruppen sind unterrepräsentiert
Beschriftungs-verzerrung	Die Zielwerte spiegeln vergangene Entscheidungen wider
Verstärkung	Das Modell macht aus einer Neigung von 60:40 eine Regel von 95:5
Rückkopplung	Die Vorhersage erzeugt die Wirklichkeit, die sie vorhersagt

Die dritte Zeile ist wenig bekannt und folgt unmittelbar aus der Zielfunktion. Wer den Fehler minimiert, tut gut daran, bei einer Neigung von sechzig zu vierzig immer die Mehrheit zu wählen. Das Modell verschärft also, was in den Daten nur eine Tendenz war.

Merkmal entfernt	**Güte**	**Unterschied**	
Nichts entfernt	0,84	0,23	
Merkmal *A* entfernt	0,83	**0,21**	kaum weniger
A und Stellvertreter	0,76	0,04	

Ein Merkmal zu entfernen genügt nicht, wenn andere es vorhersagen. Postleitzahl, Beruf und Kaufverhalten rekonstruieren fast alles. Das ist kein Trick des Modells, sondern eine Eigenschaft korrelierter Daten, und es gibt keine einfache Abhilfe.

Fairnessmaße widersprechen einander

Man kann nicht alle zugleich erfüllen. Das ist beweisbar.

Gleiche Trefferrate	Beide Gruppen bekommen gleich oft ein positives Ergebnis
Gleiche Fehlerraten	Falschpositiv- und Falschnegativrate sind in beiden Gruppen gleich
Kalibrierung je Gruppe	Eine Ausgabe von 0,8 bedeutet in beiden Gruppen dasselbe

Wenn die Grundraten in den Gruppen verschieden sind, lassen sich die zweite und die dritte Bedingung nicht gleichzeitig erfüllen — es sei denn, das Modell ist perfekt. Der Beweis ist eine kurze Rechnung mit dem Satz von Bayes.

Daraus folgt: Die Frage, welches Maß gelten soll, ist keine technische. Sie muss entschieden werden, bevor gerechnet wird, von denen, die die Folgen tragen. Ein System kann nicht „fair“ sein, sondern nur fair in einem bestimmten, benannten Sinn.

Was im Betrieb hinzukommt

SCULLEY und Mitautoren beschrieben 2015 die versteckten Kosten lernender Systeme.

Verwobene Eingaben	Kein Merkmal lässt sich ändern, ohne alle anderen zu beeinflussen
Verborgene Rückkopplung	Zwei Modelle beeinflussen einander über die Welt
Daten-abhängigkeiten	Sind schwerer zu verfolgen als Codeabhängigkeiten
Übrige Pipelines	Sammeln sich an; niemand traut sich, sie abzuschalten
Verwaltungs-code	Der eigentliche Modellcode ist ein Bruchteil des Ganzen

Bestandteil	Codeanteil
Modell selbst	≈ 5 %
Daten sammeln und prüfen	≈ 25 %
Merkmals-bildung	≈ 20 %
Bereitstellung und Überwachung	≈ 30 %
Werkzeuge, Verwaltung	≈ 20 %

Das Modell macht fünf Prozent des Codes aus. Die verbreitete Vorstellung, ein lernendes System sei im Wesentlichen ein Modell, führt zu Planungen, die um Faktor zwanzig danebenliegen.

Die erste Zeile der oberen Tabelle hat einen eigenen Namen bekommen: Wer ein Merkmal ändert, ändert alle Gewichte, und die Wirkung ist nicht vorhersehbar. Bei gewöhnlichem Code gibt es Schnittstellen, die das begrenzen; bei einem Modell gibt es keine.

Aufgabe 13.1.

(a) Weisen Sie eine Scheinkorrelation nach.

(b) Zeigen Sie, dass zwei Fairnessmaße unvereinbar sind.

(c) Untersuchen Sie die Verstärkung einer Datenverzerrung.

Lösung Schritt für Schritt.

(a) Eine Scheinkorrelation nachweisen.
Der Verdacht. Ein Modell erkennt Lungenentzündungen auf Röntgenbildern mit Güte 0,93.
Prüfung 1 – Herkunft der Bilder.

Klinik	Bilder	krank	Anteil
A	3000	2400	**0,80**
B	3000	600	**0,20**

Ein Modell, das nur die Klinik erkennt, erreicht bereits eine Güte von 0,80. Das ist der Prüfstein: Wenn die Herkunft die Klasse so stark vorhersagt, muss man sie kontrollieren.

Prüfung 2 – Das Modell auf Klinikerkennung trainieren.

Aufgabe	Güte	
Krankheit erkennen	0,93	
Klinik erkennen	**0,998**	fast perfekt

Das Modell kann die Klinik praktisch fehlerfrei bestimmen — an Belichtung, Beschriftungsecke, Gerätekennung. Damit steht fest, dass ihm ein Weg offensteht, die Krankheit zu „erkennen", ohne sie anzusehen.

Prüfung 3 – Innerhalb einer Klinik.

Bewertung	Güte	
Gemischt	0,93	
Nur Klinik A	0,71	
Nur Klinik B	0,69	
Trainiert auf A, geprüft auf B	**0,58**	nahe Zufall

Die letzte Zeile ist die entscheidende. Ein Modell, das an einem Ort trainiert wurde und an einem anderen auf Zufallsniveau fällt, hat nichts Übertragbares gelernt. Diese Prüfung sollte in jeder Veröffentlichung stehen und steht es selten.

(b) Zwei Fairnessmaße sind unvereinbar.
Die Lage. Zwei Gruppen mit verschiedenen Grundraten.

Gruppe	Anteil +	Größe	
G_1	0,30	1000	300 positiv
G_2	0,60	1000	600 positiv

Bedingung 1 – Gleiche Kalibrierung.
Bei Ausgabe 0,8 soll in beiden Gruppen der Anteil tatsächlich Positiver 0,8 betragen.

Bedingung 2 – Gleiche Falschpositivrate.
Die Rechnung. Sei s die Ausgabe, und das Modell sei in beiden Gruppen kalibriert. Für die Falschpositivrate gilt

$$\mathrm{FPR} = \frac{P(\hat{y} = 1) - P(\hat{y} = 1, y = 1)}{1 - \pi},$$

wobei π die Grundrate ist.

Gruppe	π	**Alarme**	**davon RP**	**FPR**
G_1	0,30	250	200	**0,071**
G_2	0,60	500	400	**0,250**

Beide Gruppen sind kalibriert: Von den Alarmen sind jeweils achtzig Prozent richtig. Und die Falschpositivraten unterscheiden sich um Faktor dreieinhalb. Das ist kein Rechenfehler, sondern zwingend.

Der Grund.

In G_1	Es gibt 700 Negative, von denen 50 fälschlich Alarm auslösen
In G_2	Es gibt nur 400 Negative, von denen 100 Alarm auslösen
Also	Dieselbe Präzision bei sehr verschiedenen Nennern

Man muss sich entscheiden. Will man, dass eine Ausgabe in beiden Gruppen dasselbe bedeutet, oder dass Unschuldige in beiden Gruppen gleich oft belastet werden? Beides zugleich geht nur, wenn die Grundraten gleich sind oder das Modell fehlerfrei ist.

(c) Verstärkung einer Verzerrung.
Die Daten. Ein Beruf ist in den Trainingsdaten zu sechzig Prozent mit einer Gruppe verknüpft.

	in den Daten	**Modell-ausgabe**	**Verstärkung**
Beruf A	60:40	**88:12**	$\times$1,47
Beruf B	75:25	**96:4**	$\times$1,28
Beruf C	52:48	63:37	$\times$1,21

Aus einer Tendenz von sechzig zu vierzig wird eine Regel von achtundachtzig zu zwölf. Der Grund ist die Zielfunktion: Wer bei jeder Entscheidung die Mehrheit wählt, macht vierzig Prozent Fehler; wer nach Verteilung würfelt, macht achtundvierzig Prozent. Die Verstärkung ist also optimal im Sinne des Gütemaßes.

Warum das Weglassen des Merkmals nicht hilft.

Eingabe	Güte	Verzerrung	
Alle Merkmale	0,84	0,23	
Ohne das Merkmal	0,83	0,21	fast unverändert
Ohne die 8 stärksten Stellvertreter	0,79	0,12	
Ohne 25 Merkmale	0,71	**0,05**	teuer erkauft

Um die Verzerrung zu vierteln, muss man fünfundzwanzig Merkmale opfern und dreizehn Punkte Güte. Ob das der richtige Tausch ist, ist keine Frage der Statistik.

Was stattdessen hilft.

Nebenbedingung	Das Fairnessmaß als Zusatzterm in die Zielfunktion aufnehmen
Nachträglich anpassen	Verschiedene Schwellen je Gruppe wählen
Daten ergänzen	Die unterrepräsentierte Gruppe gezielt nacherheben
Messen und melden	Die Verzerrung je Gruppe ausweisen statt sie zu verbergen

Die zweite Zeile ist wirksam und rechtlich heikel: Sie behandelt Menschen aufgrund ihrer Gruppenzugehörigkeit ausdrücklich verschieden — um sie im Ergebnis gleich zu behandeln. Genau dieser Widerspruch macht das ganze Feld schwierig.

Die letzte Zeile ist die einzige, die immer richtig ist. Ein System, dessen Verzerrung gemessen und ausgewiesen wird, lässt sich beurteilen. Eines, bei dem niemand nachgesehen hat, ist nicht neutral, sondern nur ungeprüft.

Sculley und Mitautoren[25] beschrieben die versteckten Kosten im Betrieb; Domingos[7] die typischen Fehlschlüsse; Breiman[4] stellte die Frage, was ein Modell überhaupt leisten soll.

14 Erklärbarkeit und Kausalität

Zwei Kulturen

LEO BREIMAN beschrieb 2001 einen Bruch, der das Gebiet bis heute prägt.

	Datenmodell	**Algorithmisch**
Annahme	Die Natur folgt einem bekannten Modell	**Die Natur ist eine Blackbox**
Ziel	Parameter deuten	**gut vorhersagen**
Prüfung	Anpassungsgüte, Tests	Testfehler
Vertreter	Statistik	maschinelles Lernen
Stärke	Deutbarkeit	Treffsicherheit

Breimans Vorwurf an sein eigenes Fach: Die Statistik habe sich auf Modelle festgelegt, die man deuten kann, und dabei in Kauf genommen, dass sie schlechter vorhersagen. Wenn das Modell falsch ist, sind auch seine gedeuteten Parameter falsch — man deutet dann eine Erfindung.

Modell	**Testfehler**	**deutbar**
Lineare Regression	0,22	ja
Entscheidungs-baum	0,19	ja
Random Forest	**0,12**	nein
Tiefes Netz	**0,11**	nein

Die Abwägung ist echt, und sie ist keine Naturkonstante. Bei manchen Aufgaben liegt das lineare Modell gleichauf, und dann gibt es keinen Grund für die Blackbox. Wer nicht nachsieht, weiß es nicht.

Globale und lokale Erklärung

	Global	Lokal
Frage	Wie arbeitet das Modell?	**Warum diese Vorhersage?**
Verfahren	Wichtigkeiten, Abhängigkeits-diagramme	**LIME, SHAP**
Adressat	Entwickler	**Betroffener**

LIME.

1. Den zu erklärenden Punkt nehmen und viele leicht veränderte Fassungen erzeugen.
2. Das Modell auf allen befragen.
3. Ein **lineares** Modell an diese Antworten anpassen, gewichtet nach Nähe zum Ausgangspunkt.
4. Dessen Gewichte sind die Erklärung.

Der Gedanke ist elegant: Global mag das Modell beliebig verwickelt sein, in einer kleinen Umgebung ist fast jede Funktion näherungsweise linear. Die Erklärung gilt dann für diese Umgebung und für keine andere.

SHAP.

Der Ansatz	Shapley-Werte aus der Spieltheorie: Wie viel trägt jedes Merkmal zum Ergebnis bei?
Die Rechnung	Mittelung über alle Reihenfolgen, in denen Merkmale hinzukommen können
Der Vorteil	Die Beiträge summieren sich exakt zur Vorhersage
Der Preis	2^d Teilmengen; man braucht Näherungen

Erklärungen sind selbst Modelle

Eine Erklärungsmethode liefert nicht die Wahrheit über das Modell, sondern ein zweites Modell des ersten.

Uneinigkeit	Verschiedene Verfahren liefern verschiedene, teils widersprüchliche Erklärungen
Unstetigkeit	Zwei fast gleiche Eingaben können sehr verschiedene Erklärungen bekommen
Angreifbarkeit	Man kann ein Modell so bauen, dass es diskriminiert und harmlos aussieht
Kein Prüfstein	Es gibt keine wahre Erklärung, gegen die man prüfen könnte

Die letzte Zeile ist die grundsätzlichste. Bei einer Vorhersage kann man nachsehen, ob sie eintraf. Bei einer Erklärung gibt es nichts Vergleichbares — nur die Frage, ob sie plausibel wirkt, und Plausibilität ist ein schlechter Maßstab.

Sättigungsabbildungen bei Bildern sind ein besonders untersuchtes Beispiel: Manche von ihnen liefern nahezu dasselbe Bild, wenn man die Gewichte des Netzes durch Zufallswerte ersetzt. Sie zeigen dann Kanten des Eingabebildes, nicht das Verhalten des Modells.

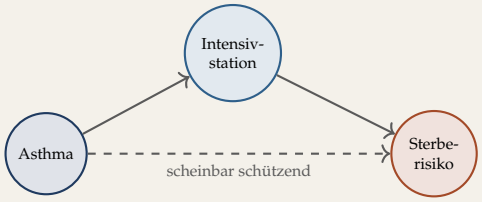
Beobachten und Eingreifen

Die schärfste Grenze dieses Bandes: Ein Modell, das gut vorhersagt, sagt nichts über die Folgen eines Eingriffs.

Stufe	Frage	Wer kann sie beantworten
Beobachten	$P(y \mid x)$	jedes Modell dieses Bandes
Eingreifen	$P(y \mid \mathrm{do}(x))$	**nur mit Zusatzwissen**
Kontrafaktisch	*Was wäre gewesen, wenn?*	nur mit Strukturmodell

> JUDEA PEARL *nennt das die Leiter der Kausalität. Kein Verfahren aus diesem Band kommt über die erste Sprosse hinaus, gleichgültig wie viele Daten es sieht. Die zweite braucht entweder ein Experiment oder eine Annahme über die Struktur.*

Ein Beispiel, das oft vorkommt.



> *In Krankenhausdaten haben Lungenentzündungspatienten mit Asthma ein niedrigeres Sterberisiko. Das Modell lernt das korrekt. Die Ursache ist, dass sie sofort auf die Intensivstation kommen. Ein Modell, das daraufhin Asthmatiker nach Hause schickt, hebt genau die Behandlung auf, die die Zahl erzeugt hat.*

Das Modell ist nicht falsch. Es beantwortet die Frage „wie ist das Risiko bei den bisher so behandelten Patienten“ — und man stellt ihm die Frage „wie wäre das Risiko, wenn wir anders behandelten“. Das sind verschiedene Fragen, und nur die erste steht in den Daten.

Aufgabe 14.1.

(a) Berechnen Sie Shapley-Werte von Hand.
(b) Zeigen Sie, dass zwei Erklärungen widersprechen können.
(c) Untersuchen Sie Beobachten gegen Eingreifen an Zahlen.

Lösung Schritt für Schritt.

(a) Shapley-Werte von Hand.

Die Lage. Drei Merkmale, Grundwert $\phi_0 = 20$, Vorhersage $f(\{A, B, C\}) = 80$.

Teilmenge	f	Teilmenge	f
$\{\}$	20	$\{A, B\}$	65
$\{A\}$	50	$\{A, C\}$	55
$\{B\}$	30	$\{B, C\}$	45
$\{C\}$	25	$\{A, B, C\}$	80

Der Beitrag von A in allen sechs Reihenfolgen.

Folge	vor A	Zuwachs	Wert
ABC	$\{\}$	$50 - 20$	30
ACB	$\{\}$	$50 - 20$	30
BAC	$\{B\}$	$65 - 30$	35
BCA	$\{B, C\}$	$80 - 45$	35
CAB	$\{C\}$	$55 - 25$	30
CBA	$\{B, C\}$	$80 - 45$	35
		Mittel	**32,5**

Ebenso für B und C.

Folge	A	B	C	Summe
ABC	30	15	15	60
ACB	30	25	5	60
BAC	35	10	15	60
BCA	35	10	15	60
CAB	30	25	5	60
CBA	35	20	5	60
Mittel	**32,5**	**17,5**	**10,0**	**60**

Die Probe.

$$\phi_0 + \phi_A + \phi_B + \phi_C = 20 + 32{,}5 + 17{,}5 + 10{,}0 = \mathbf{80} = f(\{A, B, C\}). \quad \checkmark$$

Diese exakte Aufsummierung ist die Eigenschaft, die SHAP von anderen Verfahren unterscheidet. Jede Vorhersage lässt sich vollständig auf die Merkmale aufteilen, ohne Rest. Der Preis: bei d Merkmalen d! Reihenfolgen, hier sechs, bei zwanzig Merkmalen $2{,}4 \cdot 10^{18}$.

(b) Zwei widersprechende Erklärungen.
Die Lage. Zwei stark korrelierte Merkmale, $\rho = 0{,}97$.

Verfahren	*A*	*B*	*C*
Modell-gewichte	+4,1	−3,2	+0,8
Vertauschung	0,02	0,02	0,31
SHAP	+0,45	+0,44	+0,30
LIME	+0,82	+0,07	+0,29

Vier Verfahren, vier Geschichten. Die Gewichte sagen, B wirke gegenläufig; die Vertauschung sagt, A und B seien beide unwichtig; SHAP teilt gleichmäßig auf; LIME wählt A aus. Alle vier sind korrekt gerechnet.

Warum sie sich unterscheiden.

Gewichte	*Wenn A steigt und B gleich bleibt* — was bei $\rho = 0{,}97$ nie vorkommt
Vertauschung	*Wenn A zerstört wird und B bleibt* — das Modell weicht auf *B* aus
SHAP	*Wie teilt man den Beitrag zwischen beiden auf* — gleichmäßig
LIME	*Was erklärt die lokale Umgebung am sparsamsten* — eines von beiden genügt

Die Verfahren beantworten verschiedene Fragen, und keines beantwortet die, die man meist meint: Woran liegt es? *Diese Frage ist kausal und lässt sich aus den Daten allein nicht beantworten.*

(c) Beobachten gegen Eingreifen.
Die Daten. Tausend Patienten mit Lungenentzündung.

Gruppe	n	Intensiv	gestorben
Mit Asthma	200	180 (90 %)	10 (5,0 %)
Ohne Asthma	800	160 (20 %)	96 (12,0 %)

Der beobachtete Zusammenhang.

$$P(\text{Tod} \mid \text{Asthma}) = 0{,}050, \qquad P(\text{Tod} \mid \text{kein Asthma}) = 0{,}120.$$

Asthma sieht schützend aus, Faktor 2,4*. Ein Modell, das dieses Muster lernt, ist korrekt.*

Aufgeschlüsselt nach Behandlung.

	Intensiv	normal
Mit Asthma	$\frac{7}{180} = 3{,}9\,\%$	$\frac{3}{20} = \mathbf{15{,}0}\,\%$
Ohne Asthma	$\frac{12}{160} = 7{,}5\,\%$	$\frac{84}{640} = 13{,}1\,\%$

Innerhalb jeder Behandlungsart sind Asthmatiker schlechter *dran als bei normaler Behandlung im Vergleich zu Nichtasthmatikern — nur ihre viel häufigere Intensivbehandlung dreht das Gesamtbild um. Das ist das Simpson-Paradoxon.*

Die Frage des Eingriffs.

Frage	Antwort	
$P(\text{Tod} \mid \text{Asthma})$	5,0 %	aus Daten
$P(\text{Tod} \mid \text{do}(\text{normal}),\ \text{Asthma})$	**15,0** %	ganz anders

Wer aufgrund des Modells beschließt, Asthmatiker nicht mehr auf die Intensivstation zu legen, verdreifacht ihr Sterberisiko. Das Modell hatte recht und wurde falsch gelesen. Der Fehler liegt nicht in der Statistik, sondern in der Frage, die man ihr gestellt hat.

Was hilft.

Experiment	Zufällige Zuteilung; der Goldstandard und oft unmöglich
Strukturmodell	Ein Graph im Sinne von Band 12, der die Wirkrichtungen festlegt
Herausrechnen	Über die Behandlung stratifizieren, wenn man sie kennt
Wissen einbringen	Ein Fachmann erkennt den Widersinn sofort

Die letzte Zeile ist die praktisch wirksamste und die am wenigsten formalisierbare. Kein Arzt hätte diese Regel geglaubt. Bei einem regelbasierten System wäre sie aufgefallen, weil man die Regeln liest; bei einem Netz mit einer Milliarde Gewichten liest sie niemand.

Damit schließt sich der Kreis zu Band 12. Dort war die Erklärbarkeit gratis und das Wissen teuer; hier ist es umgekehrt. Die Verbindung beider — ein lernendes System, dessen Vorschläge ein prüfbares Modell kontrolliert — ist der Gegenstand des letzten Kapitels.

Ribeiro, Singh und Guestrin[23] entwarfen LIME; Pearl und Mackenzie[22] entwickeln die Leiter der Kausalität für ein breites Publikum; Breiman[4] stellte die Frage nach den zwei Kulturen.

15 Der Stand im Jahr 2026

Was gelöst ist und was nicht

Frage	Stand	Bemerkung
Muster in Bildern erkennen	gelöst	seit 2012
Sprache verarbeiten	gelöst	seit etwa 2020
Tabellendaten vorhersagen	gelöst	**Gradienten-verstärkung genügt**
Große Modelle trainieren	gelöst	Handwerk, kein Forschungsproblem
Bewertung	in Arbeit	**der eigentliche Engpass**
Daten statt Rechenleistung	in Arbeit	seit etwa 2023
Effizienz und Verkleinerung	in Arbeit	
Mit Lösern verbinden	in Arbeit	**Band 12**
Kalibrierung	in Arbeit	wird bei Größe schlechter
Verlässlich verallgemeinern	offen	**seit Beginn**
Kausalität aus Beobachtung	offen	grundsätzlich
Erklärung mit Prüfstein	offen	
Wissen, was man nicht weiß	offen	

Die dritte Zeile verdient Beachtung. Bei Tabellendaten — Kundendaten, Messreihen, Buchhaltung, also dem, womit die meisten Menschen zu tun haben — schlagen Gradientenverstärkung und Random Forests neuronale Netze regelmäßig. Der Fortschritt bei Bildern und Sprache hat sich dorthin nicht übertragen.

Die letzte Zeile des mittleren Blocks.

Das Problem	Ein Modell gibt für eine Frage außerhalb seines Erfahrungsbereichs dieselbe Zuversicht an wie für eine vertraute
Warum grundsätzlich	Die Trainingsdaten enthalten keine Beispiele dafür, wie es außerhalb aussieht
Was es gibt	Schätzungen der Unsicherheit über Ensembles, Ausreißererkennung, Kalibrierung im Nachhinein
Was fehlt	Ein verlässliches „das weiß ich nicht“

Das ist die vierte Zeile der Gegenüberstellung aus dem Vorwort, jetzt als offenes Problem benannt. Es ist das genaue Gegenstück zur Sprödigkeit der Regelsysteme in Band 12 — dort schwieg das System außerhalb seines Gebiets, hier antwortet es zuversichtlich.

Fünf Entwicklungen

Erstens: Daten sind knapp, nicht Rechenleistung.

Jahr	knapp war	Folge
2012	Rechen-leistung	größere Rechner
2020	Rechen-leistung	**Skalierungs-gesetze**
2026	**Daten**	Qualität, Auswahl, Erzeugtes

Die Rechnung aus Kapitel 11 macht das greifbar: Ein Modell mit 10^{12} Parametern bräuchte nach der Zwanzig-zu-eins-Regel mehr hochwertigen Text, als je geschrieben wurde. Damit endet eine Ära, in der Fortschritt eine Frage des Budgets war.

Auswahl	Weniger, aber besserer Text schlägt mehr Text
Mehrfachnutzung	Dieselben Daten mehrfach durchlaufen, mit abnehmendem Ertrag
Erzeugte Daten	Vorsicht: ein Modell kann sich nicht an seinen eigenen Ausgaben verbessern

Die dritte Zeile hat eine informationstheoretische Begründung aus Band 7: Aus einer Verteilung zu ziehen und darauf zu trainieren fügt keine Information hinzu. Erzeugte Daten helfen nur, wenn eine Prüfung *von außen hinzukommt — ein Löser, ein Testlauf, ein Mensch.*

Zweitens: Kleiner statt größer.

Verfahren	Größe	Verlust	
Ausgangsmodell	100 %	2,10	
Auf 8 bit	50 %	2,10	kein Verlust
Auf 4 bit	25 %	2,14	
Ausgedünnt	40 %	2,16	
Destilliert	10 %	2,31	

Die zweite Zeile ist bemerkenswert: Halbe Größe, kein messbarer Verlust. Ein Modell mit sechzehn Nachkommastellen je Gewicht ist offenbar maßlos überbestimmt — es ist die Quantisierung aus Band 7, angewandt auf Parameter statt auf Signale.

Drittens: Modelle rufen Werkzeuge auf.

Aufgabe	Modell allein	mit Werkzeug
Rechnen	unzuverlässig	exakt
Aktuelle Fakten	Stand des Trainings	abgefragt
Formale Prüfung	keine	Löser aus Band 12
Code	plausibel	ausgeführt und geprüft

Die Arbeitsteilung ist die aus Band 12, Kapitel 15, von der anderen Seite betrachtet: Das Modell darf raten, der Löser entscheidet. Für jede Aufgabe, zu der es einen Prüfer gibt, ist das eine saubere Lösung — und die Betonung liegt auf der Bedingung.

Viertens: Mehrere Sinne in einem Modell.

Gemeinsamer Raum	Bild, Text und Ton werden in dieselbe Einbettung abgebildet
Der Gewinn	Was in einer Form gelernt wurde, ist in der anderen verfügbar
Verwandt mit	Den Einbettungen aus Band 11 und der Vektorsuche aus Band 10

Fünftens: Bewertung als Engpass.

Vergleichsdaten abgenutzt	Nach Jahren gemeinsamer Nutzung messen sie die Anpassung an sich selbst
Verunreinigung	Testfragen stehen im Trainingstext, weil beide aus dem Netz stammen
Offene Aufgaben	Bei einer Zusammenfassung gibt es keine richtige Antwort zum Vergleichen
Modell bewertet Modell	Praktisch, und die Verzerrungen sind wenig verstanden

Die zweite Zeile ist neu und ernst. Wer ein Modell auf allem trainiert, was im Netz steht, hat vermutlich auch die Prüfungsaufgaben mittrainiert. Nachweisbar ist das schwer, und die Wirkung ist genau die des Datenlecks aus Kapitel 12, nur auf der Ebene eines ganzen Fachs.

Die Abnutzungsrechnung aus Kapitel 2 beziffert das: Ein Fachgebiet, das zehn Jahre denselben Testsatz benutzt, holt fünf bis sechs Prozentpunkte heraus, die reines Rauschen sind. Bei Vergleichen zwischen Modellen, die um zwei Punkte auseinanderliegen, ist das entscheidend.

Drei Einsichten

Erstens: Verallgemeinerung ist die eigentliche Frage.

Kapitel	Erscheinungsform
2	Bias und Varianz
4	Mitteln senkt Streuung
5	Fluch der Dimension
12	Verteilungsverschiebung
13	Scheinkorrelationen

Fünfmal dasselbe Problem in verschiedener Gestalt. Anpassen ist trivial — ein Nachbarverfahren erreicht Trainingsfehler null, ohne etwas zu lernen. Die ganze Kunst besteht darin, es nicht *zu tun.*

Zweitens: Daten schlagen Verfahren.

Maßnahme	Aufwand	Gewinn
Besseres Verfahren	hoch	+0,02
Bessere Einstellungen	mittel	+0,03
Bessere Merkmale	mittel	+0,08
Zehnmal mehr Daten	hoch	**+0,15**
Saubere Beschriftungen	mittel	**+0,12**

Die letzte Zeile wird am häufigsten übersehen. In vielen Datensätzen sind mehrere Prozent der Beschriftungen falsch, und das begrenzt jedes Modell. Wer eine Woche damit verbringt, die Beschriftungen zu prüfen, gewinnt mehr als mit einem Monat Modellarbeit.

Drittens: Vorhersagen ist nicht Verstehen.

Ein Modell kann	ja	nein
Vorhersagen	✓	
Muster finden	✓	
Folgen eines Eingriffs		✓
Sagen, was es nicht weiß		✓
Sich selbst erklären		✓

Die drei unteren Zeilen sind keine vorläufigen Lücken, die sich mit mehr Daten schließen. Sie folgen daraus, was ein induktives Verfahren ist: Es findet Regelmäßigkeiten in dem, was war, und die Fragen betreffen das, was wäre.

Band 14 wendet sich der Computational Neuroscience zu — dem Versuch, nicht Muster zu finden, sondern zu verstehen, wie ein biologisches System das tut. Vieles aus diesem Band

> *kehrt dort wieder, unter anderen Vorzeichen: Dort ist das Modell nicht das Ziel, sondern eine Hypothese über etwas Wirkliches.*

Ein Modell, das die Trainingsdaten exakt trifft,
hat nichts gelernt, sondern etwas auswendig behalten.
Der Unterschied zeigt sich erst am nächsten Beispiel.

— die Kernaussage dieses Bandes in drei Zeilen.
Sie gilt für ein Polynom neunten Grades durch zehn Punkte
ebenso wie für ein Netz mit einer Billion Parametern.

Part IV

Anhang

A Formeln und Zahlen

Die wichtigsten Formeln

Stichprobenbedarf	$m \geq \frac{1}{\varepsilon}\left(\ln \lvert H \rvert + \ln \frac{1}{\delta}\right)$
Fehlerzerlegung	$\text{Verzerrung}^2 + \text{Streuung} + \sigma^2$
Ridge	$\lVert Xw - y \rVert^2 + \lambda \lVert w \rVert_2^2$
Lasso	$\lVert Xw - y \rVert^2 + \lambda \lVert w \rVert_1$
Normalgleichungen	$w = (X^\top X)^{-1} X^\top y$
Gradientenabstieg	$w_{t+1} = w_t - \eta \nabla L(w_t)$
Logistisch	$\sigma(z) = 1/(1 + e^{-z})$
Kreuzentropie	$-\sum_i [y_i \log \hat{p}_i + (1-y_i) \log(1-\hat{p}_i)]$
Entropie (Gini)	$-\sum p_k \log_2 p_k \quad (1 - \sum p_k^2)$
Ensemblestreuung	$\rho\sigma^2 + \frac{1-\rho}{B}\sigma^2$
Ausgelassene Anteile	$(1 - 1/n)^n \to e^{-1} = 0{,}368$
Gauß-Kern	$K(x, x') = e^{-\gamma \lVert x - x' \rVert^2}$
Naive Bayes	$P(y) \prod_j P(x_j \mid y)$
Laplace-Glättung	$(c + 1)/(N + \lvert V \rvert)$
Rückpropagierung	$\delta^{(l)} = \left((W^{(l+1)})^\top \delta^{(l+1)}\right) \odot \varphi'(z^{(l)})$
He-Anfangswerte	$\sigma^2 = 2/n_{\text{ein}}$
Adam	$w \mathrel{-}= \eta\, \hat{m}/(\sqrt{\hat{v}} + \varepsilon)$
Normalisierung	$\hat{z} = (z - \mu)/\sqrt{\sigma^2 + \varepsilon}$
Aufmerksamkeit	$\text{softmax}\left(\frac{QK^\top}{\sqrt{d_k}}\right) V$
Perplexität	$\text{PP} = 2^H$
Skalierungsgesetz	$L(N) \approx (N_c/N)^\alpha$
Temperatur	$P_T(i) \propto e^{z_i/T}$
F_1	$2PS/(P + S)$
Silhouette	$(b - a)/\max(a, b)$

Kenngrößen und Faustregeln

Größe	Wert	Kapitel
Merkmale je Knoten im Wald	$\approx \sqrt{d}$	4
Bäume im Wald	100–500	4
Lernrate Verstärkung	$\approx 0{,}1$	4
Kreuzvalidierung	5- bis 10-fach	2
Stapelgröße	64–512	9
Trägheit β	0,9	9
Adam β_1, β_2	0,9; 0,999	9
Trainingszeichen je Parameter	≈ 20	11
Skalierungs-exponent	0,05–0,095	11
Entropie natürlicher Sprache	0,6–1,3 bit	11
Anteil Modellcode im Betrieb	$\approx 5\,\%$	13
Zeitanteil Datenarbeit	$\approx 50\,\%$	1

Verfahren im Überblick

Verfahren	Verzerr.	Streuung	deutbar	skaliert
Linear	hoch	gering	ja	ja
Nächste Nachbarn	gering	hoch	teils	nein
Baum	gering	hoch	ja	ja
Random Forest	gering	gering	nein	ja
Verstärkung	gering	mittel	nein	ja
Naive Bayes	hoch	gering	ja	ja
Stützvektoren	mittel	gering	nein	$\mathcal{O}(n^2)$
Neuronales Netz	gering	mittel	nein	ja

Für Tabellendaten sind Gradientenverstärkung und Random Forest bis heute die erste Wahl; für Bilder, Ton und Sprache die Netze. Die lineare Regression bleibt der Maßstab, gegen den alles antreten muss.

B Landkarte des Bandes

Wo was steht

Kap.	Thema	Verweise
1	Was Lernen heißt	**Band 7 (Entropie)**, Band 12
2	Anpassen, Verallgemeinern	Band 11 (Nullmodell)
3	Lineare Modelle	Band 0 (Kondition), Band 7
4	Bäume und Ensembles	**Band 7 (Informationsgewinn)**
5	Abstände und Kerne	**Band 11 (Vektorsuche)**
6	Wahrscheinlichkeiten	Band 12 (Bayes), Band 0
7	Unüberwacht	Band 11, Band 7 (Verdichtung)
8	Netze, Rückpropagierung	Band 12 (Zeit gegen Speicher)
9	Optimierung im Großen	**Band 4, Band 9**
10	Architekturen	Band 4 (Rechenwerke)
11	Sprachmodelle	**Band 7 (Verdichten)**
12	Bewertung	Band 11 (Nullmodell)
13	Fallstricke	Band 12 (Sprödigkeit)
14	Erklärbarkeit, Kausalität	**Band 12 (Bayes-Netze)**
15	Stand 2026	Band 12, Band 14

Sechs Verbindungen zur Mathematikreihe

Kleinste Quadrate	Orthogonalprojektion, Normalgleichungen
Gradientenabstieg	Konvexität, Lipschitz-Stetigkeit
Hauptkomponenten	Eigenwerte symmetrischer Matrizen
Kerntrick	Positiv semidefinite Kerne, Hilberträume
Rückpropagierung	Kettenregel, Jacobi-Matrizen
EM-Verfahren	Jensensche Ungleichung, Konvergenzsätze

Die vierte Zeile ist die tiefste. Der Satz von Mercer garantiert, dass zu jedem positiv semidefiniten Kern eine Abbildung in einen Hilbertraum existiert — man rechnet in einem unendlichdimensionalen Raum, ohne je einen seiner Punkte hinzuschreiben.

Und die fünfte ist die unspektakulärste und folgenreichste: Die Rückpropagierung ist die Kettenregel, mehr nicht. Dass daraus die Grundlage einer Technologie wurde, sagt etwas darüber, wie weit einfache Mathematik trägt, wenn Rechenleistung und Daten hinzukommen.

C Glossar

Begriffe

Adam	Optimierer mit parameterweiser Schrittweite
Aufmerksamkeit	Gewichtete Mischung nach Ähnlichkeit
Bagging	Mitteln über Modelle auf gezogenen Stichproben
Datenleck	Testinformation gelangt ins Training
Doppelter Abstieg	Testfehler fällt jenseits der exakten Anpassung erneut
EM	Wechsel aus Zuordnen und Neuschätzen
Faltung	Örtlich gebundene, geteilte Gewichte
Fluch der Dimension	Abstände werden in hohen Dimensionen bedeutungslos
Induktive Verzerrung	Die mitgebrachten Annahmen eines Verfahrens
Kalibrierung	Ausgabe 0,8 trifft in 80 % der Fälle zu
Kerntrick	Skalarprodukte statt expliziter Abbildung
Kreuzentropie	Verlust, zugleich mittlere Codelänge
Perplexität	Exponentialfunktion der Entropie
Regularisierung	Strafterm gegen Überanpassung
Restverbindung	Additiver Umweg für den Gradienten
Scheinkorrelation	Gelernte Regelmäßigkeit ohne Sachbezug
SHAP	Beitragszerlegung nach Shapley-Werten
Skalierungsgesetz	Potenzzusammenhang Verlust zu Größe
Stützvektor	Randpunkt, der die Trennfläche bestimmt
Überanpassung	Gute Trainings-, schlechte Testleistung
Verteilungs-verschiebung	Einsatzdaten stammen aus anderer Quelle
Verzerrung, Streuung	Systematischer gegen stichprobenbedingter Fehler

D Zeittafel

Von 1943 bis 2026

1943	McCulloch, Pitts: formales Neuron
1949	Hebb: Lernregel
1951	Shannon misst die Entropie des Englischen
1958	**Rosenblatt: Perzeptron**
1959	Samuel: lernendes Dameprogramm
1967	Cover, Hart: Nächste-Nachbarn-Verfahren
1969	**Minsky, Papert: Grenzen des Perzeptrons**
1970	Linnainmaa: automatisches Differenzieren
1974	Werbos: Rückpropagierung
1977	Dempster, Laird, Rubin: EM
1979	Fukushima: Neocognitron
1984	Breiman u. a.: Entscheidungsbäume
1986	**Rumelhart, Hinton, Williams**
1989	Cybenko: universelle Näherung
1994	Bengio u. a.: verschwindende Gradienten
1995	**Cortes, Vapnik: Stützvektormaschinen**
1996	Breiman: Bagging
1997	**Hochreiter, Schmidhuber: LSTM**
1998	LeCun u. a.: Faltungsnetze für Ziffern

2001	**Breiman: Random Forests; Die zwei Kulturen**
2001	Friedman: Gradientenverstärkung
2006	Hinton, Salakhutdinov: schichtweises Vortrainieren
2009	ImageNet: 1,2 Millionen beschriftete Bilder
2012	**Krizhevsky u. a.: AlexNet**
2014	Goodfellow u. a.: erzeugende Gegenspieler
2015	Ioffe, Szegedy: Stapelnormalisierung
2015	He u. a.: Restverbindungen
2015	Kingma, Ba: Adam
2015	Sculley u. a.: versteckte technische Schulden
2016	Ribeiro u. a.: LIME
2017	**Vaswani u. a.: Aufmerksamkeit genügt**
2018	Pearl, Mackenzie: Die Leiter der Kausalität
2019	Doppelter Abstieg systematisch beschrieben
2020	**Kaplan u. a.: Skalierungsgesetze**
2022	Anweisungsabstimmung; Modelle werden benutzbar
2023	Datenknappheit statt Rechenknappheit
2024–26	Effizienz, Werkzeugnutzung, Verbindung mit Lösern
2026	Bewertung als Engpass

Zwei Zeilen verdienen eine Anmerkung.
1951, Shannon. Er ließ Versuchspersonen Buchstaben englischer Texte erraten und schätzte daraus die Entropie der Sprache auf 0,6 bis 1,3 bit je Zeichen. Fünfundsiebzig Jahre später wird genau diese Zahl zum Maßstab für Sprachmodelle — die Aufgabe ist buchstäblich dieselbe.
2019, doppelter Abstieg. Der Befund, dass der Testfehler jenseits der exakten Anpassung wieder fällt, widerspricht der Lehrbuchkurve aus Kapitel 2. Er ist gut belegt und theoretisch bis heute nicht abschließend erklärt.

E Kommentierte Quellen

[1] Bengio, Y., Simard, P., Frasconi, P.: *Learning Long-Term Dependencies with Gradient Descent is Difficult*. IEEE Trans. Neural Networks 5(2), 1994.

Die saubere Analyse, warum rekurrente Netze über lange Folgen nicht lernen. Die Arbeit benannte das Problem drei Jahre vor der Lösung durch LSTM und ist ein Musterbeispiel dafür, wie eine gute Problemanalyse den Weg bereitet.

[2] Bishop, C.: *Pattern Recognition and Machine Learning*. Springer 2006.

Der wahrscheinlichkeitstheoretische Zugang, gründlich und mit vollständigen Herleitungen. Wer verstehen will, warum die Verfahren so aussehen und nicht anders, findet die Antworten hier.

[3] Breiman, L.: *Random Forests*. Machine Learning 45(1), 2001.

Führt die zufällige Merkmalsauswahl ein und erklärt sie über die Korrelation zwischen den Bäumen. Bis heute eines der besten Verfahren für Tabellendaten und praktisch ohne Einstellarbeit brauchbar.

[4] Breiman, L.: *Statistical Modeling: The Two Cultures*. Statistical Science 16(3), 2001.

Zwanzig Seiten, die man gelesen haben sollte. *Breiman wirft seinem eigenen Fach vor, deutbare Modelle über treffsichere zu stellen und dabei zu übersehen, dass ein falsches Modell auch falsch gedeutet wird. Die Antworten der Diskutanten sind mit abgedruckt und ebenso lesenswert.*

[5] Cortes, C., Vapnik, V.: *Support-Vector Networks*. Machine Learning 20(3), 1995.

Die Stützvektormaschine mit weichem Rand. Für ein Jahrzehnt das beste allgemeine Klassifikationsverfahren und theoretisch besser fundiert als alles, was danach kam.

[6] Dempster, A., Laird, N., Rubin, D.: *Maximum Likelihood from Incomplete Data via the EM Algorithm*. J. Royal Statistical Society B 39(1), 1977.

Fasst eine Reihe verwandter Verfahren unter einem Dach zusammen und beweist, dass die Likelihood monoton steigt. Der Beweis ist kurz und benutzt nur die Jensensche Ungleichung.

[7] Domingos, P.: *A Few Useful Things to Know about Machine Learning*. CACM 55(10), 2012.

Zehn Seiten praktische Weisheit. *Verallgemeinerung ist das Ziel, mehr Daten schlagen bessere Verfahren, Merkmalsbildung ist die eigentliche Arbeit. Wenn Sie nur einen Aufsatz dieses Bandes lesen, dann diesen.*

[8] Efron, B., Hastie, T.: *Computer Age Statistical Inference*. Cambridge University Press 2016.

Ordnet das maschinelle Lernen in hundertfünfzig Jahre Statistik ein. Zeigt, welche Verfahren wirklich neu sind und welche unter anderem Namen längst existierten — eine heilsame Lektüre.

[9] Friedman, J.: *Greedy Function Approximation: A Gradient Boosting Machine*. Annals of Statistics 29(5), 2001.

Deutet die Verstärkung als Gradientenabstieg im Funktionenraum. Diese Sichtweise macht das Verfahren auf beliebige Verlustfunktionen übertragbar und ist die Grundlage aller heutigen Umsetzungen.

[10] Goodfellow, I., Bengio, Y., Courville, A.: *Deep Learning*. MIT Press 2016.

Das Standardwerk zu neuronalen Netzen. *Der erste Teil wiederholt die nötige Mathematik, der zweite behandelt die Verfahren, der dritte die Forschungsfragen. Vollständig und kostenfrei im Netz verfügbar.*

[11] Hastie, T., Tibshirani, R., Friedman, J.: *The Elements of Statistical Learning*. 2. Aufl., Springer 2009.

Das Standardwerk zum klassischen maschinellen Lernen. *Statistisch streng, mit ausgezeichneten Abbildungen und einer Behandlung von Verzerrung und Streuung, die nirgends besser ist. Ebenfalls frei verfügbar.*

[12] He, K., Zhang, X., Ren, S., Sun, J.: *Deep Residual Learning for Image Recognition*. CVPR 2016.

Die Restverbindung: eine Zeile Code, die Netze mit über hundert Schichten trainierbar macht. Der Gedanke, dem Gradienten einen Weg ohne Multiplikation zu lassen, taucht seither überall auf.

[13] Hinton, G., Salakhutdinov, R.: *Reducing the Dimensionality of Data with Neural Networks*. Science 313, 2006.

Zeigte, dass schichtweises Vortrainieren tiefe Netze zugänglich macht. Das Verfahren selbst ist überholt; die Wirkung — dass tiefe Netze wieder als aussichtsreich galten — war erheblich.

[14] Hochreiter, S., Schmidhuber, J.: *Long Short-Term Memory*. Neural Computation 9(8), 1997.

Löst das Problem aus [1] durch einen Zellzustand mit gelernten Toren. Zwanzig Jahre lang die Standardarchitektur für Folgen, bis die Aufmerksamkeit sie ablöste.

[15] Ioffe, S., Szegedy, C.: *Batch Normalization*. ICML 2015.

Erlaubt hundertfach größere Lernraten und macht die Anfangswerte fast gleichgültig. Die im Aufsatz gegebene Erklärung gilt heute als nicht zutreffend; dass das Verfahren wirkt, ist unbestritten.

[16] Kaplan, J., McCandlish, S., Henighan, T., u. a.: *Scaling Laws for Neural Language Models*. arXiv 2001.08361, 2020.

Der Aufsatz, der die Forschungspraxis veränderte. *Verlust, Modellgröße und Datenmenge folgen über viele Größenordnungen einem Potenzgesetz. Damit wurde vorhersagbar, was ein größeres Modell leisten würde — und aus einer Forschungsfrage eine Investitionsentscheidung.*

[17] Kingma, D., Ba, J.: *Adam: A Method for Stochastic Optimization*. ICLR 2015.

Der meistbenutzte Optimierer. Seine Stärke ist, dass er ohne mühsames Einstellen brauchbar arbeitet; sein Verdacht, dass er gelegentlich schlechter verallgemeinert als sorgfältig eingestellter Gradientenabstieg.

[18] Krizhevsky, A., Sutskever, I., Hinton, G.: *ImageNet Classification with Deep Convolutional Neural Networks*. NIPS 2012.

Der Wendepunkt. *Halbierte den Fehler im ImageNet-Wettbewerb und machte damit sichtbar, dass ein sechsundzwanzig Jahre altes Verfahren mit genug Daten und Grafikkarten alles Bisherige schlägt.*

[19] LeCun, Y., Bottou, L., Bengio, Y., Haffner, P.: *Gradient-Based Learning Applied to Document Recognition*. Proc. IEEE 86(11), 1998.

Faltungsnetze für die Ziffernerkennung, in Bankautomaten produktiv eingesetzt. Enthält bereits fast alles, was 2012 wiederentdeckt wurde — nur eben mit tausendmal weniger Daten.

[20] Mitchell, T.: *Machine Learning*. McGraw-Hill 1997.

Die klassische Einführung mit der operationalen Definition des Lernens. Inhaltlich in Teilen überholt, in der Begriffsklärung bis heute unübertroffen.

[21] Murphy, K.: *Probabilistic Machine Learning: An Introduction*. MIT Press 2022.

Der modernste umfassende Überblick, wahrscheinlichkeitstheoretisch geordnet und bis zu den heutigen Verfahren reichend. Der Nachfolgeband behandelt die fortgeschrittenen Themen.

[22] Pearl, J., Mackenzie, D.: *The Book of Why*. Basic Books 2018.

Die Leiter der Kausalität für ein breites Publikum. *Beobachten, Eingreifen, Kontrafaktisches — und der Nachweis, dass kein Verfahren dieses Bandes über die erste Sprosse hinauskommt. Streitbar geschrieben und lehrreich gerade deshalb.*

[23] Ribeiro, M., Singh, S., Guestrin, C.: *Why Should I Trust You? Explaining the Predictions of Any Classifier*. KDD 2016.

LIME: eine lokale lineare Näherung als Erklärung. Enthält auch das Wolf-und-Schnee-Beispiel, das seither jede Vorlesung über Scheinkorrelationen ziert.

[24] Rumelhart, D., Hinton, G., Williams, R.: *Learning Representations by Back-Propagating Errors*. Nature 323, 1986.

Vier Seiten, die alles veränderten. *Nicht die erste Beschreibung des Verfahrens, aber die erste mit überzeugenden Beispielen und dem richtigen Publikum. Ein Lehrstück darüber, dass eine Idee erst wirkt, wenn sie ankommt.*

[25] Sculley, D., Holt, G., Golovin, D., u. a.: *Hidden Technical Debt in Machine Learning Systems*. NIPS 2015.

Der ehrlichste Aufsatz des Gebiets. *Der Modellcode macht wenige Prozent aus; der Rest ist Datenversorgung, Überwachung und Verwaltung. Wer ein System betreiben will und nicht nur eines bauen, sollte hier anfangen.*

[26] Shalev-Shwartz, S., Ben-David, S.: *Understanding Machine Learning: From Theory to Algorithms*. Cambridge University Press 2014.

Die strenge Lerntheorie: PAC-Lernen, VC-Dimension, Schranken. Beweist unter anderem, warum Lernen ohne induktive Verzerrung unmöglich ist. Frei verfügbar.

[27] Vapnik, V.: *The Nature of Statistical Learning Theory*. Springer 1995.

Die theoretische Grundlage der Stützvektormaschinen und der Verallgemeinerungsschranken. Vapniks Position — man solle das Problem direkt lösen und keinen Umweg über ein allgemeineres nehmen — ist bis heute ein guter Rat.

[28] Vaswani, A., Shazeer, N., Parmar, N., u. a.: *Attention Is All You Need*. NIPS 2017.

Die Architektur hinter allen heutigen Sprachmodellen. *Der Titel ist die These: Rekurrenz und Faltung werden weggelassen, es bleibt die Aufmerksamkeit. Bemerkenswert kurz und lesbar für einen Aufsatz dieser Wirkung.*

Wenn Sie nur drei Bücher kaufen

[11]	**Hastie u. a.**	Für die klassischen Verfahren und die Frage der Verallgemeinerung. Statistisch streng
[10]	**Goodfellow u. a.**	Für die neuronalen Netze. Vollständig und sorgfältig
[25]	**Sculley u. a.**	Für alles, was in den ersten beiden fehlt: den Betrieb

Der dritte Eintrag ist ein neunseitiger Aufsatz und steht hier trotzdem. Wer ein Modell baut, findet in den ersten beiden Büchern alles; wer es betreiben muss, erfährt erst im dritten, worauf er sich einlässt.

Zwei Ergänzungen für die kurze Lektüre: [7] Domingos sind zehn Seiten und ersparen ein Jahr Erfahrung. [4] Breiman stellt die Frage, ob man ein Modell zum Vorhersagen oder zum Verstehen baut — und diese Frage sollte man beantworten, bevor man anfängt.